

بسم الله الرحمن الرحيم

وقل رب زدني علماً

باسمه تعالی



دانشگاه صنعتی مازندران

مجتمع دانشگاهی برق و کامپیوتر

پایان نامه کارشناسی ارشد رشته مهندسی کامپیوتر- هوش مصنوعی

عنوان

تطبیق دامنه در شبکه های عصبی عمیق برای کاربرد
تشخیص اشیا با استفاده از داده آموزشی مصنوعی در زمان
آزمون (test time domain adaptation)

توسط

امیررضا کاظم لو

استاد راهنما

دکتر محمدعلی کیوانراد

مرداد ماه ۱۴۰۵



دانشگاه صنعتی مازندران

مجتمع دانشگاهی برق و کامپیوتر

پایان نامه کارشناسی ارشد رشته مهندسی کامپیوتر- هوش مصنوعی

توسط: امیررضا کاظم لو

با عنوان:

تطبیق دامنه در شبکه های عصبی عمیق برای کاربرد تشخیص اشیا با استفاده از

داده آموزشی مصنوعی در زمان آزمون (test time domain adaptation)

در تاریخ توسط کمیته تخصصی زیر مورد بررسی قرار گرفت و با امتیاز و درجه به تصویب رسید.

- ۱. استاد راهنمای اول: دکتر محمد علی کیوان راد
- ۲. استاد راهنمای دوم:
- ۳. استاد مشاور:
- ۴. استاد داور خارجی:
- ۵. استاد داور داخلی:
- ۶. مدیر تحصیلات تکمیلی

تقدیرم به

بمراه و هم قدم تمام سختی ها و فرازونشیب های زندگیم
کسی که در تمام سختی ها و شادی های زندگی من همراهم بوده

تقدیم به صاحب الزمان

قدردانی

برای مهربان‌های بی‌نیازم، آن‌کس که در مواقع خطر تنهاییم گذاشت. در کویر تنهایی، یل‌زانی‌س و مسج حرف‌های مکاری‌ام و در غلظت ناامیدی و شکرم بود. عزیزان بر سعادت و فردی علم منکر که سطر سطرش را با مشق و به امید رعایت نگه‌شام و پاس از آن خداست...

...

تمام حقوق مادی و معنوی مترتب بر نتایج مطالعات،
ابتکارات و نوآوری‌های حاصل از این تحقیق متعلق به
دانشگاه صنعتی مالک‌اشتر است.

تأیید صحت، اصالت و رعایت امانت در رساله

اینجانب امیررضا کاظم‌لو دانشجوی رشته مهندسی کامپیوتر گرایش هوش مصنوعی و رباتیکز مقطع تحصیلی کارشناسی ارشد به شماره دانشجویی ۴۰۳۱۴۱۹۰۱۳، صحت، اصالت و رعایت امانت در رساله را تأیید و اعلام می‌نمایم کلیه نتایج این رساله و نشریات مرتبط با آن (از قبیل مقالات استخراج‌شده) حاصل کار اینجانب و بدون هرگونه دخل و تصرف است و موارد نسخه‌برداری‌شده از آثار دیگران را با درج کامل مشخصات منبع ذکر کرده‌ام.

علاوه براین، هرگونه آثار مرتبط با این رساله را با رعایت امانت منتشر نموده و یا خواهم نمود. بنابراین، در تمامی آثار مرتبط (نظیر مقاله، ثبت اختراع، شرکت در جشنواره‌ها و مواردی از این قبیل) حقوق مالکیت دانشگاه صنعتی مالک‌اشتر (ازجمله حقوق اساتید محترم راهنما و مشاور) را رعایت می‌نمایم و هرگونه اثری را با هماهنگی و درج نام مبادی ذی‌صلاح دانشگاه (ازجمله اساتید محترم راهنما) منتشر خواهم نمود.

در صورت اثبات خلاف مندرجات فوق و یا هرگونه تخلفی که صحت، اصالت و رعایت امانت در رساله را مخدوش نماید، دانشگاه می‌تواند مطابق با ضوابط و مقررات حاکم (قانون حمایت از حقوق مؤلفان و مصنفان و قانون ترجمه و تکثیر کتب و نشریات و آثار صوتی، ضوابط و مقررات آموزشی، پژوهشی و انضباطی) با اینجانب رفتار نماید. بنابراین، حق هرگونه اعتراض در خصوص احقاق حقوق مکتسب و تشخیص و تعیین تخلف و مجازات را از خویش سلب می‌نمایم. همچنین، مسئولیت هرگونه پاسخگویی به اشخاص اعم از حقیقی و حقوقی و مراجع ذی‌صلاح (اعم از اداری و قضایی) به عهده اینجانب خواهد بود و دانشگاه هیچ‌گونه مسئولیتی در این خصوص نخواهد داشت.

تاریخ دفاع

امیررضا کاظم‌لو

اثرنگشت و امضاء

فهرست مطالب

عنوان	صفحه
فهرست مطالب	ز
فهرست جدول‌ها	ی
فهرست شکل‌ها	ک
چکیده	1
فصل 1: مقدمه	3
1-1. مقدمه	3
1-2. ضرورت انجام پژوهش	5
1-3. انگیزه و هدف	6
1-4. ساختار پایان‌نامه	7
فصل 2: شبکه‌های عصبی کانولوشنی	ERROR! BOOKMARK NOT DEFINED.
2-1. مقدمه	9
2-2. شبکه عصبی کانولوشنی	ERROR! BOOKMARK NOT DEFINED.
2-2-1. ساختار	Error! Bookmark not defined.
2-2-2. اجزای شبکه کانولوشن	Error! Bookmark not defined.
2-3. انتقال یادگیری	ERROR! BOOKMARK NOT DEFINED.
2-4. جمع‌بندی	ERROR! BOOKMARK NOT DEFINED.
فصل 3: مروری بر قطعه‌بندی معنایی	ERROR! BOOKMARK NOT DEFINED.
3-1. مقدمه	30
3-2. تقطیع معنایی	30
3-2-1. تعاریف	30
3-2-2. اصطلاحات و اجزای تشکیل‌دهنده	Error! Bookmark not defined.
3-2-3. کاربردها	Error! Bookmark not defined.
3-3. انواع معماری‌ها	ERROR! BOOKMARK NOT DEFINED.
3-3-1. رویکردهای غیر عمیق	Error! Bookmark not defined.
3-3-2. رویکردهای عمیق	Error! Bookmark not defined.
3-4. مروری خاص بر معماری‌های بلادرنگ	ERROR! BOOKMARK NOT DEFINED.

Error! Bookmark not defined.	3-4-1	شبکه Deeplab
Error! Bookmark not defined.	3-4-2	شبکه SegNet
Error! Bookmark not defined.	3-4-3	شبکه ENet
Error! Bookmark not defined.	3-4-4	شبکه PSPNet
Error! Bookmark not defined.	3-4-5	شبکه ICNet
Error! Bookmark not defined.	3-4-6	شبکه BiSeNet
Error! Bookmark not defined.	3-4-7	شبکه Fast-SCNN
Error! Bookmark not defined.	3-4-8	مقایسه شبکه‌ها
ERROR! BOOKMARK NOT DEFINED.	3-5	دادگان مطرح
Error! Bookmark not defined.	3-5-1	Cityscapes
Error! Bookmark not defined.	3-5-2	Pascal VOC 2012
Error! Bookmark not defined.	3-5-3	COCO
30	3-6	جمع‌بندی
ERROR! BOOKMARK NOT DEFINED.		فصل 4: روش پیشنهادی
31	4-1	مقدمه
31	4-2	روش پیشنهادی
31	4-2-1	ایده اصلی
Error! Bookmark not defined.	4-2-2	آزمایش اولیه ایده
Error! Bookmark not defined.	4-2-3	پیش‌پردازش و افزایش داده
Error! Bookmark not defined.	4-2-4	ساختار شبکه
Error! Bookmark not defined.	4-2-5	تابع خطا
Error! Bookmark not defined.	4-2-6	تابع بهینه‌ساز
Error! Bookmark not defined.	4-2-7	اندازه دسته‌ها
31	4-3	جمع‌بندی
ERROR! BOOKMARK NOT DEFINED.		فصل 5: نتایج و ارزیابی
32	5-1	مقدمه
32	5-2	معیارهای ارزیابی
32	5-2-1	دقت
ERROR! BOOKMARK NOT DEFINED.	5-3	نتایج ارزیابی روش پیشنهادی
Error! Bookmark not defined.	5-3-1	نتایج پیاده‌سازی روش اولیه
Error! Bookmark not defined.	5-3-2	نتایج اضافه کردن لبه Canny بعنوان کانال چهارم

5-3-3. نتایج اضافه کردن لبه HED بعنوان کانال چهارم.....	Error! Bookmark not defined.
5-3-4. نتایج جمع کردن لبه Canny با تصویر.....	Error! Bookmark not defined.
5-3-5. نتایج جمع کردن لبه HED با تصویر.....	Error! Bookmark not defined.
5-4. جمع‌بندی	33
فصل 6: نتیجه‌گیری و پیشنهادها.....	ERROR! BOOKMARK NOT DEFINED.
6-1. نتیجه‌گیری	ERROR! BOOKMARK NOT DEFINED.
6-2. پیشنهاد کارهای آینده.....	ERROR! BOOKMARK NOT DEFINED.
مراجع	34
واژه‌نامه انگلیسی به فارسی.....	39

فهرست جدول‌ها

شماره جدول	عنوان جدول	صفحه
جدول 1-3	مقایسه شبکه‌ها	Error! Bookmark not defined.
جدول 1-5	شرح نمادهای بکار رفته	Error! Bookmark not defined.
جدول 2-5	مقایسه دقت‌های اولیه	Error! Bookmark not defined.
جدول 3-5	نتایج اضافه کردن لبه Canny بعنوان کانال چهارم	Error! Bookmark not defined.
جدول 3-5	نتایج اضافه کردن لبه HED بعنوان کانال چهارم	Error! Bookmark not defined.
جدول 4-5	نتایج جمع کردن لبه Canny با تصویر	Error! Bookmark not defined.
جدول 5-5	نتایج جمع کردن لبه HED با تصویر	Error! Bookmark not defined.

فهرست شکل‌ها

شماره شکل	عنوان شکل	صفحه
شکل 1-2	تفاوت ساختار شبکه پیش‌خور با شبکه کانولوشن [۲]	Error! Bookmark not defined.
شکل 2-2	تفاوت هسته و فیلتر [۳]	Error! Bookmark not defined.
شکل 2-3	اعمال کانولوشن 3×3 روی تصویر 5×5 با پدینگ ۱ و گام ۲ [۴]	Error! Bookmark not defined.
شکل 2-4	اعمال فیلتر 3×3 با گام ۲ روی تصویر 5×5 [۵]	Error! Bookmark not defined.
شکل 2-5	عملیات کانولوشن ترانهاده [۵]	Error! Bookmark not defined.
شکل 2-6	عملیات ضرب ماتریسی جهت اعمال کانولوشن [۳]	Error! Bookmark not defined.
شکل 2-7	ضرب ترانهاده ماتریس هسته در تصویر کوچک جهت بازسازی تصویری با ابعاد تصویر بزرگ [۳]	Error! Bookmark not defined.
شکل 2-8	شطرنجی‌شدن [۳]	Error! Bookmark not defined.
شکل 2-9	کانولوشن متخلخل با هسته 3×3 و نرخ تخلخل ۲ [53]	Error! Bookmark not defined.
شکل 2-10	اعمال کانولوشن جداشونده مکانی [44]	Error! Bookmark not defined.
شکل 2-11	اعمال کانولوشن عادی با خروجی $1 \times 8 \times 8$ [50]	Error! Bookmark not defined.
شکل 2-12	اعمال کانولوشن عادی با خروجی $8 \times 8 \times 256$ [50]	Error! Bookmark not defined.
شکل 2-13	اعمال کانولوشن عمقی با استفاده از ۳ هسته [50]	Error! Bookmark not defined.
شکل 2-14	تبدیل یک تصویر ۳ کاناله به ۱ کاناله توسط کانولوشن نقطه‌ای [54]	Error! Bookmark not defined.
شکل 2-15	اعمال ادغام‌های میانگین و بیشینه با ابعاد 2×2 و گام ۲ [50]	Error! Bookmark not defined.
شکل 2-16	ادغام بیشینه با ذخیره اندیس و ادغام معکوس [۱۰]	Error! Bookmark not defined.
شکل 2-17	استفاده از لایه ادغام میانگین سراسری [۱۲]	Error! Bookmark not defined.
شکل 2-18	لایه ادغام هرمی مکانی در شبکه SPPNet [۱۳]	Error! Bookmark not defined.
شکل 2-19	لایه تمام‌ام متصل	Error! Bookmark not defined.
شکل 2-20	توسعه‌های شبکه VGG با ساختارهای مختلف [34]	Error! Bookmark not defined.
شکل 2-21	نمایش اثر اعمال پشت سر هم دو لایه 3×3 [34]	Error! Bookmark not defined.
شکل 2-22	نمایش شبکه ResNet با ۳۴ لایه [37]	Error! Bookmark not defined.
شکل 2-23	معماری اتصال میانبر [37]	Error! Bookmark not defined.
شکل 3-1	مثالی از خروجی مسائل مختلف [۲۵]	Error! Bookmark not defined.

شکل 2-3 مدل سازی تصویر با گراف بدون جهت [48]..... Error! Bookmark not defined.
 شکل 3-3 سه گونه های از معماری های میدان تصادفی شرطی مورد استفاده در برجسب زنی
 صفحه [41]..... Error! Bookmark not defined.
 شکل 4-3 روند پردازش در شبکه Deeplab نسخه ۱ [60]..... Error! Bookmark not defined.
 شکل 5-3 معماری SegNet [58]..... Error! Bookmark not defined.
 شکل 6-3 بلوک ها و معماری شبکه ENet [51]..... Error! Bookmark not defined.
 شکل 7-3 معماری شبکه PSPNet [61]..... Error! Bookmark not defined.
 شکل 8-3 معماری شبکه ICNet [62]..... Error! Bookmark not defined.
 شکل 9-3 معماری شبکه BiSeNet [63]..... Error! Bookmark not defined.
 شکل 10-3 شبکه Fast-SCNN [64]..... Error! Bookmark not defined.
 شکل 11-3 نمونه تصویر از دادگان Cityscapes..... Error! Bookmark not defined.
 شکل 12-3 نمونه تصویر از دادگان Pascal Voc..... Error! Bookmark not defined.
 شکل 13-3 نمونه تصویر از دادگان COCO..... Error! Bookmark not defined.
 شکل 1-4 فیلتر عمودی و افقی Sobel..... Error! Bookmark not defined.
 شکل 2-4 خروجی فیلتر Sobel..... Error! Bookmark not defined.
 شکل 3-4 خروجی روش Canny..... Error! Bookmark not defined.
 شکل 4-4 مقایسه خروجی روش Canny و شبکه HED..... Error! Bookmark not defined.
 شکل 5-4 ساختار شبکه HED [69]..... Error! Bookmark not defined.
 شکل 6-4 خروجی شبکه HED..... Error! Bookmark not defined.
 شکل 7-4 اجزای تشکیل دهنده واحدهای Residual و Pr_Residual..... Error! Bookmark not defined.
 شکل 8-4 معماری ICNet..... Error! Bookmark not defined.
 شکل 9-4 واحد ادغام هرمی..... Error! Bookmark not defined.
 شکل 10-4 آنتروپی میان دسته ای..... Error! Bookmark not defined.
 شکل 1-5 توضیح بصری IoU..... Error! Bookmark not defined.
 شکل 2-5 تفاوت خروجی های شبکه اصلی و شبکه پیاده شده ابتدایی..... Error! Bookmark not defined.
 شکل 3-5 خروجی قراردادن لبه Canny بعنوان کانال چهارم..... Error! Bookmark not defined.
 شکل 4-5 خروجی قراردادن لبه HED بعنوان کانال چهارم..... Error! Bookmark not defined.
 شکل 5-5 خروجی جمع کردن لبه Canny با تصویر..... Error! Bookmark not defined.

شکل 5-6 خروجی جمع کردن لبه HED با تصویر Error! Bookmark not defined.

شکل 6-1 نمونه خروجی شبکه Yolov3[78] Error! Bookmark not defined.

شکل 6-2 نمونه خروجی تشخیص عمق [۸۳] Error! Bookmark not defined.

چکیده

مدل‌های یادگیری ماشین^۱ همواره در تلاش هستند تا در طول فرآیند آموزش، مدلی مقاوم به دست آورند که بتواند به خوبی روی نمونه‌های آزمون تعمیم یابد، حتی در زمان مواجهه با تغییرات توزیع^۲. با این حال، این مدل‌ها اغلب به دلیل توزیع‌های ناشناخته داده‌های آزمون دچار افت عملکرد می‌شوند. روش‌های سنتی مانند انطباق دامنه^۳ برای حل این مشکل، نیازمند دسترسی همزمان به داده‌های برچسب‌دار مبدأ^۴ و داده‌های بدون برچسب هدف^۵ هستند. این موضوع در بسیاری از کاربردهای حساس به حریم خصوصی مانند تصویربرداری پزشکی بسیار غیرعملی است، زیرا داده‌های مبدأ نمی‌توانند به اشتراک گذاشته شوند.

برای غلبه بر این محدودیت، پارادایم نوظهور انطباق در زمان آزمون^۶ که به اختصار TTA نامیده می‌شود، راهکاری ارائه می‌دهد که پتانسیل انطباق یک مدل از پیش آموزش‌دیده^۷ با داده‌های بدون برچسب را در طول مرحله آزمایش و پیش از انجام پیش‌بینی‌ها دارا است. بر اساس شکل داده‌های آزمون در زمان استنتاج^۸، این رویکرد به سه دسته اصلی تقسیم می‌شود:

انطباق دامنه در زمان آزمون^۹ یا TTDA: که از کل مجموعه داده‌های هدف برای انطباق چند دوره‌ای^{۱۰} قبل از تولید پیش‌بینی‌های نهایی استفاده می‌کند.

انطباق دسته‌ای در زمان آزمون^{۱۱} یا TTBA: که به طور مستقل مدل را با یک نمونه یا یک دسته کوچک^{۱۲} سازگار می‌کند، به طوری که پیش‌بینی هر دسته مستقل از سایر دسته‌ها است.

انطباق آنلاین در زمان آزمون^{۱۳} یا OTTA: که به جریانی از داده‌ها می‌پردازد که در آن‌ها دسته‌ها به صورت متوالی وارد می‌شوند و هر کدام تنها یک بار قابل مشاهده هستند. در این رویکرد، دانش آموخته شده از دسته‌های قبلی برای پردازش دسته‌های فعلی استفاده و انباشته می‌شود.

¹ Machine Learning

² Distribution Shifts

³ Domain Adaptation

⁴ Source Data

⁵ Target Data

⁶ Test-Time Adaptation

⁷ Pre-trained Model

⁸ Inference Time

⁹ Test-Time Domain Adaptation

¹⁰ Multi-epoch

¹¹ Test-Time Batch Adaptation

¹² Mini-batch

¹³ Online Test-Time Adaptation

این پایان‌نامه با تمرکز بر سناریوهای پویای داده و کاربردهای بینایی ماشین نظیر تشخیص شی، به بررسی چالش‌های عمده در روش‌های OTTA از جمله فراموشی فاجعه‌بار^۱ دانش مبدأ می‌پردازد. هدف این پژوهش، توسعه و بهبود الگوریتم‌های انطباق برخط با بهره‌گیری از مکانیزم‌هایی مانند حداقل‌سازی آنتروپی و شبه برچسب‌گذاری^۲ است، تا مدل بتواند ضمن حفظ پایداری دانش اولیه، با سرعت و دقت بالایی با توزیع‌های جدید در محیط هدف تطبیق یابد.

کلید واژه‌ها: انطباق آنلاین در زمان آزمون، انطباق آنلاین در زمان آزمون، تغییرات توزیع، تشخیص شی

برای مثال گذاشتم و بعد از مشخص شدن Commented [ak1]: روش تغیر خواهد کرد.

¹ Catastrophic Forgetting

² Pseudo-labeling

فصل 1: مقدمه

1-1. مقدمه

مدل‌های یادگیری عمیق در وظایف بینایی ماشین مانند تشخیص شیء به موفقیت‌های چشمگیری دست یافته‌اند. با این حال، عملکرد این مدل‌ها به شدت وابسته به فرض یکسان بودن توزیع داده‌های آموزش و آزمون است. در سناریوهای واقعی، مدل‌ها غالباً با تغییرات توزیع مواجه می‌شوند که منجر به افت شدید عملکرد می‌گردد [1]. این پدیده در ادبیات این حوزه به عنوان شکاف دامنه¹ شناخته می‌شود. برای غلبه بر این چالش، جامعه تحقیقاتی به طور تاریخی بر دو رویکرد اصلی تکیه کرده است. رویکرد اول، تعمیم دامنه² است که به طور دقیق بر مرحله آموزش تمرکز دارد و تلاش می‌کند تا یک مدل مقاوم از داده‌های مبدأ بیاموزد که بتواند روی داده‌های هدف دیده نشده تعمیم یابد [2]. رویکرد دوم، انطباق دامنه³ است که از دانش دامنه مبدأ برای بهبود عملکرد در دامنه هدف بهره می‌برد [3]. از آنجا که رویکرد انطباق دامنه از داده‌های واقعی محیط هدف برای کاهش شکاف استفاده می‌کند، غالباً تطبیق‌پذیری بالاتری برای محیط‌های عملیاتی خاص ارائه می‌دهد.

انطباق دامنه بر اساس میزان دسترسی به برچسب‌های دامنه هدف، به سه دسته کلی تقسیم می‌شود:

¹ Domain Gap

² Domain Generalization

³ Domain Adaptation

۱. انطباق دامنه نظارت شده^۱: در این حالت به یک مجموعه داده کاملاً برچسب دار در دامنه هدف دسترسی داریم که بیشتر به عنوان یک حد بالای تئوریک (Theoretical Upper Bound) برای عملکرد در نظر گرفته می شود. دلیل استفاده کم از این روش، ذات domain adaptation هست که هدف آن این است که در محیطی که تولید داده برچسب خورده دشوار است بتوانیم نتیجه مناسبی داشته باشیم.

Commented [ak2]: خودم از قصد footnote اش نکردم که بپرسم باید footnote یا نه

۲. انطباق دامنه نیمه نظارتی^۲: در این سناریو، تعداد کمی داده برچسب دار به همراه حجم زیادی داده بدون برچسب از دامنه هدف در دسترس است.

Commented [ak3]: همون موضوعی که مطرح کردید که چرا از داده های لیبل خورده در زمان تست استفاده نمی کنیم.

۳. انطباق دامنه بدون نظارت^۳ یا UDA: در این روش، به داده های برچسب دار مبدأ و داده های بدون برچسب هدف به طور همزمان دسترسی وجود دارد. دلیل استقبال گسترده از روش های بدون نظارت نسبت به روش های نظارت شده و نیمه نظارتی، هزینه ها و محدودیت های عملیاتی است. فرآیند جمع آوری و برچسب گذاری داده در مقیاس بزرگ برای هر محیط جدید، غالباً دشوار، پرهزینه و گاهی غیرممکن است. رویکردهای UDA به عنوان یک راه حل منطقی تر برای انتقال دانش در شرایط کمبود برچسب معرفی شده اند.

Commented [ak4]: این که این مخفف های انگلیسی رو استفاده کنم مشکلی ندارد؟

با وجود موفقیت های چشمگیر UDA، این روش ها به صورت پیش فرض نیازمند آن هستند که دسترسی به داده های مبدأ و هدف به صورت همزمان در طول فرآیند انطباق امکان پذیر باشد. این پیش فرض در بسیاری از کاربردهای دنیای واقعی، مانند حوزه های حساس به حریم خصوصی نظیر تصویربرداری پزشکی، داده های محرمانه که در آن ها داده های مبدأ قابل اشتراک گذاری نیستند، غیرعملی است [4]. علاوه بر این، انتقال مجموعه داده های عظیم مبدأ برای انطباق روی دستگاه هایی با منابع محدود نیز به لحاظ محاسباتی و ذخیره سازی پرهزینه است. به منظور رفع این موانع، رویکرد انطباق دامنه بدون منبع^۴ توسعه یافته است که در آن، فرآیند انطباق تنها با استفاده از مدل از پیش آموزش دیده روی مبدأ و داده های بدون برچسب هدف انجام می شود [5].

در نهایت، در بسیاری از کاربردهای مدرن و پویای بینایی ماشین، دسترسی به کل مجموعه داده هدف به صورت یکجا و آفلاین امکان پذیر نیست و داده ها به صورت جریانی از داده دریافت می شوند. برای پاسخ به این چالش، انطباق آنلاین در زمان آزمون که به اختصار OTTA نامیده می شود، توسعه یافته است [6]. در این چارچوب، دسته های کوچک داده (Mini-batches) به صورت متوالی وارد سیستم می شوند و هر دسته تنها یک بار قابل مشاهده است. رویکرد OTTA با استفاده مجدد و انباشت دانشی که از دسته های قبلی آموخته شده است، به پردازش دسته های فعلی کمک می کند و تطبیق پذیری مدل را در لحظه تضمین می نماید.

Commented [ak5]: اسمی نیست که جدید باشه و کاربر شاید ندونه ولی چون مفهوم فارسی اش گیج کننده هست گذاشتم بمونه. آیا باید بذارم کلا بمونه یا نه در متن پایان نامه؟

¹ Supervised DA

² Semi-Supervised DA

³ Unsupervised DA

⁴ Source-Free Domain Adaptation

1-2. ضرورت انجام پژوهش

روش های سنتی یادگیری ماشین معمولاً بر این فرض استوارند که داده های آموزش و آزمون به طور مستقل و یکسان از یک توزیع نمونه برداری شده اند. با این حال، هنگامی که این مدل ها در محیط های واقعی مستقر می شوند، توزیع داده های آزمون اغلب با داده های آموزش تفاوت دارد که این مسئله منجر به افت شدید عملکرد سیستم می گردد. این چالش که به عنوان تغییرات توزیع شناخته می شود، در کاربردهای بینایی ماشین مانند تشخیص شیء بسیار شایع است؛ به عنوان مثال می توان به تغییرات ناشی از استفاده از دوربین های مختلف در محیط واقعی [7]، تغییرات مناظر جاده ای در شهرهای مختلف [8] و تفاوت دستگاه های تصویربرداری اشاره کرد [4].

برای غلبه بر این چالش، تکنیک های انطباق دامنه معرفی شده اند. اما بیشتر این روش ها نیازمند دسترسی همزمان به داده های برچسب دار مبدأ و داده های بدون برچسب هدف در طول فاز انطباق هستند. این پیش فرض در کاربردهای حساس به حریم خصوصی، نظیر حوزه های پزشکی یا داده های تجاری محافظت شده، بسیار غیرعملی و محدودکننده است. بنابراین، پارادایم انطباق در زمان آزمون به عنوان یک راهکار جایگزین، امن و عملی مطرح شده است که تنها نیازمند دسترسی به مدل از پیش آموزش دیده و داده های آزمون در زمان استنتاج است.

با این وجود، بسیاری از روش های انطباق در زمان آزمون، مانند انطباق دامنه در زمان آزمون (TTDA)، نیازمند در اختیار داشتن کل مجموعه داده هدف و پردازش چند دوره ای (Multi-epoch) پیش از تولید پیش بینی های نهایی هستند که این امر در بسیاری از سناریوهای پویای دنیای واقعی امکان پذیر نیست. در محیط های عملیاتی، سیستم غالباً با جریانی از داده ها روبه رو است که در آن دسته های کوچک داده (Mini-batches) به صورت متوالی وارد سیستم می شوند و هر دسته تنها یک بار قابل مشاهده است. این شرایط عملیاتی سخت گیرانه، ضرورت توسعه الگوریتم های انطباق آنلاین در زمان آزمون (OTTA) را به شدت ایجاب می کند [6].

در رویکرد آنلاین، دانش آموخته شده از دسته های گذشته باید برای کمک به پردازش دسته های فعلی بازاستفاده و انباشته شود. با توجه به چالش های جدی و حل نشده ای این حوزه از جمله «فراموشی فاجعه بار» و انباشت خطا هنگام مواجهه مداوم با داده های جدید، به ویژه در وظایف پیچیده ای همچون تشخیص شیء که نیازمند دقت بالا در محلی سازی و دسته بندی است، انجام پژوهشی که بتواند پایداری مدل را حفظ کرده و همزمان با توزیع های جدید به صورت برخط تطبیق یابد، کاملاً ضروری است. کاربرد این نوع از سیستم های پردازش تصویر در محیط هایی هست که اغلب به دلایل مختلف مانند حفظ حریم خصوصی، اهمیت و محرمانگی دیتا آموزش دیده نیاز به عدم دسترسی به دیتای منبع تست وجود دارد [9] و در کنار آن نیازمند آن هستیم که به صورت لحظه ای به محیط های مختلف با توزیع های متفاوت با توزیع منبع انطباق پیدا

خیلی از این مطالب این بخش ضرورت تکراری هست هر دو را آوردیم که تصمیم بگیریم در کجا ازش استفاده کنیم.

باز هم مطمئن نیستیم که این ها باشه یا نه چون ترجمه اش نامفهوم هست

Commented [M8]: میشه وسط متن هم cite کنم

کنیم تا از کاهش کیفیت و دقت مدل در محیط های با توزیع متفاوت با توزیع منبع جلوگیری کنیم.

3-1. انگیزه و هدف

توسعه و استقرار سیستم های بینایی ماشین در دنیای واقعی، همواره با چالش های عملی متعددی روبه رو است. یکی از جذاب ترین و اقتصادی ترین روش ها برای آموزش مدل های یادگیری عمیق، استفاده از داده های مصنوعی است که به دلیل هزینه پایین و مقیاس پذیری بالا، امکان آموزش مدل های پیچیده را فراهم می کند. با این حال، هنگامی که این مدل ها در محیط های واقعی مستقر می شوند، به دلیل پدیده تغییرات توزیع میان داده های آموزش و داده های عملیاتی، با افت شدید عملکرد مواجه می گردند.

انگیزه اولیه برای استفاده از تکنیک های انطباق دامنه پر کردن این شکاف و بهبود کارایی مدل در دامنه هدف است. اما روش های سنتی انطباق دامنه بدون نظارت، نیازمند دسترسی همزمان به داده های مبدأ و داده های هدف هستند. در سناریوهای واقعی، محدودیت های مربوط به حریم خصوصی، امنیت داده ها و هزینه های گزاف ذخیره سازی، و حتی داشتن سخت افزار پردازشی با قابلیت پردازش پایین در زمان تست، دسترسی به داده های مبدأ و یا استفاده از آن ها را در زمان استقرار مدل غیرممکن می سازد. به همین دلیل، انگیزه محققان به سمت پارادایم انطباق در زمان آزمون سوق پیدا کرد که در آن، مدل تنها با اتکا به وزن های از پیش آموزش دیده و داده های در حال دریافت، خود را تطبیق می دهد.

با این وجود، بسیاری از رویکردهای موجود نظیر انطباق دامنه در زمان، فرض می کنند که سیستم به کل مجموعه داده های هدف دسترسی دارد و می تواند پیش از انجام پیش بینی های نهایی، فرآیند انطباق را در چندین Epoch انجام دهد. این فرض در کاربردهای حساس و بی درنگ مانند رانندگی خودران کاملاً باطل است؛ زیرا در این سیستم ها داده ها به جریانی از داده ها و در قالب دسته های کوچک متوالی وارد می شوند و هر دسته تنها یک بار قابل مشاهده است. این واقعیت عملیاتی، انگیزه اصلی این پژوهش برای تمرکز بر روی انطباق آنلاین در زمان آزمون است. استفاده از رویکرد آنلاین در وظیفه پیچیده ای مانند تشخیص شیء چالش های مضاعفی را به همراه دارد. برخلاف دسته بندی ساده تصاویر، تشخیص شیء نیازمند محلی سازی دقیق و رگرسیون است که باعث می شود نویز موجود در شبه برچسب ها به شدت افزایش یابد. مدل هایی که به صورت آنلاین با این داده های نویزی تطبیق می یابند، به سرعت دچار انباشت خطا و فراموشی فاجعه بار می شوند؛ به این معنا که با تطبیق یافتن با داده های جدید، عملکرد و دانش پایه خود را روی داده های قبلی و اصلی از دست می دهند.

هدف پژوهش:

هدف اصلی این پایان نامه، توسعه یک چارچوب کارآمد و مقاوم برای انطباق آنلاین در زمان آزمون در کاربرد تشخیص شیء است که بتواند با غلبه بر محدودیت های ذکر شده، دانش مدل را در لحظه و در مواجهه با محیط های ناشناخته ارتقا دهد. برای دستیابی به این هدف کلی، اهداف خرد زیر دنبال می شوند:

- طراحی مکانیزمی برای تولید شبه برچسب های قابل اعتماد از داده های جریانی که بتوانند با وجود توزیع های متغیر، خطای محلی سازی و دسته بندی را به حداقل برسانند.
- توسعه و بهینه سازی روش های مبتنی بر یادگیری مداوم و استفاده مجدد از دانش تا از طریق تکنیک هایی نظیر منظم سازی ضد فراموشی^۱، پایداری مدل در برابر پدیده فراموشی فاجعه بار تضمین شود.
- کاهش وابستگی مدل به داده های گذشته و فراهم کردن قابلیت انطباق سریع^۲ برای دسته های داده ای که تنها یک بار رصد می شوند.

1-4. ساختار پایان نامه

ساختار این پایان نامه در پنج فصل به شرح زیر سازماندهی شده است:

فصل اول: کلیات پژوهش. این فصل به معرفی مبانی نظری و ضرورت انجام پژوهش در حوزه انطباق دامنه اختصاص دارد. در این فصل، چالش «شکاف دامنه» به ویژه در کاربردهای بینایی ماشین و تشخیص شیء مورد بررسی قرار گرفته و اهمیت استفاده از رویکردهای انطباق آنلاین در زمان آزمون، به خصوص در سناریوی انتقال از داده های مصنوعی به دنیای واقعی، تشریح می شود. همچنین اهداف و سوالات اصلی پژوهش در این فصل بیان می گردند.

فصل دوم: مروری بر ادبیات موضوع. این فصل مروری جامع بر پیشینه تحقیق و روش شناسی های موجود ارائه می دهد. در این بخش، سناریوهای مختلف انطباق دامنه نظیر انطباق بدون نظارت و انطباق بدون منبع تعریف شده و رویکردهای اصلی مورد استفاده، از جمله روش های مبتنی بر یادگیری تخصصی^۳، بازسازی دامنه، و رویکردهای مبتنی بر خودآموزی نظیر شبه برچسب گذاری و کمینه سازی آنتروپی به تفصیل شرح داده می شوند.

فصل سوم: روش شناسی و مدل پیشنهادی.

این فصل، بخش محوری و نوآورانه ای پایان نامه است که به معرفی دقیق چارچوب و الگوریتم پیشنهادی می پردازد. در این فصل، معماری مدل، توابع زیان مورد استفاده، و نحوه غلبه بر

¹ Anti-forgetting Regularization

² Fast Adaptation

³ Adversarial Learning

چالش های خاص انطباق برخط (مانند فراموشی فاجعه بار و انباشت نویز در شبه برچسب ها) برای وظیفه تشخیص شیء فرمول بندی و ارائه می گردد.

فصل چهارم: آزمایش ها و ارزیابی نتایج. این فصل به تحلیل نتایج تجربی و بررسی عملکرد روش پیشنهادی در مقایسه با سایر روش های پایه اختصاص دارد. در این راستا، مجموعه داده های استاندارد مورد استفاده برای معرفی شده، جزئیات پیاده سازی بیان می گردد و در نهایت، نتایج ارزیابی های کمی و کیفی به دقت مورد بحث و مقایسه قرار می گیرند.

فصل پنجم: نتیجه گیری و پیشنهادها. در نهایت، فصل پنجم به جمع بندی دستاوردهای پایان نامه اختصاص یافته است. در این فصل، یافته های اصلی پژوهش مرور شده، محدودیت های کار بیان می گردد و بر اساس دستاوردها، پیشنهاداتی کاربردی برای مسیرهای تحقیقاتی آینده در زمینه انطباق دامنه در زمان آزمون ارائه می شود.

فصل 2: مروری بر ادبیات انطباق دامنه در زمان آزمون

2-1. مقدمه

در این فصل، سیر تکامل روش‌های یادگیری ماشین برای غلبه بر پدیده تغییرات توزیع به صورت گام‌به‌گام مورد بررسی قرار می‌گیرد. در ابتدا، مفاهیم پایه یادگیری انتقالی و انطباق دامنه به عنوان راهکارهای کلاسیک برای کاهش شکاف دامنه معرفی می‌شوند. سپس، با توجه به محدودیت‌های عملیاتی و دنیای واقعی نظیر لزوم حفظ حریم خصوصی و عدم امکان دسترسی به داده‌های حجیم مبدأ، گذاری منطقی به سمت روش‌های انطباق دامنه بدون منبع خواهیم داشت.

در ادامه، به بررسی پارادایم‌های پویاتر یعنی انطباق در زمان آزمون و به طور ویژه، هسته اصلی این پایان‌نامه، یعنی انطباق آنلاین در زمان آزمون می‌پردازیم. در این بخش، چالش‌های بنیادین سیستم‌ها هنگام مواجهه با داده‌های جریانی، از جمله انباشت خطا و فراموشی فاجعه‌بار، به دقت تحلیل می‌شوند. در بخش پایانی این فصل، تمامی این مفاهیم را در بستر پیچیده و چندوجهی تشخیص شیء ارزیابی خواهیم کرد. همچنین نقش کلیدی معماری‌های پیشرفته استخراج ویژگی، در بهبود فرآیند هم‌ترازی ویژگی‌ها ارزیابی می‌شود تا بستر نظری لازم برای معرفی چارچوب پیشنهادی در فصل سوم به طور کامل فراهم گردد.

2-2. یادگیری انتقالی و انطباق دامنه

2-2-1. پدیده تغییر توزیع

در روش های سنتی یادگیری ماشین، یک فرض بنیادین و کلاسیک وجود دارد مبنی بر این که داده های آموزش و آزمون به طور مستقل و دارای توزیع یکسان (I.I.D) هستند. با این حال، در کاربردهای عملی و هنگام استقرار مدل ها در دنیای واقعی، این فرض غالباً نقض می شود و مدل ها با پدیده تغییرات توزیع مواجه می گردند که منجر به افت شدید عملکرد آن ها می شود. برای غلبه بر این محدودیت، حوزه یادگیری انتقالی معرفی شد که هدف آن استفاده از دانش استخراج شده از یک مسئله با دامنه برای بهبود یادگیری در یک مسئله یا دامنه مرتبط دیگر است [10].

در ادبیات این حوزه، پدیده تغییر توزیع عمدتاً بر پایه دو فرض اصلی طبقه بندی می شود: تغییر Covariate Shift که در آن تغییر در توزیع ویژگی های ورودی عامل ایجاد برچسب ها هستند $P(x|y)$ ، یعنی تغییر در توزیع احتمالی نمونه های ورودی $P(x)$ ، و Label Shift که در آن برچسب های خروجی عامل ایجاد ویژگی ها در نظر گرفته می شوند $p(y|x)$ ، یعنی تغییر در توزیع احتمالی کلاس های خروجی $P(y)$ [1].

برای مقابله با این تغییرات، جامعه تحقیقاتی به طور تاریخی بر دو تکنیک عمده تکیه کرده است: تعمیم دامنه¹ که منحصراً بر فاز آموزش تمرکز دارد تا مدلی مقاوم از داده های مبدأ بیاموزد، و انطباق دامنه که در فاز انطباق نیازمند دسترسی به داده های هدف است [11]. انطباق دامنه حالت خاص و بسیار پرکاربری از یادگیری انتقالی است که در آن فضای ویژگی² و فضای برچسب ها معمولاً یکسان است، اما توزیع حاشیه ای داده ها میان دامنه مبدأ و هدف تفاوت دارد [12]. در میان سناریوهای مختلف، انطباق دامنه بدون نظارت بیشترین توجه تحقیقاتی را به خود جلب کرده است؛ رویکردی که در آن سیستم تلاش می کند با بهره گیری از داده های کاملاً برچسب دار مبدأ، عملکرد مدل را روی دامنه هدف که فاقد هرگونه برچسب است، ارتقا دهد.

2-2-2. انطباق دامنه بدون نظارت (UDA)

برای کاهش شکاف دامنه در رویکردهای بدون نظارت، محققان تکنیک های متنوعی را توسعه داده اند که به طور کلی در سه دسته اصلی جای می گیرند:

- هم ترازی در سطح ویژگی:

این روش ها تلاش می کنند تا یک فضای ویژگی نامتغیر از دامنه³ پیدا کنند. یک رویکرد رایج در این دسته، استفاده از معیارهای آماری صریح برای اندازه گیری و کمینه سازی فاصله بین توزیع های مبدأ و هدف است. به عنوان مثال، یکی از پرکاربردترین معیارها، بیشینه اختلاف میانگین⁴ است که با استفاده

¹ Domain Generalization

² Feature Space

³ Domain-invariant

⁴ Maximum Mean Discrepancy

از آن، شبکه عصبی مجبور می شود ویژگی هایی را استخراج کند که از نظر آماری در هر دو دامنه به هم نزدیک باشند [13].

- روش های یادگیری تخصصی:

با الهام از شبکه های مولد تخصصی، این دسته از روش ها یک بازی مینی مکس را میان دو بخش از شبکه ایجاد می کنند. در این ساختار، یک تفکیک کننده دامنه¹ آموزش می بیند تا منشأ داده ها (مبدأ یا هدف بودن) را تشخیص دهد، در حالی که یک استخراج کننده ویژگی² تلاش می کند ویژگی هایی تولید کند که تفکیک کننده را فریب دهند. نتیجه این رقابت، استخراج بازنمایی هایی است که برای وظیفه اصلی (مانند دسته بندی) مفید بوده اما اطلاعات مربوط به دامنه از آن ها حذف شده است [14].

- ترجمه در سطح ورودی:

این روش ها به جای هم ترازی در فضای ویژگی های انتزاعی، تلاش می کنند شکاف دامنه را مستقیماً در سطح پیکسل ها کاهش دهند. با استفاده از شبکه های تبدیل تصویر به تصویر، تصاویر دامنه مبدأ به گونه ای تغییر داده می شوند که از نظر سبک بصری (نورپردازی، بافت و غیره) مشابه دامنه هدف به نظر برسند، اما محتوای معنایی آن ها حفظ شود. سپس مدل تشخیص دهنده روی این تصاویر ترجمه شده آموزش می بیند [15].

منظم سازی در سطح خروجی³ و تخمین پیشین کلاس⁴: این دسته از تکنیک ها به جای فضای ویژگی یا پیکسل، بر اصلاح خروجی های مدل و تطبیق توزیع پیشین کلاس ها در دامنه هدف تمرکز دارند [17], [16], [11].

علی رغم موفقیت چشمگیر این روش ها در کاهش شکاف توزیع، وجه اشتراک و نقطه ضعف تمامی آن ها، نیاز قطعی به دسترسی همزمان و آفلاین به داده های هر دو دامنه مبدأ و هدف در مرحله آموزش است. این الزام به دسترسی همزمان، به ویژه در حوزه های حساس به حریم خصوصی نظیر تصویربرداری پزشکی یا داده های امنیتی که در آن ها داده های مبدأ به هیچ وجه قابل به اشتراک گذاری نیستند، به شدت بازدارنده و غیرعملی است [11]. این محدودیت بنیادین، مسیر را برای ظهور نسل جدیدی از الگوریتم ها که مستقل از داده های مبدأ و سازگار با زمان آزمون هستند، هموار ساخته است.

¹ Domain Discriminator

² Feature Extractor

³ Output-level Regularization

⁴ Class-prior Estimation

2-3. انطباق دامنه بدون منبع (SFDA)

1-3-2. ضرورت و چالش های SFDA

همان طور که در بخش های پیشین اشاره شد، پیش فرض بنیادین در روش های سنتی انطباق دامنه بدون نظارت این است که دسترسی همزمان به هر دو مجموعه داده مبدأ و هدف در طول فرآیند انطباق فراهم باشد تا بتوان توزیع آن ها را به صورت مستقیم هم تراز کرد [18]. با این حال، در بسیاری از سناریوهای کاربردی دنیای واقعی، این پیش فرض نقض می شود.

نخستین و مهم ترین دلیل برای این امر، دغدغه های مربوط به حفظ حریم خصوصی، محرمانگی و حق تکثیر است؛ به عنوان مثال، در کاربردهای تصویربرداری پزشکی، به اشتراک گذاری داده های مبدأ عملاً غیرممکن است [19]، [5]. علاوه بر این، در محیط هایی که از دستگاه هایی با منابع محدود استفاده می شود، ذخیره سازی کل مجموعه داده های مبدأ برای آموزش، به شدت پرهزینه و نیازمند منابع محاسباتی بالا است. به منظور غلبه بر این محدودیت ها، پارادایم «انطباق دامنه بدون منبع» معرفی شده است [20]. در این رویکرد، فرآیند آموزش در دو مرحله مجزا انجام می پذیرد: ابتدا مدل روی داده های برچسب دار مبدأ آموزش می بیند و سپس، در مرحله انطباق، تنها با استفاده از مدل از پیش آموزش دیده و داده های بدون برچسب هدف خود را با محیط جدید سازگار می کند. این فرآیند دو مرحله ای به طور مؤثری ایزوله سازی داده ها را میان دامنه ها تضمین می کند.

اگرچه حذف وابستگی به داده های مبدأ مزایای عملی فراوانی به همراه دارد، اما رویکردهای انطباق بدون منبع را با سه چالش اساسی و منحصربه فرد مواجه می سازد:

- عدم امکان هم ترازای مستقیم توزیع ها: از آنجا که داده های مبدأ در فاز انطباق در دسترس نیستند، استفاده از روش های سنتی برای اندازه گیری و کاهش مستقیم فاصله میان توزیع مبدأ و هدف کاملاً غیرعملی می گردد. این مانع بزرگ، اعمال روش های سنتی را در چارچوب بدون منبع مختل کرده و محققان را ناگزیر می سازد تا از تکنیک های جایگزین برای استخراج دانش نهفته در اوزان مدل مبدأ استفاده کنند.
- انباشت خطا و نویز در شبه برچسب ها: به دلیل فقدان نظارت مستقیم از سوی داده های مبدأ در طول فرآیند آموزش در دامنه هدف، مدل ها با انحراف ناشناخته ای مواجه می شوند و ناگزیرند برای ایجاد سیگنال های نظارتی به خروجی های خود تکیه کنند که رایج ترین رویکرد برای این کار استفاده از خودآموزی¹ و شبه برچسب گذاری است [21]. این رویکرد شامل تولید پروتوتایپ ها، تخصیص شبه برچسب ها، و فیلتر کردن شبه برچسب ها و در

¹ Self-Training

کنار این ها استفاده از روش های خود توجهی^۱ به عنوان ماژول کمکی هست. با توجه به وجود شکاف دامنه، خروجی های اولیه مدل روی داده های هدف به ناچار حاوی نویز و برچسب های نادرست هستند. استفاده از این داده های مسموم در فاز انطباق می تواند منجر به انباشت خطا شده و دقت مدل را به شدت کاهش دهد [22].

- فراموشی فاجعه بار: یکی دیگر از معضلات جدی در غیاب داده های مبدأ این است که مدل در حین تطبیق یافتن با توزیع داده های جدید، ممکن است دانش حیاتی و الگوهای تعمیم پذیری^۲ که پیش تر از دامنه مبدأ آموخته بود را فراموش کند [23]. این پدیده به خصوص زمانی که مدل به صورت مداوم با داده های در حال تغییر مواجه می شود، می تواند باعث افت شدید عملکرد سیستم در دامنه اولیه گردد.

2-3-2. روش های مبتنی بر داده

در رویکردهای انطباق دامنه بدون منبع، روش های مبتنی بر داده^۳ با هدف جبران کمبود داده های مبدأ و غلبه بر چالش فقدان برچسب در داده های هدف طراحی شده اند. این دسته از الگوریتم ها به جای تمرکز صرف بر معماری مدل، به طور مستقیم به دستکاری، بازسازی و استخراج اطلاعات از خود داده ها می پردازند. بر اساس بررسی های انجام شده، این روش ها به دو زیرشاخه اصلی «بازسازی مبتنی بر دامنه» و «استخراج اطلاعات مبتنی بر تصویر» تقسیم می شوند [18].

Commented [ak9]: We propose a novel approach for the SF-UDA setting based on a loss reweighting strategy that brings robustness against the noise that inevitably affects the pseudo-labels. The classification loss is reweighted based on the reliability of the pseudo-labels that is measured by estimating their uncertainty.

a self-supervised contrastive framework
We set the new SF-UDA state-of-the-art on VisDA-C and DomainNet and PACS


Commented [ak10]: Existing methods, which are mostly based on self-training and entropy regularization, can suffer from these non-stationary environments. Due to the distribution shift over time in the target domain, pseudo-labels become unreliable. The noisy pseudo-labels can further lead to error accumulation and catastrophic forgetting.

To tackle these issues, we propose a continual test-time adaptation approach (CoTTA) which comprises two parts. Firstly, we propose to reduce the error accumulation by using weight-averaged and augmentation-averaged predictions which are often more accurate. On the other hand, to avoid catastrophic forgetting, we propose to stochastically restore a small part of the neurons to the source pre-trained weights during each iteration to help preserve source knowledge in the longterm.

¹ Self attention

² Generalization

³ Data-Based



شکل 1- طبقه‌بندی روش‌های sfda

2-3-2-1. بازسازی مبتنی بر دامنه¹

هدف اصلی در این زیرشاخه، خلق یا شبیه‌سازی یک دامنه جدید است تا بتواند به عنوان جایگزینی برای دامنه مبدأ در دسترس‌نبوده عمل کند و سیگنال‌های نظارتی لازم را برای آموزش مدل در دامنه هدف فراهم آورد. این بازسازی از طریق سه رویکرد متمایز انجام می‌شود:

- تولید دامنه مجازی²: از آنجا که هم‌ترازی مستقیم توزیع‌ها به دلیل نبود داده‌های مبدأ ناممکن است، این روش‌ها یک دامنه مجازی جایگزین می‌سازند. یکی از راهکارهای رایج، استفاده از شبکه‌های مولد تخصصی برای تولید تصاویری است که از نظر معنایی با دامنه مبدأ مطابقت دارند [24]. رویکرد دیگر، مدل‌سازی توزیع مبدأ از طریق تخمین توزیع‌های گوسی با استفاده از دانش پنهان در اوزان طبقه‌بند³ از پیش آموزش‌دیده است که معروف‌ترین این روش‌ها VDM-DA³ است [25]. همچنین، به منظور افزایش مقیاس و تنوع

Commented [ak11]: in which the virtual domain acts as a bridge between the source and target domains. we generate the virtual domain samples by using an approximated Gaussian Mixture Model (GMM) in the feature space, such that the virtual domain maintains a similar distribution with the source domain without access to the original source data. Moreover, we also design an effective distribution alignment method to reduce the distribution divergence between the virtual domain and the target domain by gradually improving the compactness of the target domain distribution through model learning.

¹ Domain-based Reconstruction

² Virtual domain generation

³ Virtual domain modeling

داده های این دامنه مجازی، از تکنیک های ترکیب داده مانند Mixup¹ استفاده می شود تا مرزهای تصمیم گیری نرم تر و مقاوم تری به دست آید [26].

- هم ترازی تخصصی درون دامنه²: این روش ها به جای تولید تصاویر جدید، نمونه های موجود در دامنه هدف را بر اساس میزان اطمینان پیش بینی های مدل، به دو گروه «شبه به مبدأ»³ و «متفاوت از مبدأ»⁴ تقسیم می کنند [27]. سپس، با اعمال یک آموزش تخصصی درون خود دامنه هدف، سعی می شود ویژگی های گروه با اطمینان پایین به گونه ای تغییر یابند که توسط طبقه بندی های مدل بهتر شناخته شوند. به عنوان مثال، برخی روش ها از واگرایی کولبک-لیبلر برای اندازه گیری و کاهش اختلاف میان طبقه بندی های مختلف مدل استفاده می کنند [28].

- نظارت دامنه آشفته⁵: فرض پایه در این رویکرد آن است که اگر مدل بتواند در برابر اعوجاج ها و نویزهای مرتبط با دامنه مقاومت کند، قادر به استخراج ویژگی های نامتغیر از دامنه خواهد بود. بنابراین، با افزودن اغتشاشات⁶ خاص دامنه به داده های هدف بدون برچسب، یک «ابر دامنه هدف» ساخته می شود و مدل آموزش می بیند تا پیش بینی های سازگاری روی تصاویر اصلی و تصاویر آشفته ارائه دهد [29].

2-2-3. استخراج اطلاعات مبتنی بر تصویر⁷

اطلاعات موجود در یک تصویر را می توان به دو بخش «محتوا» (مرتبط با برچسب) و «سبک» (مرتبط با دامنه) تقسیم کرد. این دسته از روش ها با واکاوی ساختار ذاتی داده های هدف و استخراج یکی از این دو مؤلفه، فرآیند انطباق را بدون نیاز به داده های مبدأ پیش می برند:

خوشه بندی همسایگی⁷: این تکنیک بر این مشاهدات استوار است که حتی با وجود شکاف دامنه، داده های هدف همچنان خوشه های ساختاریافته ای در فضای ویژگی تشکیل می دهند که اعضای هر خوشه به یک کلاس مشترک تعلق دارند. با الزام شبکه به حفظ سازگاری میان گره های همسایه، نمونه های متعلق به یک خوشه تشویق می شوند تا مرزهای تصمیم گیری مشترکی پیدا کنند [30]. این امر دشواری دسته بندی را کاهش می دهد؛ زیرا خطاهای طبقه بندی غالباً در مرزهای متراکم رخ می دهند.

Commented [ak12]: <https://share.gemini.google/WxWvujnFTL55>

Instead of just teaching a neural network that "Image A is a Cat" and "Image B is a Dog," mixup teaches the network that an image mathematically composed of 70% Image A and 30% Image B should be predicted as 70% Cat and 30% Dog. This simple linearity constraint smooths the model's predictive uncertainty, effectively preventing overfitting and making the resulting feature space far more robust to noise and adversarial manipulation. Given how this linear interpolation forces the network to smooth its decision boundaries across the feature space

Commented [ak13]: <https://share.gemini.google/CMIEIoNJztwF>

We consider two settings: the offline setting where all target data can be visited multiple times (epochs) to arrive at a prediction for each target sample, and the online setting where the target data needs to be directly classified upon arrival. we introduce a second classifier, but with another classifier head fixed. When adapting to the target domain, the additional classifier initialized from source classifier is expected to find misclassified features. Next, when updating the feature extractor, those features will be pushed towards the right side of the source decision boundary, thus achieving source-free domain adaptation.

The Anchor Classifier (C_1): The original classifier trained on the source data is frozen during adaptation. Its established decision boundary acts as an "anchor" in the feature space to retain source knowledge.

The Bait Classifier (C_2): A secondary classifier is introduced and initialized with the weights of the anchor classifier.

First, the feature extractor f is frozen. The target features in a mini-batch are split into a "certain" set (C) and an "uncertain" set (U) based on the prediction entropy of the anchor classifier. The bait classifier C_2 is then optimized to agree with the anchor on certain features, but disagree on uncertain features. This pushes the bait classifier's decision boundary toward the misaligned, uncertain features. The loss function maximizes the symmetric KL divergence for uncertain features and minimizes it for certain ones

Next, the classifiers are frozen, and the feature extractor f is updated. The goal is to pull the target features so that both the anchor and the bait classifiers yield similar predictions. This forces the target features toward the correct side of the established source decision boundary.

Additionally, a class-balance loss $\mathcal{L}_b$ is applied to prevent the model from degenerate solutions where all uncertain features are pushed into a single class.

Commented [ak14]: پپیر اشن رو خوندم ایده اصلی شون فقط اون PERTURBATION ها بود و خود مدل فقط دو تا لاس برای IMG LEVEL AND INSTANCE LEVEL گذاشته بود از طریق GRL. A super target domain can be constructed by augmenting more target domain perturbations to the target domain images. The optimal direction of the target domain to the domain invariant space can be approximated as the alignment direction from the super target domain to the target domain. Based on this idea, we propose a novel method called SOAP (SOurce data-free domain Adaptation through domain Perturbation) which can remove domain perturbation from the target domain.

¹ Intra-domain Adversarial Alignment

² Source-similar

³ Source-dissimilar

⁴ Perturbed Domain Supervision

⁵ Perturbations

⁶ Image-based Information Extraction

⁷ Neighborhood Clustering

ترجمه سبک تصویر^۱: هدف این روش ها، تبدیل سبک تصاویر دامنه هدف به سبک تصاویر دامنه مبدأ است، بی آنکه محتوای معنایی آن ها دچار تغییر شود. از آنجا که روش های سنتی انتقال سبک نیازمند تصاویر مبدأ هستند، در چارچوب بدون منبع، از پارامترهای ذخیره شده در لایه های Batch Normalization مدل آموزش دیده (یعنی میانگین و واریانس) به عنوان نماینده ای از سبک دامنه مبدأ استفاده می شود [31]. همچنین، برخی رویکردها برای افزایش استحکام مدل، تصاویر هدف را با سبک های تصادفی و متنوع غنی می کنند تا وابستگی شبکه به یک سبک خاص کاهش [32].

2-3-3. روش های مبتنی بر مدل^۲

برخلاف رویکردهای مبتنی بر داده که تمرکز آن ها بر خلق یا تغییر داده های هدف است، روش های مبتنی بر مدل در انطباق دامنه بدون منبع، معماری و پارامترهای مدل از پیش آموزش دیده را به عنوان نقطه شروع در نظر گرفته و با استفاده از تکنیک های یادگیری خودنظارتی بخش هایی از شبکه را برای تطبیق با دامنه جدید به روزرسانی می کنند [18]. این روش ها با اتکا به این فرض که مدل مبدأ دارای سطح قابل قبولی از قابلیت تعمیم است، تلاش می کنند از خروجی های خود مدل بر روی داده های هدف استفاده کنند. پرکاربردترین استراتژی ها در این دسته شامل خودآموزی، شبه برچسب گذاری و کمینه سازی آنتروپی است.

1-3-3-2. خودآموزی و شبه برچسب گذاری

در غیاب برچسب های واقعی در دامنه هدف، شهودی ترین ایده استفاده از پیش بینی های خود مدل به عنوان سیگنال نظارتی است. در این فرآیند، مدل به صورت تکرارشونده خروجی های خود را پالایش می کند. استراتژی شبه برچسب گذاری معمولاً از سه گام اساسی تشکیل می شود:

- تولید نمونه اولیه^۳: هدف این مرحله یافتن یک نماینده یا پروتوتایپ در فضای ویژگی برای هر کلاس است. برخی روش ها نمونه هایی که دارای آنتروپی خود^۴ پایینی هستند را به عنوان نماینده انتخاب می کنند. رویکرد محبوب تر، محاسبه «مرکز ثقل»^۵ برای هر کلاس با استفاده از تکنیک های خوشه بندی عمیق^۶ است تا نمایندگان استوارتری در برابر نویز به دست آیند [33].

- تخصیص شبه برچسب: پس از تعیین مراکز کلاس ها، برچسب هر نمونه در دامنه هدف بر اساس کمترین فاصله هندسی (مانند فاصله کسینوسی) تا این پروتوتایپ ها یا صرفاً بر اساس بیشترین میزان اطمینان خروجی مدل (Argmax) تخصیص می یابد. در رویکردهای

رو generative کاری که می کنند به مدل ترین می کنند به این صورت که تصویر تارگت رو میدن بهش و تصویری که تبدیل کرده به استایل سورس رو میدن به مدل ترین رو هم میدن به generative روی سورس و تصویر قبل از مدل می گیرن اگر loss مدل سورس بعد این دو تا خروجی رو با هم information شون متفاوت باشه در پریدیکشن و این که یه هم دارن که از خروجی تصویر تولید شده در مدل entropy loss سورس بدست می آید.

Commented [ak16]: to solve this problem, we present an effective framework by separating the training process into two stages: (1) pre-training a generalized source model and (2) adapting a target model with self-supervised learning. In our framework, we propose the Cross-Patch Style Swap (CPSS) to diversify samples with various patch styles in the feature-level, which can benefit the training of both stages. First, CPSS can significantly improve the generalization ability of the source model, providing more accurate pseudo-labels for the latter stage. Second, CPSS can reduce the influence of noisy pseudo-labels and also avoid the model overfitting to the target domain during self-supervised learning, consistently boosting the performance on the target and open domains.

Commented [ak17]: <https://share.gemini.google/8JINIF7mxXog>

The approach works by jointly learning the parameters of a neural network alongside the cluster assignments of the resulting visual features it extracts. It aims to create highly transferable, general-purpose image features without relying on large, manually annotated datasets like ImageNet.

The authors propose an alternating framework that closely mirrors standard supervised training, but utilizes unsupervised clustering to generate its own training targets. The methodology consists of the following core steps:

- **Iterative Clustering:** The network maps raw images to feature vectors, which are then grouped using a standard clustering algorithm, primarily k-means.
- **Pseudo-Labeling:** The cluster assignments generated by the k-means algorithm are treated as target "pseudo-labels" for the images.
- **Weight Updating:** The model uses these pseudo-labels as supervision, updating the weights of the convnet by predicting the cluster assignments through backpropagation.
- **Avoiding Trivial Solutions:** To prevent the network from collapsing all inputs into a single cluster or turning all features to zero, the authors automatically reassign empty clusters during k-means optimization and sample images uniformly across pseudo-labels during training.
- **Preprocessing:** Because unsupervised methods often struggle to learn from raw color, the model applies a fixed linear transformation based on Sobel filters to remove color and increase local edge contrast

We cluster the output of the convnet and use the subsequent cluster assignments as "pseudo-labels" to optimize Eq. (1). This deep clustering (DeepCluster) ap-proach iteratively learns the features and groups them.

¹ Image Style Translation

² Model-Based

³ Prototype

⁴ Self-entropy

⁵ Centroid

⁶ Deep Clustering

پیشرفته‌تر، از معماری معلم-دانش‌آموز استفاده می‌شود؛ به این صورت که مدل معلم (که معمولاً میانگین متحرک نمایی از وزن‌های دانش‌آموز است) شبه‌برچسب‌های پایدارتری تولید کرده و مدل دانش‌آموز با آن‌ها آموزش می‌بیند [34].

- فیلتر کردن شبه‌برچسب: به دلیل وجود شکاف دامنه، پیش‌بینی‌های اولیه مدل به ناچار حاوی برچسب‌های نویزی هستند. اگر مدل با این برچسب‌های غلط آموزش ببیند، دچار انباشت خطا می‌شود. برای مقابله با این مشکل، محققان از تکنیک‌های فیلتر کردن نمونه‌های غیرمطمئن یا رویکردهای یادگیری نیمه‌نظارتی نظیر میکس‌مچ^۱ استفاده می‌کنند تا اطلاعات را به شکل ایمن‌تری بین نمونه‌های با اطمینان بالا و پایین ترکیب و منتقل کنند [35].

2-3-2. کمینه‌سازی آنتروپی (Entropy Minimization)

ایده کمینه‌سازی آنتروپی ریشه در ادبیات یادگیری نیمه‌نظارتی دارد [36]. فرض اساسی این روش آن است که اگر یک مدل به خوبی با یک دامنه جدید تطبیق یافته باشد، پیش‌بینی‌های آن برای داده‌های بدون برچسب باید قطعی^۲ و دارای عدم قطعیت (آنتروپی) پایینی باشند. بنابراین، می‌توان از تابع زیان کمینه‌سازی آنتروپی برای وادار کردن مدل به ارائه پیش‌بینی‌های قاطعانه در دامنه هدف استفاده کرد.

با این وجود، استفاده صرف از کمینه‌سازی آنتروپی می‌تواند منجر به یک راه‌حل بدیهی^۳ شود؛ وضعیتی که در آن شبکه برای کاهش سریع آنتروپی، تمامی نمونه‌های دامنه هدف را به یک کلاس واحد (که معمولاً کلاس اکثریت است) اختصاص می‌دهد. برای جلوگیری از این سوگیری، رویکردهای نوین مانند روش SHOT یک عبارت «بیشینه‌سازی تنوع» یا آنتروپی دسته‌ای^۴ را به تابع زیان اضافه می‌کنند [5]. ترکیب کمینه‌سازی آنتروپی فردی و بیشینه‌سازی تنوع دسته‌ای، به عنوان «بیشینه‌سازی اطلاعات»^۵ شناخته می‌شود که علاوه بر ایجاد پیش‌بینی‌های قاطع، توزیع متعادلی از کلاس‌ها را در دامنه هدف تضمین می‌نماید.

2-4. انطباق در زمان آزمون^۶

به رغم موفقیت‌های رویکرد انطباق دامنه بدون منبع، این روش‌ها عموماً با این پیش‌فرض عمل می‌کنند که کل داده‌های هدف از پیش در دسترس است و مدل می‌تواند طی چندین دور روی آن‌ها

Commented [ak18]: <https://share.gemini.google/Shz1rJBYuKsc>

In this work, we unify the current dominant approaches for semi-supervised learning to produce a new algorithm, MixMatch, that guesses low-entropy labels for data-augmented un-labeled examples and mixes labeled and unlabeled data using MixUp

The core achievement is unifying three dominant, previously separate SSL approaches into a single algorithm: consistency regularization, entropy minimization, and generic regularization.

¹ MixMatch

² Deterministic

³ Trivial Solution

⁴ Batch Entropy

⁵ Information Maximization

⁶ Test-Time Adaptation - TTA

آموزش ببیند [11]. با این حال، در بسیاری از سناریوهای کاربردی، جمع‌آوری یکباره داده‌های هدف پیش از زمان ارزیابی امکان‌پذیر نیست. برای پاسخ به این نیاز، پارادایم نوظهور انطباق در زمان آزمون معرفی شده است که پتانسیل انطباق مدل از پیش آموزش‌دیده با داده‌های بدون برچسب را دقیقاً در مرحله آزمایش و پیش از انجام پیش‌بینی‌ها دارا است [37].

Commented [ak19]: Title: Test-time training with self-supervision for generalization under distribution shifts

1-4-2. تفاوت انطباق در زمان آزمون با انطباق دامنه بدون منبع

تفاوت بنیادین میان این دو پارادایم، در زمان‌بندی و نحوه دسترسی به داده‌ها در فاز استنتاج نهفته است. در رویکرد استاندارد بدون منبع، فرآیند تطبیق به صورت «آفلاین» انجام می‌شود. در این حالت، مدل به کل مجموعه داده‌های بدون برچسب هدف دسترسی دارد و می‌تواند فرآیند انطباق چند دوره‌ای را پیش از تولید پیش‌بینی‌های نهایی به طور کامل انجام دهد [38]. در مقابل، انطباق در زمان آزمون مستقیماً در فاز استنتاج و روی داده‌های آزمون اعمال می‌شود. در این چارچوب، مدل همزمان با دریافت نمونه‌های جدید (به صورت تک‌نمونه یا دسته‌ای)، پارامترهای خود را در لحظه به‌روزرسانی کرده و بلافاصله پیش‌بینی نهایی را برای همان نمونه‌ها ارائه می‌دهد [6]. در واقع، در مقالات مروری اخیر اشاره شده است که انطباق در زمان آزمون را می‌توان به عنوان یک حالت «آنلاین» از رویکرد بدون منبع در نظر گرفت که در آن مدل مستقیماً و بدون درنگ با داده‌های آزمون در دامنه هدف سازگار می‌شود [18]. این تفاوت در نحوه دسترسی، محدودیت‌های سخت‌گیرانه‌تری را برای روش‌های زمان آزمون ایجاد می‌کند. در این روش‌ها، داده‌های آزمون معمولاً تنها یک بار قابل مشاهده هستند و امکان آموزش مکرر روی آن‌ها وجود ندارد. در نتیجه، این الگوریتم‌ها باید به گونه‌ای طراحی شوند که با کمترین حجم محاسبات و به سرعت (در حد پردازش یک دسته از داده‌ها)، تغییرات توزیع را خنثی کرده و از تخریب دانش پایه مدل جلوگیری نمایند [23].

Commented [ak20]: Universal source-free domain adaptation

Commented [ak21]: Continual test-time domain adaptation

2-4-2. انطباق دسته‌ای در زمان آزمون¹

در سناریوهایی که سیستم در فاز استنتاج تنها با یک نمونه منفرد (Single Instance) یا یک دسته بسیار کوچک از داده‌ها (Mini-batch) مواجه می‌شود، پارادایم انطباق دسته‌ای در زمان آزمون مورد استفاده قرار می‌گیرد [37]. در این رویکرد، مدل به طور کاملاً مستقل خود را با یک نمونه یا یک دسته کوچک سازگار می‌کند و ویژگی بارز آن این است که فرآیند انطباق انجام‌شده برای یک دسته، هیچ‌گونه تأثیری بر پردازش و انطباق دسته‌های بعدی ندارد [11].

بر اساس بررسی‌های انجام‌شده، محققان برای پیاده‌سازی این نوع انطباق مستقل در زمان آزمون، تکنیک‌های متنوعی را ارائه داده‌اند که به طور کلی در سه دسته اصلی طبقه‌بندی می‌شوند:

¹ Test-Time Batch Adaptation - TTBA

1 - کالیبراسیون نرمال سازی دسته ای¹:

یکی از راهکارهای اولیه و مؤثر، تنظیم لایه های نرمال سازی شبکه است. در این روش، آماره های میانگین و واریانس که در حین آموزش روی دامنه مبدأ به دست آمده اند، با آماره های جدیدی که مستقیماً از نمونه یا دسته آزمون در حال پردازش تخمین زده می شوند، ترکیب شده یا به طور کامل جایگزین می گردند [39]. این کار باعث می شود ویژگی های استخراج شده با توزیع نمونه ای فعلی سازگاری بهتری پیدا کنند.

Commented [ak22]: Evaluating prediction-time batch normalization for robustness under covariate shift

2 - بهینه سازی مدل:

در این رویکرد، پارامترهای مدل از پیش آموزش دیده، برای هر نمونه آزمون به صورت خاص تنظیم دقیق (Fine-tuning) می شوند. این کار معمولاً از طریق دو روش انجام می پذیرد: نخست، با استفاده از وظایف کمکی خودنظارتی² نظیر پیش بینی زاویه چرخش تصویر که در زمان آموزش و آزمون به صورت مشترک بهینه سازی می شوند [37]؛ و دوم، از طریق تعریف توابع هدف بدون نظارت (Unsupervised Objectives) مانند کمینه سازی آنتروپی برای میانگین پیش بینی ها روی نسخه های تقویت شده (Augmented) از داده ورودی [40].

Commented [ak23]: MEMO: test time robustness via adaptation and augmentation

3 - انطباق ورودی³:

برخلاف رویکرد قبلی که اوزان مدل را تغییر می داد، در این روش اوزان شبکه کاملاً ثابت و منجمد باقی می ماند و در عوض، خود داده های ورودی بهینه سازی و اصلاح می شوند. به عنوان مثال، با استفاده از شبکه های رمزگذار-رمزگشا⁴ یا پرامپت های بصری⁵، تصویر ورودی در فاز آزمون به گونه ای ترجمه و سازگار می شود که خطای بازسازی به حداقل رسیده و تصویر نهایی تطابق بهتری با توزیع داده های دامنه مبدأ داشته باشد [41].

Commented [ak24]: Test-time adaptable neural networks for robust medical image segmentation

2-5. انطباق آنلاین در زمان آزمون⁶

این بخش به عنوان این پایان نامه است و به بررسی چالش برانگیزترین و در عین حال کاربردی ترین سناریوی انطباق می پردازیم.

1-5-2. مفهوم یادگیری جریانی و OTTA

در بسیاری از رویکردهای پیشین نظیر انطباق دامنه بدون منبع، فرض بر این است که سیستم به یک مجموعه داده بزرگ یا حداقل یک دسته مشخص از داده های هدف دسترسی دارد تا بتواند فرآیند

¹ Batch Normalization Calibration

² Self-supervised Auxiliary Tasks


³ Input Adaptation

⁴ Auto-encoders

⁵ Visual Prompts

⁶ Online Test-Time Adaptation - OTTA

تطبیق را به صورت آفلاین و در چندین دور انجام دهد. با این حال، در بسیاری از کاربردهای پویای دنیای واقعی، نظیر سیستم های رانندگی خودران یا رباتیک، داده ها به صورت یکجا و از پیش در دسترس نیستند. در این شرایط، سیستم با پدیده داده های جریان^۱ مواجه است؛ به این معنا که داده ها به صورت پیوسته، متوالی و در قالب دسته های کوچک (Mini-batches) وارد می شوند. در این سناریوهای جریانی، ذخیره سازی داده ها برای پردازش های آینده یا آموزش های چنددوره ای به دلیل محدودیت های حافظه و همچنین نیاز به تصمیم گیری های بی درنگ، کاملاً غیر عملی است.



شکل 2- پارادایم تطبیق زمان-تست با هدف انطباق مدل پیش آموزش دیده با انواع مختلف داده های تست بدون برچسب، از جمله مینی بیچ تکی در (الف)، داده های جریانی (استریمینگ) در (ب)، یا یک مجموعه داده کامل در (ج)، قبل از انجام پیش بینی ها صورت می گیرد. در طول فرآیند تطبیق، برای بهبود عملکرد در برابر تغییرات توزیع، می توان مدل یا داده های ورودی را تغییر داد. پیکان نقطه چین سبز نشان دهنده فاز آموزش زمان-تست قبل از استنتاج است، در حالی که پیکان آبی استنتاج محض را نشان می دهد.

برای غلبه بر این محدودیت های سخت گیرانه، پارادایم «انطباق آنلاین در زمان آزمون» معرفی شده است. در این چارچوب، یک مدل از پیش آموزش دیده روی دامنه مبدأ، با دنباله ای از دسته های کوچک داده های بدون برچسب هدف مواجه می شود. ویژگی بارز و چالش برانگیز این سناریو آن است که هر دسته از داده ها تنها یک بار دیده می شود و مدل باید بلافاصله پس از مشاهده آن دسته، هم پیش بینی های خود را ارائه دهد و هم پارامترهای خود را در لحظه^۲ به روزرسانی کند [6].

برخلاف انطباق دسته ای در زمان آزمون که در آن هر دسته به صورت کاملاً مستقل پردازش می شد، رویکرد آنلاین بر مفهوم محوری «استفاده مجدد از دانش»^۳ استوار است. به عبارت دیگر، دانشی که مدل از پردازش دسته های دیده شده قبلی آموخته و در اوزان خود انباشته کرده است، حفظ شده و برای کمک به پردازش و انطباق بهتر با دسته های فعلی و آینده مورد استفاده قرار می گیرد [37]. این تجمیع دانش به مدل اجازه می دهد تا در طول زمان، به طور پیوسته با محیط جدید سازگارتر شود.

¹ Streaming Data

² On-the-fly

³ Knowledge Reuse

علاوه بر این، در محیط های کاملاً پویا، ممکن است توزیع داده های آزمون به صورت مداوم تغییر کند. در چنین شرایطی که به عنوان انطباق زمان آزمون پیوسته¹ نیز شناخته می شود، رویکردهای آنلاین نه تنها باید با یک توزیع ثابت جدید سازگار شوند، بلکه باید توانایی انطباق با توزیع های متغیر² را نیز داشته باشند [23]. این مسئله، اهمیت توسعه الگوریتم هایی که بتوانند به سرعت از داده های در حال جریان یاد بگیرند و در عین حال دچار ناپایداری نشوند را دوچندان می کند.

Commented [ak25]: Title: Continual test-time domain adaptation

2-5-2. چالش انباشت خطا³: نحوه تأثیر نویز شبه برچسب ها در فرآیند یادگیری پیوسته

در سناریوی انطباق آنلاین در زمان آزمون، سیستم به طور پیوسته با داده های جدید مواجه می شود و باید بدون دسترسی به برچسب های واقعی، خود را به روزرسانی کند. در این شرایط، مدل ها به شدت به تکنیک های خودآموزی و شبه برچسب گذاری وابسته هستند [11]. با توجه به وجود تغییرات توزیع میان دامنه مبدأ و هدف، پیش بینی های اولیه مدل بر روی داده های جدید به نادرست با خطا همراه است.

هنگامی که مدل از این پیش بینی های حاوی خطا به عنوان حقیقت برای آموزش و به روزرسانی وزن های خود استفاده می کند، پدیده ای به نام انباشت خطا رخ می دهد که در ادبیات یادگیری ماشین از آن با عنوان سوگیری تأیید⁴ نیز یاد می شود. این پدیده در واقع به معنای «گلوله برفی شدن اشتباهات» مدل است. فرآیند این چرخه معیوب به این شکل است که مدل با هر بار به روزرسانی بر اساس داده های مسموم، نسبت به اشتباهات خود سوگیری پیدا کرده و در پیش بینی های بعدی، خطاهای بیشتری را با میزان اطمینان بالاتری مرتکب می شود. این روند به طور مداوم تکرار شده و خطاها روی یکدیگر انباشته می شوند تا جایی که عملکرد مدل کاملاً دچار فروپاشی می گردد [42].

Commented [ak26]: Title: Efficient test-time model adaptation without forgetting

تأثیر مخرب انباشت خطا در وظایف پیچیده ای نظیر تشخیص شیء به مراتب بحرانی تر از یک وظیفه ساده دسته بندی تصویر است. در تشخیص شیء، شبکه باید به طور همزمان محلی سازی و دسته بندی را انجام دهد. اگر کادر محدودکننده با خطای جزئی پیش بینی شود و بخش هایی از پس زمینه را در بر گیرد، ویژگی های استخراج شده از آن ناحیه برای به روزرسانی های بعدی کاملاً مخدوش می شوند. این خطای محلی سازی باعث می شود مدل در مرحله بعد یک شیء دیگر را به اشتباه دسته بندی کند و در نتیجه یک وابستگی متقابل (Inter-dependence) مخرب ایجاد می شود که چرخه انباشت خطا را تشدید می کند.

Commented [ak27]: باز هم نمی دونم با این کلمات انگلیسی چی کار کنم چون بعضی هاشون کلمات جدیدی نیستن ولی ذکر نکردنشون شاید باعث بشه که ترجمه ای که ازشون انجام شده مفهوم شون رو به خوبی نرسونه

برای مقابله با این معضل در فرآیند یادگیری پیوسته، محققان راهکارهای متعددی را برای مدیریت نویز پیشنهاد داده اند. یکی از راهکارهای بنیادین، فیلتر کردن شبه برچسب های نامطمئن پیش از اعمال آن ها در به روزرسانی وزن ها است. با این حال، استفاده از آستانه های ثابت برای فیلتر کردن می تواند

¹ Continual Test-Time Adaptation

² Non-stationary

³ Error Accumulation

⁴ Confirmation Bias

منجر به حذف بیش از حد داده ها شود؛ از این رو، تنظیم آستانه های پویا¹ متناسب با سطح یادگیری مدل پیشنهاد شده است.

رویکرد دیگر، استفاده از تکنیک های یادگیری از برجسب نویزی² است که تلاش می کند به جای حذف کامل داده های نامطمئن، اطلاعات مفیدی از آنها استخراج کند [43]. همچنین، روش هایی نظیر SHOT++ با بهره گیری از الگوریتم های نیمه نظارتی مانند میکس میچ (MixMatch)، سعی دارند تا با ترکیب ایمن نمونه های با اطمینان بالا و پایین، قابلیت اطمینان مدل را افزایش داده و از انباشت خطاهای متوالی جلوگیری کنند [44].

Commented [ak28]: Title: Self-Supervised Noisy Label Learning for Source-Free Unsupervised Domain Adaptation

Commented [ak29]: Title: Source Data-absent Unsupervised Domain Adaptation through Hypothesis Transfer and Labeling Transfer

3-5-2. پدیده فراموشی فاجعه بار

در چارچوب انطباق آنلاین در زمان آزمون، یکی از مهم ترین و شناخته شده ترین چالش ها، پدیده «فراموشی فاجعه بار» است. این پدیده زمانی رخ می دهد که مدل در تلاش برای یادگیری و سازگاری با داده های جریانی جدید، دانش حیاتی و الگوهای تعمیم پذیری پیشین خود را که در دامنه مبدأ آموخته بود، از دست می دهد [23]. مطالعات متعدد نشان داده اند که مدل های بهینه شده با روش های انطباق در زمان آزمون، در صورت عدم استفاده از مکانیزم های کنترلی، دچار افت عملکرد شدیدی روی نمونه های آموزشی اصلی می شوند [42].

برای درک بهتر، باید تفاوت این پدیده را با انباشت خطا مشخص کرد. در انباشت خطا، مدل در تلاش برای یادگیری دامنه مقصد مسیر را اشتباه می رود و با استفاده از پیش بینی های غلط خود، شبکه را با اطلاعات نویزدار مسموم می کند. اما در فراموشی فاجعه بار، مسئله اصلی مسموم شدن با نویز نیست؛ بلکه جایگزین شدن و از بین رفتن اطلاعات و توانمندی های پایه ای مدل است. دلیل اصلی بروز این اتفاق در رویکردهای آنلاین این است که شبکه های عصبی عمیق به صورت مداوم پارامترهای خود را تغییر می دهند تا با توزیع داده های جدید همسو شوند. از آنجا که در این تنظیمات هیچ گونه دسترسی به داده های مبدأ وجود ندارد، مدل به تدریج لنگرهای (Anchors) دانش اولیه خود را رها می کند. تغییرات سریع و بدون قید و شرط وزن ها باعث می شود که بازنمایی های مفید گذشته بازنویسی شده و مدل صرفاً بر روی ویژگی های دامنه فعلی بیش برآزش شود.

برای مقابله با این معضل، محققان راهکارهای متعددی را در قالب «منظم سازی ضد فراموشی»³ ارائه داده اند. از جمله این روش ها می توان به حفظ یک بانک حافظه (Memory Bank) کوچک از داده های تاریخی و یا بازگردانی تصادفی⁴ پارامترهای خاص شبکه به مقادیر اولیه شان اشاره کرد [23].

¹ Dynamic Thresholding

² Noisy Label Learning

³ Anti-forgetting Regularization

⁴ Stochastic Restoration

همچنین، برخی رویکردها سعی می کنند تنها بخش کوچکی از پارامترهای شبکه (مانند پارامترهای لایه های نرمال سازی) را به روزرسانی کنند تا هسته اصلی دانش دست نخورده باقی بماند [42].

2-5-4. راهکارهای مقابله با فراموشی در OTTA

همان طور که پیش تر بحث شد، به روزرسانی مداوم مدل بر روی داده های جریانی بدون دسترسی به داده های مبدأ، منجر به تخریب دانش اولیه و بروز پدیده فراموشی فاجعه بار می شود. برای مقابله با این معضل و حفظ پایداری مدل در انطباق آنلاین در زمان آزمون، محققان طیف گسترده ای از تکنیک ها را تحت عنوان کلی «منظم سازی ضد فراموشی»¹ توسعه داده اند. هدف اصلی این رویکردها، ایجاد تعادل میان «یادگیری سریع» ویژگی های دامنه جدید و «حفظ یکپارچگی ساختاری» دانش پیشین است. در ادامه، مهم ترین راهکارهای ارائه شده در مقالات معتبر بررسی می شوند:

الف) بازگردانی تصادفی وزن ها²:

یکی از رویکردهای نوآورانه برای جلوگیری از انحراف بیش از حد پارامترهای شبکه، ایده بازگردانی تصادفی است. در این روش، به جای محدود کردن کامل به روزرسانی ها، بخش کوچکی از پارامترهای شبکه در طول فرآیند انطباق به صورت تصادفی به مقادیر اولیه شان (وزن های مدل از پیش آموزش دیده در دامنه مبدأ) برگردانده می شوند. این تکنیک که برجسته ترین نمونه آن در روش CoTTA معرفی شده است، به عنوان یک عامل تنظیم کننده عمل کرده و از دور شدن بیش از حد شبکه از دانش پایه جلوگیری می کند [23]. در رویکردهای مشابه و پیشرفته تر نظیر PETAL، این بازگردانی به صورت کاملاً تصادفی انجام نمی شود، بلکه پارامترهایی برای بازگردانی انتخاب می شوند که نرم گرادینان (Gradient Norm) کوچک تری دارند تا تداخلی در یادگیری ویژگی های مهم دامنه هدف ایجاد نشود [45].

ب) منظم سازی آگاهانه از اهمیت پارامترها³:

رویکرد دیگر برای مقابله با فراموشی، محدود کردن به روزرسانی در پارامترهایی است که برای دانش دامنه مبدأ حیاتی هستند. به عنوان نمونه، در روش EATA یک منظم ساز فیشر (Fisher Regularizer) معرفی شده است که میزان اهمیت هر پارامتر را تخمین می زند. این مکانیزم با اعمال جریمه بر روی تغییرات پارامترهای مهم (که بر اساس نمونه های آزمون و شبه برچسب ها ارزیابی می شوند)، از تغییرات مخرب و بیش از حد در وزن های کلیدی شبکه جلوگیری می کند [46]. همچنین برخی روش ها نظیر EcoTTA با استفاده از تقطیر دانش خود نظارتی⁴، خروجی مدل در حال انطباق را مجبور می کنند تا حد امکان به خروجی مدل اولیه مبدأ نزدیک باقی بماند [46].

Commented [ak30]: Title: Continual test-time domain adaptation

Commented [ak31]: Title: Efficient test-time model adaptation without forgetting

¹ Anti-forgetting Regularization

² Stochastic Restoration

³ Importance-aware Regularization

⁴ Self-distilled Regularization

ج) استفاده از بانک حافظه:

استفاده از حافظه اپیزودیک یا بانک حافظه، یکی از روش های بسیار مؤثر برای لنگراندازی (Anchoring) دانش مدل است. در این تکنیک، یک حافظه با ظرفیت محدود برای ذخیره سازی داده های تاریخی (Historical Data) یا نمونه هایی از دامنه هدف که مدل بالاترین میزان اطمینان را روی آن ها داشته است، حفظ می شود. در حین به روزرسانی مدل با دسته های جریانی جدید، نمونه های موجود در بانک حافظه نیز بازپخش (Replay) می شوند تا مدل الگوهای گذشته را به خاطر بیاورد. به عنوان مثال، روش AUTO یک بانک حافظه از نمونه های به راحتی تشخیص داده شده (Easily Recognized Samples) ایجاد می کند تا از بیش برآزش مدل به سمت نمونه های ناشناخته و نویزدار در زمان آزمون جلوگیری نماید [47].

Commented [ak32]: Title: AUTO: Adaptive Outlier Optimization for Test-Time OOD Detection

د) محدودسازی پارامترهای قابل آموزش (Parameter Isolation):

به جای به روزرسانی کل شبکه که ریسک فراموشی را به شدت بالا می برد، برخی رویکردها تنها کسر کوچکی از پارامترهای مدل را تنظیم می کنند. رویکرد استاندارد TENT تنها پارامترهای افاین (Affine Parameters) در لایه های نرمال سازی دسته ای را به روزرسانی می کند [45]. برخی روش های جدیدتر نظیر VDP، مدل پایه را کاملاً ثابت نگه داشته و صرفاً پرامپت های ورودی را در زمان آزمون بهینه می کنند که این امر نه تنها فراموشی فاجعه بار را به صفر می رساند، بلکه از نظر محاسباتی نیز بسیار بهینه است [48].

2-6. انطباق دامنه در وظیفه تشخیص شیء

2-6-1. پیچیدگی های تشخیص شیء در برابر دسته بندی تصویر

در حالی که بسیاری از روش های پایه در انطباق دامنه و یادگیری ماشین برای وظیفه دسته بندی تصویر طراحی و بهینه سازی شده اند، اعمال این تکنیک ها بر روی مسئله تشخیص شیء چالش های منحصر به فرد و پیچیده ای را به همراه دارد. تفاوت بنیادین میان این دو وظیفه در آن است که دسته بندی تصویر تنها نیازمند یک پیش بینی واحد برای کل تصویر است (تعیین اینکه چه چیزی در تصویر وجود دارد)، در حالی که تشخیص شیء یک وظیفه چندوجهی است که به طور همزمان به محلی سازی (Localization) دقیق و دسته بندی تک تک اشیاء موجود در یک صحنه می پردازد [11].

این ماهیت دوگانه، پیچیدگی های فرآیند انطباق را به شدت افزایش می دهد. در ادامه، مهم ترین چالش های متمایزکننده تشخیص شیء در سناریوهای تغییر توزیع بررسی می شوند:

- انطباق در دو سطح متمایز Image-Level Alignment در مقابل Instance-Level Alignment :

در مسئله تشخیص شیء، شکاف دامنه تنها در سطح کلی تصویر رخ نمی دهد، بلکه در سطح نمونه های مجزا نیز وجود دارد. از یک سو، مدل با تغییرات سراسری نظیر تغییرات در شرایط نورپردازی، زمان روز، وضعیت آب و هوا و پس زمینه مواجه است که به آن تغییرات سطح تصویر گفته می شود. از سوی دیگر، ظاهر اشیاء منفرد (نظیر خودروها، عابران پیاده و غیره) نیز می تواند از نظر مقیاس، زاویه دید، بافت و رزولوشن دچار تغییرات قابل توجهی شود که به عنوان تغییرات سطح نمونه شناخته می شود. بنابراین، یک الگوریتم انطباق موفق برای تشخیص شیء باید قادر باشد ویژگی های استخراج شده را در هر دو سطح سراسری و محلی هم تراز کند.

- وابستگی متقابل خطاهای رگرسیون و دسته بندی:

در دسته بندی، خطای مدل صرفاً به معنای اشتباه در انتخاب کلاس هدف است. اما در تشخیص شیء، شبکه باید مختصات جعبه محدودکننده^۱ را نیز از طریق رگرسیون پیش بینی کند. اگر مدل در پیش بینی این جعبه کمی خطا کند و بخش هایی از پس زمینه را درون کادر قرار دهد، ویژگی های استخراج شده از آن ناحیه Region of Interest مخدوش شده و به شدت تحت تأثیر نویز پس زمینه قرار می گیرد. این خطای محلی سازی می تواند مستقیماً باعث خطای مدل در دسته بندی شیء شود و بالعکس. این وابستگی متقابل میان رگرسیون و دسته بندی، فرآیند یادگیری ویژگی های نامتغیر از دامنه^۲ را بسیار دشوارتر می سازد.

- حساسیت شدید به نویز در رویکردهای بدون منبع و زمان آزمون:

همان طور که پیش تر بحث شد، روش های انطباق دامنه بدون منبع و انطباق آنلاین در زمان آزمون، وابستگی شدیدی به شبه برچسب گذاری برای تولید سیگنال های نظارتی دارند. در تشخیص شیء، نویز شبه برچسب ها به دو شکل مخرب ظاهر می شود: اول، اشتباه در دسته بندی شیء؛ و دوم، عدم دقت در ابعاد و موقعیت جعبه محدودکننده. استفاده از این شبه برچسب های دارای نویز مضاعف برای به روزرسانی مدل در زمان آزمون، به سرعت منجر به پدیده انباشت خطا شده و چرخه یادگیری پیوسته را مسموم می کند [6].

عدم تعادل شدید کلاس ها و پس زمینه^۳:

در اکثر صحنه های واقعی، بخش عمده ای از تصویر به پس زمینه اختصاص دارد و تعداد محدودی از اشیاء پیش زمینه در آن وجود دارند. هنگام مواجهه با دامنه جدید، تغییرات شدید در ویژگی های پس زمینه می تواند باعث شود مدل بخش هایی از پس زمینه را به اشتباه به عنوان شیء تشخیص دهد (False Positives) و یا اشیاء واقعی را نادیده بگیرد (False Negatives). مدیریت این عدم تعادل

¹ Bounding Box

² Domain-invariant

³ Foreground-Background Imbalance

ساختاری در شرایطی که برچسب های واقعی در دسترس نیستند، یکی از چالش های بنیادین در انطباق مدل های تشخیص شیء محسوب می شود.

2-6-2. چالش های ارزیابی و شبکه های نوین

در حوزه انطباق دامنه برای تشخیص شیء، ارزیابی عملکرد مدل ها تحت تغییرات توزیع به مراتب پیچیده تر از وظیفه ساده دسته بندی تصویر است. برای سنجش دقیق این عملکرد، از معیار میانگین دقت متوسط¹ استفاده می شود. این معیار، توانایی مدل را به طور همزمان در دو جنبه کلیدی ارزیابی می کند: دسته بندی صحیح شیء و دقت محلی سازی آن که با استفاده از معیار اشتراک بر اجتماع² اندازه گیری می شود. در ارزیابی روش های انطباق دامنه بدون منبع و انطباق آنلاین در زمان آزمون، عملکرد مدل ها معمولاً بر روی مجموعه داده های استاندارد با تغییرات توزیع شدید، مانند انتقال از دامنه مبدأ به دامنه های مه آلود یا تاریک، با استفاده از معیار mAP گزارش می شود [11]. وجود این ارزیابی های دوگانه، اهمیت کالیبره بودن مدل را در زمان استنتاج برجسته می سازد.

با پیشرفت معماری های یادگیری عمیق، استفاده از شبکه های نوین نظیر ترانسفورمرهای بینایی³ در وظایف انطباق دامنه به شدت مورد توجه قرار گرفته است. برخلاف شبکه های کانولوشنی سنتی که تمایل به استخراج اطلاعات محلی و مختص دامنه⁴ نظیر ویژگی های بصری پس زمینه دارند، ترانسفورمرها با بهره گیری از مکانیزم خودتوجهی⁵ قادرند زمینه سراسری⁶ تصویر را بهتر مدل سازی کنند [18]. این ویژگی باعث می شود مدل به جای تمرکز بر نویزهای محیطی، بر روی نواحی کلیدی شیء متمرکز شده و از ویژگی های نامربوط پس زمینه که به شدت تحت تأثیر شکاف دامنه هستند، چشم پوشی کند. به عنوان مثال، روش هایی نظیر DSiT-B به طور کامل بر پایه معماری ViT بنا شده اند تا با استفاده از مکانیزم توجه، ویژگی های نامتغیر از دامنه⁷ را استخراج کرده و فرآیند انطباق بدون منبع را بهبود بخشند [49]. همچنین در انطباق زمان آزمون، استفاده از این معماری ها برای هم ترازوی ویژگی ها در سطح کلاس ها و کاهش انحراف مدل (Model Deviation) به شدت مؤثر واقع شده است [50].

Commented [ak33]: Title: Domain-Specificity Inducing Transformers for Source-Free Domain Adaptation

Commented [ak34]: Title: Robustifying Vision Transformer Without Retraining from Scratch Using Attention-Based Test-Time Adaptation

علاوه بر ترانسفورمرهای استاندارد، استفاده از ترانسفورمرهای تغییرشکل پذیر⁸ تحولی اساسی در انطباق دامنه برای تشخیص شیء ایجاد کرده است. در معماری های نوین، ماژول های رمزگذار و رمزگشا

¹ mean Average Precision - mAP

² Intersection over Union - IoU

³ Vision Transformers - ViT

⁴ Domain-specific

⁵ Self-Attention

⁶ Global Context

⁷ Domain-invariant

⁸ Deformable Transformers

تغییر شکل پذیر این امکان را فراهم می کنند که شبکه تنها به مجموعه ای از نقاط کلیدی^۱ در اطراف شیء و لبه های آن توجه کند، که این امر نه تنها هزینه محاسباتی را کاهش می دهد، بلکه استخراج ویژگی های مقاوم در برابر جابه جایی دامنه را تسهیل می سازد [51].

Commented [ak35]: Deformable DETR: Deformable Transformers for End-to-End Object Detection

در چارچوب های پیشرفته انطباق، نظیر رویکردهای مبتنی بر معماری معلم-دانش آموز همراه با بازآموزی پوششی^۲، از این نوع ترانسفورمرها بهره گیری می شود تا با پوشاندن بخش هایی از تصویر هدف و اجبار شبکه به بازسازی آن ها، مدل به یادگیری ساختاری و معنایی عمیق تری دست یابد [52]. این مکانیزم، مدل را در برابر نویزهای موجود در شبه برچسب ها مقاوم تر ساخته و با تکیه بر توجه تغییر شکل پذیر، هم ترازوی دقیق تری را در هر دو سطح سراسری تصویر و سطح محلی نمونه ها فراهم می آورد که مستقیماً به بهبود معیار ارزیابی mAP در زمان آزمون کمک می کند [53].

Commented [ak36]: Title: Masked autoencoders are scalable vision learners

Commented [ak37]: Title: MIC: Masked Image Consistency for Context-Enhanced Domain Adaptation

3-6-2. هم ترازوی چند سطحی^۳

در وظیفه تشخیص شیء، تغییرات توزیع غالباً اثرات مخرب خود را در دو مقیاس کاملاً متفاوت اعمال می کنند: مقیاس سراسری که مربوط به کل تصویر است و مقیاس محلی که مستقیماً به ویژگی های هر شیء برمی گردد. بر همین اساس، رویکردهای موفق در این حوزه به سمت هم ترازوی چند سطحی حرکت کرده اند تا بتوانند شکاف دامنه را به صورت همزمان در هر دو سطح کاهش دهند.

یکی از کارهای بنیادین در این زمینه، روشی است که به طور صریح دو مؤلفه مجزا را برای انطباق دامنه معرفی کرد: یکی برای هم ترازوی در سطح تصویر جهت تطبیق ویژگی های سراسری مانند استایل تصویر، شرایط آب و هوایی یا نورپردازی، و دیگری برای هم ترازوی در سطح نمونه جهت تطبیق بازنمایی های محلی^۴ استخراج شده از هر ناحیه پیشنهادی شیء^۵ [54]. این روش از طریق شبکه های تخصصی، تفکیک کننده های مستقلی را برای هر یک از این دو سطح آموزش می دهد تا ویژگی های نامتغیر از دامنه در تمام لایه های شبکه شکل بگیرند.

Commented [ak38]: Title: Domain Adaptive Faster R-CNN for Object Detection in the Wild

با این حال، در سناریوهای انطباق دامنه بدون منبع و انطباق زمان آزمون، استفاده مستقیم از روش های تخصصی وابسته به داده های مبدأ امکان پذیر نیست. در این راستا، معماری های معلم-دانش آموز^۶ به عنوان جایگزینی قدرتمند برای هم ترازوی چند سطحی در غیاب داده های مبدأ معرفی شده اند. در این چارچوب ها، مدل معلم به عنوان یک نسخه پایدار و میانگین گیری شده از اوزان^۷ مدل

¹ Keypoints

² Masked Retraining

³ Multi-level Alignment

⁴ Local Representations

⁵ Region Proposal

⁶ Teacher-Student Architectures

⁷ Exponential Moving Average

دانش آموز عمل می کند و وظیفه تولید شبه برچسب های دقیق شامل مختصات جعبه های محدودکننده و دسته بندی آن ها را بر عهده دارد [55].

Commented [ak39]: Unbiased mean teacher for cross-domain object detection

به منظور دستیابی به هم ترازی در سطح تصویر و نمونه به صورت همزمان، معمولاً یک زیان سازگاری¹ در معماری معلم-دانش آموز تعریف می شود. مدل دانش آموز تصاویر به شدت تقویت شده² یا پوشیده شده³ از دامنه هدف را دریافت می کند، در حالی که مدل معلم تصاویر اصلی یا با تقویت ضعیف را پردازش می نماید. اجبار شبکه دانش آموز به پیش بینی خروجی های یکسان با مدل معلم، نه تنها باعث هم ترازی ویژگی های سراسری در برابر اعوجاج های تصویری می شود، بلکه در سطح محلی نیز باعث می گردد تا مدل بازنمایی های منسجمی از اشیاء مستقل استخراج کند [29].

همچنین، برای بهبود هم ترازی محلی در معماری معلم-دانش آموز، برخی از مطالعات به بررسی روابط اشیاء⁴ پرداخته اند تا با مدل سازی گراف های ارتباطی میان نمونه های مختلف در یک صحنه، انسجام معنایی بین اشیاء را حفظ کرده و دقت محلی سازی را تحت تغییرات شدید توزیع افزایش دهند [56].

2-7. جمع بندی و نتیجه گیری

در این فصل، سیر تکامل روش های انطباق برای غلبه بر پدیده تغییر توزیع به طور جامع مورد بررسی قرار گرفت. همان طور که مشاهده شد، اگرچه رویکردهای انطباق دامنه بدون نظارت توانستند نیاز به برچسب های دامنه هدف را برطرف سازند، اما وابستگی قطعی آن ها به داده های مبدأ، کاربردشان را در سناریوهای حساس به حریم خصوصی عملاً مختل کرد [57]. در پاسخ به این محدودیت بنیادین، روش های انطباق دامنه بدون منبع معرفی شدند که ایزوله سازی داده ها را تضمین می کردند؛ با این وجود، این روش ها نیز همچنان نیازمند دسترسی آفلاین به کل مجموعه داده های هدف و بهینه سازی چنددوره ای (Multi-epoch) بودند [5].

Commented [ak40]: Title: A review of domain adaptation without target labels

برای سناریوهای پویای دنیای واقعی که با داده های جریانی روبه رو هستند، انطباق آنلاین در زمان آزمون به عنوان یک راهکار ضروری و بی درنگ پا به عرصه گذاشت [6]. با این حال، مرور دقیق ادبیات موضوع نشان می دهد که اکثریت قریب به اتفاق این روش های آنلاین، منحصراً برای وظیفه دسته بندی تصویر طراحی و ارزیابی شده اند و معماری آن ها به هیچ وجه پاسخگوی پیچیدگی های ساختاری وظایف پیشرفته تری نظیر تشخیص شیء نیست [18].

تشخیص شیء به دلیل ماهیت چندوجهی خود که شامل محلی سازی و دسته بندی همزمان است، در محیط های آنلاین به شدت آسیب پذیرتر است. در این شرایط عملیاتی، نويز موجود در شبه برچسب ها

¹ Consistency Loss

² Strongly Augmented

³ Masked

⁴ Object Relations

(به ویژه خطاهای مربوط به رگرسیون کادر محدودکننده) به سرعت منجر به انباشت خطا شده و با توجه به به روزرسانی های پیوسته و متوالی، شبکه را با سرعت بسیار بیشتری به سمت پدیده مخرب فراموشی فاجعه بار سوق می دهد تکنیک های موجود نظیر تنظیم آستانه های پویا، بازگردانی تصادفی وزن ها یا استفاده از بانک های حافظه ساده، اگرچه در دسته بندی موفق بوده اند، اما به تنهایی برای هم ترازی همزمان در سطوح سراسری و نمونه ای در تشخیص شیء کفایت نمی کنند [23].

بنابراین، با وجود تمام پیشرفت های صورت گرفته در شبکه های نوین و روش های انطباق، جای خالی یک چارچوب جامع و کارآمد برای «انطباق آنلاین در زمان آزمون برای تشخیص شیء» به شدت احساس می شود. شبکه های یادگیری عمیق به چارچوبی نیاز دارند که بتواند با بهره گیری از معماری های مقاوم (نظیر ساختار معلم-دانش آموز) و استراتژی های پیشرفته مدیریت نویز، بدون نیاز به دسترسی آنلاین به داده ها، تعادلی بهینه میان یادگیری سریع دامنه جدید و حفظ یکپارچگی دانش پایه برقرار سازد. در فصل سوم، با تکیه بر نقاط قوت و ضعف بررسی شده در این پیشینه تحقیق، روش پیشنهادی این پژوهش برای غلبه بر چالش های بنیادین مذکور معرفی و به طور دقیق فرمول بندی خواهد شد.

فصل 3: روش‌شناسی و مدل پیشنهادی

3-1. مقدمه

3-2. تقطیع معنایی

1-2-3. تعاریف

3-3. جمع‌بندی

فصل 4: آزمایش‌ها و ارزیابی نتایج

4-1. مقدمه

4-2. روش پیشنهادی

4-2-1. ایده اصلی

4-3. جمع‌بندی

فصل 5: نتیجه‌گیری و پیشنهادها

5-1. مقدمه

5-2. معیارهای ارزیابی

5-2-1. دقت

5-2-1-1. دقت میانگین¹

5-2-1-2. میانگین اشتراک نسبت به اجتماع $MIoU^2$

¹ Mean Accuracy

² Mean Intersection Over Union

3-5. جمع بندی

مراجع

- [1] ‘Dataset Shift in Machine Learning’. Accessed: Jul. 29, 2026. [Online]. Available: <https://mitpress.mit.edu/9780262545877/dataset-shift-in-machine-learning/>
- [2] K. Zhou, Z. Liu, Y. Qiao, T. Xiang, and C. C. Loy, ‘Domain Generalization: A Survey’, *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 45, no. 4, pp. 4396–4415, Apr. 2023, doi: 10.1109/TPAMI.2022.3195549.
- [3] W. M. Kouw and M. Loog, ‘A Review of Domain Adaptation without Target Labels’, *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 3, pp. 766–785, Mar. 2021, doi: 10.1109/TPAMI.2019.2945942.
- [4] X. Liu and Y. Yuan, ‘A Source-Free Domain Adaptive Polyp Detection Framework With Style Diversification Flow’, *IEEE Trans. Med. Imaging*, vol. 41, no. 7, pp. 1897–1908, Jul. 2022, doi: 10.1109/TMI.2022.3150435.
- [5] J. Liang, D. Hu, and J. Feng, ‘Do We Really Need to Access the Source Data? Source Hypothesis Transfer for Unsupervised Domain Adaptation’, in *Proceedings of the 37th International Conference on Machine Learning*, PMLR, Nov. 2020, pp. 6028–6039. Accessed: Jul. 29, 2026. [Online]. Available: <https://proceedings.mlr.press/v119/liang20a.html>
- [6] D. Wang, E. Shelhamer, S. Liu, B. Olshausen, and T. Darrell, ‘Tent: Fully Test-time Adaptation by Entropy Minimization’, Mar. 18, 2021, *arXiv:2006.10726*. doi: 10.48550/arXiv.2006.10726.
- [7] K. Saenko, B. Kulis, M. Fritz, and T. Darrell, ‘Adapting Visual Category Models to New Domains’, in *Computer Vision – ECCV 2010*, K. Daniilidis, P. Maragos, and N. Paragios, Eds, Berlin, Heidelberg: Springer, 2010, pp. 213–226. doi: 10.1007/978-3-642-15561-1_16.
- [8] Y.-H. Chen, W.-Y. Chen, Y.-T. Chen, B.-C. Tsai, Y.-C. F. Wang, and M. Sun, ‘No More Discrimination: Cross City Adaptation of Road Scene Segmenters’, in *2017 IEEE International Conference on Computer Vision (ICCV)*, Oct. 2017, pp. 2011–2020. doi: 10.1109/ICCV.2017.220.
- [9] J. Nath Kundu, N. Venkat, M. V. Rahul, and R. Venkatesh Babu, ‘Universal Source-Free Domain Adaptation’, in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2020, pp. 4543–4552. doi: 10.1109/CVPR42600.2020.00460.
- [10] S. J. Pan and Q. Yang, ‘A Survey on Transfer Learning’, *IEEE Trans. Knowl. Data Eng.*, vol. 22, no. 10, pp. 1345–1359, Oct. 2010, doi: 10.1109/TKDE.2009.191.
- [11] J. Liang, R. He, and T. Tan, ‘A Comprehensive Survey on Test-Time Adaptation Under Distribution Shifts’, *Int. J. Comput. Vis.*, vol. 133, no. 1, pp. 31–64, Jan. 2025, doi: 10.1007/s11263-024-02181-w.

- S. Ben-David, J. Blitzer, K. Crammer, A. Kulesza, F. Pereira, and J. W. Vaughan, [12]
‘A theory of learning from different domains’, *Mach. Learn.*, vol. 79, no. 1, pp.
151–175, May 2010, doi: 10.1007/s10994-009-5152-4.
- M. Long, Y. Cao, J. Wang, and M. I. Jordan, ‘Learning transferable features with [13]
deep adaptation networks’, in *Proceedings of the 32nd International Conference
on Machine Learning - Volume 37*, in ICML’15, vol. 37. Lille, France: JMLR.org,
Jul. 2015, pp. 97–105.
- Y. Ganin and V. Lempitsky, ‘Unsupervised domain adaptation by [14]
backpropagation’, in *Proceedings of the 32nd International Conference on
Machine Learning - Volume 37*, in ICML’15, vol. 37. Lille, France: JMLR.org,
Jul. 2015, pp. 1180–1189.
- K. Bousmalis, N. Silberman, D. Dohan, D. Erhan, and D. Krishnan, ‘Unsupervised [15]
Pixel-Level Domain Adaptation with Generative Adversarial Networks’, in *2017
IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Jul. 2017,
pp. 95–104. doi: 10.1109/CVPR.2017.18.
- M. Chen, H. Xue, and D. Cai, ‘Domain Adaptation for Semantic Segmentation [16]
With Maximum Squares Loss’, in *2019 IEEE/CVF International Conference on
Computer Vision (ICCV)*, Oct. 2019, pp. 2090–2099. doi:
10.1109/ICCV.2019.00218.
- K. Azizzadenesheli, A. Liu, F. Yang, and A. Anandkumar, ‘Regularized Learning [17]
for Domain Adaptation under Label Shifts’, Mar. 22, 2019, *arXiv*:
arXiv:1903.09734. doi: 10.48550/arXiv.1903.09734.
- J. Li, Z. Yu, Z. Du, L. Zhu, and H. T. Shen, ‘A Comprehensive Survey on Source- [18]
Free Domain Adaptation’, *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 46, no. 8,
pp. 5743–5762, Aug. 2024, doi: 10.1109/TPAMI.2024.3370978.
- K. Wu, J. Li, L. Meng, F. Li, and H. T. Shen, ‘Privacy-Preserving Adaptive [19]
Remaining Useful Life Prediction via Source-Free Domain Adaption’, *IEEE
Trans. Instrum. Meas.*, vol. 72, pp. 1–11, 2023, doi: 10.1109/TIM.2023.3309381.
- ‘Domain Adaptation in the Absence of Source Domain Data | Proceedings of the [20]
22nd ACM SIGKDD International Conference on Knowledge Discovery and Data
Mining’. Accessed: Aug. 02, 2026. [Online]. Available:
<https://dl.acm.org/doi/10.1145/2939672.2939716>
- ‘Semi-Supervised Domain Adaptation via Minimax Entropy | IEEE Conference [21]
Publication | IEEE Xplore’. Accessed: Aug. 02, 2026. [Online]. Available:
<https://ieeexplore.ieee.org/document/9010425>
- M. Litrico, A. Del Bue, and P. Morerio, ‘Guiding Pseudo-labels with Uncertainty [22]
Estimation for Source-free Unsupervised Domain Adaptation’, in *2023 IEEE/CVF
Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2023, pp.
7640–7650. doi: 10.1109/CVPR52729.2023.00738.
- Q. Wang, O. Fink, L. Van Gool, and D. Dai, ‘Continual Test-Time Domain [23]
Adaptation’, in *2022 IEEE/CVF Conference on Computer Vision and Pattern
Recognition (CVPR)*, Jun. 2022, pp. 7191–7201. doi:
10.1109/CVPR52688.2022.00706.

- Z. Huang, S. Dong, Z. Wang, and X. Wang, ‘Model adaptation: Unsupervised domain adaptation without source data’, in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2021, pp. 15637–15646. [24]
- J. Tian, J. Zhang, W. Li, and D. Xu, ‘VDM-DA: Virtual Domain Modeling for Source Data-Free Domain Adaptation’, *IEEE Trans. Circuits Syst. Video Technol.*, vol. 32, no. 6, pp. 3749–3760, Jun. 2022, doi: 10.1109/TCSVT.2021.3111034. [25]
- H. Zhang, M. Cisse, Y. N. Dauphin, and D. Lopez-Paz, ‘mixup: Beyond Empirical Risk Minimization’, Apr. 27, 2018, *arXiv*: arXiv:1710.09412. doi: 10.48550/arXiv.1710.09412. [26]
- H. Xia, H. Zhao, and Z. Ding, ‘Adaptive Adversarial Network for Source-Free Domain Adaptation’, presented at the Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021, pp. 9010–9019. Accessed: Nov. 08, 2025. [Online]. Available: https://openaccess.thecvf.com/content/ICCV2021/html/Xia_Adaptive_Adversarial_Network_for_Source-Free_Domain_Adaptation_ICCV_2021_paper.html [27]
- S. Yang, Y. Wang, L. Herranz, S. Jui, and J. van de Weijer, ‘Casting a BAIT for offline and online source-free domain adaptation’, *Comput. Vis. Image Underst.*, vol. 234, p. 103747, Sep. 2023, doi: 10.1016/j.cviu.2023.103747. [28]
- L. Xiong, M. Ye, D. Zhang, Y. Gan, X. Li, and Y. Zhu, ‘Source data-free domain adaptation of object detector through domain-specific perturbation’, *Int. J. Intell. Syst.*, vol. 36, no. 8, pp. 3746–3766, 2021, doi: 10.1002/int.22434. [29]
- S. Yang, Y. Wang, J. van de Weijer, L. Herranz, and S. Jui, ‘Exploiting the intrinsic neighborhood structure for source-free domain adaptation’, in *Proceedings of the 35th International Conference on Neural Information Processing Systems*, in NIPS ’21. Red Hook, NY, USA: Curran Associates Inc., Dec. 2021, pp. 29393–29405. [30]
- Y. Hou and L. Zheng, ‘Source Free Domain Adaptation with Image Translation’, May 16, 2021, *arXiv*: arXiv:2008.07514. doi: 10.48550/arXiv.2008.07514. [31]
- Y. Zhao, Z. Zhong, Z. Luo, G. H. Lee, and N. Sebe, ‘Source-Free Open Compound Domain Adaptation in Semantic Segmentation’, Jun. 07, 2021, *arXiv*: arXiv:2106.03422. doi: 10.48550/arXiv.2106.03422. [32]
- M. Caron, P. Bojanowski, A. Joulin, and M. Douze, ‘Deep Clustering for Unsupervised Learning of Visual Features’, in *Computer Vision – ECCV 2018: 15th European Conference, Munich, Germany, September 8–14, 2018, Proceedings, Part XIV*, Berlin, Heidelberg: Springer-Verlag, Sep. 2018, pp. 139–156. doi: 10.1007/978-3-030-01264-9_9. [33]
- A. Tarvainen and H. Valpola, ‘Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results’, in *Proceedings of the 31st International Conference on Neural Information Processing Systems*, in NIPS’17. Red Hook, NY, USA: Curran Associates Inc., Dec. 2017, pp. 1195–1204. Accessed: Aug. 04, 2026. [Online]. Available: <https://dl.acm.org/doi/10.5555/3294771.3294885> [34]

- [35] ‘MixMatch | Proceedings of the 33rd International Conference on Neural Information Processing Systems’. Accessed: Aug. 04, 2026. [Online]. Available: <https://dl.acm.org/doi/10.5555/3454287.3454741>
- [36] ‘Semi-supervised learning by entropy minimization | Proceedings of the 18th International Conference on Neural Information Processing Systems’. Accessed: Aug. 04, 2026. [Online]. Available: <https://dl.acm.org/doi/10.5555/2976040.2976107>
- [37] ‘Test-time training with self-supervision for generalization under distribution shifts | Proceedings of the 37th International Conference on Machine Learning’. Accessed: Aug. 05, 2026. [Online]. Available: <https://dl.acm.org/doi/10.5555/3524938.3525794>
- [38] ‘Universal Source-Free Domain Adaptation | IEEE Conference Publication | IEEE Xplore’. Accessed: Aug. 05, 2026. [Online]. Available: <https://ieeexplore.ieee.org/document/9157725>
- [39] Z. Nado, S. Padhy, D. Sculley, A. D’Amour, B. Lakshminarayanan, and J. Snoek, ‘Evaluating Prediction-Time Batch Normalization for Robustness under Covariate Shift’, Jan. 14, 2021, *arXiv*: arXiv:2006.10963. doi: 10.48550/arXiv.2006.10963.
- [40] M. Zhang, S. Levine, and C. Finn, ‘MEMO: test time robustness via adaptation and augmentation’, in *Proceedings of the 36th International Conference on Neural Information Processing Systems*, in NIPS ’22. Red Hook, NY, USA: Curran Associates Inc., Nov. 2022, pp. 38629–38642.
- [41] N. Karani, E. Erdil, K. Chaitanya, and E. Konukoglu, ‘Test-time adaptable neural networks for robust medical image segmentation’, *Med. Image Anal.*, vol. 68, p. 101907, Feb. 2021, doi: 10.1016/j.media.2020.101907.
- [42] S. Niu *et al.*, ‘Efficient Test-Time Model Adaptation without Forgetting’, in *Proceedings of the 39th International Conference on Machine Learning*, PMLR, Jun. 2022, pp. 16888–16905. Accessed: Aug. 05, 2026. [Online]. Available: <https://proceedings.mlr.press/v162/niu22a.html>
- [43] W. Chen, L. Lin, S. Yang, D. Xie, S. Pu, and Y. Zhuang, ‘Self-Supervised Noisy Label Learning for Source-Free Unsupervised Domain Adaptation’, in *2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Oct. 2022, pp. 10185–10192. doi: 10.1109/IROS47612.2022.9981099.
- [44] J. Liang, D. Hu, Y. Wang, R. He, and J. Feng, ‘Source Data-absent Unsupervised Domain Adaptation through Hypothesis Transfer and Labeling Transfer’, Dec. 05, 2021, *arXiv*: arXiv:2012.07297. doi: 10.48550/arXiv.2012.07297.
- [45] D. Brahma and P. Rai, ‘A Probabilistic Framework for Lifelong Test-Time Adaptation’, Apr. 04, 2023, *arXiv*: arXiv:2212.09713. doi: 10.48550/arXiv.2212.09713.
- [46] J. Song, J. Lee, I. S. Kweon, and S. Choi, ‘EcoTTA: Memory-Efficient Continual Test-Time Adaptation via Self-Distilled Regularization’, presented at the 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), IEEE Computer Society, Jun. 2023, pp. 11920–11929. doi: 10.1109/CVPR52729.2023.01147.

- P. Yang, J. Liang, J. Cao, and R. He, ‘AUTO: Adaptive Outlier Optimization for Test-Time OOD Detection’, May 17, 2025, *arXiv*: arXiv:2303.12267. doi: 10.48550/arXiv.2303.12267. [47]
- ‘Decorate the newcomers | Proceedings of the Thirty-Seventh AAAI Conference on Artificial Intelligence and Thirty-Fifth Conference on Innovative Applications of Artificial Intelligence and Thirteenth Symposium on Educational Advances in Artificial Intelligence’. Accessed: Aug. 06, 2026. [Online]. Available: <https://dl.acm.org/doi/10.1609/aaai.v37i6.25922> [48]
- S. Sanyal, A. R. Asokan, S. Bhambri, A. Kulkarni, J. N. Kundu, and R. V. Babu, ‘Domain-Specificity Inducing Transformers for Source-Free Domain Adaptation’, Aug. 27, 2023, *arXiv*: arXiv:2308.14023. doi: 10.48550/arXiv.2308.14023. [49]
- ‘Robustifying Vision Transformer Without Retraining from Scratch Using Attention-Based Test-Time Adaptation | New Generation Computing | Springer Nature Link’. Accessed: Aug. 06, 2026. [Online]. Available: <https://link.springer.com/article/10.1007/s00354-022-00197-9> [50]
- X. Zhu, W. Su, L. Lu, B. Li, X. Wang, and J. Dai, ‘Deformable DETR: Deformable Transformers for End-to-End Object Detection’, Mar. 18, 2021, *arXiv*: arXiv:2010.04159. doi: 10.48550/arXiv.2010.04159. [51]
- K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick, ‘Masked Autoencoders Are Scalable Vision Learners’, in *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2022, pp. 15979–15988. doi: 10.1109/CVPR52688.2022.01553. [52]
- L. Hoyer, D. Dai, H. Wang, and L. Van Gool, ‘MIC: Masked Image Consistency for Context-Enhanced Domain Adaptation’, in *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2023, pp. 11721–11732. doi: 10.1109/CVPR52729.2023.01128. [53]
- Y. Chen, W. Li, C. Sakaridis, D. Dai, and L. V. Gool, ‘Domain Adaptive Faster R-CNN for Object Detection in the Wild’, Mar. 08, 2018, *arXiv*: arXiv:1803.03243. doi: 10.48550/arXiv.1803.03243. [54]
- J. Deng, W. Li, Y. Chen, and L. Duan, ‘Unbiased Mean Teacher for Cross-domain Object Detection’, in *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2021, pp. 4089–4099. doi: 10.1109/CVPR46437.2021.00408. [55]
- Q. Cai, Y. Pan, C.-W. Ngo, X. Tian, L. Duan, and T. Yao, ‘Exploring Object Relation in Mean Teacher for Cross-Domain Detection’, in *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2019, pp. 11449–11458. doi: 10.1109/CVPR.2019.01172. [56]
- W. M. Kouw and M. Loog, ‘A Review of Domain Adaptation without Target Labels’, *IEEE Trans. Pattern Anal. Mach. Intell.*, vol. 43, no. 3, pp. 766–785, Mar. 2021, doi: 10.1109/TPAMI.2019.2945942. [57]

واژه‌نامه انگلیسی به فارسی

معادل فارسی	واژه انگلیسی
متخلخل	À trous (آتخو-واژه فرانسوی)
تحلیل تصاویر هوایی	Aerial Imagery Analysis
حاشیه‌نگاری	Annotation
تجمعی	Associative
مکانیزم توجه	Attention Mechanism
افزایش	Augmentation
هدایت خودکار	Autonomous Driving
نرمال‌سازی دسته	Batch Normalization
اندازه دسته	Batch Size
درون‌یابی دوخطی	Bilinear Interpolation
نمونه‌افزایی دوخطی	Bilinear Upsampling
گلوگاه	Bottleneck
چارچوب محیطی	Bounding Box
دسته	Category
کانال	Channel
اثر شطرنجی شدن	Checkerboard Artifact
رده	Class
کلیک	Clique
بینایی ماشین	Computer Vision
الحاق	Concatenate
میدان تصادفی زنجیره‌ای	Conditional Random Field
بازیابی تصویر محتوی‌محور	Content-Based Image Retrieval

Convolutional	کانولوشنی
Crop	برش
Dataset	دادگان
Deconvolution	کانولوشن معکوس
Depthwise Seperable Convolution	کانولوشن جداشونده عمقی
Dilated	متسع
Dilation	ضخیم کردن
Dilation Rate	نرخ اتساع
Discrete	گسسته
Discriminative	متمایز کننده
Down Sampling	نمونه برداری
Exploding	انفجار
Feature Encoder	رمزنگار ویژگی
Feature Extraction	استخراج ویژگی
Feature Map	نگاشت ویژگی
Feed Foreward	پیش خور
Field of View	میدان دید
Filter	فیلتر
Fine-Tune	تنظیم دقیق
Fractionally Strided Convolution	کانولوشن با گام کسری
Freeze	تثبیت
Fully Convolutional Network	شبکه تماما کانولوشن
Global Pooling	ادغام سراسری
Gradient	گرادیان

Higher Order	مرتبه بالاتر
Horizontal Flip	برگردان افقی
Human Intervention	مداخله انسانی
Image Classification	رده‌بندی تصویر
Image Classification & Localization	رده‌بندی تصویر به همراه مکان‌یابی
Image Recognition	بازشناسی تصویر
Image Segmentation	تقطیع تصویر
Image Segmentation	تقطیع تصویر
Instance-Aware Semantic Segmentation	تقطیع معنایی با در نظر گرفتن نمونه‌های مختلف
Inter-Class	میان‌رده‌ای
Interpolation	درون‌یابی
Intersection Over Union	اشتراک بر اجتماع
Kernel	هسته
Layer	لایه
Likelihood Function	تابع درست‌نمایی
Low Latency	کم‌تاخیر
Markov Random Field	میدان تصادفی مارکوف
Maximum a Posteriori	بیشینه‌کردن احتمال پسین
Mean Accuracy	دقت میانگین
Mean Intersection Over Union	میانگین اشتراک بر اجتماع

Lib No.: MUT

Degree: M.Sc.

Title: Improving Real-Time Semantic Segmentation of Urban Image using Deep Neural Networks

Author: Ali Masoudi Qaziar

Supervisors: Dr. Mohammad Ali Keyvanrad, Dr. Mohammad Fakhredanesh

Advisor: Dr. Mahdi Amiri

Department: Electrical and Computer

Date: Feb. 2020

Abstract:

Over the past decades and with the advancement of technology, the field of automatic interpretation of images for a wide variety of applications, including automated guidance, mapping and medical diagnosis. One of the most important of these interpretations is the precise segmentation of the objects within the image, taking into account their concept, which is called semantic segmentation. Semantic segmentation is one of the most important issues in machine vision.

....

Keywords: Semantic segmentation, Convolutional neural network, Machine vision, Urban images, ICNet

In the name of God



*Malek Ashtar University
of Technology*

Malek-ashtar University of Technology

Faculty of Electrical and Computer

M.Sc. Thesis

Title

**Domain adaptation in the deep neural network
for object detection utilizing artificial training
data for test time domain adaptation**

By

Ali Masoudi Qaziar

Supervised by

Dr. Mohammad Ali Keyvanrad

July. 2026