



بسمه تعالی
دانشگاه صنعتی مالک اشتر
معاونت آموزش و تحصیلات تکمیلی

پیشنهاد پایان نامه مقطع کارشناسی ارشد

کمیته محترم تحصیلات تکمیلی مجتمع دانشگاهی برق و کامپیوتر

احتراماً، اینجانب **امیررضا کاظم لو** به شماره دانشجویی **۴۰۳۱۴۱۹۰۱۳** دانشجوی کارشناسی ارشد رشته مهندسی کامپیوتر گرایش **هوش مصنوعی و رباتیک** شاغل در - که تحصیلات خود را در رشته فوق از نیمسال اول سال تحصیلی **۱۴۰۳** شروع نمودم و تاکنون تعداد **۲۶** واحد از دروس اصلی و اختصاصی را با موفقیت و با معدل کل **۱۹.۴۶** گذرانده‌ام در مرحله شروع پایان نامه خود هستم.

پس از انجام مشاوره‌های لازم و با عنایت به زمینه علمی مورد نیاز، **آقای دکتر محمدعلی کیوان راد** را بعنوان استاد راهنمای پایان نامه انتخاب کردم و با استفاده از نظرات و راهنمایی‌های ایشان پس از بررسی و مطالعه دقیق موضوع تحقیق، موضوع پایان نامه خود را کتباً و در قالب فرم پیوست تقدیم می‌نمایم. بدیهی است پذیرش قطعی موضوع پایان نامه منوط بر تصویب آن در کمیته می‌باشد. ضمناً با پیشنهاد استاد راهنمای پایان نامه آقای - را نیز بعنوان استاد مشاور انتخاب نموده‌ام.

امضاء دانشجو تاریخ: ۱۴۰۵/۰۶/۲۰

عنوان کامل پایان نامه: انطباق آنلاین در زمان آزمون برای تشخیص اشیا با تأکید ویژه بر سناریوی انطباق پیوسته.

نوع پروژه:

بدون طبقه‌بندی	محرمانه	خیلی محرمانه	سری	بکلی سری
----------------	---------	--------------	-----	----------

مراتب فوق مورد تأیید است:

- | | |
|--|---------------|
| ۱- نام و نام خانوادگی استاد راهنما | تاریخ و امضاء |
| دکتر محمد علی کیوان راد | |
| ۲- نام و نام خانوادگی استاد مشاور | تاریخ و امضاء |
| ۳- نام و نام خانوادگی کارشناس آموزش و تحصیلات تکمیلی مجتمع | تاریخ و امضاء |
| ۴- نام و نام خانوادگی مدیریت آموزش و تحصیلات تکمیلی مجتمع | تاریخ و امضاء |

* کلیه صفحات به صورت تایپ شده تحویل شوند.



دانشگاه صنعتی مالک اشتر

پرسشنامه تهیه پیشنهاد اولیه (پروپوزال) جهت پایان نامه کارشناسی ارشد

نام و نام خانوادگی دانشجو: امیررضا کاظم لو

شماره دانشجویی: ۴۰۳۱۴۱۹۰۱۳

رشته و گرایش تحصیلی: مهندسی کامپیوتر - گرایش هوش مصنوعی و رباتیک

عنوان پایان نامه:

به فارسی: تطبیق برخط دامنه در زمان آزمون برای تشخیص اشیا با تمرکز بر انتقال از داده‌های مصنوعی به واقعی

به لاتین: Online Test-Time Domain Adaptation for Object Detection

نوع تحقیق:

بنیادی ☐ توسعه‌ای ☐ کاربردی ☐

۱ - اطلاعات مربوط به دانشجو:

۱-۱- تعداد واحدهای گذرانده: ۲۶ تعداد واحدهای باقیمانده: ۶ معدل (تاکنون): ۱۹.۴۶

۱-۲- آدرس: تهران، شهرک ولی عصر خیابان آقابابایان، کوچه گلنار، پلاک ۲۳، طبقه اول

۱-۲-۱- شماره تلفن ثابت: ۰۲۱۶۶۱۳۳۵۷۱

۱-۲-۲- شماره تلفن همراه: ۰۹۱۰۱۷۲۷۲۳۴

۱-۳- در صورت بورسیه بودن، نام سازمان بورسیه دهنده:

۲ - اطلاعات مربوط به اساتید راهنما و مشاور:

سمت	نام و نام خانوادگی	تخصص یا رشته	رتبه علمی	تعداد پایان‌نامه‌های راهنمایی شده		تعداد پایان‌نامه‌های تحت راهنمایی	
				ارشد	دکتری	ارشد	دکتری
استاد راهنمای اول	محمد علی کیوان راد	مهندسی کامپیوتر - هوش مصنوعی	استادیار				
استاد راهنمای دوم							
استاد مشاور							

* تذکر: در صورتی که اساتید فوق عضو هیأت علمی دانشگاه صنعتی مالک اشتر نمی‌باشند؛ آدرس و شماره تلفن آن‌ها ذیلأ قید شود.

آدرس استاد (اساتید) راهنما:

شماره تلفن استاد (اساتید) راهنما:

آدرس استاد مشاور:

شماره تلفن استاد مشاور:

* کلیه صفحات به صورت تایپ شده تحویل شوند.

۳ - اطلاعات مربوط به پایان‌نامه:

۳-۱ - مسئله و اهداف اصلی تحقیق :

مسئله تحقیق

مدل‌های یادگیری عمیق در سال‌های اخیر به عملکرد قابل توجهی در وظایف مختلف بینایی ماشین، از جمله تشخیص اشیاء، دست یافته‌اند. با این حال، بخش مهمی از این موفقیت بر این فرض استوار است که داده‌های مورد استفاده در مرحله آموزش و داده‌هایی که مدل در زمان استقرار با آن‌ها مواجه می‌شود، از توزیع‌های یکسان یا دست‌کم مشابه پیروی می‌کنند. در کاربردهای واقعی، این فرض غالباً برقرار نیست؛ زیرا عواملی مانند تغییر شرایط روشنایی و آب‌وهوا، تغییر نوع و مشخصات حسگر، تغییر زاویه دید، تفاوت محیط جغرافیایی، تغییر پس‌زمینه و سایر تغییرات عملیاتی می‌توانند توزیع داده‌های ورودی را نسبت به داده‌های آموزشی تغییر دهند. در نتیجه، مدلی که در دامنه مبدأ عملکرد مناسبی داشته است، ممکن است هنگام استقرار در یک دامنه جدید با کاهش قابل توجه دقت مواجه شود؛ مسئله‌ای که در ادبیات یادگیری ماشین تحت عنوان «تغییر توزیع» و در مسائل انتقال میان دامنه‌ها به صورت «شکاف دامنه» مطرح می‌شود. همین زنجیره مفهومی از تغییر توزیع تا شکاف دامنه و انطباق در نسخه فعلی پیشنهادیه پایان نامه نیز به عنوان مبنای مسئله پژوهش در نظر گرفته شده است.

یکی از راهکارهای مناسب برای کاهش هزینه تهیه داده آموزشی، به‌ویژه در مسائلی که جمع‌آوری و برچسب‌گذاری داده واقعی پرهزینه، زمان‌بر یا محدود است، استفاده از داده‌های مصنوعی است. محیط‌های شبیه‌سازی شده امکان تولید حجم بالایی از داده همراه با برچسب‌های دقیق را فراهم می‌کنند و در نتیجه می‌توانند هزینه آموزش اولیه مدل‌های پیچیده را به میزان قابل توجهی کاهش دهند. پژوهش‌های جدید نیز استفاده از داده‌های مصنوعی و انتقال دانش از شبیه‌سازی به داده‌های واقعی را به عنوان یک مسیر عملی برای توسعه سامانه‌های بینایی ماشین بررسی کرده‌اند [۱]. با این حال، تفاوت میان فرآیند تولید تصاویر مصنوعی و شرایط تصویربرداری واقعی موجب ایجاد شکاف «مصنوعی به واقعی» می‌شود و بنابراین مدلی که صرفاً روی داده مصنوعی آموزش یافته است، الزاماً همان سطح عملکرد را روی داده واقعی حفظ نمی‌کند. بنابراین استفاده از داده مصنوعی به دلیل هزینه پایین و مقیاس‌پذیری مناسب می‌باشد و افت عملکرد مدل در محیط واقعی به علت تغییر توزیع، انگیزه اصلی انطباق می‌باشد.

رویکردهای متداول انطباق دامنه بدون نظارت می‌توانند با استفاده از داده‌های بدون برچسب دامنه هدف، بخشی از این شکاف را کاهش دهند؛ با این حال، در تنظیم کلاسیک این روش‌ها معمولاً فرض می‌شود که داده‌های برچسب‌دار مبدأ و داده‌های بدون برچسب هدف در فرآیند انطباق در دسترس هستند. چنین فرضی برای بسیاری از کاربردهای واقعی محدودکننده است. نگهداری یا انتقال مجموعه داده‌های حجیم مبدأ می‌تواند هزینه ذخیره‌سازی و ارتباطی بالایی داشته باشد و در برخی کاربردها نیز ملاحظات حرمانگی، مالکیت داده یا حریم خصوصی مانع از دسترسی به داده‌های اصلی آموزش در محل استقرار مدل می‌شود. این محدودیت یکی از دلایل گذار از انطباق دامنه کلاسیک به تنظیم‌های بدون منبع و زمان آزمون می‌باشد [۲].

پارادایم «انطباق در زمان آزمون»^۱ یا «TTA» برای کاهش این محدودیت مطرح شده است. در تنظیم کامل انطباق در زمان آزمون، مدل در مرحله استنتاج با اتکا به پارامترهای مدل از پیش آموزش‌دیده و داده‌های بدون برچسب آزمون خود را با توزیع جدید سازگار می‌کند و به داده‌های آموزشی اولیه دسترسی ندارد. روش‌هایی مانند کمینه‌سازی آنتروپی پیش‌بینی و به‌روزرسانی محدود پارامترهای نرمال‌سازی، مدل را نسبت به تغییرات توزیع سازگار کرد بنابراین TTA از منظر عملی، امکان نزدیک‌تر کردن فرآیند انطباق به شرایط واقعی استقرار را فراهم می‌کند. با این حال، یک محدودیت مهم همچنان باقی می‌ماند. بسیاری از سناریوهای اولیه انطباق دامنه یا انطباق در زمان آزمون، یک دامنه هدف نسبتاً ثابت یا امکان دسترسی مناسب به داده‌های هدف را در نظر می‌گیرند؛ در حالی که یک سامانه بینایی ماشین واقعی ممکن است به‌طور مستمر در محیطی غیرایستا فعالیت کند. برای مثال، یک سامانه تشخیص اشیاء در خودرو، ربات متحرک یا سامانه نظارت تصویری ممکن است طی زمان از محیط روشن به تاریک، از هوای صاف به مه‌آلود، از یک دوربین به دوربین دیگر یا از یک محیط جغرافیایی به محیطی کاملاً متفاوت منتقل شود. در چنین شرایطی، داده‌ها به صورت جریانی و متوالی وارد سامانه می‌شوند و مدل باید هم‌زمان با استنتاج، خود را با تغییرات جدید سازگار کند. به این معنا که دسته‌های کوچک داده به‌صورت متوالی مشاهده می‌شوند و هر دسته ممکن است فقط یک مرتبه در اختیار مدل قرار گیرد. این تنظیم در ادبیات جدید عمدتاً در قالب «انطباق پیوسته در زمان آزمون» و در برخی آثار در قالب انطباق آنلاین مطالعه می‌شود. روش «CoTTA» نشان داد که در محیط‌های غیرایستا و دارای تغییرات متوالی توزیع، اتکای ساده به خودآموزی یا کمینه‌سازی آنتروپی می‌تواند ناپایدار باشد؛ زیرا با تغییر دامنه، کیفیت شبه‌برچسب‌ها کاهش یافته و استفاده مجدد از پیش‌بینی‌های نادرست می‌تواند به انباشت خطا و در نهایت فراموشی فاجعه بار دانش قبلی منجر شود [۳]. این دو مسئله، یعنی «انباشت خطا» و «فراموشی فاجعه‌بار»، دو چالش محوری انطباق آنلاین در زمان آزمون در می‌باشند.

Commented [ak1]: این مقاله برای توجیه استفاده از داده مصنوعی و مسئله انتقال مصنوعی به واقعی مناسب است.

Commented [ak2]: دلیل اضافه کردن مرتبط بودن این بخش به source free domain adaptation

Commented [ak3]: این مقاله یکی از منابع پایه برای تعریف Fully Test-Time Adaptation است.

Commented [ak4]: این مقاله برای تعریف محیط غیرایستا، انباشت خطا و فراموشی فاجعه‌بار بسیار مهم است

¹ Test time domain adaptation

Commented [ak5]: این مقاله مستقیماً مسئله TTA برای تشخیص اشیا و عدم اطمینان شبه‌برچسب‌ها را بررسی می‌کند.

Commented [ak6]: برای مسئله کیفیت شبه‌برچسب در تشخیص اشیا و چارچوب معلم - دانش‌آموز منبع مناسبی است.

Commented [ak7]: برای مسئله کارایی و منظم‌سازی ضدفراموشی اضافه کردم.
این پیپر جا داره بیشتر بخونمش:
<https://chatgpt.com/share/6aa5c62b-e5e0-42eb-9afa-d24f7b7a7a2f>

Commented [ak8]: این مقاله برای نشان‌دادن وضعیت جدیدتر حوزه و اهمیت هم‌زمان دقت و کارایی در CTTA - OD بسیار مناسب است.

Commented [ak9]: این مقاله یکی از مهم‌ترین منابع مستقیم برای موضوع پایان‌نامه است؛ زیرا به انطباق آنلاین آشکارساز اشیا در دامنه‌های متغیر، جلوگیری از فراموشی و حفظ سرعت عملیاتی می‌پردازد.

Commented [ak10]: ارتباط مستقیم با انطباق آنلاین تشخیص اشیا و آزمایش انتقال «Sim۱۰K→Cityscapes» اهمیت دارد.

این مسئله در تشخیص اشیا دشوارتر از بسیاری از مسائل طبقه‌بندی تصویر است. در طبقه‌بندی، مدل عمدتاً یک برچسب یا توزیع احتمال کلاس را برای کل تصویر پیش‌بینی می‌کند؛ اما آشکارساز اشیا علاوه بر تعیین کلاس هر شیء، باید موقعیت و ابعاد آن را نیز از طریق جعبه محدودکننده برآورد کند. بنابراین خطای شبه‌برچسب در تشخیص اشیا تنها به انتخاب کلاس اشتباه محدود نیست و می‌تواند شامل خطای مکان‌یابی نیز باشد. خطای مکان‌یابی موجب استخراج ویژگی از نواحی نامناسب تصویر و ورود اطلاعات پس‌زمینه به بازنمایی شیء می‌شود؛ از طرف دیگر، خطای دسته‌بندی نیز می‌تواند فرایند یادگیری مکان شیء را مختل کند. همین وابستگی میان خطای طبقه‌بندی و خطای مکان‌یابی سبب می‌شود که استفاده از شبه‌برچسب‌های نویزی در یک چرخه انطباق پیوسته، نسبت به مسئله طبقه‌بندی حساسیت بیشتری داشته باشد.

مطالعات جدید روی انطباق در زمان آزمون برای تشخیص اشیا این مسئله را نیز تأیید می‌کنند که نشان داده‌اند که یکی از چالش‌های اساسی خودآموزی در این تنظیم، غیرقابل اعتماد بودن شبه‌برچسب‌ها تحت شکاف دامنه است و صرف اعتماد به امتیاز اطمینان آشکارساز برای انتخاب شبه‌برچسب‌ها کفایت نمی‌کند [۴]. پیش از آن نیز مطالعات انطباق دامنه برای آشکارسازی نشان داده بودند که کیفیت شبه‌برچسب‌ها یک عامل تعیین‌کننده برای موفقیت چارچوب‌های خودآموزی است [۵].

چالش دیگر، حفظ دانش مدل در طول انطباق است. اگر پارامترهای مدل صرفاً بر اساس داده‌های ورودی جاری و بدون هیچ سازوکار کنترلی به‌روزرسانی شوند، مدل ممکن است برای سازگارشدن با دامنه فعلی از بازنمایی‌های عمومی و مفیدی که در مرحله آموزش اولیه آموخته است فاصله بگیرد. در انطباق پیوسته، این مسئله می‌تواند با گذشت زمان تشدید شود و مدل بخشی از توانایی خود را برای عملکرد در شرایط قبلی یا نزدیک به دامنه مبدأ از دست بدهد. روش CoTTA برای مقابله با این مسئله بخشی از پارامترها را به شکل تصادفی به مقادیر مدل مبدأ بازمی‌گرداند [۳] [۶]. در این پروپوزال نیز ایجاد تعادل میان یادگیری سریع اطلاعات دامنه جدید و حفظ دانش پیشین، یکی از مسائل اصلی پژوهش در نظر گرفته شده است.

محدودیت مهم دیگر، هزینه محاسباتی انطباق است. مزیت نظری یک روش انطباق در زمان آزمون زمانی در محیط واقعی قابل استفاده خواهد بود که فرایند انطباق خود موجب کاهش غیرقابل قبول سرعت پردازش نشود. بسیاری از روش‌های موجود بر افزایش دقت تمرکز دارند، در حالی که کارایی محاسباتی برای کاربردهای دارای محدودیت منابع یک مسئله اساسی است [۷]. این مسئله در تشخیص اشیا اهمیت بیشتری دارد؛ زیرا خود آشکارسازی اشیا از نظر محاسباتی سنگین است و انجام چندین مرحله به‌روزرسانی برای هر فریم یا دسته داده می‌تواند کاربرد روش را در سامانه‌های برخط محدود کند. راه حل‌های مطرح شده شامل انطباق سبک و انتخابی می‌باشد [۸]. این درحالی است که سازگارسازی آف‌لاین با یک دامنه هدف ثابت برای محیط‌هایی که مدل به‌طور مداوم با تغییرات جدید مواجه می‌شود، کافی نیست و در اغلب سناریو‌ها محیط هدف پیوسته در حال تغییر است [۹].

بر این اساس، مسئله اصلی این پژوهش را می‌توان چنین صورت‌بندی کرد: چگونه می‌توان یک مدل تشخیص اشیا را که پیش‌تر، به‌طور کامل یا عمدتاً، با داده‌های دامنه مبدأ و به‌ویژه داده‌های مصنوعی آموزش دیده است، در هنگام استقرار و تنها با استفاده از جریان داده‌های بدون برچسب دامنه هدف، بدون دسترسی به داده‌های آموزشی مبدأ، به‌صورت برخط با تغییرات توزیع سازگار کرد؛ به‌گونه‌ای که هم‌زمان کیفیت پیش‌بینی‌های طبقه‌بندی و مکان‌یابی حفظ یا بهبود یابد، اثر شبه‌برچسب‌های نادرست و انباشت خطا کنترل شود، از فراموشی فاجعه‌بار دانش پیشین جلوگیری گردد و هزینه محاسباتی فرایند انطباق با محدودیت‌های یک سامانه عملیاتی سازگار باشد؟

بنابراین، مسئله پژوهش حاضر صرفاً «افزایش دقت یک مدل در یک مجموعه داده هدف ثابت» نیست؛ بلکه طراحی و ارزیابی یک سازوکار انطباق در زمان آزمون برای یک آشکارساز مستقرشده در محیط پویا است که باید میان چهار نیاز گاه متعارض تعادل برقرار کند: «یادگیری سریع اطلاعات دامنه جدید»، «قابلیت اعتماد سیگنال خودنظارتی و شبه‌برچسب‌ها»، «حفظ دانش عمومی و جلوگیری از فراموشی» و «کارایی محاسباتی در انطباق برخط». که جهت اصلی هسته این پژوهش یعنی انطباق آنلاین، داده‌های جریانی، انباشت خطا و فراموشی فاجعه‌بار می‌باشد.

اهداف اصلی تحقیق

هدف اصلی

هدف اصلی این پژوهش، طراحی، پیاده‌سازی و ارزیابی یک چارچوب کارآمد برای انطباق آنلاین در زمان آزمون مدل‌های تشخیص اشیا، با تمرکز بر سناریوی انتقال از داده‌های مصنوعی به داده‌های واقعی است؛ به‌گونه‌ای که مدل از پیش آموزش‌دیده بتواند در زمان استنتاج و بدون دسترسی به داده‌های آموزشی مبدأ یا برچسب‌های دامنه هدف، خود را با تغییرات متوالی توزیع داده سازگار کند و در عین حال، اثر خطاهای ناشی از شبه‌برچسب‌های نامطمئن و فراموشی فاجعه‌بار دانش پیشین را کنترل کرده، انطباق سریع برای دسته‌هایی که فقط یک‌بار مشاهده می‌شوند را فراهم کرده و هزینه محاسباتی انطباق را در سطح قابل قبول برای کاربردهای برخط حفظ نماید.

اهداف فرعی

۱. صورت‌بندی دقیق سناریوی انطباق آنلاین در زمان آزمون برای تشخیص اشیا

تعریف یک چارچوب روشن برای مسئله‌ای که در آن مدل آشکارساز از پیش آموزش‌دیده در اختیار است، داده‌های مبدأ در زمان انطباق قابل دسترسی نیستند، داده‌های هدف فاقد برچسب‌اند، نمونه‌ها یا دسته‌های کوچک به‌صورت جریانی وارد مدل می‌شوند و امکان مشاهده مکرر کل مجموعه داده هدف وجود ندارد. این صورت‌بندی، تفاوت پژوهش حاضر با انطباق دامنه کلاسیک، انطباق بدون منبع آفلاین و انطباق روی یک مجموعه هدف ثابت می‌باشد.

۲. توسعه سازوکاری برای استخراج سیگنال نظارتی قابل اعتماد از داده‌های بدون برچسب هدف

از آنجا که در زمان آزمون برچسب واقعی داده‌های ورودی در دسترس نیست، مدل باید سیگنال لازم برای انطباق را از پیش‌بینی‌های خود یا سایر روابط خودنظارتی استخراج کند. بنابراین یکی از اهداف اصلی، کاهش اثر شبه‌برچسب‌های نامطمئن و جلوگیری از ورود پیش‌بینی‌های نادرست به چرخه به‌روزرسانی مدل است. در تشخیص اشیا این مسئله باید هم کیفیت برچسب طبقه‌بندی و هم کیفیت جعبه‌های محدودکننده را در نظر بگیرد؛ زیرا پژوهش‌های جدید نشان داده‌اند که اعتماد صرف به امتیاز طبقه‌بندی نمی‌تواند لزوماً کیفیت شبه‌جعبه را تضمین کند [۴]. این هدف جزو اهداف مهم این پژوهش یعنی کاهش هم‌زمان خطای مکان‌یابی و طبقه‌بندی شبه‌برچسب‌ها می‌باشد.

۳. کاهش انباشت خطا در فرایند انطباق پیوسته

هدف دیگر پژوهش، جلوگیری از شکل‌گیری چرخه‌ای است که در آن یک پیش‌بینی نادرست به‌عنوان سیگنال آموزشی مورد استفاده قرار گرفته، موجب تغییر اشتباه پارامترهای مدل شود و در نمونه‌های بعدی احتمال تولید شبه‌برچسب‌های نادرست را افزایش دهد. این مسئله به‌ویژه در شرایطی که توزیع هدف به صورت پیوسته تغییر می‌کند اهمیت دارد؛ همان‌گونه که CoTTA نیز کاهش قابلیت اعتماد شبه‌برچسب تحت تغییر پیوسته توزیع و تبدیل آن به انباشت خطا را یکی از مسائل بنیادی CTTA معرفی می‌کند [۳].

۴. توسعه سازوکاری برای کاهش فراموشی فاجعه‌بار و حفظ دانش مدل مبدأ

فرایند انطباق نباید باعث شود که مدل برای سازگاری با آخرین دامنه مشاهده‌شده، دانش عمومی و بازنمایی‌های مفید خود را از دست بدهد. از این‌رو، پژوهش حاضر به دنبال ایجاد تعادل میان «انعطاف‌پذیری» برای یادگیری تغییرات جدید و «پایداری» برای حفظ دانش پیشین خواهد بود. این هدف می‌تواند از طریق منظم‌سازی پارامترها، تثبیت بخشی از مدل، استفاده از نسخه مرجع مدل، بازیابی یا حفظ دانش قبلی یا سایر راهبردهای ضدفراموشی محقق شود؛ بدون آنکه در این مرحله از پروپوزال، پژوهش به یک سازوکار خاص محدود شود. اهمیت این مسئله هم در CoTTA و هم در EATA به‌صورت مستقیم نشان داده شده است [۶]، [۳].

۵. فراهم کردن انطباق سریع و محاسباتی کارآمد برای داده‌های جریانی

هدف پژوهش تنها بهبود دقت نهایی نیست؛ بلکه سازوکار انطباق باید بتواند تحت محدودیت‌های زمان و منابع نیز اجرا شود. به همین دلیل، کاهش تعداد پارامترهای به‌روزرسانی‌شونده، تعداد مراحل بهینه‌سازی، تعداد نمونه‌های نیازمند پس‌انتشار یا سایر هزینه‌های محاسباتی، در کنار دقت مدل بررسی خواهد شد. اهمیت این موضوع در پژوهش‌های جدید انطباق آشکارسازها در زمان آزمون به‌طور مشخص مورد تأکید قرار گرفته است؛ به‌ویژه مطالعات CVPR سال ۲۰۲۴ و CVPR سال ۲۰۲۵ نشان می‌دهند که «زمان و محل به‌روزرسانی» و «هزینه محاسباتی» از مسائل مستقل و اصلی CTTA برای تشخیص اشیا هستند [۸]، [۷].

۶. بررسی اثربخشی روش در سناریوی انتقال از داده‌های مصنوعی به واقعی

با توجه به جهت اصلی این پژوهش، یکی از اهداف مشخص پژوهش آن است که توانایی چارچوب پیشنهادی در کاهش شکاف میان داده‌های مصنوعی مورد استفاده برای آموزش و تصاویر واقعی مشاهده‌شده در زمان استقرار بررسی شود. این هدف علاوه بر اهمیت کاربردی، امکان مقایسه با سناریوهای شناخته‌شده‌ای مانند «Sim۱۰K به Cityscapes» را نیز فراهم می‌کند؛ سناریویی که در ادبیات انطباق آنلاین تشخیص اشیا استفاده شده است [۹].

۷. ارزیابی عملکرد روش در شرایط تغییر متوالی دامنه هدف

برای آنکه پژوهش صرفاً یک روش انطباق آفلاین با نام TTA نباشد، عملکرد مدل باید در یک توالی از شرایط متفاوت بررسی شود. هدف آن است که مشخص گردد آیا روش پیشنهادی نه فقط بلافاصله پس از ورود به یک دامنه جدید، بلکه در طول یک جریان متغیر از دامنه‌ها نیز قادر به حفظ عملکرد پایدار است یا خیر. این ارزیابی با ماهیت اصلی CTTA، یعنی سازگاری یک مدل مبدأ با محیط‌های در حال تغییر طی استنتاج، هم‌خوانی دارد [۸]، [۷]، [۳].

۸. ارزیابی جامع روش با معیارهای دقت، پایداری و کارایی محاسباتی

روش پیشنهادی باید از چند منظر مورد ارزیابی قرار گیرد. نخست، عملکرد تشخیص اشیا با معیارهای استاندارد نظیر «mAP» یا «mean average precision» سنجیده خواهد شد. دوم، رفتار مدل در طول تغییرات متوالی دامنه و میزان افت یا حفظ عملکرد بررسی خواهد شد.

Commented [ak11]: بیشتر بخون راجیش.

سوم، هزینه عملیاتی روش از نظر زمان پردازش و انطباق، تعداد پارامترهای به‌روزرسانی‌شونده، محاسبات مورد نیاز و در صورت لزوم مصرف حافظه ارزیابی خواهد شد. چنین ارزیابی چندبعدی ضروری است؛ زیرا یک روش TTA که افزایش اندکی در دقت ایجاد کند اما هزینه استنتاج را چند برابر نماید، برای کاربرد برخط الزاماً راهکار مناسبی نیست. این مسئله در ادبیات اخیر OD-CTTA نیز صریحاً مورد تأکید قرار گرفته است [۷].

۹. مقایسه روش پیشنهادی با مدل بدون انطباق و روش‌های معتبر انطباق در زمان آزمون

برای تعیین میزان واقعی اثر روش پیشنهادی، نتایج آن باید حداقل با مدل «مبدأ - تنها»، روش‌های پایه عمومی TTA و CTТА و روش‌های جدیدتر ویژه تشخیص اشیاء مقایسه شود. در انتخاب روش‌های مقایسه، علاوه بر روش‌های بنیادی مانند CoTTA، EATA و TENT، روش‌های اختصاصی‌تر تشخیص اشیاء نظیر روش آنالین Yoo و همکاران در و روش‌های OD-CTTA جدیدتر نیز مدنظر قرار خواهند گرفت [۷]، [۶]، [۳]. این مقایسه باید تحت پروتکل آزمایشی یکسان انجام شود تا افزایش عملکرد صرفاً ناشی از تفاوت مدل پایه، تنظیمات یا داده‌ها نباشد. [۸]، [۱۰].

۱۰. انجام مطالعه مؤلفه‌ها برای تعیین سهم هر جزء از روش پیشنهادی

پس از نهایی‌شدن معماری پیشنهادی، اثر هر مؤلفه به‌صورت مستقل از طریق آزمایش‌های حذف یا جایگزینی بررسی خواهد شد (ablation study). این هدف کمک می‌کند مشخص شود که بهبود احتمالی عملکرد ناشی از کدام سازوکار است؛ برای مثال، آیا بهبود از افزایش کیفیت شبه‌برچسب ناشی می‌شود، از راهکار ضدفراموشی، از انتخاب پارامترهای قابل انطباق یا از تعامل میان این بخش‌ها. این نوع مطالعه برای اثبات سهم علمی روش پیشنهادی و تفکیک نوآوری واقعی از اثر تنظیمات آزمایشی ضروری است.

۲-۳ - تشریح و بیان موضوع :

مدل‌های یادگیری عمیق در سال‌های اخیر به بخش جدایی‌ناپذیری از سامانه‌های بنیایی ماشین تبدیل شده‌اند و در وظایفی نظیر دسته‌بندی تصویر، قطعه‌بندی معنایی و تشخیص اشیاء، عملکرد بسیار بالایی از خود نشان داده‌اند. در میان این وظایف، تشخیص اشیاء از اهمیت ویژه‌ای برخوردار است؛ زیرا مدل علاوه بر تشخیص نوع شیء موجود در تصویر، باید موقعیت مکانی و ابعاد آن را نیز به‌صورت دقیق تعیین کند. از این‌رو، آشکارسازهای اشیاء در بسیاری از سامانه‌های عملیاتی نظیر خودروهای خودران، سامانه‌های نظارت تصویری، ربات‌های متحرک، مدیریت هوشمند ترافیک و سامانه‌های پایش محیطی نقش بنیادی دارند.

با وجود پیشرفت قابل توجه معماری‌های یادگیری عمیق، عملکرد بالای این مدل‌ها عموماً بر یک فرض اساسی استوار است: داده‌هایی که مدل در زمان استقرار مشاهده می‌کند، باید از توزیعی مشابه با داده‌های مورد استفاده در مرحله آموزش پیروی کنند. این فرض در محیط‌های کنترل‌شده آزمایشگاهی می‌تواند تا حدی برقرار باشد، اما در کاربردهای واقعی غالباً نقض می‌شود. تغییر شرایط روشنایی، وضعیت آب‌وهوا، نوع دوربین، ویژگی‌های حسگر، زاویه دید، پس‌زمینه، محیط جغرافیایی، کیفیت تصویربرداری و بسیاری از عوامل دیگر می‌توانند موجب تغییر توزیع داده‌های ورودی شوند. در مسئله تشخیص اشیاء، این تغییرات نه تنها بر ویژگی‌های کلی تصویر، بلکه بر ظاهر، اندازه، وضوح و موقعیت نمونه‌های شیء نیز اثر می‌گذارند. پژوهش Domain Adaptive Faster R-CNN نشان داده است که تغییر دامنه در تشخیص اشیاء می‌تواند هم در سطح تصویر، مانند سبک و روشنایی، و هم در سطح نمونه شیء، مانند ظاهر و اندازه اشیاء، رخ دهد [۱۱].

در نتیجه این پدیده، مدلی که روی توزیع مبدأ عملکرد مناسبی دارد، ممکن است پس از استقرار در محیط جدید با کاهش قابل توجه دقت روبه‌رو شود. اختلاف میان توزیع داده‌های آموزش و آزمون معمولاً با مفهوم «تغییر توزیع» و در مسائل انتقال میان دامنه‌ها با مفهوم «شکاف دامنه» بیان می‌شود. این مسئله یکی از موانع اساسی در مسیر استقرار قابل اعتماد سامانه‌های بنیایی ماشین است؛ زیرا در بسیاری از کاربردها نمی‌توان تضمین کرد که شرایط عملیاتی آینده دقیقاً مشابه شرایط موجود هنگام جمع‌آوری داده‌های آموزشی باشد.

یکی از نمونه‌های مهم این مسئله، آموزش مدل با استفاده از داده‌های مصنوعی و استقرار آن روی داده‌های واقعی است. تولید داده مصنوعی به کمک شبیه‌سازها و موتورهای رندر امکان ایجاد حجم زیادی از تصاویر همراه با برچسب‌های دقیق را با هزینه بسیار کمتر نسبت به جمع‌آوری و برچسب زدن داده‌های واقعی فراهم می‌کند. علاوه بر این، در محیط شبیه‌سازی می‌توان عواملی نظیر زاویه دوربین، روشنایی، نوع اشیاء و شرایط محیطی را به‌صورت کنترل‌شده تغییر داد. Tang و Jia نشان داده‌اند که داده‌های مصنوعی می‌توانند برای پیش‌آموزش و انتقال دانش به محیط واقعی مفید باشند و در عین حال، انتقال از شبیه‌سازی به واقعیت همچنان یک مسئله قابل توجه در انطباق دامنه محسوب می‌شود [۱]. با این حال، فرآیند تشکیل تصاویر مصنوعی با فرآیند تصویربرداری واقعی یکسان نیست. تفاوت در بافت، نورپردازی، مدل‌سازی اشیاء، پس‌زمینه، ویژگی حسگر، نویز تصویربرداری و جزئیات محیط می‌تواند سبب شود توزیع داده مصنوعی و واقعی به مقدار قابل توجهی متفاوت باشد. در نتیجه، مدلی که تنها روی داده‌های مصنوعی آموزش دیده است الزاماً عملکرد خود را هنگام مواجهه با تصاویر واقعی حفظ نمی‌کند. این مسئله که در قالب

شکاف مصنوعی به واقعی مطرح می‌شود، نمونه مشخصی از تغییر دامنه است و یکی از انگیزه‌های اصلی استفاده از روش‌های انطباق دامنه در سامانه‌هایی محسوب می‌شود که آموزش اولیه آن‌ها با داده‌های شبیه‌سازی شده انجام می‌گیرد.

گذار از انطباق دامنه کلاسیک به انطباق بدون منبع

برای کاهش اثر شکاف دامنه، حوزه «انطباق دامنه» شکل گرفته است. در مسئله انطباق دامنه، هدف آن است که دانشی که مدل از یک دامنه مبدأ آموخته است، برای افزایش عملکرد آن در دامنه هدف مورد استفاده قرار گیرد. یکی از پرکاربردترین تنظیمات این مسئله، «انطباق دامنه بدون نظارت»^۲ یا UDA است که در آن داده‌های مبدأ دارای برچسب هستند، اما داده‌های دامنه هدف بدون برچسب در اختیار الگوریتم قرار می‌گیرند.

روش‌های UDA طی سال‌های گذشته از رویکردهای مختلفی مانند هم‌ترازی آماری توزیع‌ها، یادگیری تخصصی، انتقال در سطح تصویر و خودآموزی بهره گرفته‌اند. در حوزه تشخیص اشیا نیز روش‌هایی مانند Domain Adaptive Faster R-CNN با هم‌تراز کردن ویژگی‌ها در سطح تصویر و نمونه تلاش کرده‌اند حساسیت آشکارساز به تغییر دامنه را کاهش دهند [۱۱]. در سال‌های بعد، رویکردهای مبتنی بر مدل معلم - دانش آموز و شبه‌برچسب‌گذاری نیز به یکی از مسیرهای اصلی انطباق آشکارسازها تبدیل شدند. برای مثال، **Unbiased Mean Teacher** و سپس روش‌های جدیدتری مانند **Contrastive Mean Teacher** نشان دادند که کیفیت سیگنال‌های تولیدشده از داده هدف و نحوه انتقال آن‌ها از مدل معلم به دانش‌آموز، نقش مهمی در عملکرد آشکارسازهای تطبیق‌یافته دارد [۱۲]، [۵].

با وجود این پیشرفت‌ها، UDA کلاسیک یک پیش‌فرض مهم دارد: در زمان انطباق، داده‌های دامنه مبدأ باید همچنان قابل دسترسی باشند تا بتوان از آن‌ها همراه با داده‌های هدف استفاده کرد. این پیش‌فرض در بسیاری از کاربردهای واقعی برقرار نیست. داده‌های مبدأ ممکن است به دلیل الزامات حریم خصوصی، مالکیت داده، محدودیت انتقال اطلاعات، هزینه ذخیره‌سازی یا حجم بالا در محل استقرار مدل در دسترس نباشند. به‌عنوان نمونه، داده مورد استفاده برای آموزش یک سامانه می‌تواند متعلق به یک سازمان یا شبیه‌ساز اختصاصی باشد و تنها وزن‌های مدل آموزش‌دیده در اختیار سیستم مقصد قرار گیرند.

همین محدودیت سبب شکل‌گیری پارادایم انطباق دامنه بدون منبع یا SFDA شده است. در SFDA، در مرحله انطباق، داده‌های اصلی مبدأ در اختیار الگوریتم نیستند و تنها مدل از پیش آموزش‌دیده و داده‌های بدون برچسب دامنه هدف در دسترس‌اند. روش SHOT از نخستین نمونه‌های مهم این مسیر است که نشان داد می‌توان بدون دسترسی مجدد به داده‌های مبدأ و تنها با استفاده از فرضیه یا مدل آموزش‌دیده مبدأ، بازنمایی داده‌های هدف را تطبیق داد [۱۳]. مرور جامع Fang و همکاران نیز SFDA را پاسخی به محدودیت‌هایی نظیر حریم خصوصی، هزینه ذخیره‌سازی و انتقال داده و بار محاسباتی روش‌های متعارف UDA معرفی می‌کند [۱۴].

بنابراین، SFDA یک گام مهم در نزدیک کردن انطباق دامنه به شرایط واقعی است؛ زیرا نیاز به انتقال یا نگهداری مجموعه داده آموزشی را حذف می‌کند. با این حال، حذف داده‌های مبدأ به‌تنهایی برای بسیاری از سامانه‌های عملیاتی کافی نیست. بخش قابل توجهی از روش‌های SFDA فرض می‌کنند که مجموعه‌ای از داده‌های دامنه هدف پیش از استقرار نهایی مدل در دسترس است و می‌توان مدل را طی چندین مرحله یا چندین دور روی این مجموعه تطبیق داد. این سناریو همچنان ماهیتی عمدتاً آفلاین دارد.

در بسیاری از سامانه‌های واقعی چنین فرضی برقرار نیست. برای مثال، یک خودروی خودران نمی‌تواند پیش از ورود به یک شهر، وضعیت آب‌وهوایی یا شرایط نوری جدید، تمام داده‌های آن محیط را از قبل جمع‌آوری کند، چندین دوره انطباق انجام دهد و سپس آغاز به کار کند. اما در سناریو‌هایی، داده‌ها همزمان با فعالیت سامانه وارد می‌شوند و مدل باید در همان زمان که وظیفه پیش‌بینی را انجام می‌دهد، خود را نیز با شرایط جدید سازگار کند. این محدودیت، گذار از «انطباق بدون منبع آفلاین» به انطباق در زمان آزمون را ضروری می‌سازد. این تفاوت در ادبیات تشخیص اشیا نیز به‌صورت صریح مطرح شده است. VS و همکاران در پژوهش «Towards Online Domain Adaptive Object Detection» میان UDA، انطباق بدون منبع آفلاین و انطباق بدون منبع آنلاین تمایز قائل می‌شوند و تأکید می‌کنند که در محیط واقعی، مدل ممکن است با دامنه‌های جدیدی مواجه شود که پیش از استقرار ناشناخته بوده‌اند؛ بنابراین انطباق آفلاین برای تک‌تک تغییرات ممکن عملی نیست [۹].

انطباق در زمان آزمون

برای رفع محدودیت‌های فوق، پارادایم انطباق در زمان آزمون یا TTA توسعه یافته است. در این پارادایم، یک مدل از پیش آموزش‌دیده هنگام استقرار و با استفاده از داده‌های بدون برچسبی که در مرحله آزمون دریافت می‌کند، خود را با توزیع جدید سازگار می‌سازد. در تنظیم «کاملاً زمان آزمون»، داده‌های آموزشی مبدأ در این مرحله در دسترس نیستند و فرآیند آموزش اولیه نیز الزاماً برای انطباق آینده تغییر داده نمی‌شود.

Commented [ak12]: راجب تفاوت این دو تا بخون

Commented [ak13]: این که hypothesis چی هست مهمه و مقاله شات رو بخون.

² Unsupervised domain adaptation

یکی از روش‌های بنیادی در این زمینه، TENT است. این روش نشان داد که می‌توان با کمینه‌سازی آنتروپی پیش‌بینی‌های مدل روی داده‌های آزمون و به‌روزرسانی پارامترهای affine لایه‌های نرمال‌سازی، مدل را بدون دسترسی به داده مبدأ با توزیع جدید سازگار کرد [۱۰]. اهمیت TENT صرفاً در الگوریتم خاص آن نیست؛ این پژوهش نشان داد که بخشی از سازگاری مدل با تغییر دامنه می‌تواند مستقیماً در مرحله استنتاج و تنها با استفاده از داده‌های جاری انجام گیرد.

در ادبیات جدید، TTA به‌عنوان یک مفهوم گسترده در نظر گرفته می‌شود و بر اساس شکل دسترسی به داده‌های آزمون می‌توان آن را به چند سناریوی اصلی تقسیم کرد. Liang و همکاران در مرور جامع خود سه حالت عمده را مشخص می‌کنند: انطباق دامنه در زمان آزمون^۳ یا TTDA، انطباق دسته‌ای در زمان آزمون^۴ یا TTBA، و انطباق آنلاین در زمان آزمون^۵ یا OTTA [۱۵]. در TTDA معمولاً کل مجموعه بدون برچسب هدف پیش از تولید پیش‌بینی نهایی در دسترس قرار می‌گیرد و مدل می‌تواند طی چندین مرحله یا چندین دوره با این مجموعه سازگار شود. از این منظر، TTDA هم‌پوشانی قابل توجهی با بسیاری از مسائل SFDA دارد و به همین دلیل در بخشی از ادبیات این دو اصطلاح بسیار نزدیک به یکدیگر استفاده شده‌اند. با این حال، برای تفکیک مفهومی در این پژوهش، SFDA به‌عنوان محدودیت عدم دسترسی به داده مبدأ در نظر گرفته می‌شود، در حالی که TTDA بر نحوه و زمان استفاده از کل داده هدف برای انطباق تأکید دارد [۱۵]، [۱۴].

در TTBA مدل روی یک نمونه یا یک دسته کوچک از داده‌های آزمون سازگار می‌شود، اما وضعیت حاصل از این انطباق الزاماً به دسته‌های بعدی منتقل نمی‌شود. به بیان دیگر، هر دسته می‌تواند به‌طور نسبتاً مستقل پردازش شود. در مقابل، در OTTA داده‌ها به‌صورت متوالی وارد سامانه می‌شوند، هر نمونه یا دسته کوچک ممکن است تنها یک بار مشاهده شود و وضعیت مدل پس از پردازش داده‌های قبلی در پردازش داده‌های بعدی نقش دارد. در نتیجه، انطباق دیگر یک مجموعه عملیات مستقل نیست، بلکه به یک فرآیند یادگیری متوالی تبدیل می‌شود. مرور اختصاصی OTTA در International Journal of Computer Vision این مسئله را به‌صورت انطباق مدل با داده‌هایی توصیف می‌کند که به‌صورت دسته‌ای و در زمان واقعی وارد می‌شوند و بر اهمیت همزمان دقت و هزینه محاسباتی در چنین تنظیمی تأکید دارد [۱۶]. این ویژگی OTTA آن را برای کاربردهای عملی نظیر رانندگی خودران، رباتیک، نظارت تصویری و سامانه‌های سیار مناسب‌تر می‌کند؛ زیرا در این کاربردها امکان متوقف‌کردن سیستم، جمع‌آوری کامل داده‌های محیط و اجرای یک فرآیند انطباق چنددوره‌ای وجود ندارد. مدل باید همزمان با ورود داده، پیش‌بینی تولید کند و در صورت نیاز خود را به‌روز نماید.

از انطباق آنلاین به انطباق پیوسته در محیط‌های غیرایستا

حتی سناریوی OTTA نیز می‌تواند در سطوح مختلفی از دشواری تعریف شود. در یک حالت ساده‌تر، مدل وارد یک دامنه هدف جدید ولی نسبتاً ثابت می‌شود. در این شرایط، اگرچه داده‌ها به‌صورت آنلاین دریافت می‌شوند، توزیع هدف در طول زمان تغییر قابل توجهی نمی‌کند. اما محیط‌های واقعی غالباً غیرایستا هستند.

برای مثال، یک خودرو ممکن است در مدت کوتاهی از محیط آفتابی به سایه، سپس به باران، تاریکی، مه یا یک شهر با ساختار تصویری متفاوت وارد شود. بنابراین می‌توان توزیع داده در لحظه t را به‌صورت $P_t(X)$ در نظر گرفت که لزوماً با توزیع لحظه قبل یعنی $P_{t-1}(X)$ برابر نیست. مدل در چنین شرایطی نه تنها باید با شکاف میان مبدأ و هدف سازگار شود، بلکه باید بتواند تغییرات خودِ دامنه هدف در طول زمان را نیز دنبال کند.

این تنظیم در ادبیات معمولاً با عنوان Continual Test-Time Adaptation یا CTTA مطرح می‌شود. تفاوت مهم CTTA با برخی تنظیمات ساده‌تر OTTA در این است که مدل به‌صورت مستمر وضعیت تطبیق‌یافته خود را حفظ می‌کند و بدون اطلاع صریح از مرز میان دامنه‌ها باید تغییرات متوالی را مدیریت نماید. مرور جدید OTTA نیز continual TTA را حالتی معرفی می‌کند که مدل بدون بازنشانی مکرر به مدل مبدأ، به‌طور پیوسته نسبت به تغییرات توزیع به‌روزرسانی می‌شود [۱۶].

پژوهش CoTTA یکی از کارهای بنیادی در این سناریو است. Wang و همکاران نشان دادند که روش‌هایی که در یک دامنه هدف ثابت عملکرد مناسبی دارند ممکن است هنگام مواجهه طولانی با توزیع‌های متغیر ناپایدار شوند. آن‌ها دو مشکل اصلی را برجسته کردند: انباشت خطا ناشی از سیگنال‌های خودنظارتی نادرست و فراموشی فاجعه‌بار ناشی از فاصله‌گرفتن تدریجی مدل از دانش عمومی مبدأ [۳]. برای کاهش خطا، CoTTA از پیش‌بینی‌های میانگین‌گیری‌شده و برای حفظ دانش مبدأ از بازگردانی تصادفی بخشی^۶ از پارامترها به مقادیر اولیه استفاده می‌کند.

³ Test time domain adaptation

⁴ test time Batch domain adaptation

⁵ Online test time adaptation

Commented [ak14]: بیشتر بخون راجیون

پس از آن، پژوهش‌های متعدد نشان داده‌اند که شرایط واقعی حتی می‌توانند دشوارتر باشند. RoTTA سناریویی را مطالعه می‌کند که در آن داده‌های متوالی علاوه بر تغییر توزیع، از نظر زمانی نیز هم‌بسته‌اند و از حافظه و یک ساختار معلم - دانش آموز برای افزایش پایداری انطباق استفاده می‌کند [۱۷]. SAR نیز نشان داده است که TTA می‌تواند در حضور ترکیبی از تغییرات توزیع، اندازه کوچک دسته و توزیع نامتوازن کلاس‌ها ناپایدار شود [۱۸].

این یافته‌ها نشان می‌دهند که OTTA صرفاً مسئله «به‌روزرسانی مدل روی هر دسته جدید» نیست، بلکه مسئله اصلی کنترل یک فرآیند یادگیری بدون نظارت در طول زمان است که کوچک‌ترین خطای سیستماتیک می‌تواند با تکرار به افت شدید عملکرد منجر شود.

انباشت خطا در انطباق آنلاین

در TTA و به‌خصوص OTTA، برچسب واقعی نمونه‌های هدف در دسترس نیست. بنابراین الگوریتم برای ایجاد سیگنال آموزشی باید به اطلاعاتی مانند آنتروپی پیش‌بینی، شبه‌برچسب‌ها، سازگاری میان نماهای مختلف یک تصویر، مدل معلم، نمونه‌های ذخیره‌شده در حافظه یا ساختار بازنمایی ویژگی متکی باشد.

یکی از پرکاربردترین روش‌ها، شبه‌برچسب‌گذاری است. در این رویکرد، پیش‌بینی خود مدل به‌عنوان برچسب موقت در نظر گرفته می‌شود و برای به‌روزرسانی پارامترها مورد استفاده قرار می‌گیرد. اگر پیش‌بینی اولیه صحیح باشد، این فرآیند می‌تواند موجب بهبود مدل شود؛ اما اگر مدل به دلیل شکاف دامنه پیش‌بینی نادرستی ایجاد کند، همان پیش‌بینی نادرست وارد فرآیند آموزش می‌شود.

این مسئله در محیط آنلاین می‌تواند یک چرخه بازخورد مثبت نامطلوب ایجاد کند. یک شبه‌برچسب نادرست سبب به‌روزرسانی اشتباه پارامترها می‌شود؛ این تغییر احتمال تولید شبه‌برچسب‌های اشتباه در نمونه‌های بعدی را افزایش می‌دهد؛ خطاهای جدید مجدداً برای آموزش استفاده می‌شوند و با ادامه این چرخه، مدل می‌تواند به‌تدریج از مسیر صحیح فاصله بگیرد. این پدیده با عنوان انباشت خطا شناخته می‌شود و CoTTA آن را یکی از مشکلات بنیادی محیط‌های غیرایستای TTA معرفی می‌کند [۳].

اهمیت این مسئله در مطالعات بعدی نیز تأیید شده است. RDumb در یک ارزیابی بلندمدت نشان داد که بسیاری از روش‌های CTTA که در توالی‌های کوتاه نتایج مناسبی دارند، در بازه‌های طولانی ممکن است دچار فروپاشی عملکرد شوند؛ حتی یک راهبر ساده بازنشانی دوره‌ای مدل در برخی ارزیابی‌ها می‌تواند با روش‌های پیچیده رقابت کند [۱۹]. این نتیجه نشان می‌دهد که پایداری بلندمدت باید در کنار بهبود کوتاه‌مدت دقت به‌عنوان یکی از معیارهای اصلی طراحی OTTA در نظر گرفته شود.

فراموشی فاجعه‌بار و تعادل پایداری - انعطاف‌پذیری

چالش مهم دوم، فراموشی فاجعه‌بار است. در این حالت ممکن است مدل بتواند خود را با توزیع جدید سازگار کند، اما در جریان این سازگاری بخشی از دانشی را که در آموزش اولیه کسب کرده است از دست بدهد. اگر پارامترها تنها بر اساس چند دسته اخیر داده هدف به‌روزرسانی شوند، مدل می‌تواند بیش از حد به شرایط فعلی وابسته شود و بازنمایی‌های عمومی و مفیدی را که از مبدأ آموخته بود تخریب کند.

بنابراین در OTTA یک تضاد بنیادی میان دو نیاز وجود دارد. از یک سو مدل باید انعطاف‌پذیری کافی برای یادگیری سریع از داده‌های جدید داشته باشد و از سوی دیگر باید پایداری کافی برای حفظ دانش گذشته داشته باشد. تطبیق بیش از حد ضعیف موجب باقی ماندن شکاف دامنه می‌شود، در حالی که تطبیق بیش از حد تهاجمی می‌تواند به فراموشی یا حتی فروپاشی مدل منجر شود. EATA این مسئله را مستقیماً مورد توجه قرار داده است. این روش علاوه بر انتخاب نمونه‌های مناسب برای کاهش تعداد محاسبات پس‌انتشار، از یک تابع منظم‌سازی برای محدودکردن تغییر پارامترهای مهم مدل استفاده می‌کند و از این طریق تلاش می‌کند انطباق با داده‌های خارج از توزیع را بدون تخریب شدید عملکرد روی توزیع اصلی انجام دهد [۶].

CoTTA نیز از بازگردانی تصادفی بخشی از پارامترها به وزن‌های مدل مبدأ استفاده می‌کند [۳]. مجموعه این روش‌ها نشان می‌دهد که حفظ نوعی لنگر نسبت به دانش مبدأ، چه از طریق وزن‌ها، منظم‌سازی، معماری معلم - دانش آموز، حافظه یا ساختارهای دیگر، یکی از مؤلفه‌های مهم در طراحی الگوریتم‌های پایدار TTA است.

چالش‌های خاص انطباق در زمان آزمون برای تشخیص اشیا

بخش عمده‌ای از تحقیقات اولیه TTA و CTTA روی مسئله دسته‌بندی تصویر انجام شده است. انتقال مستقیم این روش‌ها به تشخیص اشیا ساده نیست؛ زیرا ساختار خروجی و تابع هدف در آشکارسازی به مراتب پیچیده‌تر است.

در دسته‌بندی تصویر، برای هر تصویر معمولاً یک توزیع احتمال روی کلاس‌ها تولید می‌شود. اما یک آشکارساز باید ابتدا چندین نمونه بالقوه را در تصویر پیدا کند، سپس برای هر نمونه کلاس تعیین کند و همزمان موقعیت آن را از طریق مختصات جعبه محدودکننده تخمین بزند. بنابراین سیگنال بدون نظارت در تشخیص اشیا باید دو جنبه معنایی و مکانی را به‌طور همزمان مدیریت کند.

Commented [ak15]: منظور از احتمال شرطی روی کلاس‌ها هست

Commented [ak16]: Paper جالبی هه بخون حتما

Commented [ak17]: مهمه بخون راجیش

Commented [ak18]: بخون راج

Commented [ak19]: بخون راجیش

شبه برچسب یک شیء معمولاً حداقل از یک برچسب کلاس، یک نمره اطمینان و مختصات جعبه محدودکننده تشکیل می‌شود. ممکن است مدل کلاس شیء را درست تشخیص دهد ولی جعبه آن را اشتباه تخمین بزند، یا برعکس، محل شیء را درست بیابد ولی آن را به کلاس اشتباه تخصیص دهد. علاوه بر این، جعبه نادرست باعث می‌شود ویژگی‌های مربوط به پس‌زمینه یا بخش نامرتبلی از تصویر وارد فرآیند آموزش شوند. Ruan و Tang در پژوهش «Fully Test-time Adaptation for Object Detection» نشان داده‌اند که یکی از مشکلات اساسی خودآموزی در این شرایط، غیرقابل اعتماد بودن شبه برچسب‌ها تحت تغییر دامنه است و اتکا به نمره اطمینان طبقه‌بندی به‌تنهایی برای تعیین کیفیت یک شبه‌جعبه کافی نیست. آن‌ها به همین دلیل معیارهای مبتنی بر IoU را برای پالایش شبه برچسب‌ها وارد فرآیند انطباق کردند [۴]. از سوی دیگر، معماری معلم-دانش‌آموز که در UDA تشخیص اشیا بسیار موفق بوده است، در شرایط test-time می‌تواند هزینه بالایی ایجاد کند؛ زیرا تولید چند نمای تقویت‌شده، چندین عبور رو به جلو و پس‌انتشار و نگهداری دو نسخه از مدل، سرعت پردازش را کاهش می‌دهد. Yoo و همکاران در CVPR سال ۲۰۲۴ به‌صراحت اشاره می‌کنند که بسیاری از روش‌های TTA از دسته‌بندی تصویر به تشخیص اشیا قابل انتقال مستقیم نیستند و به همین دلیل مسئله را در قالب سه سؤال «چه بخشی از آشکارساز به‌روزرسانی شود؟»، «چگونه به‌روزرسانی شود؟» و «چه زمانی به‌روزرسانی انجام گیرد؟» صورت‌بندی کردند [۸].

در روش آن‌ها، به جای تغییر همه پارامترهای آشکارساز، ماژول‌های سبک‌وزن تطبیقی به مدل افزوده می‌شوند و مدل تنها در شرایطی که نیاز به انطباق وجود دارد به‌روزرسانی می‌شود. این رویکرد نشان می‌دهد که برای OTTA در تشخیص اشیا، انتخاب محل و زمان به‌روزرسانی به اندازه انتخاب تابع زبان اهمیت دارد.

این مسیر در تحقیقات جدیدتر ادامه یافته است. Wang و همکاران در CVPR سال ۲۰۲۵ مسئله Continual Test-Time Adaptive Object Detection را مستقیماً به‌عنوان انطباق آنلاین یک آشکارساز از پیش آموزش‌دیده در محیط‌های دائماً متغیر تعریف کرده‌اند و نشان داده‌اند که هزینه محاسباتی یک مسئله مستقل و مهم در این حوزه است. روش آن‌ها با شناسایی و هرس کانال‌های حساس به دامنه تلاش می‌کند ضمن حفظ عملکرد انطباق، سربار محاسبات را کاهش دهد [۷].

همچنین Li و همکاران در ICCV ۲۰۲۵، CTTA برای تشخیص اشیا را در محیط‌های پویا بررسی کرده‌اند و سه چالش را به‌طور مشخص مطرح می‌کنند: انطباق آنلاین با داده‌های بدون برچسب، ضرورت کارایی محاسباتی و جلوگیری از فراموشی فاجعه‌بار. آن‌ها به‌جای بهینه‌سازی تعداد زیادی پارامتر، از ساختارهای تطبیقی مبتنی بر LoRA و تولید پارامتر وابسته به محیط استفاده کرده‌اند [۲۰].

بنابراین، روند ادبیات جدید نشان می‌دهد که مسئله از «آیا می‌توان مدل را در زمان آزمون تطبیق داد؟» به سمت پرسش دقیق‌تری حرکت کرده است: چگونه می‌توان یک آشکارساز را در جریان داده واقعی، با حداقل نظارت، حداقل تخریب دانش گذشته و حداقل هزینه محاسباتی، به‌طور مستمر سازگار نگه داشت؟

کارایی محاسباتی به‌عنوان بخشی از مسئله

در کاربرد آنلاین، افزایش دقت تنها معیار موفقیت نیست. اگر یک روش انطباق برای هر فریم نیازمند چندین مرحله پس‌انتشار یا اجرای چند نسخه از شبکه باشد، ممکن است حتی در صورت افزایش mAP نیز برای سامانه بلادرنگ مناسب نباشد.

این مسئله در تشخیص اشیا جدی‌تر است؛ زیرا خود اجرای یک آشکارساز نسبت به یک دسته‌بند تصویر هزینه محاسباتی بیشتری دارد. به همین دلیل در ارزیابی روش‌های OTTA علاوه بر معیارهای دقت باید معیارهایی مانند زمان انطباق، سرعت پردازش، حافظه مصرفی، تعداد پارامترهای قابل آموزش و حجم محاسبات نیز در نظر گرفته شوند. مقاله مروری جدید OTTA نیز بر ارزیابی همزمان اثربخشی و کارایی با معیارهایی مانند GFLOPs، زمان واقعی اجرا و حافظه GPU تأکید می‌کند [۱۶].

این موضوع در جدیدترین تحقیقات CTTA نیز همچنان از محورهای اصلی است. برای نمونه، پژوهش‌های سال‌های ۲۰۲۵ و ۲۰۲۶ همچنان تعادل میان کارایی و قدرت تعمیم را به‌عنوان یکی از مسائل حل‌نشده CTTA مطرح می‌کنند.

صورت‌بندی جایگاه پژوهش حاضر

بر اساس مطالب فوق، می‌توان سناریوی پژوهش حاضر را به‌صورت زیر در نظر گرفت. یک مدل تشخیص اشیا ابتدا در یک دامنه مبدأ آموزش داده می‌شود که می‌تواند بخش عمده یا تمام داده‌های آن مصنوعی باشد. پس از اتمام آموزش، داده‌های مبدأ دیگر در اختیار فرآیند انطباق قرار ندارند. مدل در محیط واقعی مستقر می‌شود و با جریانی از تصاویر بدون برچسب مواجه است که توزیع آن‌ها می‌تواند با دامنه مبدأ متفاوت باشد و علاوه بر آن، در طول زمان نیز تغییر کند.

در هر لحظه t ، تنها نمونه یا دسته کوچک جاری B_t و وضعیت فعلی مدل در اختیار الگوریتم قرار دارد. مدل باید پیش‌بینی تشخیص اشیا را تولید کند و در صورت نیاز با استفاده از اطلاعات بدون برچسب همین جریان خود را به‌روزرسانی نماید. وضعیت حاصل از انطباق می‌تواند برای پردازش دسته‌های بعدی مورد استفاده قرار گیرد؛ بنابراین خطا یا دانش آموخته‌شده در مراحل گذشته مستقیماً بر رفتار آینده مدل اثر می‌گذارد. در چنین تنظیمی، چهار مسئله به یکدیگر وابسته‌اند. نخست، مدل باید از داده‌های بدون برچسب هدف سیگنال نظارتی قابل اعتماد استخراج کند و در تشخیص اشیا، اعتبار هر دو جزء طبقه‌بندی و مکانیابی را در نظر بگیرد. دوم، باید مانع از آن شود که شبه‌برچسب‌های نادرست در طول جریان داده به انباشت خطا منجر شوند. سوم، باید تعادلی میان یادگیری شرایط جدید و حفظ دانش عمومی مدل ایجاد شود تا فراموشی فاجعه‌بار کنترل گردد. چهارم، کل این فرآیند باید با محدودیت‌های زمانی و محاسباتی یک سامانه آنلاین سازگار باشد.

از این منظر، هدف پژوهش حاضر صرفاً ارائه یک روش جدید برای SFDA یا انطباق یک آشکارساز با یک مجموعه هدف ثابت نیست؛ بلکه تمرکز آن بر توسعه و بهبود انطباق آنلاین در زمان آزمون برای تشخیص اشیا در محیط‌های دارای تغییر توزیع متوالی است. SFDA در این چارچوب پیش‌شرط عملی مسئله را مشخص می‌کند، یعنی «عدم دسترسی به داده‌های مبدأ»؛ TTA مشخص می‌کند که انطباق در مرحله استقرار انجام می‌شود؛ OTTA محدودیت جریان داده و یک‌بار مشاهده‌شدن دسته‌ها را اضافه می‌کند؛ و CTTA شرایط دشوارتر و واقع‌گرایانه‌تری را در نظر می‌گیرد که در آن خود توزیع هدف نیز در طول زمان تغییر می‌کند. نکته مهم این است که OTTA و CTTA را یکی در نظر نگیریم. OTTA مفهوم گسترده‌تر انطباق آنلاین است؛ CTTA یک تنظیم دشوارتر است که در آن تغییر توزیع ادامه‌دار است، مرز دامنه‌ها ممکن است مشخص نباشد و وضعیت مدل نیز در طول زمان حفظ می‌شود.

در نهایت، سناریوی انتقال از داده مصنوعی به داده واقعی بستر مناسبی برای مطالعه این مسئله فراهم می‌کند؛ زیرا از یک سو استفاده از داده‌های مصنوعی می‌تواند هزینه تولید مجموعه آموزشی را به‌طور قابل توجهی کاهش دهد و از سوی دیگر، شکاف طبیعی میان شبیه‌سازی و واقعیت، مدل را در زمان استقرار با تغییر توزیع واقعی مواجه می‌کند. هدف نهایی آن است که آشکارساز از پیش آموزش‌دیده بتواند بدون دسترسی به داده‌های اصلی مبدأ و بدون دریافت برچسب از محیط هدف، ضمن پردازش آنلاین داده‌های ورودی، خود را با تغییرات دامنه سازگار سازد و همزمان دقت طبقه‌بندی و مکانیابی، پایداری بلندمدت، حفظ دانش پیشین و کارایی محاسباتی را در سطح قابل قبول حفظ نماید.

۳-۳ - ضرورت انجام تحقیق :

پیشرفت مدل‌های یادگیری عمیق موجب شده است سامانه‌های بینایی ماشین و به‌ویژه مدل‌های تشخیص اشیا در شرایط آزمایشگاهی به عملکرد بالایی دست یابند؛ با این حال، استقرار این مدل‌ها در محیط‌های واقعی همچنان با مسئله مهم تغییر توزیع داده مواجه است. مدلی که روی یک توزیع مشخص آموزش دیده است، ممکن است در اثر تغییر شرایط تصویربرداری، روشنایی، آب‌وهوا، نوع حسگر، محیط جغرافیایی، پس‌زمینه یا سایر عوامل عملیاتی با داده‌هایی مواجه شود که با توزیع آموزش متفاوت‌اند و در نتیجه عملکرد آن کاهش یابد. از آنجا که امکان پیش‌بینی و بازنمایی تمام شرایطی که یک سامانه پس از استقرار با آن‌ها روبرو خواهد شد وجود ندارد، صرف افزایش تنوع مجموعه‌داده آموزشی نمی‌تواند به‌تنهایی مسئله تعمیم در محیط‌های پویا را به‌طور کامل حل کند. از این‌رو، توانایی سازگارشدن مدل پس از استقرار و در مواجهه با داده‌های واقعی، به یکی از مسائل مهم در توسعه سامانه‌های قابل اعتماد بینایی ماشین تبدیل شده است [۱۶].

این ضرورت در سناریوهایی که مدل با استفاده از داده‌های مصنوعی آموزش داده می‌شود اهمیت بیشتری پیدا می‌کند. استفاده از شبیه‌سازها می‌تواند هزینه جمع‌آوری و برچسب‌گذاری داده را کاهش داده و امکان تولید حجم زیادی از نمونه‌های برچسب‌دار را فراهم کند؛ اما تفاوت میان فرآیند تولید تصاویر مصنوعی و شرایط تصویربرداری واقعی سبب ایجاد شکاف «مصنوعی به واقعی» می‌شود. از این‌رو، هرچند داده‌های مصنوعی از نظر هزینه و مقیاس‌پذیری مزیت قابل توجهی دارند، استفاده عملی از مدل‌های آموزش‌دیده روی این داده‌ها مستلزم وجود سازوکاری است که بتواند مدل را پس از استقرار با توزیع واقعی داده تطبیق دهد. این مسئله در پژوهش حاضر اهمیت ویژه‌ای دارد؛ زیرا یکی از سناریوهای اصلی مورد بررسی، انتقال مدل تشخیص اشیا از داده‌های آموزشی مصنوعی به داده‌های واقعی است.

روش‌های کلاسیک انطباق دامنه تا حدی امکان کاهش این شکاف را فراهم کرده‌اند؛ با این حال، بخش قابل توجهی از آن‌ها فرض می‌کنند که دامنه هدف پیش از استقرار مشخص است و فرآیند انطباق می‌تواند به‌صورت آفلاین انجام شود. حتی در تنظیم انطباق دامنه بدون منبع نیز معمولاً یک مجموعه هدف مشخص در اختیار مدل قرار می‌گیرد تا پیش از استفاده نهایی روی آن تطبیق انجام شود. این فرض با شرایط بسیاری از سامانه‌های واقعی سازگار نیست؛ زیرا مدل پس از استقرار ممکن است به‌طور مداوم وارد محیط‌هایی شود که در زمان آموزش ناشناخته بوده‌اند. پژوهش VS و همکاران در حوزه تشخیص اشیا نیز به‌صراحت نشان می‌دهد که انطباق آفلاین با یک دامنه هدف ثابت برای سامانه‌ای که هنگام استقرار با تغییرات جدید و متوالی دامنه روبرو می‌شود، کافی نیست و انطباق آنلاین برای چنین شرایطی ضرورت دارد [۹].

به همین دلیل، انطباق در زمان آزمون و به‌طور خاص انطباق آنلاین در زمان آزمون اهمیت پیدا می‌کند. در OTTA، مدل باید هنگام دریافت داده‌های بدون برچسب و همزمان با انجام استنتاج، خود را با توزیع جاری سازگار کند. برخلاف تنظیمات آفلاین، امکان چندین بار مشاهده کل مجموعه هدف یا انجام چندین دوره آموزش روی آن وجود ندارد و داده‌ها غالباً به‌صورت دسته‌های کوچک و متوالی وارد سامانه می‌شوند. مرور

Commented [ak20]: UDA به دادهٔ مبدأ نیاز دارد ← در

استقرار نمی‌خواهیم یا نمی‌توانیم دادهٔ مبدأ را داشته باشیم ←

SFDA این محدودیت را حذف می‌کند ← اما SFDA آفلاین هنوز

فرض می‌کند دادهٔ هدف را از قبل داریم ← در دنیای واقعی

چنین نیست ← پس ← TTA و در دادهٔ جریانی ← OTTA و در

تغییرات مداوم CTTA

تمرکز پژوهش بر انطباق آنلاین در زمان آزمون برای تشخیص اشیا است،

با تأکید ویژه بر سناریوی انطباق پیوسته تحت تغییرات غیرایستای توزیع

هدف.

جامع Wang و همکاران نشان می‌دهد که این ویژگی بلادرنگ OTTA آن را برای محیط‌های واقعی مناسب می‌کند، اما در عین حال محدودیت‌های مهمی مانند وابستگی برخی روش‌ها به اندازه دسته، ناپایداری بهینه‌سازی و هزینه محاسباتی را به همراه دارد. این مطالعه همچنین نشان می‌دهد که عملکرد تعدادی از روش‌های موجود با کوچک‌شدن اندازه دسته کاهش می‌یابد؛ در حالی که در بسیاری از سامانه‌های واقعی ممکن است مدل مجبور باشد هر نمونه یا تعداد بسیار محدودی از نمونه‌ها را در هر لحظه پردازش کند [۱۶].

ضرورت پژوهش حاضر زمانی بیشتر آشکار می‌شود که محیط هدف نیز ثابت نباشد. در کاربردهایی نظیر خودروهای خودران، ربات‌های متحرک و سامانه‌های نظارت تصویری، مدل ممکن است به‌صورت متوالی با شرایط متفاوتی مانند روشنایی روز و شب، باران، مه، تغییر دوربین، تغییر محیط جغرافیایی یا سایر اغتشاش‌های تصویری روبه‌رو شود. در این وضعیت، مدل نه‌تنها باید شکاف میان دامنه مبدأ و هدف را کاهش دهد، بلکه باید تغییر خود توزیع هدف را نیز در طول زمان دنبال کند. چنین مسئله‌ای در قالب انطباق پیوسته در زمان آزمون یا CoTTA مطالعه می‌شود. CoTTA نشان داده است که روش‌های متکی بر خودآموزی یا کمینه‌سازی آنتروپی در محیط‌های غیرایستامی ممکن است به دلیل کاهش کیفیت شبه‌برچسب‌ها به انباشت خطا و در ادامه به فراموشی فاجعه‌بار منجر شوند [۳].

انباشت خطا یکی از مهم‌ترین دلایل ضرورت توسعه روش‌های جدید در این حوزه است. در زمان آزمون، برچسب صحیح داده‌های ورودی در اختیار مدل قرار ندارد و در بسیاری از روش‌ها، خود پیش‌بینی مدل یا نسخه‌ای پالایش‌شده از آن به‌عنوان سیگنال نظارتی مورد استفاده قرار می‌گیرد. در چنین شرایطی، اگر مدل به علت شکاف دامنه در مراحل اولیه پیش‌بینی نادرستی انجام دهد، استفاده مجدد از همان پیش‌بینی برای به‌روزرسانی پارامترها می‌تواند احتمال خطا در نمونه‌های بعدی را افزایش دهد. در یک سامانه آنلاین، این فرآیند ممکن است بارها تکرار شود و خطاهای کوچک اولیه به انحراف تدریجی مدل تبدیل شوند. پژوهش‌های جدید نیز همچنان این حلقه بازخورد خودارجاع را یکی از مسائل اصلی CoTTA می‌دانند. برای نمونه، Chen و همکاران در CVPR سال ۲۰۲۶ تصریح می‌کنند که اتکا به خودنظارتی می‌تواند خطاهای اولیه را تقویت کرده و به «رانش مدل» منجر شود [۲۱].

در کنار انباشت خطا، فراموشی فاجعه‌بار نیز یک مانع بنیادی است. مدلی که به‌طور مداوم تنها بر اساس داده‌های جدید به‌روزرسانی می‌شود ممکن است به تدریج بازنمایی‌ها و دانشی را که در مرحله آموزش مبدأ کسب کرده است از دست بدهد. بنابراین، روش انطباق باید میان دو ویژگی متعارض تعادل ایجاد کند: از یک سو، انعطاف‌پذیری کافی برای یادگیری سریع تغییرات جدید و از سوی دیگر، پایداری کافی برای جلوگیری از تخریب دانش پیشین. CoTTA برای مقابله با این مسئله بخشی از پارامترهای مدل را به وزن‌های مبدأ بازمی‌گرداند [۳] و EATA نیز با حفظ پارامترهای مهم مدل تلاش می‌کند فراموشی ناشی از انطباق را کاهش دهد [۶]. این موضوع در پژوهش ما نیز به‌عنوان یکی از چالش‌های اصلی OTTA در نظر گرفته شده است. پژوهش EATA علاوه بر مسئله فراموشی، هزینه انجام پس‌انتشار برای هر نمونه آزمون را نیز یکی از محدودیت‌های روش‌های TTA معرفی می‌کند.

این چالش‌ها در وظیفه تشخیص اشیاء نسبت به بسیاری از مطالعات اولیه TTA که بر دسته‌بندی تصویر متمرکز بوده‌اند، پیچیده‌تر هستند. در دسته‌بندی تصویر، خروجی اصلی مدل یک برچسب برای کل تصویر است؛ اما در تشخیص اشیاء، مدل باید همزمان کلاس اشیاء و موقعیت آن‌ها را از طریق جعبه‌های محدودکننده تعیین کند. بنابراین یک شبه‌برچسب می‌تواند از نظر طبقه‌بندی صحیح اما از نظر مکانیابی نادرست باشد، یا بالعکس. Tang و Ruan در پژوهش خود درباره Fully Test-Time Adaptation for Object Detection نشان داده‌اند که نمره اطمینان طبقه‌بندی به‌تنهایی معیار کافی برای سنجش کیفیت شبه‌برچسب‌های تشخیص اشیاء نیست و عدم اطمینان ناشی از شکاف دامنه می‌تواند فرآیند خودآموزی را مختل کند [۴].

اهمیت همزمان طبقه‌بندی و مکانیابی حتی در پژوهش‌های جدید سال ۲۰۲۶ نیز همچنان مورد تأکید است. Qin و همکاران در CVPR سال ۲۰۲۶ بیان می‌کنند که بسیاری از روش‌های Test-Time Adaptive Object Detection عمدتاً بر بهبود اطمینان طبقه‌بندی متمرکز داشته‌اند و افت دقت جعبه‌های محدودکننده را کمتر مورد توجه قرار داده‌اند؛ در حالی که برای یک آشکارساز، هر دو مؤلفه طبقه‌بندی و مکانیابی باید تحت تغییر دامنه پایدار باقی بمانند [۲۲]. این موضوع نشان می‌دهد که انطباق در زمان آزمون برای تشخیص اشیاء هنوز دارای چالش‌های خاصی است که نمی‌توان آن‌ها را صرفاً با انتقال مستقیم روش‌های دسته‌بندی برطرف کرد.

از سوی دیگر، بسیاری از روش‌های TTA اولیه روی وظیفه دسته‌بندی و با به‌روزرسانی لایه‌های نرمال‌سازی یا سر طبقه‌بندی توسعه یافته‌اند و انتقال مستقیم آن‌ها به آشکارسازهای پیچیده همواره امکان‌پذیر نیست. Yoo و همکاران در CVPR سال ۲۰۲۴ این محدودیت را به‌طور مستقیم مطرح کرده و مسئله انطباق پیوسته آشکارساز اشیاء را بر اساس سه پرسش «چه بخشی از مدل به‌روزرسانی شود؟»، «به چه روش به‌روزرسانی شود؟» و «در چه زمانی به‌روزرسانی انجام گیرد؟» صورت‌بندی کرده‌اند [۸]. نتایج آن‌ها نشان می‌دهد که طراحی «ماژول‌های سبک و انتخاب زمان مناسب انطباق می‌تواند در کنار افزایش دقت، سرعت پردازش را نیز حفظ کند. همین موضوع نشان می‌دهد که در تشخیص اشیاء، نحوه کنترل فرآیند به‌روزرسانی بخشی از خود مسئله پژوهشی است و نه صرفاً یک جزئیات اجرایی.

Commented [ak21]
Efficient Test-Time Model Adaptation
without Forgetting
مقاله خوبیه بخونش

Commented [ak22]
ViTPrompt: Training-Free Prompt
Refinement with Visual Tokens for Open-Vocabulary Detection

Commented [ak23]
چک کن حتما چی کار می‌کنه:
What How and When Should Object Detectors Update in
Continually Changing Test Domains?

کارایی محاسباتی نیز یکی دیگر از دلایل اصلی ضرورت انجام این پژوهش است. هدف یک روش آنلاین صرفاً افزایش دقت نیست؛ زیرا اگر فرآیند انطباق موجب افزایش شدید زمان پردازش، مصرف حافظه یا تعداد عملیات پس‌انتشار شود، استفاده از آن در یک سامانه واقعی و به‌ویژه در کاربردهای دارای محدودیت زمانی یا سخت‌افزاری امکان‌پذیر نخواهد بود. مرور OTTA در IJCV به همین دلیل علاوه بر دقت، معیارهایی نظیر GFLOPs، زمان واقعی اجرا و مصرف حافظه GPU را برای ارزیابی روش‌های انطباق آنلاین وارد مقایسه کرده است [۱۶].

اهمیت این مسئله برای تشخیص اشیاء در سال‌های اخیر به‌طور مستقیم مورد توجه قرار گرفته است. Wang و همکاران در CVPR سال ۲۰۲۵ بیان می‌کنند که بسیاری از روش‌های CTTA برای تشخیص اشیاء عمدتاً بر اثربخشی انطباق تمرکز کرده‌اند و کارایی محاسباتی را کمتر مورد توجه قرار داده‌اند؛ در حالی که این ویژگی برای استقرار در سامانه‌های دارای منابع محدود ضروری است [۷]. روش آن‌ها با تمرکز بر کانال‌های حساس به دامنه توانسته است سربار محاسباتی را نسبت به روش مرجع کاهش دهد، اما مطرح‌شدن چنین مسئله‌ای در یک پژوهش مستقل نشان می‌دهد که تعادل میان کیفیت انطباق و هزینه محاسباتی همچنان یک مسئله باز در CTTA و ODTTA است.

این مسئله حتی در پژوهش‌های سال ۲۰۲۶ نیز حل‌شده تلقی نمی‌شود. Lai و همکاران در CVPR سال ۲۰۲۶، مسئله CTTA را صراحتاً دارای یک تعارض میان کارایی و تعمیم‌پذیری معرفی می‌کنند؛ به این معنا که به‌روزرسانی تعداد بیشتری از پارامترها می‌تواند توان انطباق را افزایش دهد، اما در مقابل هزینه استنتاج آنلاین را بالا می‌برد [۲۳]. از این‌رو، یافتن زیرمجموعه یا سازوکاری کم‌هزینه برای انطباق مؤثر، همچنان یکی از محورهای فعال پژوهش در این حوزه است.

علاوه بر آن، پژوهش‌های جدید نشان می‌دهند که مسئله فقط «چقدر از مدل به‌روزرسانی شود» نیست، بلکه نوع سیگنال مورد استفاده برای انطباق نیز اهمیت بنیادی دارد. Chen و همکاران در CVPR سال ۲۰۲۶ نشان داده‌اند که چرخه‌های خودنظارتی می‌توانند خطاهای اولیه را در طول انطباق پیوسته تقویت کنند [۲۱]؛ همچنین Que و همکاران در مسئله Test-Time Prompt Tuning برای تشخیص اشیاء نشان داده‌اند که کمینه‌سازی آنتروپی در شرایط تغییر دامنه می‌تواند پیش‌بینی‌های اشتباه را با اطمینان بالاتر تثبیت کرده و به مشکل کالیبراسیون منجر شود [۲۴]. اگرچه چارچوب آن‌ها بر آشکارسازهای مبتنی بر مدل‌های بینایی-زبان متمرکز است، نتیجه اصلی آن‌ها اهمیت طراحی سیگنال انطباق قابل اعتماد در تشخیص اشیاء را تقویت می‌کند.

همچنین، پژوهش Li و همکاران در ICCV سال ۲۰۲۵ سه مسئله را برای CTTA در تشخیص اشیاء به‌صورت مستقیم برجسته می‌کند: انطباق آنلاین با داده‌های بدون برچسب، نیاز به کارایی محاسباتی بالا و حفظ عملکرد مدل در مواجهه با تغییرات متوالی محیط [۲۰]. این پژوهش نشان می‌دهد که حتی به‌روزرسانی تعداد محدودی از پارامترها بر اساس تعداد کمی تصویر آزمون ممکن است بازتابی بخش‌های دیگر شبکه را تحت تأثیر قرار داده و باعث افت عملکرد شود؛ از این‌رو، هنوز در مورد بهترین سازوکار برای تغییر مدل در زمان آزمون اتفاق نظر مشخصی وجود ندارد. از منظر کاربردی نیز انجام این پژوهش اهمیت دارد. سامانه‌های تشخیص اشیاء در حوزه‌هایی مانند رانندگی خودران، کنترل ترافیک، رباتیک متحرک و نظارت تصویری با داده‌های جریانی و شرایط محیطی متغیر سروکار دارند. در چنین کاربردهایی، نمی‌توان برای هر تغییر آب‌وهوا، هر دوربین جدید یا هر محیط جغرافیایی، یک مجموعه داده برچسب‌دار جدید تهیه و مدل را از ابتدا آموزش داد. همچنین، در بسیاری از موارد داده‌های مبدأ در محل استقرار مدل در دسترس نیستند و امکان ذخیره‌سازی یا انتقال آن‌ها وجود ندارد. بنابراین، یک روش انطباق آنلاین که تنها با استفاده از مدل از پیش آموزش‌دیده و جریان داده‌های بدون برچسب بتواند خود را با محیط جدید سازگار کند، می‌تواند فاصله میان عملکرد آزمایشگاهی و استقرار واقعی مدل‌های تشخیص اشیاء را کاهش دهد.

بر این اساس، ضرورت پژوهش حاضر از اجتماع چند مسئله حل‌نشده ناشی می‌شود: تغییر مستمر توزیع داده پس از استقرار، عدم دسترسی به برچسب‌های دامنه هدف و داده‌های مبدأ، غیرقابل اعتماد بودن سیگنال‌های خودنظارتی و شبه‌برچسب‌ها، خطر انباشت خطا در طول زمان، فراموشی فاجعه‌بار دانش مبدأ، پیچیدگی همزمان طبقه‌بندی و مکانیابی در تشخیص اشیاء و ضرورت محدود نگه‌داشتن هزینه محاسباتی انطباق. ادبیات جدید سال‌های ۲۰۲۴ تا ۲۰۲۶ نشان می‌دهد که هر یک از این موارد همچنان محور پژوهش‌های فعال TTA و CTTA است و راه‌حل واحدی که بتواند همه این نیازها را به‌طور همزمان برآورده کند وجود ندارد.


در نتیجه، انجام پژوهشی با تمرکز بر بهبود روش‌های انطباق آنلاین در زمان آزمون برای تشخیص اشیاء ضروری است تا مدلی که در ابتدا روی دامنه مبدأ و به‌ویژه داده‌های مصنوعی آموزش دیده است بتواند هنگام استقرار، بدون دسترسی به داده‌های آموزشی مبدأ و بدون دریافت برچسب از دامنه هدف، با جریان‌های متغیر داده تطبیق پیدا کند. چنین روشی باید علاوه بر افزایش دقت تشخیص در دامنه‌های جدید، کیفیت سیگنال انطباق را کنترل کند، از تشدید خطاهای متوالی جلوگیری نماید، دانش مفید مدل مبدأ را حفظ کند و هزینه محاسباتی آن به اندازه‌ای باشد که امکان استفاده در محیط‌های عملیاتی و آنلاین را فراهم سازد. از این منظر، مسئله پژوهش حاضر نه صرفاً بهبود یک معیار دقت در یک مجموعه داده ثابت، بلکه حرکت به سمت آشکارسازهایی پایدار، سازگار، کم‌هزینه و قابل استفاده در محیط‌های واقعی و پویا است.

Commented [ak24] The Golden Subspace: Where Efficiency Meets Generalization in Continual Test-Time Adaptation

Commented [ak25] InsCal: Calibrated Multi-Source Fully Test-Time Prompt Tuning for Object Detection

۳-۴ - سابقه تحقیقات و مطالعات انجام گرفته :

با توجه به اهمیت مسئله تغییر توزیع داده و کاهش عملکرد مدل‌های یادگیری عمیق در شرایط خارج از توزیع آموزش، طی سال‌های اخیر مطالعات گسترده‌ای در زمینه سازگاری مدل‌ها با دامنه‌های جدید انجام شده است. مسیر توسعه این تحقیقات را می‌توان از روش‌های کلاسیک انطباق دامنه آغاز کرد و سپس با ظهور محدودیت‌های عملی، به سمت روش‌های بدون منبع، انطباق در زمان آزمون و در نهایت انطباق آنلاین و پیوسته در زمان آزمون دنبال کرد. در ادامه، مهم‌ترین مطالعات انجام‌شده در این مسیر و ارتباط آن‌ها با مسئله پژوهش حاضر بررسی می‌شوند.



شکل ۱- مقایسه تنظیمات مختلف تطبیق زمان آزمون (Test-Time Adaptation). در روش‌های اولیه مانند Fully TTA، مدل با یک توزیع آزمون ثابت و نمونه‌های مستقل سازگار می‌شود. در مقابل، Continual TTA تغییرات پیوسته توزیع داده در طول زمان را در نظر می‌گیرد. با این حال، در شرایط واقعی داده‌های آزمون معمولاً دارای همبستگی زمانی بوده و نمونه‌ها مستقل نیستند. رویکرد Practical TTA با ترکیب تغییرات توزیع و نمونه‌برداری هم‌بسته، شرایط واقعی‌تر محیط‌های آزمون را مدل می‌کند و هدف آن سازگاری پایدارتر مدل در جریان‌های داده‌ای پویا است [۱۷].

مطالعات اولیه در انطباق دامنه و کاهش شکاف توزیع

یکی از نخستین رویکردها برای مقابله با افت عملکرد مدل‌ها در دامنه‌های جدید، استفاده از روش‌های انطباق دامنه بوده است. ایده اصلی این روش‌ها کاهش اختلاف میان توزیع داده‌های دامنه مبدأ و هدف است تا مدلی که روی داده‌های مبدأ آموزش دیده، بتواند در دامنه هدف نیز عملکرد مناسبی داشته باشد.

در بسیاری از روش‌های اولیه، فرض می‌شد که داده‌های مبدأ دارای برچسب و داده‌های هدف بدون برچسب در دسترس هستند. این تنظیم که با عنوان تطبیق دامنه بدون نظارت^۷ شناخته می‌شود، تلاش می‌کند با استفاده از داده‌های بدون برچسب دامنه هدف، بازنمایی‌های استخراج‌شده توسط مدل را میان دو دامنه هم‌راستا کند.

یکی از مسیرهای مهم در UDA، استفاده از روش‌های مبتنی بر هم‌ترازی ویژگی‌ها بود. در این روش‌ها تلاش می‌شود فاصله آماری میان ویژگی‌های استخراج‌شده از دو دامنه کاهش یابد. روش‌هایی مانند Deep Domain Confusion و Maximum Mean Discrepancy نشان دادند که می‌توان با نزدیک کردن توزیع ویژگی‌های دو دامنه، قابلیت تعمیم مدل را افزایش داد [۲۵].

با گسترش استفاده از شبکه‌های عمیق در وظایف بینایی ماشین، روش‌های مبتنی بر یادگیری تخصصی نیز مورد توجه قرار گرفتند. در این روش‌ها، یک شبکه استخراج‌کننده ویژگی تلاش می‌کند ویژگی‌هایی تولید کند که یک شبکه تشخیص دامنه نتواند تفاوت میان داده‌های مبدأ و هدف را تشخیص دهد. Ganin و همکاران با معرفی Domain-Adversarial Neural Network (DANN) نشان دادند که می‌توان با استفاده از آموزش تخصصی، ویژگی‌هایی مستقل‌تر از دامنه ایجاد کرد [۲۶]. اگرچه این روش‌ها توانستند شکاف دامنه را در بسیاری از مسائل کاهش دهند، اما یک محدودیت بنیادی داشتند: نیاز به دسترسی هم‌زمان به داده‌های مبدأ و هدف در زمان انطباق. این محدودیت در کاربردهای واقعی، به‌خصوص در شرایطی که داده‌های مبدأ حجیم، محرمانه یا غیرقابل انتقال هستند، استفاده از این روش‌ها را دشوار می‌کند.

مطالعات انجام شده در انطباق دامنه برای تشخیص اشیا

در مقایسه با دسته‌بندی تصویر، مسئله انطباق دامنه در تشخیص اشیا پیچیدگی بیشتری دارد؛ زیرا مدل علاوه بر تعیین کلاس، باید موقعیت مکانی اشیا را نیز پیش‌بینی کند. بنابراین تغییر دامنه می‌تواند هم ویژگی‌های معنایی و هم ویژگی‌های مکانی اشیا را تحت تأثیر قرار دهد. Chen و همکاران در پژوهش Domain Adaptive Faster R-CNN for Object Detection in the Wild یکی از مطالعات بنیادی در این زمینه را ارائه کردند. آن‌ها نشان دادند که تغییر دامنه در تشخیص اشیا می‌تواند هم در سطح تصویر و هم در سطح نمونه‌شیء رخ دهد و به همین دلیل، انطباق باید هر دو سطح را در نظر بگیرد. روش ارائه‌شده با استفاده از شبکه‌های انطباق دامنه در سطح تصویر و نمونه تلاش کرد ویژگی‌های استخراج‌شده توسط آشکارساز Faster R-CNN را میان دو دامنه هم‌تراز کند [۱۱].

⁷ Unsupervised Domain Adaptation (UDA)

پس از آن، روش‌های مبتنی بر مدل معلم - دانش‌آموز و شبه‌برچسب‌گذاری به یکی از مسیرهای اصلی انطباق تشخیص اشیاء تبدیل شدند. Deng و همکاران در روش Unbiased Mean Teacher for Cross-Domain Object Detection نشان دادند که استفاده از یک مدل معلم پایدار برای تولید شبه‌برچسب‌های باکیفیت‌تر می‌تواند فرآیند انتقال دانش به مدل دانش‌آموز را بهبود دهد. این روش با کاهش سوگیری ناشی از نمونه‌های با اطمینان پایین، عملکرد تشخیص اشیاء را در دامنه هدف افزایش داد [۱۲].

روش Contrastive Mean Teacher نیز با اضافه کردن یادگیری کنتراستی تلاش کرد فاصله میان نمونه‌های مشابه در دو دامنه را کاهش داده و بازنمایی‌های مقاوم‌تری ایجاد کند [۵].

با وجود موفقیت این روش‌ها، آن‌ها همچنان به داده‌های مبدأ در مرحله آموزش یا انطباق وابسته هستند. بنابراین، در شرایطی که داده‌های مبدأ پس از آموزش مدل در دسترس نباشند، نیاز به روش‌های جدیدتر احساس شد.

مطالعات انجام شده در Source-Free Domain Adaptation

برای رفع محدودیت وابستگی به داده‌های مبدأ، مفهوم Source-Free Domain Adaptation (SFDA) مطرح شد. در این تنظیم، تنها مدل آموزش‌دیده روی دامنه مبدأ و داده‌های بدون برچسب دامنه هدف در دسترس هستند و داده‌های اصلی مبدأ در فرآیند انطباق استفاده نمی‌شوند. Liang و همکاران با معرفی روش Source Hypothesis Transfer (SHOT) از نخستین مطالعات مهم در این زمینه بودند. آن‌ها نشان دادند که می‌توان بدون دسترسی به داده‌های مبدأ و تنها با استفاده از مدل آموزش‌دیده، بازنمایی‌های استخراج‌شده را برای دامنه هدف تطبیق داد. ایده اصلی این روش، جداسازی بخش استخراج ویژگی و طبقه‌بندی و سپس تطبیق ویژگی‌ها با استفاده از داده‌های هدف بدون برچسب بود [۱۳].

پس از SHOT، مطالعات متعددی در حوزه SFDA انجام شد که هدف آن‌ها بهبود کیفیت انطباق بدون استفاده از داده‌های مبدأ بود. روش‌هایی مانند NRC، AdaContrast و دیگر روش‌های مبتنی بر خوشه‌بندی، یادگیری کنتراستی و خودآموزی نشان دادند که می‌توان با استفاده از ساختار داخلی داده‌های هدف، مدل را به سمت توزیع جدید هدایت کرد.

با این حال، بسیاری از روش‌های SFDA همچنان یک فرض مهم دارند: مجموعه‌ای از داده‌های هدف باید پیش از استفاده نهایی مدل در اختیار الگوریتم قرار گیرد تا فرآیند انطباق به‌صورت آفلاین انجام شود. این موضوع باعث شد که توجه پژوهشگران به سمت شرایطی جلب شود که داده‌های هدف به‌صورت تدریجی و همزمان با استفاده از مدل وارد سیستم می‌شوند.


مطالعات اولیه در Test-Time Adaptation

با هدف کاهش وابستگی مدل به شرایط ثابت آموزش، مفهوم Test-Time Adaptation (TTA) مطرح شد. در این چارچوب، مدل پس از آموزش اولیه، هنگام مرحله آزمون و با استفاده از داده‌های بدون برچسب ورودی، خود را با شرایط جدید سازگار می‌کند.

یکی از مطالعات تأثیرگذار در این حوزه، روش Tent: Fully Test-Time Adaptation by Entropy Minimization توسط Wang و همکاران است. این روش نشان داد که می‌توان تنها با کمینه‌سازی آنترپی خروجی مدل روی داده‌های آزمون و به‌روزرسانی پارامترهای affine لایه‌های Batch Normalization، بدون استفاده از داده‌های مبدأ، مدل را با توزیع جدید تطبیق داد [۱۰].

اگرچه TENT نشان داد که انطباق در زمان آزمون امکان‌پذیر است، اما محدودیت‌هایی نیز داشت. این روش عمدتاً روی دسته‌بندی تصویر آزمایش شد و فرض می‌کرد که تغییرات دامنه نسبتاً پایدار هستند. همچنین، استفاده از تنها نمونه‌های جاری و نبود سازوکارهای حفظ دانش گذشته می‌توانست در شرایط طولانی‌مدت موجب ناپایداری شود.

در ادامه، روش‌هایی مانند EATA تلاش کردند این مشکلات را کاهش دهند. Niu و همکاران با معرفی EATA نشان دادند که همه نمونه‌های آزمون برای انطباق مفید نیستند و انتخاب نمونه‌های مناسب می‌تواند علاوه بر کاهش هزینه محاسباتی، از تغییرات مخرب مدل جلوگیری کند. همچنین، استفاده از منظم‌سازی برای حفظ پارامترهای مهم مدل، مسئله فراموشی را کاهش داد [۶].



شکل ۳ - نتایج حاصل از استفاده از adaptor module که همانطور که مشاهده می شود در فضا ابری و تاریک نتایج بهتری بدست آورده است [8]


مطالعات انجام شده در Continual Test-Time Adaptation و Online Test-Time Adaptation

با افزایش توجه به کاربردهای واقعی، مشخص شد که بسیاری از روش‌های TTA هنوز برای شرایط عملیاتی واقعی کافی نیستند؛ زیرا در محیط واقعی، داده‌ها معمولاً به صورت یک جریان پیوسته وارد سیستم می‌شوند و امکان مشاهده دوباره کامل داده‌های آزمون وجود ندارد. در این شرایط، مفهوم Online Test-Time Adaptation (OTTA) مطرح شد. برخلاف تنظیمات آفلاین، در OTTA مدل باید هنگام دریافت داده‌های جدید، همزمان با انجام پیش‌بینی، خود را نیز به‌روزرسانی کند.

Wang و همکاران در روش Continual Test-Time Domain Adaptation (CoTTA) یکی از نخستین مطالعات مهم در این حوزه را ارائه کردند. آن‌ها نشان دادند که روش‌های معمول TTA در مواجهه با تغییرات پیوسته دامنه دچار دو مشکل اصلی می‌شوند: انباشت خطا و فراموشی فاجعه‌بار. برای مقابله با این مشکلات، CoTTA از ترکیب مدل معلم میانگین‌گیری‌شده، افزایش داده و بازگردانی تصادفی بخشی از پارامترها استفاده کرد [۳].

پس از CoTTA، روش‌های متعددی برای بهبود پایداری CTTA ارائه شدند. RotTA با تمرکز بر داده‌های وابسته به زمان و توزیع‌های پویا، استفاده از حافظه و نمونه‌برداری متوازن را برای حفظ تنوع داده پیشنهاد کرد [۱۷]. همچنین، روش SAR تلاش کرد با اصلاح فرآیند بهینه‌سازی و جلوگیری از انطباق بیش از حد، پایداری مدل را در شرایط دشوار افزایش دهد [۱۸].

با این حال، مطالعات بعدی نشان دادند که حتی روش‌های پیشرفته CTTA نیز در بازه‌های طولانی ممکن است دچار افت عملکرد شوند. پژوهش RDumb با بررسی بلندمدت روش‌های CTTA نشان داد که بسیاری از الگوریتم‌ها در مواجهه با توالی‌های طولانی داده، به دلیل انباشت خطا و رانش مدل، عملکرد خود را از دست می‌دهند [۱۹].



شکل ۳ - مقایسه روش‌های مختلف در محیط آزمون با دامنه‌های پیوسته در حال تغییر. مدل اولیه با تصاویر سالم آموزش دیده و در زمان آزمون به ترتیب با Impulse Noise، Motion، Contrast، Pixelate، و مجدداً تصاویر Clean مواجه می‌شود. روش Direct-Test به دلیل عدم تطبیق با تغییر توزیع داده، در دامنه‌های مخدوش‌شده با افت محسوس mAP مواجه است. Full-Finetuning قادر به بازیابی بخشی از عملکرد است، اما پس از هر تغییر دامنه به تعداد زیادی نمونه برای سازگاری نیاز دارد. در مقابل، روش پیشنهادی مقاله (ours) با استفاده از یک Lightweight Adaptor پس از هر تغییر دامنه در مدت کوتاهی عملکرد خود را بازیابی می‌کند. نسخه Ours-Skip نیز با حذف گام‌های غیرضروری تطبیق، عملکردی بسیار نزدیک به روش اصلی ارائه می‌دهد و در نتیجه هزینه محاسباتی تطبیق بر خط را کاهش می‌دهد. این نتایج ضرورت طراحی روش‌های تطبیق سریع و کارآمد برای محیط‌های آزمون با تغییرات مداوم توزیع داده را نشان می‌دهند [8].

مطالعات جدید در Online Test-Time Adaptation برای تشخیص اشیا

اگرچه بخش زیادی از مطالعات اولیه TTA روی دسته‌بندی تصویر انجام شده‌اند، انتقال این ایده‌ها به تشخیص اشیا همچنان یک مسئله باز است. دلیل اصلی این موضوع، پیچیدگی ساختار خروجی آشکارسازها و نیاز همزمان به حفظ دقت طبقه‌بندی و مکانیابی است. VS و همکاران در پژوهش Towards Online Domain Adaptive Object Detection یکی از مطالعات اولیه در زمینه انطباق آنلاین آشکارسازها را ارائه کردند. آن‌ها نشان دادند که روش‌های آفلاین انطباق دامنه برای شرایطی که داده‌ها به‌صورت جریان وارد می‌شوند مناسب نیستند و آشکارساز باید بتواند هنگام استقرار خود را با تغییرات محیطی سازگار کند [۹].

Ruan و Tang در پژوهش Fully Test-Time Adaptation for Object Detection مسئله استفاده از TTA در تشخیص اشیا را بررسی کردند. آن‌ها نشان دادند که استفاده مستقیم از معیارهای رایج مانند اطمینان طبقه‌بندی برای انتخاب شبه‌برچسب‌ها کافی نیست، زیرا کیفیت مکانیابی جعبه‌های محدودکننده نیز باید در فرآیند انطباق در نظر گرفته شود [۴].




شکل ۴ - چارچوب کلی تطبیق پیوسته در زمان آزمون برای تشخیص اشیا. در این سناریو، یک مدل تشخیص‌دهنده که در مرحله آموزش آفلاین بر روی دامنه مبدأ یاد گرفته است، در زمان آزمون بدون دسترسی به داده‌های آموزشی اولیه با محیط‌هایی مواجه می‌شود که به‌صورت پیوسته تغییر می‌کنند. هدف روش‌های تطبیق زمان آزمون، سازگار کردن مدل با این تغییرات در حین استنتاج است. با توجه به محدودیت منابع محاسباتی در کاربردهای مانند خودروهای خودران و پهپادها، به‌روزرسانی کامل مدل می‌تواند هزینه‌بر باشد. از این رو، رویکردهای جدید تلاش می‌کنند تنها بخش‌های حساس و قابل تطبیق مدل را به‌روزرسانی کرده و بخش‌های پایدار و مستقل از دامنه را حفظ کنند که باعث کاهش هزینه محاسباتی، امکان سازگاری می‌شود [۷].

Yoo و همکاران در پژوهش What, How, and When Should Object Detectors Update in Continually Changing Environments مسئله CTTA برای آشکارسازهای اشیا را از منظر سه سؤال اساسی بررسی کردند: چه بخشی از مدل باید به‌روزرسانی شود،

چگونه باید به‌روزرسانی انجام شود و چه زمانی مدل باید تغییر کند. این پژوهش نشان داد که طراحی فرآیند انطباق برای آشکارسازها تنها به انتخاب تابع زیان محدود نیست، بلکه کنترل محل و زمان به‌روزرسانی نیز اهمیت بنیادی دارد [۸].

در ادامه، Wang و همکاران در CVPR سال ۲۰۲۵ مسئله Efficient Test-Time Adaptive Object Detection via Sensitivity-Guided Pruning را مطرح کردند. آن‌ها نشان دادند که علاوه بر افزایش دقت انطباق، کاهش هزینه محاسباتی یکی از چالش‌های اصلی استقرار CTTA در تشخیص اشیاء است و پیشنهاد کردند تنها بخش‌های حساس به تغییر دامنه به‌روزرسانی شوند [۷].

همچنین Li و همکاران در ICCV سال ۲۰۲۵ مسئله Continual Adaptation for Object Detection in Dynamic Scenarios را بررسی کردند و با استفاده از تولید پارامترهای وابسته به محیط تلاش کردند میان سازگاری با شرایط جدید و حفظ دانش قبلی تعادل ایجاد کنند [۲۰].



شکل ۵- بررسی تأثیر حذف کانال‌های ویژگی بر عملکرد مدل درون‌دامنه و میان‌دامنه. این نمودار نشان می‌دهد که کانال‌های مختلف ویژگی تأثیر یکسانی بر سازگاری مدل ندارند. حذف برخی کانال‌ها باعث بهبود عملکرد در دامنه جدید می‌شود، در حالی که حذف برخی دیگر موجب کاهش دقت می‌گردد. این تحلیل اهمیت شناسایی ویژگی‌های وابسته و مستقل از دامنه را برای تطبیق انتخابی مدل در زمان آزمون نشان می‌دهد. محور افقی تغییر عملکرد در حالت میان‌دامنه (Cross-Domain) و محور عمودی تغییر عملکرد در حالت درون‌دامنه (In-Domain) را پس از حذف یک کانال مشخص نشان می‌دهد. نقاط قرارگرفته در نواحی مثبت نشان‌دهنده کانال‌هایی هستند که حذف آن‌ها موجب بهبود عملکرد می‌شود، در حالی که نقاط منفی بیانگر کانال‌هایی هستند که حذف آن‌ها باعث کاهش عملکرد می‌گردد [۷].

با توجه به تنوع تنظیمات موجود در ادبیات انطباق در زمان آزمون، مطالعات مرتبط را نمی‌توان صرفاً بر اساس عنوان روش با یکدیگر مقایسه کرد؛ زیرا بخشی از روش‌ها برای دسته‌بندی تصویر، بخشی برای انطباق برخط دامنه و بخشی به‌طور مستقیم برای انطباق پیوسته آشکارسازهای اشیاء ارائه شده‌اند. از این‌رو، در جدول زیر مهم‌ترین مطالعات از منظر نوع انطباق، سازوکار به‌روزرسانی مدل، کنترل انباشت خطا، جلوگیری از فراموشی و محدودیت‌های مرتبط با مسئله پژوهش حاضر مقایسه شده‌اند [۳]، [۴]، [۶]، [۷]، [۸]، [۹]، [۱۰]، [۱۷]، [۲۰].

محدودیت و ارتباط با پژوهش حاضر	کنترل انباشت خطا و فراموشی	ایده و روش اصلی	نوع / تنظیم انطباق	پژوهش
روش بنیادی TTA است، اما عمدتاً برای دسته‌بندی طراحی شده و کیفیت مکانیابی جعبه‌ها را در نظر نمی‌گیرد	کنترل صریحی برای فراموشی یا انباشت خطا ندارد؛ محدود کردن پارامترهای قابل آموزش تا حدی از تغییر شدید مدل جلوگیری می‌کند	کمینه‌سازی آنتروپی پیش‌بینی‌ها و به‌روزرسانی پارامترهای affine لایه‌های نرمال‌سازی در زمان آزمون	TTA عمومی	TENT – Wang et al. [۱۰] (۲۰۲۱)
یکی از پایه‌های اصلی CTTA، ولی به‌روزرسانی وسیع مدل برای آشکارسازها می‌تواند پرهزینه باشد. بیشتر در کلاس بندی استفاده می‌شود.	مدل معلم باعث کاهش نوسان شبه برچسب‌ها شده و stochastic Restoration برای کاهش فراموشی استفاده می‌شود	استفاده از مدل معلم میانگین‌گیری شده، پیش‌بینی تحت افزایش داده و بازگردانی تصادفی بخشی از پارامترها به مقادیر مدل مبدأ	CTTA عمومی	CoTTA – Wang et al. [۳] (۲۰۲۲)

[ak27] Commented: فقط تعداد کمی از پارامترها، یعنی پارامترهای affine لایه‌های Batch Normalization مثل γ و β ، در زمان آزمون به‌روزرسانی می‌شوند؛ بقیه وزن‌های شبکه ثابت می‌مانند.

پس چون بخش بزرگی از مدل دست‌نخورده باقی می‌ماند، احتمال اینکه مدل با چند نمونه جدید بیش از حد تغییر کند و دانشی که قبلاً یاد گرفته خراب شود کمتر است.

[ak27] Commented: منظور از «پیش‌بینی تحت افزایش داده» در CoTTA این است که مدل فقط یک نسخه خام از تصویر را نمی‌بیند، بلکه چند نسخه تغییر یافته از همان تصویر هم به مدل داده می‌شود؛ مثلاً با تغییرات تصویری مثل flip، crop یا تغییرات ظاهری.

بعد مدل معلم روی این نسخه‌های مختلف پیش‌بینی انجام می‌دهد و این پیش‌بینی‌ها با هم میانگین‌گیری یا تجمیع می‌شوند تا یک خروجی پایدارتر به‌دست آید.

ایده اصلی این است که اگر یک پیش‌بینی فقط به‌خاطر یک تغییر جزئی در تصویر عوض شود، احتمالاً خیلی قابل اعتماد نیست. اما اگر روی چند نسخه متفاوت تصویر تقریباً یک نتیجه بدهد، می‌توان بیشتر به آن اعتماد کرد.

در CoTTA منظور میانگین‌گرفتن خود label نیست؛ چیزی که میانگین گرفته می‌شود بردار احتمال خروجی مدل روی چند نسخه augment شده از همان تصویر است.


EATA – Niu et al. [۶] (۲۰۲۲)	TTA کارآمد / قابل استفاده در جریان پیوسته	انتخاب نمونه‌های قابل اعتماد و غیر تکراری و انجام انطباق فقط روی نمونه‌های مناسب؛ استفاده از منظم‌سازی مبتنی بر Fisher	حذف نمونه‌های نامطمئن انباشت خطا را کاهش می‌دهد و Fisher regularization پارامترهای مهم مدل مبدأ را حفظ می‌کند	هم‌زمان به اعتمادپذیری، کارایی و فراموشی می‌پردازد؛ با این حال معیارهای آن عمدتاً برای دسته‌بندی طراحی شده‌اند
RoTTA – Yuan et al. [۱۷] (۲۰۲۳)	CTTA در جریان‌های پویا و هم‌بسته زمانی	استفاده از حافظه متوازن، نرمال‌سازی مقاوم و ساختار معلم-دانش‌آموز با توجه به عدم قطعیت و تازگی نمونه‌ها	حافظه متوازن مانع غالب‌شدن نمونه‌های اخیر شده و مدل معلم پایداری زمانی ایجاد می‌کند	برای داده‌های ویدئویی و جریانی مهم است، ولی توسعه حافظه برای تشخیص اشیاء نیازمند معیار کیفیت جعبه نیز هست
Towards Online Domain Adaptive Object Detection [۹] (۲۰۲۳)	Online DAOD؛ نه CTTA سخت‌گیرانه	استفاده از حافظه و ساختار Transformer برای نگهداری الگوهای نماینده دامنه هدف و یادگیری روابط کنتراستی در جریان داده	اطلاعات تاریخی وابستگی مدل به دسته فعلی را کاهش می‌دهد	برای بخش Synthetic→Real و حافظه بسیار مرتبط است، اما پروتکل آن دقیقاً با source-free CTTA یکسان نیست
Fully Test-Time Adaptation for Object Detection – Ruan & Tang (۲۰۲۴) [۴]	TTA ویژه تشخیص اشیاء؛ غیر پیوسته یا کمتر متمرکز بر CTTA بلندمدت	پالایش شبه‌برچسب‌ها با استفاده هم‌زمان از اطمینان طبقه‌بندی و اطلاعات مرتبط با IoU و کیفیت مکانیایی	مانع ورود جعبه‌های با مکانیایی ضعیف به خودآموزی می‌شود، حتی اگر اطمینان طبقه‌بندی بالا باشد	برای مسئله اصلی پژوهش حاضر بسیار مهم است، زیرا نشان می‌دهد confidence طبقه‌بندی به‌تنهایی کافی نیست؛ کنترل بلندمدت فراموشی محدود است
What, How, and When Should Object Detectors Update in Continually Changing Test Domains? – Yoo et al. [۸] (۲۰۲۴)	CTTA مستقیم برای تشخیص اشیاء	افزودن آداپتورهای سبک و مستقل از معماری، ثابت نگه‌داشتن مدل از پیش‌آموزش‌دیده، هم‌ترازی ویژگی‌های کلاس‌محور و تعیین زمان لازم برای به‌روزرسانی	ثابت نگه‌داشتن بخش اصلی مدل رانش پارامترها را کاهش می‌دهد؛ سازوکار «چه زمانی به‌روزرسانی شود» از به‌روزرسانی‌های غیرضروری جلوگیری می‌کند	یکی از نزدیک‌ترین روش‌ها به مسئله پژوهش حاضر؛ ممکن است ثابت نگه‌داشتن backbone انعطاف‌پذیری در تغییرات شدید را محدود کند
Efficient Test-Time Adaptive Object Detection via Sensitivity-Guided Pruning – Wang et al. [۷] (۲۰۲۵)	CTTA مستقیم و کارآمد برای تشخیص اشیاء	اندازه‌گیری حساسیت کانال‌ها به شکاف دامنه در سطح تصویر و شیء، هرس کانال‌های حساس و فعال‌سازی مجدد تصادفی آنها	فعال‌سازی مجدد امکان بازیابی از تصمیم هرس نامناسب را فراهم می‌کند و ویژگی‌های نسبتاً پایدار حفظ می‌شوند	مستقیماً با هدف کاهش هزینه محاسباتی پژوهش حاضر مرتبط است، ولی کیفیت معیار حساسیت نقش تعیین‌کننده دارد
Environment- Conditional Parameter Generation – Li et al. [۲۰] (۲۰۲۵)	CTTA مستقیم برای تشخیص اشیاء	استفاده از آداپتورهای مبتنی بر LoRA و مسیرهای دامنه‌ناورد/دامنه‌ویژه و تولید پارامترهای انطباق متناسب با محیط	جداسازی دانش عمومی و تغییرات وابسته به محیط باعث کاهش تخریب مدل مبدأ می‌شود	گزینه مهم برای طراحی انطباق پارامتر-کارآمد و تعادل پایداری-انعطاف‌پذیری؛ نیازمند ساختار و آماده‌سازی اضافه است
AMROD [۲۷]	CTTA مستقیم و Source-Free برای تشخیص اشیاء	ترکیب Mean Teacher، افزایش داده ضعیف/قوی، شبه‌برچسب‌گذاری، یادگیری کنتراستی سطح شیء و Adaptive Monitoring	پایش تطبیقی از به‌روزرسانی نامناسب جلوگیری می‌کند و Adaptive Randomized Restoration پارامترها را به سمت دانش مبدأ بازمی‌گرداند	از نزدیک‌ترین کارها به ترکیب «کیفیت شبه‌برچسب + کنترل انباشت خطا + جلوگیری از فراموشی» در موضوع پایان‌نامه است

STFAR – Self- Training with Feature Alignment Regularization [۲۸]	TTA ویژه تشخیص اشیا	ساختار معلم-دانش آموز همراه با هم‌ترازی ویژگی سراسری و کنتراست foreground مبتنی بر prototype	مدل معلم و لنگرهای ویژگی مبدأ از رانش ناشی از شبه‌برچسب‌های نادرست می‌کاهند	برای طراحی بخش کنترل انباشت خطا بسیار مفید است، ولی نگهداری آمار/پروتوتایپ‌های مبدأ ممکن است با تعریف بسیار سخت‌گیرانه source-free محدودیت داشته باشد
--	------------------------	--	--	--

دیتاست‌ها و روش‌ها و سناریوهای ارزیابی

برای ارزیابی چارچوب پیشنهادی، مناسب‌ترین طراحی آن است که ترکیبی از تغییرات مصنوعی کنترل‌شده، شرایط واقعی نامساعد، تغییرات گسسته، تغییرات تدریجی و سناریوی بلندمدت استفاده شود؛ به‌طور مشخص، بنچمارک‌های COCO→COCO-C، Cityscapes→Cityscapes-C [۳۱]، [۳۰]، [۳۱]، Cityscapes→ACDC [۲۹]، SHIFT-Discrete [۳۲] و SHIFT-Continuous [۳۲] و UAVDT→UAVDT-C در مطالعات اصلی CTTA برای آشکارسازی شیء مورد استفاده قرار گرفته‌اند. مقاله یو و همکاران در CVPR سال ۲۰۲۴ این مسئله را برای COCO-C و SHIFT صورت‌بندی کرد، مقاله SGP در CVPR سال ۲۰۲۵ ارزیابی دودورهای Cityscapes-C، ACDC و UAVDT-C را ارائه داد، و مقاله لی و همکاران در ICCV سال ۲۰۲۵ نتایج جدیدتری برای COCO-C و SHIFT گزارش کرد. در این پروپوزال پیشنهاد می‌شود Cityscapes→Cityscapes-C و Cityscapes→ACDC به‌عنوان آزمایش‌های اصلی بلندمدت، SHIFT [۳۲] به‌عنوان آزمایش تغییر گسسته و تدریجی، COCO-C به‌عنوان آزمایش بزرگ‌مقیاس چندکلاسه، در نظر گرفته شوند. این طراحی با صورت‌بندی فعلی پروپوزال، یعنی سازگارسازی آنلاین، بدون داده مبدأ، روی جریان پیوسته داده و بدون بازنشانی مدل میان دامنه‌ها، سازگار است [۳۳].

در پروتکل SGP [۷]، همه سه آزمایش Cityscapes-C، ACDC [۳۳] و UAVDT-C [۳۴] با Faster R-CNN و ResNet-۱۸ انجام شده‌اند، تنها ضرایب مقیاس‌پذیر لایه‌های BatchNorm در زمان آزمون سازگار می‌شوند، جریان هدف برای ۱۰ دور تکرار می‌شود، و معیار اصلی mAP@۵۰ همراه با FLOPs است. این یک مزیت مهم برای پروپوزال حاضر دارد، زیرا علاوه بر دقت، امکان ارزیابی مستقیم انباشت خطا، فراموشی در بلندمدت و هزینه محاسباتی را فراهم می‌کند. از سوی دیگر، نتایج COCO-C [۲۹] و SHIFT در مقاله یو با Faster R-CNN و دو backbone ResNet-۵۰ و Swin-T ارائه شده‌اند؛ مقاله نشان می‌دهد روش مبتنی بر آداپتور می‌تواند بدون به‌روزرسانی کامل backbone، در COCO-C تا حدود ۴/۹ واحد mAP و در SHIFT تا حدود ۷/۹ واحد mAP بهبود ایجاد کند.



شکل ۶-مقایسه کیفی روش‌های مختلف قطعه‌بندی پاناپتیک روی چند نمونه مجموعه داده ACDC. تصاویر شامل شرایط نامساعد و متغیر محیطی مانند مه، شب، باران و برف هستند و خروجی روش‌های مختلف قطعه‌بندی در کنار تصویر اصلی نمایش داده شده است. تفاوت عملکرد مدل‌ها در این شرایط نشان می‌دهد که تغییرات آب‌وهوایی و روشنایی می‌توانند باعث تغییر توزیع داده و کاهش قابلیت تعمیم مدل‌های بینایی ماشین شوند؛ موضوعی که ضرورت استفاده از روش‌های سازگاری با دامنه در محیط‌های واقعی را برجسته می‌کند [۳۳].

جدول بنچمارک‌های اصلی

Commented [ak29]: هر دو اینا توی مقاله سایت شده shift هستن

Commented [ak30]: و UAVDT-C به‌عنوان آزمون تعمیم بین

سناریوهای زمینی و هوایی

Commented [ak31]: ACDC: The Adverse Conditions Dataset with Correspondences for Robust Semantic Driving Scene Perception

Commented [ak32]: Efficient Test-time Adaptive Object Detection via Sensitivity-Guided Pruning

نکته مهم برای تفسیر جدول منظور از «mAP مدل بدون انطباق» در جدول زیر، عملکرد Direct-Test است؛ یعنی مدل آموزش‌دیده روی مبدأ مستقیماً و بدون هیچ سازگارسازی روی جریان هدف ارزیابی شده است، نه mAP آن روی داده مبدأ. همچنین اعداد مقالات مختلف تنها زمانی باید مستقیماً با یکدیگر مقایسه شوند که معماری، تعریف mAP و پروتکل جریان هدف یکسان باشد؛ به‌ویژه مقاله SGP صراحتاً از mAP@50 استفاده می‌کند [۷].

انتخاب بنچمارک‌ها و معیارهای ارزیابی

در این پژوهش، ارزیابی در چارچوب سازگارسازی پیوسته و بدون دسترسی به داده مبدأ در زمان آزمون انجام خواهد شد. ابتدا آشکارساز با استفاده از داده‌های برچسب‌دار دامنه مبدأ آموزش داده می‌شود و پس از پایان این مرحله، در فرایند سازگارسازی هیچ تصویر یا برچسبی از داده آموزشی مبدأ در اختیار الگوریتم قرار نخواهد گرفت؛ تنها پارامترهای مدل آموزش‌دیده و، در صورت نیاز روش، اطلاعات از پیش ذخیره‌شده‌ای که از داده خام مبدأ مستقل باشند قابل استفاده خواهند بود. نمونه‌های هدف به‌صورت ترتیبی و بدون برچسب وارد مدل می‌شوند و برچسب‌های حقیقی هدف صرفاً برای ارزیابی نهایی مورد استفاده قرار می‌گیرند و در هیچ مرحله‌ای در به‌روزرسانی مدل دخالت ندارند. مطابق تعریف CTTA، مدل هنگام انتقال از یک دامنه هدف به دامنه بعدی بازنشانی نمی‌شود؛ بنابراین اگر (θ_t) پارامترهای مدل در زمان t و B_t دسته ورودی بدون برچسب باشد، به‌روزرسانی به‌صورت $\theta_{t+1} = \text{Adapt}(\theta_t, B_t)$ انجام می‌شود و نه به‌صورت $\text{Adapt}(\theta_0, B_t)$ این شرط سبب می‌شود اثرات انباشت خطا، انتقال دانش میان دامنه‌ها و فراموشی فاجعه‌بار در طول زمان قابل اندازه‌گیری باشند. این صورت‌بندی با تعریف CTTA در CoTTA و پروتکل‌های CTTA-OD سازگار است و در پیاده‌سازی سناریوهای ارزیابی و در معرض دیتاست‌ها و یا دیتاست مشخص با متغیرهای متفاوت باید در نظر گرفته شود.

معیارهای ارزیابی

- دقت آشکارسازی: mAP متوسط کل جریان، mAP هر دامنه، و mAP هر دور؛ در صورت امکان، $\text{mAP}@50:95$ نیز جداگانه ارائه شود تا ارزیابی به یک آستانه IoU محدود نماند.
- سود سازگارسازی: $\Delta \text{mAP} = \text{mAP}_{\text{CTTA}} - \text{mAP}$ میزان بهبودی که در MAP در تطبیق رخ داده است.
- فراموشی: علاوه بر F_{src} می‌توان روند mAP را در دوره‌های ۱، ۵ و ۱۰ گزارش کرد. SGP دقیقاً مقادیر دوره‌های ۱، ۵ و ۱۰ را برای Cityscapes-C، ACDC و UAVDT-C ارائه می‌کند؛ این نحوه گزارش برای تشخیص افت یا بهبود تدریجی بسیار مناسب است.
- پایداری نسبت به ترتیب: ترتیب استاندارد باید برای مقایسه با ادبیات حفظ شود و سپس چند ترتیب جایگزین با همان دامنه‌ها اجرا شود؛ میانگین $\pm$ انحراف معیار MAP در این ترتیب‌ها به‌عنوان شاخص استحکام ترتیبی گزارش شود.
- هزینه محاسباتی: FLOPs کل، FLOPs مربوط به forward و backward، تعداد به‌روزرسانی‌ها، FPS، تأخیر متوسط هر نمونه و حافظه GPU برای نشان دادن هزینه محاسباتی ارائه می‌شود.
- نتیجه بازگشت به مبدأ: بعد از آخرین دامنه هدف، مدل نهایی بدون هیچ به‌روزرسانی روی داده مبدأ ارزیابی شود. افت کم mAP در این مرحله نشان می‌دهد روش هنگام یادگیری دامنه‌های جدید، دانش مبدأ را بهتر حفظ کرده است؛ این سنجش مستقیماً با مسئله فراموشی فاجعه‌بار در CTTA مرتبط است.

نحوه استفاده از این دیتاست‌ها:

- Cityscapes→Cityscapes-C: مناسب‌ترین بنچمارک اصلی برای آزمایش کنترل‌شده بلندمدت است، زیرا SGP چهار تغییر مشخص را در شدت حداکثری به‌صورت Contrast→Defocus→Snow→Motion طی ۱۰ دور تکرار کرده و Direct-Test برابر ۴۰۵ و روش پیشنهادی خود را برابر ۱۱۰۴ برای mAP@50 گزارش کرده است. این اختلاف بزرگ، فضای کافی برای تحلیل کیفیت سازگارسازی و انباشت خطا فراهم می‌کند.
- Cityscapes→ACDC: باید در کنار Cityscapes-C قرار گیرد، زیرا ACDC شامل شرایط واقعی Night، Fog، Rain و Snow است؛ در پروتکل SGP ترتیب Snow→Rain→Night→Fog طی ۱۰ دور اجرا می‌شود و عملکرد از ۲۲۰۰ به ۲۴۰۲ mAP@50 می‌رسد. بنابراین این بنچمارک مشخص می‌کند که بهبود روش روی خرابی‌های مصنوعی به محیط واقعی نیز منتقل می‌شود یا خیر.
- SHIFT-Discrete: برای ارزیابی واکنش مدل به تغییر ناگهانی شرایط توصیه می‌شود. ترتیب Cloudy→Overcast→Foggy→Rainy→Dawn→Night→Clear شامل تغییرات هم در آب‌وهوا و هم در روشنایی است؛

Commented [ak33]: بگو این فضای مصنوعی بوده الان می‌خوایم کاری کنیم برای فضای واقعی

Commented [ak34]: این جمله بده و انگار داره به دور روی سی ترین میشه و بعد میاد اینجا در حالی که باید می‌گفتی که من می‌خوام ببینم روی محیط واقعی هم کار می‌کنه یا نه

در مقاله یو، Direct-Test برابر ۳۵،۹ به ۳۸،۵ و برای ۵۰-ResNet-T/Swin و Ours-Skip برابر ۳۹،۰ به ۴۰،۶ بهبود پیدا کرده است.

- SHIFT-Continuous: برای پایان‌نامه اهمیت ویژه‌ای دارد، زیرا به‌جای فرض مرزهای کاملاً مشخص بین دامنه‌ها، شدت Fog یا Rain به‌صورت تدریجی تغییر می‌کند. مقاله اصلی SHIFT نیز این مجموعه‌داده را مشخصاً برای مطالعه تغییرات پیوسته محیط رانندگی معرفی کرده است؛ بنابراین این آزمایش نزدیک‌تر به مسئله واقعی «تشخیص زمان مناسب سازگارسازی» است.
- COCO→COCO-C: برای آزمون تعمیم در مقیاس بزرگ کاربرد دارد؛ وجود ۱۵ نوع corruption سبب می‌شود روش در برابر خانواده‌های متفاوت نویز، تاری، آب‌وهوا و تخریب دیجیتال آزمایش شود. یو و همکاران Direct-Test برابر ۱۷،۷ برای Swin-T را به ۲۲،۶ افزایش دادند و لی و همکاران برای ۵۰-ResNet مقدار ۱۷،۳ را به ۲۳،۰ رساندند؛ بنابراین این بنچمارک برای مقایسه با دو نسل از روش‌های CTTA-OD مناسب است.
- UAVDT→UAVDT-C: به‌عنوان آزمایش تعمیم توصیه می‌شود، زیرا جریان آن از تصاویر هوایی و سناریوی UAV تشکیل شده است و از نظر مقیاس اجسام و زاویه دید با Cityscapes تفاوت محسوسی دارد. SGP در این پروتکل Direct-Test برابر ۶،۴ و نتیجه نهایی ۱۴،۳ درصد برای mAP@۵۰ را گزارش می‌کند؛ یعنی افزایش ۷،۹ درصدی mAP در میانگین ده دور.

داده آموزشی مبدأ	جریان هدفCTTA	توالی پیشنهادی مواجهه	تعداد دور پیشنهادی	هدف و جنبه مورد سنجش
Cityscapes Train	Cityscapes-C	Motion → Snow → Defocus → Contrast	۱۰ دور، مطابق SGP	آزمون اصلی سازگارسازی بلندمدت؛ مناسب برای سنجش انباشت خطا، افت تدریجی عملکرد، فراموشی فاجعه‌بار و پایداری روش در مواجهه تکراری با تغییرات مصنوعی کنترل‌شده. این پروتکل دقیقاً قابلیت مقایسه با نتایج SGP را فراهم می‌کند.
Cityscapes Train	ACDC	Snow → Rain → Night → Fog	۱۰ دور	مکمل Cityscapes-C با تغییرات واقعی آب‌وهوایی و روشنایی. چون داده مبدأ در هر دو آزمایش Cityscapes است، می‌توان عملکرد روش را روی تغییر مصنوعی و واقعی با یک مدل مبدأ مشترک بررسی کرد.
SHIFT Train	SHIFT-Discrete	Cloudy → Overcast → Foggy → Rainy → Dawn → Night → Clear	۱ دور استاندارد مطابق پروتکل یو؛ علاوه بر آن، اجرای چند ترتیب جایگشت‌یافته برای آزمون حساسیت به ترتیب پیشنهاد می‌شود	ارزیابی تغییرات ناگهانی و گسسته در شرایط آب‌وهوا و زمان روز؛ قرار گرفتن Clear در انتهای توالی نیز برای بررسی توان بازیابی دانش مفید است.
SHIFT Train	SHIFT-Continuous	Clear → Foggy → Clear → Clear → Rainy → Clear	یک عبور از هر جریان حدود ۴۰۰۰ فریمی؛ اجرای مستقل هر دو مسیر	بررسی domain drift تدریجی؛ در اینجا مرز صریحی میان دامنه‌ها وجود ندارد و روش باید شدت تغییر توزیع را در طول زمان دنبال کند. این سناریو از نظر کاربردهای واقعی رانندگی خودکار بسیار مهم است.
COCO Train	COCO-C	۱۵ خرابی استاندارد به ترتیب دقیق	۱ دور استاندارد	آزمون روی آشکارسازی ۸۰ کلاس و طیف وسیعی از نویز، تاری، شرایط جوی و اختلالات دیجیتال؛ مرحله Original در انتها

جدول بعدی، سپس Original/Clean		برای اندازه‌گیری بازگشت به توزیع مبدأ و فراموشی بسیار مناسب است.
UAVDT-C	Fog → Defocus → Motion → Night	۱۰ دور
UAVDT؛ تصاویر روز روشن		بررسی اینکه چارچوب پیشنهادی صرفاً به تصاویر دوربین زمینی و Cityscapes وابسته نیست و در تصاویر هوایی UAV/، اجسام کوچک و زاویه دید متفاوت نیز پایدار باقی می‌ماند.

توالی دقیق پیشنهادی COCO-C

برای COCO-C ترتیب استاندارد مورد استفاده در مطالعات اخیر باید حفظ شود تا نتایج قابل مقایسه باقی بمانند. در مقاله لی و همکاران، خرابی‌ها به چهار گروه Noise، Blur، Weather و Digital و به ترتیب Gaussian، Shot، Impulse، Defocus، Glass، Motion، Fog، Frost، Snow، Zoom، Brightness، Contrast، Elastic، Pixelate و JPEG سازمان‌دهی شده‌اند؛ در پروتکل CTTA مقاله یو، پس از این جریان، داده Original/Clean نیز برای ارزیابی حفظ دانش در نظر گرفته می‌شود.

ترتیب زمانی	گروه تغییر توزیع	دامنه هدف	نقش در ارزیابی
۱	نویز	Gaussian Noise	نویز گاوسی؛ شروع جریان هدف با تغییر شدید سطح پیکسل
۲	نویز	Shot Noise	نویز شات/پواسون
۳	نویز	Impulse Noise	نویز ضربه‌ای
۴	تاری	Defocus Blur	تاری ناشی از خارج شدن از فوکوس
۵	تاری	Glass Blur	تاری غیرخطی/شیشه‌ای
۶	تاری	Motion Blur	تاری ناشی از حرکت
۷	تاری	Zoom Blur	تاری ناشی از بزرگ‌نمایی
۸	شرایط محیطی	Snow	تغییر جوی ناشی از برف
۹	شرایط محیطی	Frost	پوشیدگی و اعوجاج ناشی از یخ‌زدگی
۱۰	شرایط محیطی	Fog	افت کنتراست و دید در مه
۱۱	شرایط محیطی	Brightness	تغییر سطح روشنایی
۱۲	دیجیتال	Contrast	تغییر کنتراست
۱۳	دیجیتال/هندسی	Elastic Transform	تغییر شکل الاستیک تصویر
۱۴	دیجیتال	Pixelate	پیکسلی‌شدن تصویر
۱۵	دیجیتال	JPEG Compression	مصنوعات فشرده‌سازی JPEG
۱۶	بازگشت به توزیع اولیه	Original / Clean COCO	آزمون «بازگشت به مبدأ» برای بررسی میزان حفظ دانش و فراموشی پس از عبور از همه خرابی‌ها

۵-۳ - فرضیه‌های تحقیق (سؤالات تحقیق) :

با توجه به مسئله پژوهش، هدف اصلی این تحقیق بررسی امکان بهبود عملکرد مدل‌های تشخیص اشیا در شرایط انطباق آنلاین در زمان آزمون است؛ به گونه‌ای که مدل بتواند بدون دسترسی مجدد به داده‌های مبدأ و بدون استفاده از برچسب‌های داده‌های هدف، خود را با تغییرات متوالی و پویا در توزیع داده‌ها سازگار کند و در عین حال دانش آموخته‌شده قبلی خود را تا حد امکان حفظ نماید. در این راستا، سؤالات تحقیق بر سه چالش اساسی شامل قابلیت اعتماد سیگنال‌های نظارتی تولیدشده از داده‌های بدون برچسب، جلوگیری از انباشت خطا و فراموشی فاجعه‌بار، و سرعت و کارایی انطباق در محیط‌های جریانی متمرکز می‌شوند.

با توجه به ماهیت اکتشافی و الگوریتمی پژوهش، سؤالات زیر به عنوان سؤالات اصلی تحقیق در نظر گرفته می‌شوند:

سؤال اصلی تحقیق:

آیا می‌توان با طراحی و بهبود یک روش انطباق آنلاین در زمان آزمون، عملکرد مدل تشخیص اشیا را در مواجهه با تغییرات متوالی و غیرایستای دامنه، به‌ویژه در سناریوی انتقال از داده‌های مصنوعی به داده‌های واقعی، بدون دسترسی به داده‌های مبدأ و برچسب‌های دامنه هدف، بهبود داد و همزمان از افت دانش قبلی مدل جلوگیری کرد؟

برای پاسخ به سؤال اصلی، سؤالات فرعی زیر بررسی خواهند شد:

۱. آیا استفاده از سازوکارهای مناسب برای افزایش قابلیت اعتماد شبه‌برچسب‌ها و سیگنال‌های خودنظارتی می‌تواند باعث بهبود فرآیند انطباق مدل تشخیص اشیا در شرایط آنلاین شود؟

۲. آیا می‌توان با کنترل کیفیت داده‌ها و سیگنال‌های مورد استفاده در فرآیند انطباق، از انباشت خطا در طول توالی داده‌های آزمون جلوگیری کرد؟

۳. آیا روش پیشنهادی می‌تواند ضمن سازگاری با توزیع‌های جدید، از فراموشی فاجعه‌بار و افت دانش آموخته‌شده در دامنه مبدأ جلوگیری کند؟

۴. آیا استفاده از سازوکارهای مناسب برای حفظ دانش قبلی، می‌تواند پایداری مدل را در مواجهه با تغییرات متوالی و غیرایستای دامنه افزایش دهد، بدون آنکه سرعت انطباق مدل با دامنه جدید به‌طور معناداری کاهش یابد؟

۵. آیا روش پیشنهادی می‌تواند در مقایسه با مدل بدون انطباق و روش‌های پایه انطباق در زمان آزمون، عملکرد بهتری را در تشخیص اشیا در دامنه هدف ارائه دهد؟

۶. آیا روش پیشنهادی می‌تواند همزمان دقت طبقه‌بندی اشیا و محلی‌سازی آن‌ها را در شرایط تغییر دامنه حفظ یا بهبود دهد؟ این سؤال از آن جهت اهمیت دارد که در تشخیص اشیا، برخلاف دسته‌بندی تصویر، کیفیت انطباق تنها با صحت کلاس پیش‌بینی‌شده سنجیده نمی‌شود و دقت مکان‌یابی اشیا نیز بخش مهمی از عملکرد مدل است.

۷. آیا انطباق آنلاین پیشنهادی می‌تواند با تعداد محدودی از نمونه‌های جاری و بدون مشاهده مجدد کامل داده‌های قبلی، خود را با تغییرات جدید محیط سازگار کند؟

۸. آیا روش پیشنهادی از نظر هزینه محاسباتی و زمان موردنیاز برای انطباق، قابلیت استفاده در سناریوهای جریانی و نزدیک به زمان واقعی را خواهد داشت؟

بر این اساس، فرضیه کلی پژوهش آن است که طراحی یک سازوکار انطباق آنلاین در زمان آزمون که کیفیت سیگنال‌های خودنظارتی را کنترل کرده و همزمان سازوکارهایی برای حفظ دانش قبلی مدل در نظر بگیرد، می‌تواند موجب بهبود پایداری و عملکرد مدل تشخیص اشیا در شرایط تغییر متوالی دامنه شود؛ بدون آنکه برای این انطباق نیاز به دسترسی مجدد به داده‌های مبدأ یا برچسب‌های داده‌های هدف وجود داشته باشد.

۶-۳ - نتایج مورد انتظار پس از انجام تحقیق :

انتظار می‌رود اجرای این پژوهش به ارائه و ارزیابی یک چارچوب انطباق آنلاین در زمان آزمون برای مدل‌های تشخیص اشیا منجر شود که بتواند در شرایط تغییر توزیع و ورود پیوسته داده‌های بدون برچسب، عملکرد مدل را با دامنه هدف سازگار کند. با توجه به اهداف پژوهش، نتایج مورد انتظار را می‌توان در چند محور اصلی بیان کرد.

۱. بهبود عملکرد تشخیص اشیا در دامنه هدف

انتظار می‌رود روش پیشنهادی بتواند در شرایط وجود شکاف دامنه، به‌ویژه در سناریوی انتقال از داده‌های مصنوعی به داده‌های واقعی، عملکرد مدل تشخیص اشیا را نسبت به حالت بدون انطباق بهبود دهد. این بهبود باید در معیارهای استاندارد ارزیابی تشخیص اشیا، از جمله میانگین دقت متوسط (mAP) و معیارهای مرتبط با دقت تشخیص و محلی‌سازی، قابل مشاهده و اندازه‌گیری باشد.

۲. افزایش پایداری عملکرد در طول جریان داده

یکی از نتایج مورد انتظار، کاهش افت تدریجی عملکرد مدل در طول پردازش یک جریان پیوسته از داده‌ها است. در شرایط OTTA، مدل به صورت متوالی با نمونه‌هایی از دامنه‌های مختلف مواجه می‌شود و وضعیت مدل پس از هر مرحله بر مراحل بعدی اثر می‌گذارد. انتظار می‌رود روش پیشنهادی بتواند در چنین شرایطی عملکرد خود را در طول توالی داده با ثبات بیشتری حفظ کند و از افت شدید عملکرد در مراحل پایانی جریان جلوگیری نماید.

۳. کاهش انباشت خطا ناشی از شبه‌برچسب‌های نامطمئن
از آنجا که در زمان آزمون برچسب واقعی داده‌های هدف در اختیار مدل قرار ندارد، بخشی از فرآیند انطباق به سیگنال‌های تولیدشده از پیش‌بینی خود مدل وابسته خواهد بود. انتظار می‌رود سازوکار پیشنهادی با کنترل کیفیت این سیگنال‌ها و جلوگیری از استفاده نامناسب از نمونه‌های نامطمئن، میزان انتشار خطا در طول فرآیند انطباق را کاهش دهد.

در نتیجه، انتظار می‌رود مدل در مراحل بعدی جریان داده کمتر تحت تأثیر خطاهای انباشته‌شده مراحل قبلی قرار گیرد.

۴. کاهش فراموشی فاجعه‌بار و حفظ دانش قبلی
یکی از مهم‌ترین نتایج مورد انتظار، ایجاد تعادل میان یادگیری شرایط جدید و پایداری دانش قبلی است. به عبارت دیگر، مدل باید بتواند خود را با دامنه‌های جدید سازگار کند، بدون آنکه این سازگاری به از دست رفتن شدید دانش عمومی یا توانایی مدل در مواجهه با توزیع‌های قبلی منجر شود.

انتظار می‌رود این موضوع از طریق مقایسه عملکرد مدل در مراحل مختلف جریان داده و همچنین بررسی میزان افت عملکرد نسبت به مدل اولیه قابل ارزیابی باشد.

۵. بهبود همزمان طبقه‌بندی و محلی‌سازی اشیا
با توجه به ماهیت مسئله تشخیص اشیا، انتظار می‌رود روش پیشنهادی تنها به بهبود اطمینان طبقه‌بندی محدود نشود، بلکه بتواند عملکرد مدل را در بخش محلی‌سازی نیز حفظ یا بهبود دهد. بنابراین، ارزیابی روش باید به گونه‌ای انجام شود که مشخص شود بهبود حاصل شده صرفاً ناشی از تغییر در پیش‌بینی کلاس‌ها نیست و کیفیت مکان‌یابی اشیا نیز تحت تأثیر مثبت فرآیند انطباق قرار گرفته است.

۶. سازگاری سریع با تغییرات جدید دامنه
انتظار می‌رود مدل بتواند با تعداد محدودی از داده‌های جدید خود را با شرایط محیطی جدید سازگار کند و برای دستیابی به عملکرد مناسب به مشاهده مکرر یا پردازش چندباره کل داده‌های هدف وابسته نباشد. این ویژگی برای سناریوی OTTA اهمیت ویژه‌ای دارد، زیرا داده‌ها به صورت جریان وارد سیستم شده و هر نمونه یا دسته داده ممکن است تنها یک بار در دسترس باشد.

۷. حفظ عملکرد در برابر تغییرات متوالی و غیرایستای دامنه
انتظار می‌رود روش پیشنهادی در شرایطی که توزیع داده‌های هدف در طول زمان ثابت نیست، نسبت به روش‌های انطباقی که برای یک دامنه ثابت طراحی شده‌اند، پایداری بیشتری نشان دهد. به طور مشخص، عملکرد روش باید در شرایطی بررسی شود که مدل پس از سازگاری با یک توزیع، با توزیع دیگری مواجه می‌شود و مرز میان این تغییرات نیز لزوماً از پیش مشخص نیست.

۸. کاهش هزینه و سربار محاسباتی فرآیند انطباق
از آنجا که یکی از الزامات کاربردهای آنلاین، محدودیت زمان و منابع محاسباتی است، انتظار می‌رود فرآیند انطباق پیشنهادی از نظر تعداد پارامترهای به‌روزشونده، تعداد محاسبات اضافی و زمان موردنیاز برای هر مرحله، در محدوده‌ای قابل قبول قرار گیرد. بنابراین، علاوه بر معیارهای دقت، هزینه محاسباتی و زمان انطباق نیز در ارزیابی نهایی مورد توجه قرار خواهد گرفت.

۹. ارائه شواهد تجربی درباره سازوکارهای مؤثر در OTTA برای تشخیص اشیا
انتظار می‌رود آزمایش‌های انجام‌شده تنها به مقایسه نهایی عملکرد مدل محدود نشوند، بلکه از طریق آزمایش‌های تفکیکی (Ablation Study) مشخص شود که هر یک از اجزای روش پیشنهادی چه نقشی در عملکرد نهایی دارند. به این ترتیب، سهم هر سازوکار در بهبود قابلیت اعتماد شبه‌برچسب‌ها، کاهش انباشت خطا، حفظ دانش قبلی و افزایش پایداری مدل قابل بررسی خواهد بود.

۱۰. ارائه یک چارچوب ارزیابی برای سنجش پایداری مدل در انطباق آنلاین
در نهایت، انتظار می‌رود پژوهش حاضر علاوه بر ارائه یک روش انطباقی، امکان ارزیابی جامع عملکرد مدل را در سناریوی OTTA فراهم کند. این ارزیابی باید صرفاً بر عملکرد نهایی مدل در یک دامنه متمرکز نباشد، بلکه تغییرات عملکرد در طول جریان داده، میزان افت دانش قبلی، سرعت انطباق، کیفیت تشخیص و هزینه محاسباتی را نیز دربرگیرد.

در مجموع، نتیجه مورد انتظار پژوهش، دستیابی به روشی است که میان انطباق‌پذیری با دامنه جدید، پایداری دانش قبلی، کنترل خطا و هزینه محاسباتی تعادل مناسبی برقرار کند. چنین روشی می‌تواند زمینه را برای استفاده عملی‌تر از مدل‌های تشخیص اشیا در محیط‌هایی فراهم کند

که در آن‌ها توزیع داده‌ها در طول زمان تغییر می‌کند، داده‌های مبدأ در زمان استقرار در دسترس نیستند و برچسب واقعی داده‌های هدف نیز در اختیار سیستم قرار نمی‌گیرد.

۷-۳ - در صورت کاربردی بودن تحقیق، چه سازمانهایی می‌توانند از نتایج بدست آمده استفاده کنند .

ردیف	نام سازمان	نوع استفاده
۱	شرکت‌های خودروسازی و توسعه‌دهندگان سامانه‌های رانندگی هوشمند (ایران خودرو، سایپا و شرکت‌های دانش‌بنیان فعال در حوزه خودروهای هوشمند)	مدل‌های تشخیص اشیا در خودروهای خودران و سامانه‌های کمک‌راننده معمولاً با استفاده از داده‌های گسترده آزمایشگاهی، شبیه‌سازی‌شده یا داده‌های جمع‌آوری‌شده در محیط‌های محدود آموزش می‌بینند. نتایج این تحقیق می‌تواند به این شرکت‌ها کمک کند تا مدل‌های ادراک بصری خود را پس از استقرار در شرایط جدید مانند شهرهای متفاوت، تغییرات آب‌وهوایی، تغییر نور محیط یا تفاوت دوربین‌ها، بدون نیاز به انتقال داده‌های محرمانه اولیه یا انجام فرآیند آموزش مجدد کامل، به‌صورت پیوسته تطبیق دهند.
۲	مراکز مدیریت هوشمند ترافیک و سازمان‌های توسعه‌دهنده شهر هوشمند (Smart City & Intelligent Traffic Management)	سیستم‌های نظارت تصویری شهری با تعداد زیادی دوربین در نقاط مختلف مواجه هستند که هرکدام شرایط متفاوتی از نظر زاویه دید، کیفیت تصویر، نور، تراکم ترافیک و شرایط محیطی دارند. استفاده از روش‌های انطباق آنلاین می‌تواند امکان سازگار شدن مدل‌های تشخیص خودرو، عابر، موتورسیکلت و سایر اشیا را برای هر موقعیت فراهم کرده و نیاز به تنظیم دستی یا جمع‌آوری داده‌های برچسب‌دار از هر دوربین را کاهش دهد.
۳	شرکت‌های فعال در حوزه نقشه‌برداری هوشمند، نقشه‌های HD و پایش زیرساخت‌های حمل‌ونقل	شرکت‌هایی که از خودروهای مجهز به دوربین یا تجهیزات تصویربرداری برای تهیه و به‌روزرسانی نقشه‌های دقیق استفاده می‌کنند، با تغییر مداوم شرایط محیطی و جغرافیایی مواجه هستند. نتایج این پژوهش می‌تواند به بهبود قابلیت تطبیق مدل‌های تشخیص علائم راهنمایی، موانع، خطوط جاده و عناصر محیطی در مناطق جدید کمک کند، بدون آنکه برای هر منطقه نیاز به ایجاد مجموعه داده آموزشی جدید باشد.
۴	شرکت‌ها و سازمان‌های فعال در حوزه امنیت، پایش تصویری و صنایع دفاعی	سامانه‌های نظارت تصویری امنیتی و نظامی معمولاً در محیط‌هایی با شرایط متغیر مانند تغییر زاویه دوربین، شرایط جوی، تغییر میدان دید و تفاوت تجهیزات تصویربرداری استفاده می‌شوند. روش‌های ارائه‌شده در این تحقیق می‌توانند به افزایش قابلیت سازگاری مدل‌های تشخیص اشیا در محیط‌های جدید و کاهش وابستگی به داده‌های آموزشی از پیش جمع‌آوری‌شده کمک کنند.

۵	مراکز تصویربرداری پزشکی و شرکت‌های توسعه‌دهنده سامانه‌های هوش مصنوعی پزشکی	در بسیاری از کاربردهای پزشکی، تفاوت میان دستگاه‌های تصویربرداری، مراکز درمانی و شرایط ثبت تصاویر باعث ایجاد تغییر دامنه می‌شود. همچنین به دلیل مسائل مربوط به حریم خصوصی، انتقال داده‌های بیماران برای آموزش مجدد مدل‌ها دشوار است. چارچوب‌های انطباق در زمان آزمون می‌توانند امکان سازگاری مدل‌ها با داده‌های جدید را بدون نیاز به انتقال داده‌های حساس فراهم کنند.
۶	شرکت‌های فعال در حوزه رباتیک، پهپادها و سیستم‌های بینایی هوشمند	ربات‌ها و پهپادها در طول مأموریت خود ممکن است با محیط‌هایی مواجه شوند که در زمان آموزش مدل مشاهده نشده‌اند. استفاده از روش‌های انطباق آنلاین می‌تواند به این سیستم‌ها اجازه دهد در حین عملیات، مدل بینایی خود را با شرایط جدید محیطی، تغییر نور، تغییر پس‌زمینه و تفاوت مکان‌ها سازگار کنند.
۷	شرکت‌های ارائه‌دهنده خدمات هوش مصنوعی و پلتفرم‌های بینایی ماشین	شرکت‌هایی که مدل‌های تشخیص اشیا را به‌عنوان سرویس ارائه می‌کنند، می‌توانند از نتایج این پژوهش برای توسعه مدل‌هایی استفاده کنند که پس از استقرار در محیط مشتریان مختلف، بدون نیاز به بازآموزی کامل و انتقال داده‌های اختصاصی هر مشتری، قابلیت تطبیق با شرایط جدید را داشته باشند.

۴- روش انجام تحقیق :

۴-۱- روش گردآوری اطلاعات :

با توجه به ماهیت پژوهش حاضر که در حوزه انطباق آنلاین و پیوسته در زمان آزمون (Continual Test-Time Domain Adaptation) برای مدل‌های تشخیص اشیا انجام می‌شود، روش گردآوری اطلاعات در این تحقیق به‌صورت ترکیبی از مطالعه کتابخانه‌ای، بررسی مقالات علمی معتبر، تحلیل روش‌های موجود و انجام آزمایش‌های تجربی بر روی مجموعه‌داده‌های استاندارد خواهد بود. در مرحله نخست، برای شناخت دقیق مسئله و استخراج مبانی نظری پژوهش، مطالعات انجام‌شده در زمینه تغییر توزیع داده، انطباق دامنه، انطباق دامنه بدون منبع، انطباق در زمان آزمون و انطباق پیوسته در زمان آزمون مورد بررسی قرار خواهند گرفت. هدف از این مطالعات، بررسی روند تکامل روش‌های موجود، شناخت محدودیت‌های هر دسته از روش‌ها و مشخص کردن چالش‌های حل‌نشده در حوزه انطباق مدل‌های یادگیری عمیق پس از استقرار است.

در ادامه، مقالات منتشرشده در مجلات و کنفرانس‌های معتبر بین‌المللی در حوزه یادگیری ماشین و بینایی ماشین، از جمله IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)، International Conference on Machine Vision (ICCV)، European Conference on Computer Vision (ECCV)، International Conference on Computer Learning (ICML) و مجلاتی مانند IEEE Transactions on Pattern Analysis and Machine Intelligence (TPAMI) و International Journal of Computer Vision (IJCV) بررسی خواهند شد.

در بخش مرور ادبیات، تمرکز اصلی بر روش‌های ارائه‌شده در حوزه Test-Time Adaptation و به‌طور ویژه Online/Continual Test-Time Adaptation خواهد بود. اطلاعات مورد نیاز شامل نحوه تولید سیگنال‌های نظارتی بدون استفاده از برچسب واقعی، روش‌های به‌روزرسانی مدل در زمان آزمون، راهکارهای جلوگیری از فراموشی فاجعه‌بار، روش‌های کاهش انباشت خطا، سازوکارهای حفظ دانش قبلی و روش‌های کاهش هزینه محاسباتی خواهد بود.

همچنین، با توجه به اینکه مسئله پژوهش بر روی تشخیص اشیا (Object Detection) متمرکز است، مطالعات اختصاصی انجام‌شده در زمینه انطباق آشکارسازهای اشیا در شرایط تغییر دامنه بررسی خواهند شد. در این مرحله، نحوه تأثیر تغییر توزیع داده بر دو مؤلفه اصلی تشخیص

اشیا، یعنی طبقه‌بندی اشیا و مکان‌یابی آن‌ها، همچنین محدودیت‌های انتقال مستقیم روش‌های TTA از وظیفه دسته‌بندی تصویر به تشخیص اشیا تحلیل خواهد شد.

برای گردآوری منابع علمی، از پایگاه‌های داده معتبر علمی شامل:

- IEEE Xplore
- ACM Digital Library
- SpringerLink
- ScienceDirect
- Google Scholar
- arXiv

استفاده خواهد شد. انتخاب مقالات بر اساس ارتباط مستقیم با موضوع پژوهش، میزان استاندارد، اعتبار محل انتشار و جدید بودن نتایج انجام خواهد گرفت؛ به گونه‌ای که علاوه بر مقالات پایه و تأثیرگذار، پژوهش‌های جدید منتشرشده در سال‌های اخیر در حوزه OTTA، CTTA و Test-Time Adaptive Object Detection نیز مورد بررسی قرار گیرند.

در بخش تجربی تحقیق، اطلاعات مورد نیاز برای ارزیابی روش پیشنهادی از طریق مجموعه‌داده‌های استاندارد تشخیص اشیا و سناریوهای تغییر دامنه جمع‌آوری خواهد شد. این مجموعه‌داده‌ها شامل داده‌هایی هستند که امکان بررسی شرایطی مانند انتقال از داده مصنوعی به واقعی (Synthetic-to-Real)، تغییرات محیطی و تغییرات متوالی توزیع داده را فراهم می‌کنند. همچنین، معیارهای ارزیابی استاندارد در حوزه تشخیص اشیا مانند mean Average Precision (mAP)، دقت تشخیص، میزان افت عملکرد در طول جریان داده، میزان فراموشی مدل و هزینه محاسباتی فرآیند انطباق برای مقایسه روش‌ها مورد استفاده قرار خواهند گرفت.

در نهایت، اطلاعات جمع‌آوری شده از مطالعات نظری و نتایج آزمایش‌های تجربی برای تحلیل نقاط قوت و ضعف روش‌های موجود، استخراج شکاف‌های پژوهشی و طراحی یا بهبود یک روش انطباق آنلاین در زمان آزمون برای مدل‌های تشخیص اشیا استفاده خواهد شد.

۲-۴ - روش و مراحل تحقیق :

با توجه به ماهیت مسئله، این پژوهش از نظر هدف، کاربردی - توسعه‌ای و از نظر روش اجرا، تجربی و مبتنی بر شبیه‌سازی و ارزیابی محاسباتی خواهد بود. هدف اصلی، بررسی و بهبود روش‌های انطباق آنلاین و پیوسته در زمان آزمون برای مدل‌های تشخیص اشیا در شرایط تغییر توزیع داده است.

در این پژوهش، یک مدل تشخیص اشیا ابتدا با استفاده از داده‌های دامنه مبدأ آموزش داده خواهد شد. پس از پایان مرحله آموزش اولیه، داده‌های مبدأ در فرآیند انطباق در دسترس مدل قرار نخواهند گرفت و مدل در مرحله استقرار با یک جریان از داده‌های بدون برچسب دامنه هدف مواجه خواهد شد. داده‌های ورودی به‌صورت متوالی و در قالب نمونه یا دسته‌های کوچک وارد سیستم می‌شوند و مدل باید ضمن تولید پیش‌بینی، در صورت نیاز خود را بر اساس اطلاعات موجود در داده‌های جاری به‌روزرسانی کند.

این تنظیم با ماهیت OTTA و CTTA مطابقت دارد؛ در این روش‌ها، مدل از پیش آموزش‌دیده در هنگام دریافت داده‌های هدف با تغییر توزیع مواجه شده و باید بدون استفاده از داده مبدأ خود را تطبیق دهد. در CTTA، علاوه بر تفاوت میان دامنه مبدأ و هدف، توزیع داده هدف نیز در طول زمان تغییر می‌کند. CoTTA این مسئله را با تأکید بر دو چالش اصلی، یعنی غیرقابل اعتماد شدن شبه‌برچسب‌ها و در نتیجه انباشت خطا و فراموشی فاجعه‌بار، صورت‌بندی کرده است.

مراحل انجام تحقیق به شرح زیر خواهد بود:

مرحله اول: مطالعه و تحلیل مبانی نظری و ادبیات پژوهش

در مرحله نخست، مطالعات نظری و پژوهش‌های انجام‌شده در زمینه تغییر توزیع داده، Unsupervised Domain Adaptation، Source-Free Domain Adaptation، Test-Time Adaptation، Online Test-Time Adaptation و Continual Test-Time Adaptation بررسی خواهند شد.

در این مرحله، ضمن بررسی روش‌های پایه مانند TTA مبتنی بر کمینه‌سازی آنتروپی، روش‌های مبتنی بر شبه‌برچسب‌گذاری، مدل‌های معلم - دانش‌آموز، روش‌های مبتنی بر حافظه و روش‌های به‌روزرسانی انتخابی پارامترها، تمرکز ویژه‌ای بر روش‌هایی خواهد بود که برای داده‌های جریانی و تغییرات مداوم توزیع طراحی شده‌اند.

همچنین، مطالعات اختصاصی مربوط به Test-Time Adaptive Object Detection بررسی خواهند شد؛ زیرا بسیاری از روش‌های اولیه TTA برای دسته‌بندی تصویر طراحی شده‌اند و انتقال مستقیم آن‌ها به تشخیص اشیاء با چالش‌هایی همراه است. Yoo و همکاران نشان داده‌اند که در تشخیص اشیاء، علاوه بر اینکه باید مشخص شود چه پارامترهایی به‌روزرسانی شوند و چگونه این به‌روزرسانی انجام شود، زمان انجام انطباق نیز اهمیت دارد [۸].

مرحله دوم: انتخاب و آماده‌سازی مدل پایه تشخیص اشیاء

در مرحله دوم، یک مدل تشخیص اشیاء به‌عنوان مدل پایه انتخاب خواهد شد. مدل پایه ابتدا بر روی داده‌های دامنه مبدأ آموزش داده یا از یک مدل از پیش آموزش‌دیده مناسب استفاده خواهد شد.

در صورت تمرکز آزمایش‌ها بر سناریوی Synthetic-to-Real، داده‌های مصنوعی یا شبیه‌سازی‌شده به‌عنوان دامنه مبدأ و داده‌های واقعی به‌عنوان دامنه هدف در نظر گرفته خواهند شد. مدل در این مرحله صرفاً دانش اولیه مورد نیاز برای تشخیص اشیاء را از دامنه مبدأ دریافت خواهد کرد و پس از اتمام آموزش، داده‌های مبدأ برای فرآیند انطباق در اختیار روش پیشنهادی قرار نخواهند گرفت. هدف از این مرحله ایجاد یک نقطه شروع یکسان برای مقایسه روش‌های مختلف است تا تفاوت عملکرد مشاهده‌شده در مرحله انطباق ناشی از سازوکار انطباق باشد، نه تفاوت در آموزش اولیه مدل.

مرحله سوم: تعریف سناریوی جریان داده و تغییرات دامنه

پس از آموزش مدل پایه، داده‌های هدف به شکل یک جریان متوالی در اختیار مدل قرار خواهند گرفت. برخلاف روش‌های انطباق آفلاین که ممکن است کل مجموعه داده هدف را از ابتدا در اختیار داشته باشند، در این پژوهش مدل تنها به داده‌های جاری دسترسی خواهد داشت.

به‌صورت مفهومی، جریان داده را می‌توان به‌صورت زیر نمایش داد:

$$B_1 \rightarrow B_2 \rightarrow B_3 \rightarrow \dots \rightarrow B_t$$

که در آن B_t دسته داده‌ای است که در زمان t وارد سیستم می‌شود.

برای هر دسته، مدل ابتدا پیش‌بینی خود را تولید کرده و سپس، در صورت نیاز، از اطلاعات بدون برچسب موجود در همان دسته برای فرآیند انطباق استفاده خواهد کرد. پارامترهای حاصل از انطباق نیز برای پردازش دسته‌های بعدی حفظ خواهند شد.

در سناریوی CTTA، توزیع داده می‌تواند در طول زمان تغییر کند:

$$P_1(X) \rightarrow P_2(X) \rightarrow \dots \rightarrow P_t(X)$$

بنابراین مدل نه‌تنها باید با شکاف میان دامنه مبدأ و هدف سازگار شود، بلکه باید بتواند تغییرات متوالی در خود دامنه هدف را نیز دنبال کند. این ویژگی، تفاوت اصلی سناریوی مورد مطالعه با بسیاری از تنظیمات آفلاین TTA یا SFDA خواهد بود.

مرحله چهارم: انتخاب و پیاده‌سازی روش‌های پایه

در این مرحله، چند روش پایه از ادبیات TTA و CTTA برای ایجاد مبنای مقایسه پیاده‌سازی یا بازتولید خواهند شد. روش‌های پایه می‌توانند شامل موارد زیر باشند:

- مدل بدون انجام انطباق در زمان آزمون؛
- روش‌های TTA مبتنی بر کمینه‌سازی آنتروپی؛
- روش‌های مبتنی بر آمار یا پارامترهای Batch Normalization؛
- روش‌های مبتنی بر شبه‌برچسب‌گذاری؛
- روش‌های Teacher-Student؛
- روش‌های CTTA مانند CoTTA؛
- روش‌های اختصاصی CTTA برای تشخیص اشیاء.

انتخاب نهایی روش‌های پایه بر اساس ارتباط آن‌ها با مسئله، امکان بازتولید و سازگاری با معماری تشخیص اشیاء انجام خواهد شد. این مقایسه اهمیت ویژه‌ای دارد؛ زیرا مطالعات جدید نشان می‌دهند که بسیاری از روش‌های TTA که برای دسته‌بندی توسعه یافته‌اند، برای تشخیص اشیاء مستقیماً قابل استفاده نیستند و روش‌های به‌روزرسانی کامل مدل نیز می‌توانند از نظر هزینه محاسباتی و حساسیت به سیگنال‌های نویزی مشکل‌ساز باشند [۸].

مرحله پنجم: طراحی و توسعه روش پیشنهادی

در این مرحله، بر اساس شکاف‌های شناسایی‌شده در مطالعات پیشین، روش پیشنهادی برای بهبود CTTA در تشخیص اشیاء طراحی خواهد شد. روش پیشنهادی بر سه محور اصلی متمرکز خواهد بود:

الف) افزایش قابلیت اعتماد سیگنال انطباق

از آنجا که برچسب واقعی داده‌های هدف در زمان آزمون در دسترس نیست، روش باید بتواند از اطلاعاتی مانند پیش‌بینی مدل، $confidence$ ، شبه‌برچسب‌ها، سازگاری پیش‌بینی‌ها یا سایر سیگنال‌های بدون نظارت استفاده کند. هدف این بخش کاهش ورود نمونه‌ها یا پیش‌بینی‌های نامطمئن به فرآیند به‌روزرسانی خواهد بود.

این موضوع در تشخیص اشیا اهمیت بیشتری دارد؛ زیرا کیفیت یک پیش‌بینی علاوه بر کلاس، به کیفیت مکان‌یابی جعبه محدودکننده نیز وابسته است. مطالعات اختصاصی TTA برای تشخیص اشیا نیز بر این تفاوت تأکید کرده‌اند [۴].

Fully Test-time Adaptation for Object Detection :Commented [ak36]

ب) کنترل انباشت خطا و فراموشی فاجعه‌بار

سازوکاری برای جلوگیری از تقویت خطاهای ناشی از داده‌های قبلی و همچنین حفظ بخشی از دانش مدل مبدأ بررسی و طراحی خواهد شد. هدف این بخش ایجاد تعادل میان توانایی مدل برای یادگیری شرایط جدید و پایداری برای حفظ دانش قبلی خواهد بود.

این مسئله از چالش‌های بنیادی CoTTA است؛ CoTTA نیز نشان داده است که شبه‌برچسب‌های نویزی در شرایط تغییر متوالی دامنه می‌توانند موجب انباشت خطا و در ادامه فراموشی فاجعه‌بار شوند [۳].

ج) کنترل هزینه محاسباتی انطباق

به‌منظور حفظ قابلیت استفاده روش در شرایط آنلاین، تعداد پارامترهای قابل آموزش، میزان محاسبات اضافه‌شده و زمان لازم برای انطباق در طراحی روش مورد توجه قرار خواهد گرفت.

این موضوع در تحقیقات جدید CTTA برای تشخیص اشیا اهمیت بیشتری پیدا کرده است. برای مثال، Wang و همکاران در CVPR ۲۰۲۵ روش خود را با هدف کاهش هزینه محاسباتی CTTA-OD ارائه کرده‌اند و گزارش کرده‌اند که با راهبرد هرس کانال می‌توان ضمن حفظ عملکرد انطباق، هزینه FLOPs را کاهش داد [۷].

Efficient Test-time Adaptive Object Detection via Sensitivity-Guided Pruning :Commented [ak37]

مرحله ششم: طراحی آزمایش‌های کنترل‌شده و Ablation Study

پس از پیاده‌سازی روش پیشنهادی، آزمایش‌های تفکیکی برای بررسی نقش هر یک از اجزای روش انجام خواهد شد. برای مثال، در صورت وجود چند مؤلفه در روش پیشنهادی، حالت‌های زیر قابل بررسی خواهند بود:

Baseline

Baseline + A

Baseline + B

Baseline + $A + B$

که در آن A و B می‌توانند سازوکارهای مربوط به کیفیت شبه‌برچسب، حفظ دانش، کنترل به‌روزرسانی یا کاهش هزینه محاسباتی باشند. هدف از این آزمایش‌ها مشخص کردن سهم واقعی هر مؤلفه در عملکرد نهایی است و از این طریق مشخص خواهد شد که آیا بهبود عملکرد حاصل از روش پیشنهادی ناشی از یک جزء خاص است یا حاصل تعامل چند مؤلفه با یکدیگر.

مرحله هفتم: ارزیابی عملکرد در شرایط مختلف تغییر دامنه

برای بررسی میزان تعمیم‌پذیری روش، آزمایش‌ها در شرایط مختلف انجام خواهند شد. این شرایط می‌توانند شامل:

- تغییرات شدید و خفیف دامنه؛
- تغییرات متوالی دامنه؛
- دامنه‌های ثابت در مقابل دامنه‌های غیرایستا؛
- تغییرات ناگهانی در مقابل تغییرات تدریجی؛
- اندازه‌های مختلف batch؛
- توالی‌های کوتاه و طولانی داده؛
- و در صورت امکان، سناریوی Synthetic-to-Real باشند.

این طراحی باعث خواهد شد عملکرد روش صرفاً در یک شرایط خاص بررسی نشود و پایداری آن در برابر تغییرات مختلف ارزیابی گردد.

مرحله هشتم: تحلیل نتایج و مقایسه با روش‌های موجود

در مرحله نهایی، عملکرد روش پیشنهادی با روش‌های پایه مقایسه خواهد شد. علاوه بر عملکرد نهایی مدل، روند تغییر عملکرد در طول جریان داده نیز بررسی خواهد شد.

در این مرحله مشخص خواهد شد که روش پیشنهادی تا چه اندازه می‌تواند:

- عملکرد تشخیص اشیا را بهبود دهد؛
- سرعت سازگاری با دامنه جدید را افزایش دهد؛
- انباشت خطا را کاهش دهد؛
- از فراموشی فاجعه‌بار جلوگیری کند؛
- عملکرد طبقه‌بندی و مکان‌یابی را حفظ کند؛
- و هزینه محاسباتی انطباق را کنترل نماید.

در صورت مشاهده نقاط ضعف یا ناپایداری، پارامترهای روش و اجزای آن از طریق آزمایش‌های تکمیلی مورد بررسی و اصلاح قرار خواهند گرفت.

۳-۴ - قلمرو تحقیق :

قلمرو تحقیق حاضر از سه بعد موضوعی، داده‌ای - تجربی و زمانی مشخص می‌شود.

قلمرو موضوعی

موضوع اصلی این پژوهش در حوزه یادگیری ماشین، یادگیری عمیق و بینایی ماشین قرار دارد و به‌طور مشخص بر مسئله Continual / Online Test-Time Domain Adaptation برای تشخیص اشیا تمرکز دارد.

در این پژوهش، انطباق دامنه، Source-Free Domain Adaptation و Test-Time Adaptation به‌عنوان مبانی و مراحل شکل‌گیری مسئله مورد مطالعه قرار می‌گیرند؛ با این حال، تمرکز اصلی پژوهش بر انطباق آنلاین و پیوسته در زمان آزمون خواهد بود.

به‌طور مشخص، پژوهش بر شرایطی متمرکز است که در آن:

۱. مدل در ابتدا روی یک دامنه مبدأ آموزش دیده است؛

۲. پس از آموزش، داده‌های مبدأ در زمان انطباق در دسترس نیستند؛

۳. داده‌های هدف فاقد برچسب هستند؛

۴. داده‌های هدف به‌صورت متوالی وارد سیستم می‌شوند؛

۵. توزیع داده هدف می‌تواند در طول زمان تغییر کند؛

۶. مدل باید وضعیت تطبیق‌یافته خود را برای داده‌های بعدی حفظ کند.

این تعریف با صورت‌بندی CTTA در ادبیات سازگار است؛ CoTTA نیز دقیقاً بر محیط‌هایی تمرکز می‌کند که توزیع هدف در طول زمان تغییر می‌کند و مدل باید بدون استفاده از داده مبدأ به‌صورت پیوسته سازگار شود.

قلمرو وظیفه‌ای

از نظر وظیفه بینایی ماشین، تمرکز تحقیق بر Object Detection خواهد بود.

بنابراین خروجی مدل شامل اطلاعات مربوط به اشیای موجود در تصویر، کلاس هر شیء و موقعیت مکانی آن خواهد بود. در نتیجه، ارزیابی روش تنها بر اساس صحت طبقه‌بندی انجام نخواهد شد و کیفیت مکان‌یابی اشیا نیز در نظر گرفته خواهد شد.

این انتخاب به دلیل اهمیت کاربردی تشخیص اشیا و همچنین وجود چالش‌های خاص این وظیفه در TTA انجام می‌شود. پژوهش Yoo و همکاران نشان داده است که بسیاری از روش‌های TTA اولیه که عمدتاً برای دسته‌بندی توسعه یافته‌اند، برای تشخیص اشیا نیازمند طراحی متفاوتی هستند.

قلمرو داده‌ای

داده‌های مورد استفاده شامل مجموعه داده‌های استاندارد تشخیص اشیا و مجموعه داده‌هایی خواهند بود که امکان ایجاد تغییر دامنه و جریان داده غیرایستا را فراهم کنند.

در صورت امکان، یکی از سناریوهای اصلی ارزیابی، Synthetic-to-Real Domain Shift خواهد بود؛ به این معنا که مدل اولیه بر روی داده‌های مصنوعی یا شبیه‌سازی‌شده آموزش داده شده و سپس در مرحله آزمون با داده‌های واقعی مواجه شود.

علاوه بر این، برای ارزیابی توانایی روش در شرایط CTTA، توالی‌هایی از دامنه‌های مختلف ایجاد خواهند شد؛ به گونه‌ای که مدل پس از سازگاری با یک شرایط، با شرایط دیگری مواجه شود.

به عنوان مثال، می‌توان یک جریان داده را به شکل زیر تعریف کرد:

$$D_S \rightarrow D_{T_1} \rightarrow D_{T_2} \rightarrow D_{T_3}$$

که در آن D_S دامنه مبدأ و D_{T_1} ، D_{T_2} و D_{T_3} دامنه‌های هدف متوالی هستند.

در این حالت، مدل پس از ورود به D_{T_1} به وضعیت اولیه خود بازگردانده نخواهد شد و وضعیت حاصل از انطباق برای پردازش D_{T_2} و سپس D_{T_3} حفظ خواهد شد. این ویژگی برای مطالعه فراموشی فاجعه‌بار و پایداری بلندمدت ضروری است.

قلمرو روش شناختی

پژوهش حاضر در محدوده روش‌های بدون نظارت در زمان آزمون قرار دارد؛ بنابراین برچسب واقعی داده‌های هدف در فرآیند انطباق در اختیار مدل قرار نخواهد گرفت.

برچسب‌های واقعی داده‌های هدف صرفاً در مرحله ارزیابی نهایی و برای اندازه‌گیری عملکرد روش استفاده خواهند شد و در فرآیند به‌روزرسانی مدل نقشی نخواهند داشت.

این تفکیک اهمیت زیادی دارد؛ زیرا در غیر این صورت مسئله از Test-Time Adaptation بدون نظارت به یک نوع انطباق نظارت‌شده تبدیل خواهد شد.

قلمرو محاسباتی

از نظر محاسباتی، پژوهش شامل پیاده‌سازی، آموزش مدل پایه، اجرای روش‌های TTA/CTTA، انجام انطباق روی جریان داده و ارزیابی عملکرد خواهد بود.

علاوه بر دقت مدل، هزینه محاسباتی انطباق نیز بخشی از قلمرو تحقیق است. این موضوع به‌ویژه برای OTTA اهمیت دارد؛ زیرا در محیط آنلاین، فرآیند انطباق باید با محدودیت زمانی و محاسباتی سازگار باشد. پژوهشی در کنفرانس CVPR ۲۰۲۵ در رابطه با CTTA برای تشخیص اشیاء نیز صراحتاً کارایی محاسباتی را یکی از چالش‌های اصلی این مسئله معرفی می‌کند [۷].

قلمرو زمانی مطالعات

از نظر زمانی، در مرور ادبیات تلاش خواهد شد ضمن استفاده از مطالعات بنیادی و تأثیرگذار در حوزه Domain Adaptation و TTA، تمرکز ویژه‌ای بر پژوهش‌های منتشرشده در سال‌های اخیر، به‌خصوص مطالعات ۲۰۲۲ تا ۲۰۲۶، قرار گیرد.

این بازه به دلیل رشد سریع تحقیقات در زمینه CTTA و TTA برای تشخیص اشیاء انتخاب می‌شود. برای مثال، CoTTA در سال ۲۰۲۲ مسئله انطباق پیوسته تحت تغییرات غیرایستا را مطرح کرد، در سال ۲۰۲۴ روش‌های اختصاصی OTTA برای تشخیص اشیاء توسعه یافتند و در سال‌های ۲۰۲۵ و ۲۰۲۶ موضوعاتی مانند کارایی محاسباتی، تولید پارامتر وابسته به محیط و پایداری انطباق همچنان مورد مطالعه قرار گرفته‌اند.

۴-۴ - روش‌های مورد نظر برای تجزیه و تحلیل اطلاعات و آزمون فرضیه‌ها :

با توجه به ماهیت تجربی تحقیق، تحلیل اطلاعات در این پژوهش عمدتاً به‌صورت کمی و مبتنی بر نتایج آزمایش‌های محاسباتی انجام خواهد شد. هدف از تحلیل داده‌ها، مقایسه عملکرد روش پیشنهادی با مدل پایه و روش‌های موجود و همچنین بررسی میزان تحقق فرضیه‌ها و سؤالات تحقیق خواهد بود.

از آنجا که مسئله مورد مطالعه، انطباق پیوسته در زمان آزمون است، ارزیابی صرفاً بر اساس یک مقدار نهایی از عملکرد مدل انجام نخواهد شد؛ بلکه عملکرد مدل در طول جریان داده نیز مورد تحلیل قرار خواهد گرفت.

ارزیابی عملکرد تشخیص اشیاء

معیار اصلی برای ارزیابی کیفیت تشخیص اشیاء، mean Average Precision (mAP) خواهد بود.

برای مقایسه دقیق‌تر، در صورت امکان معیارهای AP در سطوح مختلف IoU نیز گزارش خواهند شد؛ برای مثال AP_{50} و AP_{75} و در صورت استفاده از استاندارد COCO، مقدار $mAP@[0.5:0.95]$ نیز گزارش خواهد شد.

این معیارها امکان تفکیک دو جنبه مهم عملکرد مدل را فراهم می‌کنند: توانایی تشخیص صحیح کلاس اشیاء و توانایی مکان‌یابی دقیق جعبه‌های محدودکننده.

در صورت نیاز، معیارهای Precision و Recall نیز برای تحلیل رفتار مدل در برابر خطاهای تشخیص و عدم تشخیص اشیا محاسبه خواهند شد.

تحلیل عملکرد در طول جریان داده

یکی از تفاوت‌های اصلی ارزیابی این تحقیق با انطباق دامنه آفلاین این است که عملکرد مدل تنها در پایان فرآیند اندازه‌گیری نخواهد شد. برای هر بخش از جریان داده، مقدار عملکرد مدل ثبت خواهد شد:

$$mAP_1, mAP_2, \dots, mAP_T$$

سپس نمودار تغییر عملکرد مدل در طول زمان یا طول جریان داده رسم خواهد شد.

این تحلیل مشخص خواهد کرد که آیا مدل:

به صورت تدریجی بهبود می‌یابد؛

پس از انطباق اولیه پایدار می‌شود؛

در اثر انطباق بیش از حد دچار افت می‌شود؛

یا در طول زمان دچار فروپاشی عملکرد می‌شود.

این نوع ارزیابی با ماهیت CTTA ضروری است، زیرا یک روش ممکن است در یک دامنه خاص عملکرد مناسبی داشته باشد، اما پس از چندین تغییر متوالی دامنه دچار افت شدید شود. CoTTA نیز مسئله انباشت خطا و فراموشی را دقیقاً در زمینه انطباق طولانی‌مدت و تغییرات متوالی توزیع مطرح کرده است.

اندازه‌گیری پایداری مدل

برای سنجش پایداری، علاوه بر مقدار نهایی mAP، میانگین عملکرد مدل در طول کل جریان داده نیز بررسی خواهد شد.

به صورت مفهومی می‌توان عملکرد متوسط در طول جریان را به شکل زیر تعریف کرد:

$$mAP_{avg} = \frac{1}{T} \sum_{t=1}^T mAP_t$$

این معیار نشان می‌دهد که مدل در کل فرآیند انطباق چه سطحی از عملکرد را حفظ کرده است، نه اینکه صرفاً در آخرین دامنه چه عملکردی دارد. همچنین میزان تغییرپذیری عملکرد در طول جریان نیز بررسی خواهد شد. در صورت مناسب بودن ساختار داده، انحراف معیار عملکرد در طول مراحل مختلف به عنوان یکی از شاخص‌های پایداری گزارش خواهد شد.

اندازه‌گیری میزان فراموشی فاجعه‌بار

برای بررسی فرضیه مربوط به حفظ دانش قبلی، عملکرد مدل پس از انطباق با دامنه‌های جدید با عملکرد آن پیش از انطباق مقایسه خواهد شد. اگر A_{old} عملکرد مدل روی یک دامنه قبلی قبل از انطباق و A_{old}^{after} عملکرد همان مدل پس از انطباق با دامنه‌های جدید باشد، می‌توان میزان افت عملکرد را به صورت زیر در نظر گرفت:

$$F = A_{old} - A_{old}^{after}$$

مقدار بزرگ‌تر F نشان‌دهنده فراموشی بیشتر خواهد بود.

همچنین در صورت طراحی توالی‌های چنددامنه‌ای، می‌توان عملکرد مدل را پس از عبور از هر دامنه بر روی دامنه‌های قبلی اندازه‌گیری کرد. این روش امکان بررسی مستقیم این موضوع را فراهم می‌کند که آیا انطباق با دامنه جدید باعث از دست رفتن دانش مربوط به دامنه‌های قبلی شده است یا خیر.

این تحلیل از نظر روش‌شناختی اهمیت زیادی دارد، زیرا در CTTA هدف صرفاً افزایش عملکرد روی آخرین دامنه نیست؛ بلکه باید میان سازگاری با شرایط جدید و حفظ دانش قبلی تعادل ایجاد شود. این موضوع یکی از انگیزه‌های اصلی روش‌هایی مانند CoTTA و همچنین روش‌های جدید CTTA برای تشخیص اشیا بوده است.

تحلیل انباشت خطا و قابلیت اعتماد سیگنال انطباق

برای بررسی فرضیه مربوط به کیفیت شبه‌برچسب‌ها و سیگنال‌های خودنظارتی، توزیع confidence پیش‌بینی‌ها، کیفیت شبه‌برچسب‌ها و در صورت امکان ارتباط confidence با صحت واقعی پیش‌بینی بررسی خواهد شد.

در تشخیص اشیا، این تحلیل باید علاوه بر کلاس، کیفیت مکان‌یابی را نیز در نظر بگیرد؛ زیرا یک prediction با confidence بالا لزوماً دارای جعبه محدودکننده دقیق نیست. بنابراین، در صورت امکان موارد زیر بررسی خواهند شد:

- میانگین confidence پیش‌بینی‌ها؛
- Precision نمونه‌های انتخاب‌شده برای انطباق؛
- نسبت شبه‌برچسب‌های صحیح؛
- کیفیت مکان‌یابی جعبه‌های انتخاب‌شده؛
- تغییر کیفیت شبه‌برچسب‌ها در طول جریان داده.

هدف این تحلیل آن است که مشخص شود آیا سازوکار پیشنهادی واقعاً باعث افزایش قابلیت اعتماد سیگنال انطباق می‌شود یا صرفاً عملکرد نهایی مدل را بهبود می‌دهد.

تحلیل سرعت انطباق

یکی دیگر از معیارهای مهم، سرعت سازگاری مدل با دامنه جدید خواهد بود. برای این منظور بررسی خواهد شد که مدل پس از ورود به یک دامنه جدید، چه تعداد نمونه یا batch نیاز دارد تا به سطح مشخصی از عملکرد برسد.

برای مثال، اگر A_0 عملکرد مدل قبل از انطباق و A_t عملکرد مدل پس از مشاهده $batch_t$ باشد، روند:

$$A_0 \rightarrow A_1 \rightarrow A_2 \rightarrow \dots$$

بررسی خواهد شد.

این تحلیل مشخص می‌کند که آیا روش پیشنهادی تنها پس از مشاهده تعداد زیادی نمونه عملکرد خود را بهبود می‌دهد یا می‌تواند در مراحل ابتدایی ورود به دامنه جدید نیز سازگاری مناسبی داشته باشد.

ارزیابی هزینه محاسباتی

از آنجا که هدف پژوهش انطباق آنلاین است، هزینه محاسباتی بخشی از ارزیابی اصلی خواهد بود. معیارهای مورد بررسی می‌توانند شامل موارد زیر باشند:

- زمان inference؛
- زمان اضافی مورد نیاز برای adaptation؛
- تعداد پارامترهای قابل آموزش؛
- تعداد پارامترهای به‌روزرسانی‌شده؛
- میزان حافظه مصرفی؛
- تعداد عملیات محاسباتی یا GFLOPs، در صورت امکان؛
- و نرخ پردازش داده، مانند FPS.

در صورت استفاده از سخت‌افزار ثابت، زمان پردازش و FPS برای روش‌های مختلف تحت شرایط یکسان اندازه‌گیری خواهند شد.

این موضوع به‌ویژه در Object Detection اهمیت دارد؛ پژوهش CVPR ۲۰۲۴ برای OTTA در تشخیص اشیا بر نیاز به انطباق کارآمد و سریع تأکید می‌کند و پژوهش CVPR سال ۲۰۲۵ نیز کارایی محاسباتی را به‌طور مستقیم به‌عنوان یکی از چالش‌های CTTA-OD بررسی کرده است [۷], [۸].

مقایسه با روش‌های پایه

برای آزمون فرضیه‌های پژوهش، روش پیشنهادی با چند دسته روش مقایسه خواهد شد:

حالت اول: بدون انطباق

مدل پایه بدون هیچ‌گونه به‌روزرسانی در زمان آزمون روی جریان داده اجرا خواهد شد.

این حالت مشخص می‌کند که چه میزان افت عملکرد صرفاً ناشی از Domain Shift است.

حالت دوم: روش‌های TTA موجود

روش‌های منتخب TTA و OTTA به‌عنوان baseline استفاده خواهند شد.

حالت سوم: روش‌های CTTA

روش‌هایی که به صورت اختصاصی برای شرایط continual طراحی شده‌اند، مانند CoTTA یا روش‌های جدیدتر مرتبط، در صورت سازگاری با وظیفه Object Detection مورد مقایسه قرار خواهند گرفت. CoTTA به طور خاص برای محیط‌های غیرایستا طراحی شده و برای کنترل انباشت خطا و فراموشی از میانگین‌گیری پیش‌بینی‌ها و بازگردانی بخشی از پارامترها استفاده می‌کند. حالت چهارم: روش پیشنهادی در نهایت، روش پیشنهادی تحت همان شرایط داده، معماری، جریان داده و منابع محاسباتی با روش‌های فوق مقایسه خواهد شد.

تحلیل نهایی و آزمون فرضیه‌های تحقیق

در نهایت، نتایج حاصل از آزمایش‌ها در قالب یک جدول مقایسه‌ای و نمودارهای تحلیلی ارائه خواهند شد. تحلیل نهایی بر اساس چند محور انجام می‌شود:


- دقت تشخیص (Detection Accuracy)
- پایداری انطباق (Adaptation Stability)
- فراموشی (Forgetting)
- تجمع خطا (Error Accumulation)
- سرعت انطباق (Adaptation Speed)
- هزینه محاسباتی (Computational Cost)

بنابراین، موفقیت روش پیشنهادی صرفاً بر اساس بیشترین مقدار mAP تعیین نخواهد شد. یک روش زمانی مناسب تلقی خواهد شد که بتواند در مجموع، بهبود عملکرد تشخیص، سازگاری با دامنه جدید، پایداری در طول جریان، کنترل فراموشی و انباشت خطا و هزینه محاسباتی قابل قبول را فراهم کند.

این نحوه ارزیابی با جهت‌گیری تحقیقات جدید CTTA برای Object Detection نیز سازگار است؛ برای نمونه، Yoo و همکاران علاوه بر افزایش mAP، سرعت پردازش را نیز در ارزیابی خود گزارش کرده‌اند، در حالی که Wang و همکاران در CVPR سال ۲۰۲۵ مستقیماً کاهش هزینه محاسباتی را به عنوان هدف CTTA-OD بررسی کرده‌اند [۷]، [۸].

چارچوب کلی انطباق دامنه پیوسته و برخط در زمان آزمون

Continual / Online Test-Time Domain Adaptation



در پژوهش فعلی باید بگوییم:

$$SourceModel \rightarrow TargetStream(B_1) \rightarrow Adapt \rightarrow (B_2) \rightarrow Adapt \rightarrow (B_3) \rightarrow Adapt \rightarrow \dots$$

و نکته بسیار مهم این است که وزن های شبکه به صورت زیر بدست میاید:

$$\theta_{t+1} = Adapt(\theta_t, B_t)$$

و نه:

$$\theta_{t+1} = Adapt(\theta_0, B_t)$$

یعنی مدل مرحله $t + 1$ از مدل تطبیق یافته مرحله t به دست می آید و مرتب به مدل اولیه بازنشانی نمی شود. همین موضوع منشأ اصلی هم فرصت یادگیری پیوسته و هم خطر error accumulation و catastrophic forgetting است. این صورت بندی با تعریف CTTA در CoTTA و ادبیات جدید OTTA سازگار است.

۵- نیازهای تحقیق :

۵-۱ - هزینه انجام تحقیق :

با توجه به ماهیت محاسباتی پژوهش حاضر، بخش اصلی هزینه تحقیق مربوط به تأمین توان پردازشی مورد نیاز برای آموزش مدل پایه، اجرای روش های انطباق در زمان آزمون، اجرای آزمایش های متعدد در سناریوهای پیوسته و انجام مطالعات Ablation خواهد بود. از آنجا که مجموعه داده های مورد استفاده در پژوهش از میان مجموعه داده های عمومی و استاندارد حوزه تشخیص اشیا و تطبیق دامنه انتخاب خواهند شد، نیاز به خرید داده های اختصاصی یا انجام فرآیند جمع آوری داده اولیه وجود ندارد. در نسخه فعلی پژوهش نیز مجموعه هایی مانند Cityscapes, Cityscapes-Foggy و Sim۱۰k به عنوان منابع اصلی داده در نظر گرفته شده اند و هدف، استفاده از داده های عمومی برای امکان مقایسه مستقیم با مطالعات پیشین است.

توضیحات	برآورد هزینه (ریال)	شرح هزینه
در صورت استفاده از زیرساخت دانشگاه یا آزمایشگاه، هزینه مستقیم این بخش می تواند صفر باشد. در صورت نیاز به استفاده از سرورهای ابری یا اجاره GPU، هزینه متناسب با تعداد آزمایش ها، مدت زمان اجرا و نوع GPU خواهد بود.	۵۰۰-۰ میلیون	سخت افزار و توان پردازشی
نرم افزارهای اصلی مورد استفاده، چارچوب های یادگیری عمیق و کتابخانه های مورد نیاز متن باز و رایگان هستند. مجموعه داده های اصلی نیز از منابع عمومی و مطابق مجوزهای مربوطه تهیه خواهند شد.	۰	نرم افزار و داده
در صورت استخراج مقاله از پژوهش و ارسال به نشریات یا کنفرانس هایی که دارای هزینه انتشار یا پردازش مقاله باشند، هزینه مربوطه ایجاد خواهد شد.	۱۰۰ میلیون	انتشار نتایج
هزینه نهایی به میزان استفاده از منابع پردازشی دانشگاهی یا سرورهای ابری و	۶۰۰-۰ میلیون	مجموع برآورد هزینه

همچنین محل انتشار نتایج وابسته خواهد بود.	
---	--

بخش قابل توجهی از این پژوهش را می‌توان با استفاده از منابع موجود دانشگاه، آزمایشگاه یا زیرساخت‌های محاسباتی در دسترس انجام داد. بنابراین، هزینه‌های فوق سقف برآوردی بوده و الزاماً به معنای هزینه قطعی پژوهش نیستند. همچنین برخلاف پژوهش‌هایی که نیازمند جمع‌آوری داده میدانی یا خرید مجموعه‌داده اختصاصی هستند، در پژوهش حاضر تمرکز بر استفاده از مجموعه‌داده‌های عمومی و استاندارد است. این موضوع علاوه بر کاهش هزینه، امکان بازتولید آزمایش‌ها و مقایسه منصفانه‌تر نتایج با روش‌های پیشین را فراهم می‌کند.

۲-۵ - امکانات لازم (سخت‌افزاری - نرم‌افزاری و منابع و ...):

مکانات سخت‌افزاری

۱. پردازنده گرافیکی (GPU)

مهم‌ترین نیاز محاسباتی این پژوهش، دسترسی به یک یا چند پردازنده گرافیکی مناسب برای یادگیری عمیق است. دلیل این نیاز، اجرای مدل‌های تشخیص اشیا، آموزش اولیه مدل روی دامنه مبدأ، اجرای متوالی داده‌های هدف، به‌روزرسانی مدل در زمان آزمون و تکرار آزمایش‌ها در سناریوهای مختلف است.

همچنین از آنجا که پژوهش حاضر تنها شامل یک اجرای ساده مدل نیست و نیازمند اجرای مجموعه‌ای از آزمایش‌های مقایسه‌ای، Ablation Study و آزمایش‌های مربوط به توالی‌های مختلف دامنه است، دسترسی به GPU با حافظه کافی اهمیت دارد. استفاده از GPUهایی با حداقل حدود ۱۶ گیگابایت حافظه گرافیکی و ترجیحاً ۲۴ گیگابایت یا بیشتر مناسب خواهد بود. در صورت در دسترس بودن، GPUهای قدرتمند سری NVIDIA RTX یا GPUهای محاسباتی سروری مانند NVIDIA A۱۰۰ می‌توانند برای اجرای سریع‌تر آزمایش‌ها مورد استفاده قرار گیرند.

لازم به ذکر است که وجود GPU با حافظه ۲۴ گیگابایت یا بیشتر یک نیاز ترجیحی است و نه یک الزام مطلق؛ زیرا بخشی از آزمایش‌های Test-Time Adaptation را می‌توان با batch size کوچک و به‌روزرسانی محدود پارامترها اجرا کرد.

۲. پردازنده مرکزی (CPU) و حافظه اصلی (RAM)

یک پردازنده مرکزی چند هسته‌ای مناسب برای:

- پیش‌پردازش داده‌ها؛
- بارگذاری و مدیریت جریان داده؛
- اجرای Data Loader؛
- آماده‌سازی batchهای متوالی؛
- ثبت و تحلیل نتایج؛
- و مدیریت فرآیندهای آزمایشی

مورد نیاز است.

همچنین حداقل ۳۲ گیگابایت RAM پیشنهاد می‌شود. در صورت اجرای هم‌زمان چند فرآیند آزمایشی یا استفاده از مجموعه‌داده‌های حجیم، حافظه بیشتر می‌تواند موجب کاهش زمان پردازش و افزایش کارایی آزمایش‌ها شود.

۳. حافظه ذخیره‌سازی

به دلیل حجم مجموعه‌داده‌های تصویری و همچنین نیاز به ذخیره:

- داده‌های آموزشی؛
- داده‌های اعتبارسنجی و آزمون؛
- وزن‌های مدل؛
- checkpointها؛
- نتایج آزمایش‌ها؛
- logها؛

- و خروجی مطالعات Ablation

استفاده از یک حافظه SSD پرسرعت، ترجیحاً NVMe توصیه می‌شود. ظرفیت حدود ۵۰۰ گیگابایت یا بیشتر برای شروع مناسب خواهد بود و در صورت استفاده هم‌زمان از چند مجموعه داده و نگهداری checkpoint‌های متعدد، ظرفیت بالاتر مورد نیاز خواهد بود.

۲. امکانات نرم‌افزاری (Software)

- سیستم‌عامل Linux، ترجیحاً یکی از نسخه‌های پایدار Ubuntu، برای اجرای آزمایش‌ها پیشنهاد می‌شود؛ زیرا بسیاری از ابزارهای یادگیری عمیق، CUDA و کتابخانه‌های مرتبط با بینایی ماشین پشتیبانی مناسبی در این محیط دارند.
- زبان برنامه‌نویسی پایتون (Python) نسخه ۳.۸ یا بالاتر.
- چارچوب‌های یادگیری عمیق:

- PyTorch: به عنوان چارچوب اصلی برای پیاده‌سازی، آموزش و ارزیابی مدل‌های تشخیص اشیاء.

به‌عنوان چارچوب اصلی برای موارد زیر استفاده خواهد شد:

- پیاده‌سازی مدل تشخیص اشیاء؛
- آموزش مدل پایه؛
- اجرای فرآیند inference؛
- محاسبه سیگنال‌های مورد استفاده در انطباق؛
- به‌روزرسانی پارامترهای مدل؛
- پیاده‌سازی روش‌های TTA و CTTA؛
- و ارزیابی روش پیشنهادی

- کتابخانه‌های کمکی:

- کتابخانه‌های پردازش داده و بینایی ماشین

برای محاسبه معیارهایی مانند:

- mAP
- AP₅₀
- AP₇₅
- Precision
- Recall

و سایر معیارهای مورد نیاز، از ابزارهای استاندارد ارزیابی Object Detection استفاده خواهد شد. ارزیابی صرفاً به یک مقدار نهایی mAP محدود نخواهد شد و روند عملکرد مدل در طول جریان داده نیز بررسی خواهد شد.

- کتابخانه‌ها و ابزارهای ارزیابی تشخیص اشیاء

کتابخانه‌های مورد نیاز شامل موارد زیر خواهند بود:

- NumPy
- OpenCV
- Pandas
- Matplotlib
- Scikit-learn

همچنین بسته به معماری مدل و روش‌های مورد استفاده، کتابخانه‌های تخصصی تشخیص اشیاء و پردازش GPU نیز استفاده خواهند شد.

- محیط توسعه و مدیریت بسته‌ها:

برای مدیریت محیط آزمایشگاهی و جلوگیری از ناسازگاری نسخه کتابخانه‌ها می‌توان از:

- Conda

- یا Python Virtual Environment

همچنین برای ثبت نسخه کد و امکان بازتولید آزمایش‌ها، استفاده از Git پیشنهاد می‌شود.

۳. منابع داده و علمی (Data and Scientific Resources)

مجموعه داده‌های عمومی تشخیص اشیا

با توجه به ماهیت پژوهش، استفاده از مجموعه داده‌های عمومی و استاندارد در حوزه تشخیص اشیا و انطباق دامنه ضروری است. مجموعه داده‌های اصلی مورد استفاده می‌توانند شامل موارد زیر باشند:

۱. Cityscapes

مجموعه داده‌ای از تصاویر واقعی محیط‌های شهری که برای ارزیابی مدل‌های تشخیص و درک صحنه‌های شهری مورد استفاده قرار می‌گیرد. این مجموعه می‌تواند به عنوان یکی از دامنه‌های واقعی در سناریوهای تغییر دامنه مورد استفاده قرار گیرد.

۲. Foggy Cityscapes

نسخه‌ای از Cityscapes است که شرایط مه‌آلود را شبیه‌سازی می‌کند و امکان بررسی اثر تغییر شرایط محیطی و تغییر توزیع داده بر عملکرد مدل را فراهم می‌سازد. این مجموعه به ویژه برای بررسی رفتار مدل در مواجهه با تغییرات تدریجی یا متفاوت در شرایط تصویری مناسب است.

۳. Sim10k

مجموعه داده‌ای شامل تصاویر مصنوعی مربوط به صحنه‌های رانندگی است که می‌تواند برای بررسی سناریوی Synthetic-to-Real Domain Shift مورد استفاده قرار گیرد.

منابع علمی

دسترسی به IEEE Xplore, ACM Digital Library, SpringerLink, ScienceDirect, Google Scholar, Semantic Scholar و arXiv و مقالات کنفرانس‌های CVPR, ICCV, ECCV, NeurIPS, ICML و ICLR.

۶- حداکثر زمان مورد نیاز برای انجام تحقیق :

ردیف	فاز تحقیق	شرح فعالیت‌ها	حداکثر زمان تخصیص یافته (ماه)
۱	فاز اول: مطالعه و تعمیق در مسئله	مرور جامع و عمیق ادبیات حوزه‌های Unsupervised Domain Adaptation, Source-Free Domain Adaptation, Test-Time Adaptation, Online Test-Time Adaptation و Test-Time Adaptation با تمرکز بر کاربرد آن‌ها در تشخیص اشیا. مطالعه روش‌های مرتبط با داده‌های جریانی، انباشت خطا، فراموشی فاجعه‌بار و کارایی محاسباتی. دسته‌بندی و تحلیل روش‌های موجود، شناسایی شکاف‌های پژوهشی و نهایی‌سازی صورت‌بندی مسئله و ایده پیشنهادی.	۳ ماه
۲	فاز دوم: آماده‌سازی و پیاده‌سازی پایه	آماده‌سازی محیط برنامه‌نویسی و نصب چارچوب‌ها و کتابخانه‌های مورد نیاز مانند PyTorch و CUDA. انتخاب، دریافت و آماده‌سازی مجموعه داده‌های استاندارد. طراحی پروتکل ایجاد جریان متوالی داده‌های هدف بدون برچسب و سناریوهای تغییر دامنه. پیاده‌سازی و اجرای مدل‌های پایه و روش‌های Baseline برای اطمینان از صحت Pipeline و ایجاد نتایج مرجع اولیه.	۲ ماه
۳	فاز سوم: طراحی و پیاده‌سازی روش پیشنهادی	طراحی و پیاده‌سازی چارچوب پیشنهادی برای انطباق آنلاین و پیوسته در زمان آزمون. توسعه سازوکار استخراج و ارزیابی قابلیت اعتماد سیگنال انطباق از داده‌های بدون برچسب، طراحی راهبرد به‌روزرسانی مدل در طول جریان داده، و توسعه مکانیزم‌های کنترل Catastrophic Forgetting و Error Accumulation و حفظ دانش پیشین. ادغام اجزای روش، تنظیم پارامترها، تست و رفع خطای کامل پیاده‌سازی.	۶ ماه

۴ ماه	اجرای سناریوهای اصلی آزمایش در قالب جریان‌های متوالی داده و تغییرات مختلف دامنه. ارزیابی عملکرد مدل در طول فرآیند انطباق و بررسی <i>Detection Accuracy</i> , <i>Error Accumulation</i> , <i>Forgetting</i> , <i>Adaptation Stability</i> و <i>Adaptation Speed</i> و <i>Computational Cost</i> . اجرای مطالعات مؤلفه‌ها (Ablation Study) برای تعیین سهم هر بخش از روش پیشنهادی. مقایسه با مدل بدون انطباق و روش‌های معتبر <i>TTA</i> و <i>CTTA</i> و تحلیل جداول، نمودارها و نتایج علمی.	فاز چهارم: اجرای آزمایش‌ها و تحلیل نتایج
۳ ماه	نگارش و تکمیل فصول پایان‌نامه/مقاله شامل مقدمه، مبانی و کارهای پیشین، روش پیشنهادی، پروتکل آزمایش‌ها، نتایج و تحلیل، و نتیجه‌گیری. تهیه جداول، نمودارها و شکل‌های نهایی، آماده‌سازی اسلایدهای دفاع و انجام بازیابی و اصلاح نهایی متن بر اساس بازخورد استاد راهنما.	فاز پنجم: نگارش و تدوین نهایی
۱۸ ماه	مجموع زمان	

۷- زمان‌بندی تحقیق (نمودار گانت):

زمان مورد نیاز	ماه اول	ماه دوم	ماه سوم	ماه چهارم	ماه پنجم	ماه ششم	ماه هفتم	ماه هشتم	ماه نهم	ماه دهم	ماه یازدهم	ماه دوازدهم
فاز اول												
فاز دوم												
فاز سوم												
فاز چهارم												
فاز پنجم												

۸- فهرست منابع و مأخذ:

- [۱] H. Tang and K. Jia, "A New Benchmark: On the Utility of Synthetic Data With Blender for Bare Supervised Learning and Downstream Domain Adaptation," presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, ۲۰۲۳, pp. ۱۵۹۵۴–۱۵۹۶۴. Accessed: Sep. ۱۱, ۲۰۲۶. [Online]. Available: https://openaccess.thecvf.com/content/CVPR۲۰۲۳/html/Tang_A_New_Benchmark_On_the_Utility_of_Synthetic_Data_With_CVPR۲۰۲۳_paper.html
- [۲] J. Nath Kundu, N. Venkat, M. V. Rahul, and R. Venkatesh Babu, "Universal Source-Free Domain Adaptation," in ۲۰۲۰ IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), Jun. ۲۰۲۰, pp. ۴۵۴۳–۴۵۵۲. doi: ۱۰.۱۱۰۹/CVPR۴۲۶۰۰۲۰۲۰۰۰۴۶۰.
- [۳] Q. Wang, O. Fink, L. Van Gool, and D. Dai, "Continual Test-Time Domain Adaptation," presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, ۲۰۲۲, pp. ۷۲۰۱–۷۲۱۱. Accessed: Sep. ۱۳, ۲۰۲۶. [Online]. Available: https://openaccess.thecvf.com/content/CVPR۲۰۲۲/html/Wang_Continual_Test-Time_Domain_Adaptation_CVPR۲۰۲۲_paper.html?utm_source=chatgpt.com

- [4] X. Ruan and W. Tang, "Fully Test-time Adaptation for Object Detection," in *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, Jun. 2024, pp. 1038–1047. doi: 10.1109/CVPRW63382.2024.00110.
- [5] S. Cao, D. Joshi, L.-Y. Gui, and Y.-X. Wang, "Contrastive Mean Teacher for Domain Adaptive Object Detectors," in *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2023, pp. 23839–23848. doi: 10.1109/CVPR47392.2023.02283.
- [6] S. Niu et al., "Efficient Test-Time Model Adaptation without Forgetting," in *Proceedings of the 39th International Conference on Machine Learning*, PMLR, Jun. 2022, pp. 16888–16905. Accessed: Sep. 13, 2026. [Online]. Available: <https://proceedings.mlr.press/v162/niu22a.html>
- [7] K. Wang et al., "Efficient Test-Time Adaptive Object Detection via Sensitivity-Guided Pruning," in *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2024, pp. 10577–10586. doi: 10.1109/CVPR47392.2024.00989.
- [8] "What, How, and When Should Object Detectors Update in Continually Changing Test Domains?" Accessed: Sep. 13, 2026. [Online]. Available: <https://www.computer.org/csdl/proceedings-article/cvpr/2024/53...x354/2-hMpwgeigA>
- [9] V. Vs, P. Oza, and V. M. Patel, "Towards Online Domain Adaptive Object Detection," arXiv.org. Accessed: Sep. 13, 2026. [Online]. Available: <https://arxiv.org/abs/22.04.05289v2>
- [10] D. Wang, E. Shelhamer, S. Liu, B. Olshausen, and T. Darrell, "Tent: Fully Test-time Adaptation by Entropy Minimization," Mar. 18, 2021, arXiv: arXiv:20.06.10726. doi: 10.48550/arXiv.20.06.10726.
- [11] Y. Chen, W. Li, C. Sakaridis, D. Dai, and L. Van Gool, "Domain Adaptive Faster R-CNN for Object Detection in the Wild," in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, Jun. 2018, pp. 3339–3348. doi: 10.1109/CVPR.2018.00352.
- [12] J. Deng, W. Li, Y. Chen, and L. Duan, "Unbiased Mean Teacher for Cross-domain Object Detection," in *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2021, pp. 4089–4099. doi: 10.1109/CVPR46437.2021.00408.
- [13] "Do We Really Need to Access the Source Data? Source Hypothesis Transfer for Unsupervised Domain Adaptation." Accessed: Sep. 14, 2026. [Online]. Available: <https://proceedings.mlr.press/v119/liang20a.html>
- [14] "Source-free unsupervised domain adaptation: A survey - ScienceDirect." Accessed: Sep. 14, 2026. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S0893608024001540>
- [15] "A Comprehensive Survey on Test-Time Adaptation Under Distribution Shifts | International Journal of Computer Vision." Accessed: Sep. 14, 2026. [Online]. Available: <https://dl.acm.org/doi/10.1007/s11263-024-02402-1>
- [16] "In Search of Lost Online Test-Time Adaptation: A Survey | International Journal of Computer Vision | Springer Nature Link." Accessed: Sep. 14, 2026. [Online]. Available: <https://link.springer.com/article/10.1007/s11263-024-02213-5>
- [17] L. Yuan, B. Xie, and S. Li, "Robust Test-Time Adaptation in Dynamic Scenarios," arXiv.org. Accessed: Sep. 14, 2026. [Online]. Available: <https://arxiv.org/abs/23.03.12899v1>
- [18] S. Niu et al., "Towards Stable Test-Time Adaptation in Dynamic Wild World," arXiv.org. Accessed: Sep. 14, 2026. [Online]. Available: <https://arxiv.org/abs/23.02.12400v1>
- [19] O. Press, S. Schneider, M. Kümmerer, and M. Bethge, "RDumb: A simple approach that questions our progress in continual test-time adaptation," arXiv.org. Accessed: Sep. 14, 2026. [Online]. Available: <https://arxiv.org/abs/23.06.05401v3>
- [20] D. Li, A. Wu, Y. Li, Y. Wang, and Y. Han, "Continual Adaptation: Environment-Conditional Parameter Generation for Object Detection in Dynamic Scenarios," presented at the Proceedings of the IEEE/CVF International Conference on Computer Vision, 2025, pp. 4434–4442. Accessed: Sep. 15, 2026. [Online].

Available: https://openaccess.thecvf.com/content/ICCV2020/html/Li_Continual_Adaptation_Environment-Conditional_Parameter_Generation_for_Object_Detection_in_Dynamic_ICCV_2020_paper.html?utm_source=chatgpt.com

- X. Chen *et al.*, “Test-Time Distillation for Continual Model Adaptation,” presented at the Proceedings of [21] the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2026, pp. 7593–7604. Accessed: Sep. 17, 2026. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2026F/html/Chen_Test-Time_Distillation_for_Continual_Model_Adaptation_CVPRF_2026_paper.html?utm_source=chatgpt.com
- Y. Qin *et al.*, “ViTPrompt: Training-Free Prompt Refinement with Visual Tokens for Open-Vocabulary [22] Detection,” presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2026, pp. 3111–3121. Accessed: Sep. 17, 2026. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2026/html/Qin_ViTPrompt_Training-Free_Prompt_Refinement_with_Visual_Tokens_for_Open-Vocabulary_Detection_CVPR_2026_paper.html?utm_source=chatgpt.com
- G. Lai, D.-W. Zhou, Z. Li, and H.-J. Ye, “The Golden Subspace: Where Efficiency Meets Generalization in [23] Continual Test-Time Adaptation,” presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2026, pp. 3866–3875. Accessed: Sep. 17, 2026. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2026/html/Lai_The_Golden_Subspace_Where_Efficiency_Meets_Generalization_in_Continual_Test-Time_CVPR_2026_paper.html?utm_source=chatgpt.com
- X. Que, D. Wang, X. Liu, and Q. Yu, “InsCal: Calibrated Multi-Source Fully Test-Time Prompt Tuning for [24] Object Detection,” presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2026, pp. 3693–3694. Accessed: Sep. 17, 2026. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2026/html/Que_InsCal_Calibrated_Multi-Source_Fully_Test-Time_Prompt_Tuning_for_Object_Detection_CVPR_2026_paper.html?utm_source=chatgpt.com
- E. Tzeng, J. Hoffman, N. Zhang, K. Saenko, and T. Darrell, “Deep Domain Confusion: Maximizing for Domain [25] Invariance,” Dec. 10, 2014, *arXiv: arXiv:1412.3474*. doi: 10.48550/arXiv.1412.3474.
- Y. Ganin *et al.*, “Domain-Adversarial Training of Neural Networks,” May 26, 2016, *arXiv: arXiv:1505.07818*. [26] doi: 10.48550/arXiv.1505.07818.
- S. Cao *et al.*, “Continual Test-Time Adaptation for Object Detection with Adaptive Monitoring and [27] Randomized Restoration,” *arXiv.org*. Accessed: Sep. 28, 2026. [Online]. Available: <https://arxiv.org/abs/2406.1649v6>
- Y. Chen, X. Xu, Y. Su, and K. Jia, “STFAR: Improving Object Detection Robustness at Test-Time by Self- [28] Training with Feature Alignment Regularization,” *arXiv.org*. Accessed: Sep. 28, 2026. [Online]. Available: <https://arxiv.org/abs/2303.11937v1>
- C. Michaelis *et al.*, “Benchmarking Robustness in Object Detection: Autonomous Driving when Winter is [29] Coming,” *arXiv.org*. Accessed: Sep. 29, 2026. [Online]. Available: <https://arxiv.org/abs/1907.07484v2>
- M. Cordts *et al.*, “The Cityscapes Dataset for Semantic Urban Scene Understanding,” *arXiv.org*. Accessed: [30] Sep. 29, 2026. [Online]. Available: <https://arxiv.org/abs/1604.01685v2>
- “WNJXYK/TTA-Cityscapes-C · Datasets at Hugging Face.” Accessed: Sep. 29, 2026. [Online]. Available: <https://huggingface.co/datasets/WNJXYK/TTA-Cityscapes-C>
- T. Sun *et al.*, “SHIFT: A Synthetic Driving Dataset for Continuous Multi-Task Domain Adaptation,” [32] presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 21371–21382. Accessed: Sep. 29, 2026. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2022/html/Sun_SHIFT_A_Synthetic_Driving_Dataset_for_Continuous_Multi-Task_Domain_Adaptation_CVPR_2022_paper.html?utm_source=chatgpt.com

- C. Sakaridis *et al.*, "ACDC: The Adverse Conditions Dataset with Correspondences for Robust Semantic [۳۳]
Driving Scene Perception," Nov. ۱۲, ۲۰۲۵, *arXiv*: arXiv:۲۱۰۴.۱۳۳۹۵. doi: ۱۰.۴۸۵۵۰/arXiv.۲۱۰۴.۱۳۳۹۵.
- D. Du *et al.*, "The Unmanned Aerial Vehicle Benchmark: Object Detection and Tracking," Mar. ۲۶, ۲۰۱۸, [۳۴]
arXiv: arXiv:۱۸۰۴.۰۰۵۱۸. doi: ۱۰.۴۸۵۵۰/arXiv.۱۸۰۴.۰۰۵۱۸.

* کلیه صفحات به صورت تایپ شده تحویل شوند.

۹- نظریه شورای تحصیلات تکمیلی مجتمع دانشگاهی برق و کامپیوتر
(دقت شود که این صفحه به طور مجزا تهیه و تکمیل شود)

پایان نامه دانشجو خانم / آقای

با موضوع پایان نامه..... به

راهنمایی آقای دکتر و استاد مشاور آقای دکتر..... در

شورای گروه علمی..... مورخ

مورد بررسی قرار و به تصویب رسید.

ردیف	نام و نام خانوادگی اعضای گروه علمی	محل امضاء
۱		
۲		
۳		
۴		
۵		
۶		

۷

