



دانشگاه صنعتی مالک اشتر

بسمه تعالی

دانشگاه صنعتی مالک اشتر

معاونت آموزش و تحصیلات تکمیلی

پیشنهاد پایان نامه مقطع کارشناسی ارشد

کمیته محترم تحصیلات تکمیلی مجتمع دانشگاهی برق و کامپیوتر

احتراماً، اینجانب امیررضا کاظم لو به شماره دانشجویی ۴۰۳۱۴۱۹۰۱۳ دانشجوی کارشناسی ارشد رشته مهندسی کامپیوتر گرایش هوش مصنوعی و رباتیک شاغل در - که تحصیلات خود را در رشته فوق از نیمسال اول سال تحصیلی ۱۴۰۳ شروع نمودم و تاکنون تعداد ۲۶ واحد از دروس اصلی و اختصاصی را با موفقیت و با معدل کل ۱۹.۴۶ گذرانده‌ام در مرحله شروع پایان نامه خود هستم.

پس از انجام مشاوره‌های لازم و با عنایت به زمینه علمی مورد نیاز، آقای دکتر محمدعلی کیوان راد را بعنوان استاد راهنمای پایان نامه انتخاب کردم و با استفاده از نظرات و راهنمایی‌های ایشان پس از بررسی و مطالعه دقیق موضوع تحقیق، موضوع پایان نامه خود را کتباً و در قالب فرم پیوست تقدیم می‌نمایم. بدیهی است پذیرش قطعی موضوع پایان نامه منوط بر تصویب آن در کمیته می‌باشد.

ضمناً با پیشنهاد استاد راهنمای پایان نامه آقای - را نیز بعنوان استاد مشاور انتخاب نموده‌ام.

امضاء دانشجو

تاریخ: ۱۴۰۵/۰۶/۲۰

عنوان کامل پایان نامه : انطباق آنلاین در زمان آزمون برای تشخیص اشیا با تأکید ویژه بر سناریوی انطباق پیوسته.

نوع پروژه:

بدون طبقه‌بندی	محرمانه	خیلی محرمانه	سری	بکلی سری
----------------	---------	--------------	-----	----------

مراتب فوق مورد تأیید است:

تاریخ و امضاء

۱ - نام و نام خانوادگی استاد راهنما

دکتر محمد علی کیوان راد

تاریخ و امضاء

۲ - نام و نام خانوادگی استاد مشاور

تاریخ و امضاء

۳- نام و نام خانوادگی کارشناس آموزش و تحصیلات تکمیلی مجتمع

تاریخ و امضاء

۴- نام و نام خانوادگی مدیریت آموزش و تحصیلات تکمیلی مجتمع

* کلیه صفحات به صورت تایپ شده تحویل شوند.



دانشگاه صنعتی شاهرود

بسمه تعالی
دانشگاه صنعتی مالک اشتر
معاونت آموزش و تحصیلات تکمیلی

پرسشنامه تهیه پیشنهاد اولیه (پروپوزال) جهت پایان نامه کارشناسی ارشد

نام و نام خانوادگی دانشجو: امیررضا کاظم لو

شماره دانشجویی: ۴۰۳۱۴۱۹۰۱۳

رشته و گرایش تحصیلی: مهندسی کامپیوتر - گرایش هوش مصنوعی و رباتیک

عنوان پایان نامه:

به فارسی: تطبیق برخط دامنه در زمان آزمون برای تشخیص اشیا با تمرکز بر انتقال از داده‌های مصنوعی به واقعی

به لاتین: Online Test-Time Domain Adaptation for Object Detection with a Focus on Synthetic-to-Real Transfer

نوع تحقیق:

☐ بنیادی ☐ توسعه‌ای ☐ کاربردی

1- اطلاعات مربوط به دانشجو:

1-1- تعداد واحدهای گذرانده: ۲۶ تعداد واحدهای باقیمانده: ۶ معدل (تاکنون): ۱۹.۴۶

1-2- آدرس: تهران، شهرک ولی عصر خیابان آقابابایان، کوچه گلنار، پلاک ۲۳، طبقه اول

1-2-1- شماره تلفن ثابت: ۰۲۱۶۶۱۳۳۵۷۱

1-2-2- شماره تلفن همراه: ۰۹۱۰۱۷۲۷۲۳۴

1-3- در صورت بورسیه بودن، نام سازمان بورسیه دهنده:

2- اطلاعات مربوط به اساتید راهنما و مشاور:

سمت	نام و نام خانوادگی	تخصص یا رشته	رتبه علمی	تعداد پایان نامه‌های راهنمایی شده		تعداد پایان نامه‌های تحت راهنمایی	
				ارشد	دکتری	ارشد	دکتری
استاد راهنمای اول	محمد علی کیوان راد	مهندسی کامپیوتر - هوش مصنوعی	استادیار				
استاد راهنمای دوم							
استاد مشاور							

* تذکر: در صورتی که اساتید فوق عضو هیأت علمی دانشگاه صنعتی مالک اشتر نمی‌باشند؛ آدرس و شماره تلفن آن‌ها ذیل آفید شود.

آدرس استاد (اساتید) راهنما:

شماره تلفن استاد (اساتید) راهنما:

آدرس استاد مشاور:

شماره تلفن استاد مشاور:

3- اطلاعات مربوط به پایان نامه :

3-1- مسئله و اهداف اصلی تحقیق :

مسئله تحقیق

مدل‌های یادگیری عمیق در سال‌های اخیر به عملکرد قابل توجهی در وظایف مختلف بینایی ماشین، از جمله تشخیص اشیاء، دست یافته‌اند. با این حال، بخش مهمی از این موفقیت بر این فرض استوار است که داده‌های مورد استفاده در مرحله آموزش و داده‌هایی که مدل در زمان استقرار با آن‌ها مواجه می‌شود، از توزیع‌های یکسان یا دست‌کم مشابه پیروی می‌کنند. در کاربردهای واقعی، این فرض غالباً برقرار نیست؛ زیرا عواملی مانند تغییر شرایط روشنایی و آب‌وهوا، تغییر نوع و مشخصات حسگر، تغییر زاویه دید، تفاوت محیط جغرافیایی، تغییر پس‌زمینه و سایر تغییرات عملیاتی می‌توانند توزیع داده‌های ورودی را نسبت به داده‌های آموزشی تغییر دهند. در نتیجه، مدلی که در دامنه مبدأ عملکرد مناسبی داشته است، ممکن است هنگام استقرار در یک دامنه جدید با کاهش قابل توجه دقت مواجه شود؛ مسئله‌ای که در ادبیات یادگیری ماشین تحت عنوان «تغییر توزیع» و در مسائل انتقال میان دامنه‌ها به صورت «شکاف دامنه» مطرح می‌شود. همین زنجیره مفهومی از تغییر توزیع تا شکاف دامنه و انطباق در نسخه فعلی پیشنهادیه پایان نامه نیز به عنوان مبنای مسئله پژوهش در نظر گرفته شده است.

یکی از راهکارهای مناسب برای کاهش هزینه تهیه داده آموزشی، به‌ویژه در مسائلی که جمع‌آوری و برچسب‌گذاری داده واقعی پرهزینه، زمان‌بر یا محدود است، استفاده از داده‌های مصنوعی است. محیط‌های شبیه‌سازی شده امکان تولید حجم بالایی از داده همراه با برچسب‌های دقیق را فراهم می‌کنند و در نتیجه می‌توانند هزینه آموزش اولیه مدل‌های پیچیده را به میزان قابل توجهی کاهش دهند. پژوهش‌های جدید نیز استفاده از داده‌های مصنوعی و انتقال دانش از شبیه‌سازی به داده‌های واقعی را به عنوان یک مسیر عملی برای توسعه سامانه‌های بینایی ماشین بررسی کرده‌اند [1]. با این حال، تفاوت میان فرآیند تولید تصاویر مصنوعی و شرایط تصویربرداری واقعی موجب ایجاد شکاف «مصنوعی به واقعی» می‌شود و بنابراین مدلی که صرفاً روی داده مصنوعی آموزش یافته است، الزاماً همان سطح عملکرد را روی داده واقعی حفظ نمی‌کند. بنابراین استفاده از داده مصنوعی به دلیل هزینه پایین و مقیاس‌پذیری مناسب می‌باشد و افت عملکرد مدل در محیط واقعی به علت تغییر توزیع، انگیزه اصلی انطباق می‌باشد.

رویکردهای متداول انطباق دامنه بدون نظارت می‌توانند با استفاده از داده‌های بدون برچسب دامنه هدف، بخشی از این شکاف را کاهش دهند؛ با این حال، در تنظیم کلاسیک این روش‌ها معمولاً فرض می‌شود که داده‌های برچسب‌دار مبدأ و داده‌های بدون برچسب هدف در فرایند انطباق در دسترس هستند. چنین فرضی برای بسیاری از کاربردهای واقعی محدودکننده است. نگهداری یا انتقال مجموعه داده‌های حجیم مبدأ می‌تواند هزینه ذخیره‌سازی و ارتباطی بالایی داشته باشد و در برخی کاربردها نیز ملاحظات محرمانگی، مالکیت داده یا حریم خصوصی مانع از دسترسی به داده‌های اصلی آموزش در محل استقرار مدل می‌شود. این محدودیت یکی از دلایل گذار از انطباق دامنه کلاسیک به تنظیم‌های بدون منبع و زمان آزمون می‌باشد [2].

پارادایم «انطباق در زمان آزمون»¹ یا «TTA» برای کاهش این محدودیت مطرح شده است. در تنظیم کامل انطباق در زمان آزمون، مدل در مرحله استنتاج با اتکا به پارامترهای مدل از پیش آموزش‌دیده و داده‌های بدون برچسب آزمون خود را با توزیع جدید سازگار می‌کند و به داده‌های آموزشی اولیه دسترسی ندارد. یکی از کارهای پایه در این حوزه، روش «TENT» است که نشان داد می‌توان در زمان آزمون و بدون دسترسی به داده مبدأ، با کمینه‌سازی آنتروپی پیش‌بینی و به‌روزرسانی محدود پارامترهای نرمال‌سازی، مدل را نسبت به تغییرات توزیع سازگار کرد [3]. بنابراین TTA از منظر عملی، امکان نزدیک‌تر کردن فرایند انطباق به شرایط واقعی استقرار را فراهم می‌کند.

با این حال، یک محدودیت مهم همچنان باقی می‌ماند. بسیاری از سناریوهای اولیه انطباق دامنه یا انطباق در زمان آزمون، یک دامنه هدف نسبتاً ثابت یا امکان دسترسی مناسب به داده‌های هدف را در نظر می‌گیرند؛ در حالی که یک سامانه بینایی ماشین واقعی ممکن است به‌طور مستمر در محیطی غیرایستا فعالیت کند. برای مثال، یک سامانه تشخیص اشیاء در خودرو، ربات متحرک یا سامانه

Commented [ak1]: این مقاله برای توجیه استفاده از داده مصنوعی و مسئله انتقال مصنوعی به واقعی مناسب است.

Commented [ak2]: دلیل اضافه کردن مرتبط بودن این بخش به source free domain adaptation

Commented [ak3]: این مقاله یکی از منابع پایه برای تعریف Fully Test-Time Adaptation است.

¹ Test time domain adaptation

نظارت تصویری ممکن است طی زمان از محیط روشن به تاریک، از هوای صاف به مه‌آلود، از یک دوربین به دوربین دیگر یا از یک محیط جغرافیایی به محیطی کاملاً متفاوت منتقل شود. در چنین شرایطی، داده‌ها به صورت جریانی و متوالی وارد سامانه می‌شوند و مدل باید هم‌زمان با استنتاج، خود را با تغییرات جدید سازگار کند. به این معنا که دسته‌های کوچک داده به‌صورت متوالی مشاهده می‌شوند و هر دسته ممکن است فقط یک مرتبه در اختیار مدل قرار گیرد.

این تنظیم در ادبیات جدید عمدتاً در قالب «انطباق پیوسته در زمان آزمون» و در برخی آثار در قالب انطباق آنلاین مطالعه می‌شود. روش «CoTTA» نشان داد که در محیط‌های غیرایستا و دارای تغییرات متوالی توزیع، اتکای ساده به خودآموزی یا کمینه‌سازی آنتروپی می‌تواند ناپایدار باشد؛ زیرا با تغییر دامنه، کیفیت شبه‌برچسب‌ها کاهش یافته و استفاده مجدد از پیش‌بینی‌های نادرست می‌تواند به انباشت خطا و در نهایت فراموشی فاجعه بار دانش قبلی منجر شود [4]. این دو مسئله، یعنی «انباشت خطا» و «فراموشی فاجعه‌بار»، دو چالش محوری انطباق آنلاین در زمان آزمون در می‌باشند.

این مسئله در تشخیص اشیاء دشوارتر از بسیاری از مسائل طبقه‌بندی تصویر است. در طبقه‌بندی، مدل عمدتاً یک برچسب یا توزیع احتمال کلاس را برای کل تصویر پیش‌بینی می‌کند؛ اما آشکارساز اشیاء علاوه بر تعیین کلاس هر شیء، باید موقعیت و ابعاد آن را نیز از طریق جعبه محدودکننده برآورد کند. بنابراین خطای شبه‌برچسب در تشخیص اشیاء تنها به انتخاب کلاس اشتباه محدود نیست و می‌تواند شامل خطای مکان‌یابی نیز باشد. خطای مکان‌یابی موجب استخراج ویژگی از نواحی نامناسب تصویر و ورود اطلاعات پس‌زمینه به بازنمایی شیء می‌شود؛ از طرف دیگر، خطای دسته‌بندی نیز می‌تواند فرایند یادگیری مکان شیء را مختل کند. همین وابستگی میان خطای طبقه‌بندی و خطای مکان‌یابی سبب می‌شود که استفاده از شبه‌برچسب‌های نویزی در یک چرخه انطباق پیوسته، نسبت به مسئله طبقه‌بندی حساسیت بیشتری داشته باشد.

مطالعات جدید روی انطباق در زمان آزمون برای تشخیص اشیاء این مسئله را نیز تأیید می‌کنند. Ruan و Tang در پژوهش «Fully Test-time Adaptation for Object Detection» نشان داده‌اند که یکی از چالش‌های اساسی خودآموزی در این تنظیم، غیرقابل اعتماد بودن شبه‌برچسب‌ها تحت شکاف دامنه است و صرف اعتماد به امتیاز اطمینان آشکارساز برای انتخاب شبه‌برچسب‌ها کفایت نمی‌کند [5]. پیش از آن نیز مطالعات انطباق دامنه برای آشکارسازی نشان داده بودند که کیفیت شبه‌برچسب‌ها یک عامل تعیین‌کننده برای موفقیت چارچوب‌های خودآموزی است؛ برای نمونه، «Contrastive Mean Teacher» به‌طور مشخص افت ناشی از شبه‌برچسب‌های کم‌کیفیت را یکی از محدودیت‌های روش‌های معلم — دانش‌آموز در تشخیص اشیاء گزارش می‌کند [6].

چالش دیگر، حفظ دانش مدل در طول انطباق است. اگر پارامترهای مدل صرفاً بر اساس داده‌های ورودی جاری و بدون هیچ سازوکار کنترلی به‌روزرسانی شوند، مدل ممکن است برای سازگار شدن با دامنه فعلی از بازنمایی‌های عمومی و مفیدی که در مرحله آموزش اولیه آموخته است فاصله بگیرد. در انطباق پیوسته، این مسئله می‌تواند با گذشت زمان تشدید شود و مدل بخشی از توانایی خود را برای عملکرد در شرایط قبلی یا نزدیک به دامنه مبدأ از دست بدهد. روش CoTTA برای مقابله با این مسئله بخشی از پارامترها را به شکل تصادفی به مقادیر مدل مبدأ بازمی‌گرداند [4]؛ روش EATA نیز نشان داده است که حفظ پارامترهای مهم مدل از طریق منظم‌سازی می‌تواند ضمن کاهش فراموشی، هزینه انطباق را نیز کاهش دهد [7]. در این پروپوزال نیز ایجاد تعادل میان یادگیری سریع اطلاعات دامنه جدید و حفظ دانش پیشین، یکی از مسائل اصلی پژوهش در نظر گرفته شده است.

محدودیت مهم دیگر، هزینه محاسباتی انطباق است. مزیت نظری یک روش انطباق در زمان آزمون زمانی در محیط واقعی قابل استفاده خواهد بود که فرایند انطباق خود موجب کاهش غیرقابل قبول سرعت پردازش نشود. این مسئله در تشخیص اشیاء اهمیت بیشتری دارد؛ زیرا خود آشکارسازی اشیاء از نظر محاسباتی سنگین است و انجام چندین مرحله به‌روزرسانی برای هر فریم یا دسته داده می‌تواند کاربرد روش را در سامانه‌های برخط محدود کند. پژوهشی در کنفرانس CVPR ۲۰۲۴ درباره انطباق پیوسته آشکارسازهای اشیاء، مسئله «چه بخشی از مدل، چگونه و در چه زمانی به‌روزرسانی شود» را مستقیماً بررسی کرده و نشان داده است که انطباق سبک و انتخابی می‌تواند ضمن حفظ سرعت استنتاج، عملکرد آشکارساز را در دامنه‌های متغیر بهبود دهد [8]. همچنین پژوهش جدیدتر در کنفرانس CVPR ۲۰۲۵ در زمینه «Continual Test-time Adaptive Object Detection» تصریح

Commented [ak4]: این مقاله برای تعریف محیط غیرایستا، انباشت خطا و فراموشی فاجعه‌بار بسیار مهم است

Commented [ak5]: این مقاله مستقیماً مسئله TTA برای تشخیص اشیاء و عدم اطمینان شبه‌برچسب‌ها را بررسی می‌کند.

Commented [ak6]: برای مسئله کیفیت شبه‌برچسب در تشخیص اشیاء و چارچوب معلم - دانش‌آموز منبع مناسبی است.

Commented [ak7]: برای مسئله کارایی و منظم‌سازی ضدفراموشی اضافه کردم.
این پیپر جا داره بیشتر بخونمش:
<https://chatgpt.com/share/6aa5c62b-e5e0-83eb-98fa-d247b2a2a82f>

Commented [ak8]: این مقاله یکی از مهم‌ترین منابع مستقیم برای موضوع پایان‌نامه است؛ زیرا به انطباق آنلاین آشکارساز اشیاء در دامنه‌های متغیر، جلوگیری از فراموشی و حفظ سرعت عملیاتی می‌پردازد.

Commented [ak9]: این مقاله برای نشان دادن وضعیت جدیدتر حوزه و اهمیت همزمان دقت و کارایی در CTTA - OD بسیار مناسب است.

Commented [ak10]: ارتباط مستقیم با انطباق آنلاین تشخیص اشیا و آزمایش انتقال «Cityscapes»→ «Sim10K» اهمیت دارد.

می‌کند که بسیاری از روش‌های موجود بر افزایش دقت تمرکز دارند، در حالی که کارایی محاسباتی برای کاربردهای دارای محدودیت منابع یک مسئله اساسی است [9].

از سوی دیگر، مطالعات اختصاصی تشخیص اشیا نشان داده‌اند که نیاز به انطباق آنلاین فقط یک مسئله نظری نیست. پژوهش «Towards Online Domain Adaptive Object Detection» مسئله استقرار آشکارساز در دامنه‌های متغیر را بررسی کرده و استدلال می‌کند که سازگارسازی آنلاین با یک دامنه هدف ثابت برای محیط‌هایی که مدل به‌طور مداوم با تغییرات جدید مواجه می‌شود، کافی نیست. این پژوهش همچنین سناریوی انتقال مدل آموزش دیده روی داده مصنوعی «Sim10K» به داده واقعی «Cityscapes» را به عنوان یکی از تنظیم‌های آنلاین ارزیابی کرده است [10]. که یکی از اهداف پژوهش انطباق مدل تشخیص اشیا از داده‌های آموزشی مصنوعی به داده‌های واقعی در زمان استقرار، می‌باشد.

بر این اساس، مسئله اصلی این پژوهش را می‌توان چنین صورت‌بندی کرد: چگونه می‌توان یک مدل تشخیص اشیا را که پیش‌تر، به‌طور کامل یا عمدتاً، با داده‌های دامنه مبدأ و به‌ویژه داده‌های مصنوعی آموزش دیده است، در هنگام استقرار و تنها با استفاده از جریان داده‌های بدون برچسب دامنه هدف، بدون دسترسی به داده‌های آموزشی مبدأ، به‌صورت برخط با تغییرات توزیع سازگار کرد؛ به‌گونه‌ای که هم‌زمان کیفیت پیش‌بینی‌های طبقه‌بندی و مکان‌یابی حفظ یا بهبود یابد، اثر شبه‌برچسب‌های نادرست و انباشت خطا کنترل شود، از فراموشی فاجعه‌بار دانش پیشین جلوگیری گردد و هزینه محاسباتی فرایند انطباق با محدودیت‌های یک سامانه عملیاتی سازگار باشد؟ بنابراین، مسئله پژوهش حاضر صرفاً «افزایش دقت یک مدل در یک مجموعه داده هدف ثابت» نیست؛ بلکه طراحی و ارزیابی یک سازوکار انطباق در زمان آزمون برای یک آشکارساز مستقرشده در محیط پویا است که باید میان چهار نیاز گاه متعارض تعادل برقرار کند: «یادگیری سریع اطلاعات دامنه جدید»، «قابلیت اعتماد سیگنال خودنظارتی و شبه‌برچسب‌ها»، «حفظ دانش عمومی و جلوگیری از فراموشی» و «کارایی محاسباتی در انطباق برخط». که جهت اصلی هسته این پژوهش یعنی انطباق آنلاین، داده‌های جریانی، انباشت خطا و فراموشی فاجعه‌بار می‌باشد.

اهداف اصلی تحقیق

هدف اصلی

هدف اصلی این پژوهش، طراحی، پیاده‌سازی و ارزیابی یک چارچوب کارآمد برای انطباق آنلاین در زمان آزمون مدل‌های تشخیص اشیا، با تمرکز بر سناریوی انتقال از داده‌های مصنوعی به داده‌های واقعی است؛ به‌گونه‌ای که مدل از پیش آموزش دیده بتواند در زمان استنتاج و بدون دسترسی به داده‌های آموزشی مبدأ یا برچسب‌های دامنه هدف، خود را با تغییرات متوالی توزیع داده سازگار کند و در عین حال، اثر خطاهای ناشی از شبه‌برچسب‌های نامطمئن و فراموشی فاجعه‌بار دانش پیشین را کنترل کرده، انطباق سریع برای دسته‌هایی که فقط یک‌بار مشاهده می‌شوند را فراهم کرده و هزینه محاسباتی انطباق را در سطح قابل قبول برای کاربردهای برخط حفظ نماید.

اهداف فرعی

1. صورت‌بندی دقیق سناریوی انطباق آنلاین در زمان آزمون برای تشخیص اشیا

تعریف یک چارچوب روشن برای مسئله‌ای که در آن مدل آشکارساز از پیش آموزش دیده در اختیار است، داده‌های مبدأ در زمان انطباق قابل دسترسی نیستند، داده‌های هدف فاقد برچسب‌اند، نمونه‌ها یا دسته‌های کوچک به‌صورت جریانی وارد مدل می‌شوند و امکان مشاهده مکرر کل مجموعه داده هدف وجود ندارد. این صورت‌بندی، تفاوت پژوهش حاضر با انطباق دامنه کلاسیک، انطباق بدون منبع آنلاین و انطباق روی یک مجموعه هدف ثابت می‌باشد.

2. توسعه سازوکاری برای استخراج سیگنال نظارتی قابل اعتماد از داده‌های بدون برچسب هدف

از آنجا که در زمان آزمون برچسب واقعی داده‌های ورودی در دسترس نیست، مدل باید سیگنال لازم برای انطباق را از پیش‌بینی‌های خود یا سایر روابط خودنظارتی استخراج کند. بنابراین یکی از اهداف اصلی، کاهش اثر شبه‌برچسب‌های نامطمئن و جلوگیری از ورود

پیش‌بینی‌های نادرست به چرخه به‌روزرسانی مدل است. در تشخیص اشیا این مسئله باید هم کیفیت برچسب طبقه‌بندی و هم کیفیت جعبه‌های محدودکننده را در نظر بگیرد؛ زیرا پژوهش‌های جدید نشان داده‌اند که اعتماد صرف به امتیاز طبقه‌بندی نمی‌تواند لزوماً کیفیت شبه‌جعبه را تضمین کند [5]. این هدف جزو اهداف مهم این پژوهش یعنی کاهش هم‌زمان خطای مکان‌یابی و طبقه‌بندی شبه‌برچسب‌ها می‌باشد.

3. کاهش انباشت خطا در فرایند انطباق پیوسته

هدف دیگر پژوهش، جلوگیری از شکل‌گیری چرخه‌ای است که در آن یک پیش‌بینی نادرست به‌عنوان سیگنال آموزشی مورد استفاده قرار گرفته، موجب تغییر اشتباه پارامترهای مدل شود و در نمونه‌های بعدی احتمال تولید شبه‌برچسب‌های نادرست را افزایش دهد. این مسئله به‌ویژه در شرایطی که توزیع هدف به صورت پیوسته تغییر می‌کند اهمیت دارد؛ همان‌گونه که CoTTA نیز کاهش قابلیت اعتماد شبه‌برچسب تحت تغییر پیوسته توزیع و تبدیل آن به انباشت خطا را یکی از مسائل بنیادی CTTA معرفی می‌کند [4].

4. توسعه سازوکاری برای کاهش فراموشی فاجعه‌بار و حفظ دانش مدل مبدأ

فرایند انطباق نباید باعث شود که مدل برای سازگاری با آخرین دامنه مشاهده‌شده، دانش عمومی و بازنمایی‌های مفید خود را از دست بدهد. از این‌رو، پژوهش حاضر به دنبال ایجاد تعادل میان «انعطاف‌پذیری» برای یادگیری تغییرات جدید و «پایداری» برای حفظ دانش پیشین خواهد بود. این هدف می‌تواند از طریق منظم‌سازی پارامترها، تثبیت بخشی از مدل، استفاده از نسخه مرجع مدل، بازبازی یا حفظ دانش قبلی یا سایر راهبردهای ضدفراموشی محقق شود؛ بدون آنکه در این مرحله از پروپوزال، پژوهش به یک سازوکار خاص محدود شود. اهمیت این مسئله هم در CoTTA و هم در EATA به‌صورت مستقیم نشان داده شده است [4, 7].

5. فراهم کردن انطباق سریع و محاسباتی کارآمد برای داده‌های جریانی

هدف پژوهش تنها بهبود دقت نهایی نیست؛ بلکه سازوکار انطباق باید بتواند تحت محدودیت‌های زمان و منابع نیز اجرا شود. به همین دلیل، کاهش تعداد پارامترهای به‌روزرسانی‌شونده، تعداد مراحل بهینه‌سازی، تعداد نمونه‌های نیازمند پس‌انتشار یا سایر هزینه‌های محاسباتی، در کنار دقت مدل بررسی خواهد شد. اهمیت این موضوع در پژوهش‌های جدید انطباق آشکارسازها در زمان آزمون به‌طور مشخص مورد تأکید قرار گرفته است؛ به‌ویژه مطالعات CVPR 2024 و CVPR 2025 نشان می‌دهند که «زمان و محل به‌روزرسانی» و «هزینه محاسباتی» از مسائل مستقل و اصلی CTTA برای تشخیص اشیا هستند [9, 8].

6. بررسی اثربخشی روش در سناریوی انتقال از داده‌های مصنوعی به واقعی

با توجه به جهت اصلی این پژوهش، یکی از اهداف مشخص پژوهش آن است که توانایی چارچوب پیشنهادی در کاهش شکاف میان داده‌های مصنوعی مورد استفاده برای آموزش و تصاویر واقعی مشاهده‌شده در زمان استقرار بررسی شود. این هدف علاوه بر اهمیت کاربردی، امکان مقایسه با سناریوهای شناخته‌شده‌ای مانند «Sim10K به Cityscapes» را نیز فراهم می‌کند؛ سناریویی که در ادبیات انطباق آنلاین تشخیص اشیا استفاده شده است [10].

7. ارزیابی عملکرد روش در شرایط تغییر متوالی دامنه هدف

برای آنکه پژوهش صرفاً یک روش انطباق آفلاین با نام TTA نباشد، عملکرد مدل باید در یک توالی از شرایط متفاوت بررسی شود. هدف آن است که مشخص گردد آیا روش پیشنهادی نه فقط بلافاصله پس از ورود به یک دامنه جدید، بلکه در طول یک جریان متغیر از دامنه‌ها نیز قادر به حفظ عملکرد پایدار است یا خیر. این ارزیابی با ماهیت اصلی CTTA، یعنی سازگاری یک مدل مبدأ با محیط‌های در حال تغییر طی استنتاج، هم‌خوانی دارد [9, 8, 4].

8. ارزیابی جامع روش با معیارهای دقت، پایداری و کارایی محاسباتی

روش پیشنهادی باید از چند منظر مورد ارزیابی قرار گیرد. نخست، عملکرد تشخیص اشیا با معیارهای استاندارد نظیر «mAP» یا «mean average precision» سنجیده خواهد شد. دوم، رفتار مدل در طول تغییرات متوالی دامنه و میزان افت یا حفظ عملکرد بررسی خواهد شد. سوم، هزینه عملیاتی روش از نظر زمان پردازش و انطباق، تعداد پارامترهای به‌روزرسانی‌شونده، محاسبات مورد نیاز و در صورت لزوم مصرف حافظه ارزیابی خواهد شد. چنین ارزیابی چندبعدی ضروری است؛ زیرا یک روش TTA که

افزایش اندکی در دقت ایجاد کند اما هزینه استنتاج را چند برابر نماید، برای کاربرد برخط الزاماً راهکار مناسبی نیست. این مسئله در ادبیات اخیر OD-CTTA نیز صریحاً مورد تأکید قرار گرفته است [9].

9. مقایسه روش پیشنهادی با مدل بدون انطباق و روش‌های معتبر انطباق در زمان آزمون

برای تعیین میزان واقعی اثر روش پیشنهادی، نتایج آن باید حداقل با مدل «مبدأ - تنها»، روش‌های پایه عمومی TTA و CTТА و روش‌های جدیدتر ویژه تشخیص اشیاء مقایسه شود. در انتخاب روش‌های مقایسه، علاوه بر روش‌های بنیادی مانند TENT، CoTTA و EATA، روش‌های اختصاصی‌تر تشخیص اشیاء نظیر روش آنالین Yoo و همکاران در روش‌های OD-CTTA جدیدتر نیز مدنظر قرار خواهند گرفت [9], [8], [7], [4], [3]. این مقایسه باید تحت پروتکل آزمایشی یکسان انجام شود تا افزایش عملکرد صرفاً ناشی از تفاوت مدل پایه، تنظیمات یا داده‌ها نباشد.

10. انجام مطالعه مؤلفه‌ها برای تعیین سهم هر جزء از روش پیشنهادی

پس از نهایی‌شدن معماری پیشنهادی، اثر هر مؤلفه به‌صورت مستقل از طریق آزمایش‌های حذف یا جایگزینی بررسی خواهد شد (ablation study). این هدف کمک می‌کند مشخص شود که بهبود احتمالی عملکرد ناشی از کدام سازوکار است؛ برای مثال، آیا بهبود از افزایش کیفیت شبه‌برچسب ناشی می‌شود، از راهکار ضدفراموشی، از انتخاب پارامترهای قابل انطباق یا از تعامل میان این بخش‌ها. این نوع مطالعه برای اثبات سهم علمی روش پیشنهادی و تفکیک نوآوری واقعی از اثر تنظیمات آزمایشی ضروری است.

2-3 - تشریح و بیان موضوع :

مدل‌های یادگیری عمیق در سال‌های اخیر به بخش جدایی‌ناپذیری از سامانه‌های بینایی ماشین تبدیل شده‌اند و در وظایفی نظیر دسته‌بندی تصویر، قطعه‌بندی معنایی و تشخیص اشیاء، عملکرد بسیار بالایی از خود نشان داده‌اند. در میان این وظایف، تشخیص اشیاء از اهمیت ویژه‌ای برخوردار است؛ زیرا مدل علاوه بر تشخیص نوع شیء موجود در تصویر، باید موقعیت مکانی و ابعاد آن را نیز به‌صورت دقیق تعیین کند. از این‌رو، آشکارسازهای اشیاء در بسیاری از سامانه‌های عملیاتی نظیر خودروهای خودران، سامانه‌های نظارت تصویری، ربات‌های متحرک، مدیریت هوشمند ترافیک و سامانه‌های پایش محیطی نقش بنیادی دارند. با وجود پیشرفت قابل توجه معماری‌های یادگیری عمیق، عملکرد بالای این مدل‌ها عموماً بر یک فرض اساسی استوار است: داده‌هایی که مدل در زمان استقرار مشاهده می‌کند، باید از توزیعی مشابه با داده‌های مورد استفاده در مرحله آموزش پیروی کنند. این فرض در محیط‌های کنترل‌شده آزمایشگاهی می‌تواند تا حدی برقرار باشد، اما در کاربردهای واقعی غالباً نقض می‌شود. تغییر شرایط روشنایی، وضعیت آب‌وهوا، نوع دوربین، ویژگی‌های حسگر، زاویه دید، پس‌زمینه، محیط جغرافیایی، کیفیت تصویربرداری و بسیاری از عوامل دیگر می‌توانند موجب تغییر توزیع داده‌های ورودی شوند. در مسئله تشخیص اشیاء، این تغییرات نه تنها بر ویژگی‌های کلی تصویر، بلکه بر ظاهر، اندازه، وضوح و موقعیت نمونه‌های شیء نیز اثر می‌گذارند. پژوهش Domain Adaptive Faster R-CNN نشان داده است که تغییر دامنه در تشخیص اشیاء می‌تواند هم در سطح تصویر، مانند سبک و روشنایی، و هم در سطح نمونه شیء، مانند ظاهر و اندازه اشیاء، رخ دهد [11].

در نتیجه این پدیده، مدلی که روی توزیع مبدأ عملکرد مناسبی دارد، ممکن است پس از استقرار در محیط جدید با کاهش قابل توجه دقت روبه‌رو شود. اختلاف میان توزیع داده‌های آموزش و آزمون معمولاً با مفهوم «تغییر توزیع» و در مسأله انتقال میان دامنه‌ها با مفهوم «شکاف دامنه» بیان می‌شود. این مسئله یکی از موانع اساسی در مسیر استقرار قابل اعتماد سامانه‌های بینایی ماشین است؛ زیرا در بسیاری از کاربردها نمی‌توان تضمین کرد که شرایط عملیاتی آینده دقیقاً مشابه شرایط موجود هنگام جمع‌آوری داده‌های آموزشی باشد.

یکی از نمونه‌های مهم این مسئله، آموزش مدل با استفاده از داده‌های مصنوعی و استقرار آن روی داده‌های واقعی است. تولید داده مصنوعی به کمک شبیه‌سازها و موتورهای رندر امکان ایجاد حجم زیادی از تصاویر همراه با برچسب‌های دقیق را با هزینه بسیار کمتر نسبت به جمع‌آوری و برچسب زدن داده‌های واقعی فراهم می‌کند. علاوه بر این، در محیط شبیه‌سازی می‌توان عواملی نظیر زاویه دوربین، روشنایی، نوع اشیاء و شرایط محیطی را به‌صورت کنترل‌شده تغییر داد. Tang و Jia نشان داده‌اند که داده‌های مصنوعی می‌توانند برای پیش‌آموزش و انتقال دانش به محیط واقعی مفید باشند و در عین حال، انتقال از شبیه‌سازی به واقعیت

همچنان یک مسئله قابل توجه در انطباق دامنه محسوب می‌شود [1]. با این حال، فرآیند تشکیل تصاویر مصنوعی با فرآیند تصویربرداری واقعی یکسان نیست. تفاوت در بافت، نورپردازی، مدل‌سازی اشیاء، پس‌زمینه، ویژگی حسگر، نویز تصویربرداری و جزئیات محیط می‌تواند سبب شود توزیع داده مصنوعی و واقعی به مقدار قابل توجهی متفاوت باشد. در نتیجه، مدلی که تنها روی داده‌های مصنوعی آموزش دیده است الزاماً عملکرد خود را هنگام مواجهه با تصاویر واقعی حفظ نمی‌کند. این مسئله که در قالب شکاف مصنوعی به واقعی مطرح می‌شود، نمونه مشخصی از تغییر دامنه است و یکی از انگیزه‌های اصلی استفاده از روش‌های انطباق دامنه در سامانه‌هایی محسوب می‌شود که آموزش اولیه آن‌ها با داده‌های شبیه‌سازی شده انجام می‌گیرد.

گذار از انطباق دامنه کلاسیک به انطباق بدون منبع

برای کاهش اثر شکاف دامنه، حوزه «انطباق دامنه» شکل گرفته است. در مسئله انطباق دامنه، هدف آن است که دانشی که مدل از یک دامنه مبدأ آموخته است، برای افزایش عملکرد آن در دامنه هدف مورد استفاده قرار گیرد. یکی از پرکاربردترین تنظیمات این مسئله، «انطباق دامنه بدون نظارت»^۲ یا UDA است که در آن داده‌های مبدأ دارای برچسب هستند، اما داده‌های دامنه هدف بدون برچسب در اختیار الگوریتم قرار می‌گیرند.

روش‌های UDA طی سال‌های گذشته از رویکردهای مختلفی مانند هم‌ترازی آماری توزیع‌ها، یادگیری تخصصی، انتقال در سطح تصویر و خودآموزی بهره گرفته‌اند. در حوزه تشخیص اشیاء نیز روش‌هایی مانند Domain Adaptive Faster R-CNN با هم‌تراز کردن ویژگی‌ها در سطح تصویر و نمونه تلاش کرده‌اند حساسیت آشکارساز به تغییر دامنه را کاهش دهند [11]. در سال‌های بعد، رویکردهای مبتنی بر مدل معلم - دانش‌آموز و شبه‌برچسب‌گذاری نیز به یکی از مسیرهای اصلی انطباق آشکارسازها تبدیل شدند. برای مثال، Unbiased Mean Teacher و سپس روش‌های جدیدتری مانند Contrastive Mean Teacher نشان دادند که کیفیت سیگنال‌های تولیدشده از داده هدف و نحوه انتقال آن‌ها از مدل معلم به دانش‌آموز، نقش مهمی در عملکرد آشکارسازهای تطبیق‌یافته دارد [6], [12].

با وجود این پیشرفت‌ها، UDA کلاسیک یک پیش‌فرض مهم دارد: در زمان انطباق، داده‌های دامنه مبدأ باید همچنان قابل دسترس باشند تا بتوان از آن‌ها همراه با داده‌های هدف استفاده کرد. این پیش‌فرض در بسیاری از کاربردهای واقعی برقرار نیست. داده‌های مبدأ ممکن است به دلیل الزامات حریم خصوصی، مالکیت داده، محدودیت انتقال اطلاعات، هزینه ذخیره‌سازی یا حجم بالا در محل استقرار مدل در دسترس نباشند. به‌عنوان نمونه، داده مورد استفاده برای آموزش یک سامانه می‌تواند متعلق به یک سازمان یا شبیه‌ساز اختصاصی باشد و تنها وزن‌های مدل آموزش‌دیده در اختیار سیستم مقصد قرار گیرند.

همین محدودیت سبب شکل‌گیری پارادایم انطباق دامنه بدون منبع یا SFDA شده است. در SFDA، در مرحله انطباق، داده‌های اصلی مبدأ در اختیار الگوریتم نیستند و تنها مدل از پیش آموزش‌دیده و داده‌های بدون برچسب دامنه هدف در دسترس‌اند. روش SHOT از نخستین نمونه‌های مهم این مسیر است که نشان داد می‌توان بدون دسترسی مجدد به داده‌های مبدأ و تنها با استفاده از فرضیه با مدل آموزش‌دیده مبدأ، بازنمایی داده‌های هدف را تطبیق داد [13]. مرور جامع Fang و همکاران نیز SFDA را پاسخی به محدودیت‌هایی نظیر حریم خصوصی، هزینه ذخیره‌سازی و انتقال داده و بار محاسباتی روش‌های متعارف UDA معرفی می‌کند [14].

بنابراین، SFDA یک گام مهم در نزدیک‌کردن انطباق دامنه به شرایط واقعی است؛ زیرا نیاز به انتقال یا نگهداری مجموعه داده آموزشی را حذف می‌کند. با این حال، حذف داده‌های مبدأ به‌تنهایی برای بسیاری از سامانه‌های عملیاتی کافی نیست. بخش قابل توجهی از روش‌های SFDA فرض می‌کنند که مجموعه‌ای از داده‌های دامنه هدف پیش از استقرار نهایی مدل در دسترس است و می‌توان مدل را طی چندین مرحله یا چندین دور روی این مجموعه تطبیق داد. این سناریو همچنان ماهیتی عمدتاً آفلاین دارد. در بسیاری از سامانه‌های واقعی چنین فرضی برقرار نیست. برای مثال، یک خودروی خودران نمی‌تواند پیش از ورود به یک شهر، وضعیت آب‌وهوایی یا شرایط نوری جدید، تمام داده‌های آن محیط را از قبل جمع‌آوری کند، چندین دوره انطباق انجام دهد و سپس آغاز به کار کند. اما در سناریو‌هایی، داده‌ها هم‌زمان با فعالیت سامانه وارد می‌شوند و مدل باید در همان زمان که وظیفه

Commented [ak12]: راجب تفاوت این دو تا بخون

Commented [ak13]: این که hypothesis چی هست مهمه و مقاله شات رو بخون.

پیش‌بینی را انجام می‌دهد، خود را نیز با شرایط جدید سازگار کند. این محدودیت، گذار از «انطباق بدون منبع آفلاین» به انطباق در زمان آزمون را ضروری می‌سازد. این تفاوت در ادبیات تشخیص اشیا نیز به‌صورت صریح مطرح شده است. VS و همکاران در پژوهش «Towards Online Domain Adaptive Object Detection» میان UDA، انطباق بدون منبع آفلاین و انطباق بدون منبع آنلاین تمایز قائل می‌شوند و تأکید می‌کنند که در محیط واقعی، مدل ممکن است با دامنه‌های جدیدی مواجه شود که پیش از استقرار ناشناخته بوده‌اند؛ بنابراین انطباق آفلاین برای تک‌تک تغییرات ممکن عملی نیست [10].

انطباق در زمان آزمون

برای رفع محدودیت‌های فوق، پارادایم انطباق در زمان آزمون یا TTA توسعه یافته است. در این پارادایم، یک مدل از پیش آموزش‌دیده هنگام استقرار و با استفاده از داده‌های بدون برچسبی که در مرحله آزمون دریافت می‌کند، خود را با توزیع جدید سازگار می‌سازد. در تنظیم «کاملاً زمان آزمون»، داده‌های آموزشی مبدأ در این مرحله در دسترس نیستند و فرآیند آموزش اولیه نیز الزاماً برای انطباق آینده تغییر داده نمی‌شود.

یکی از روش‌های بنیادی در این زمینه، TENT است. این روش نشان داد که می‌توان با کمینه‌سازی آنتروپی پیش‌بینی‌های مدل روی داده‌های آزمون و به‌روزرسانی پارامترهای affine لایه‌های نرمال‌سازی، مدل را بدون دسترسی به داده مبدأ با توزیع جدید سازگار کرد [3]. اهمیت TENT صرفاً در الگوریتم خاص آن نیست؛ این پژوهش نشان داد که بخشی از سازگاری مدل با تغییر دامنه می‌تواند مستقیماً در مرحله استنتاج و تنها با استفاده از داده‌های جاری انجام گیرد.

در ادبیات جدید، TTA به‌عنوان یک مفهوم گسترده در نظر گرفته می‌شود و بر اساس شکل دسترسی به داده‌های آزمون می‌توان آن را به چند سناریوی اصلی تقسیم کرد. Liang و همکاران در مرور جامع خود سه حالت عمده را مشخص می‌کنند: انطباق دامنه در زمان آزمون^۳ یا TTDA، انطباق دسته‌ای در زمان آزمون^۴ یا TTBA، و انطباق آنلاین در زمان آزمون^۵ یا OTTA [15].

در TTDA معمولاً کل مجموعه بدون برچسب هدف پیش از تولید پیش‌بینی نهایی در دسترس قرار می‌گیرد و مدل می‌تواند طی چندین مرحله یا چندین دوره با این مجموعه سازگار شود. از این منظر، TTDA هم‌پوشانی قابل توجهی با بسیاری از مسائل SFDA دارد و به همین دلیل در بخشی از ادبیات این دو اصطلاح بسیار نزدیک به یکدیگر استفاده شده‌اند. با این حال، برای تفکیک مفهومی در این پژوهش، SFDA به‌عنوان محدودیت عدم دسترسی به داده مبدأ در نظر گرفته می‌شود، در حالی که TTDA بر نحوه و زمان استفاده از کل داده هدف برای انطباق تأکید دارد [15]، [14].

در TTBA مدل روی یک نمونه یا یک دسته کوچک از داده‌های آزمون سازگار می‌شود، اما وضعیت حاصل از این انطباق الزاماً به دسته‌های بعدی منتقل نمی‌شود. به بیان دیگر، هر دسته می‌تواند به‌طور نسبتاً مستقل پردازش شود.

در مقابل، در OTTA داده‌ها به‌صورت متوالی وارد سامانه می‌شوند، هر نمونه یا دسته کوچک ممکن است تنها یک بار مشاهده شود و وضعیت مدل پس از پردازش داده‌های قبلی در پردازش داده‌های بعدی نقش دارد. در نتیجه، انطباق دیگر یک مجموعه

عملیات مستقل نیست، بلکه به یک فرآیند یادگیری متوالی تبدیل می‌شود. مرور اختصاصی OTTA در International Journal of Computer Vision این مسئله را به‌صورت انطباق مدل با داده‌هایی توصیف می‌کند که به‌صورت دسته‌ای و در زمان واقعی وارد می‌شوند و بر اهمیت همزمان دقت و هزینه محاسباتی در چنین تنظیمی تأکید دارد [16]. این ویژگی OTTA آن را برای کاربردهای عملی نظیر رانندگی خودران، رباتیک، نظارت تصویری و سامانه‌های سیار مناسب‌تر می‌کند؛ زیرا در این کاربردها امکان متوقف کردن سیستم، جمع‌آوری کامل داده‌های محیط و اجرای یک فرآیند انطباق چنددوره‌ای وجود ندارد. مدل باید همزمان با ورود داده، پیش‌بینی تولید کند و در صورت نیاز خود را به‌روز نماید.

از انطباق آنلاین به انطباق پیوسته در محیط‌های غیرایستا

حتی سناریوی OTTA نیز می‌تواند در سطوح مختلفی از دشواری تعریف شود. در یک حالت ساده‌تر، مدل وارد یک دامنه هدف جدید ولی نسبتاً ثابت می‌شود. در این شرایط، اگرچه داده‌ها به‌صورت آنلاین دریافت می‌شوند، توزیع هدف در طول زمان تغییر قابل توجهی نمی‌کند. اما محیط‌های واقعی غالباً غیرایستا هستند.

³ Test time domain adaptation
⁴ test time Batch domain adaptation
⁵ Online test time adaptation

برای مثال، یک خودرو ممکن است در مدت کوتاهی از محیط آفتابی به سایه، سپس به باران، تاریکی، مه یا یک شهر با ساختار تصویری متفاوت وارد شود. بنابراین می‌توان توزیع داده در لحظه t را به صورت $P_t(X)$ در نظر گرفت که لزوماً با توزیع لحظه قبل یعنی $P_{t-1}(X)$ برابر نیست. مدل در چنین شرایطی نه تنها باید با شکاف میان مبدأ و هدف سازگار شود، بلکه باید بتواند تغییرات خود دامنه هدف در طول زمان را نیز دنبال کند.

این تنظیم در ادبیات معمولاً با عنوان Continual Test-Time Adaptation یا CTTA مطرح می‌شود. تفاوت مهم CTTA با برخی تنظیمات ساده‌تر OTTA در این است که مدل به صورت مستمر وضعیت تطبیق یافته خود را حفظ می‌کند و بدون اطلاع صریح از مرز میان دامنه‌ها باید تغییرات متوالی را مدیریت نماید. مرور جدید OTTA نیز continual TTA را حالتی معرفی می‌کند که مدل بدون بازنشانی مکرر به مدل مبدأ، به‌طور پیوسته نسبت به تغییرات توزیع به‌روزرسانی می‌شود [16]. پژوهش CoTTA یکی از کارهای بنیادی در این سناریو است. Wang و همکاران نشان دادند که روش‌هایی که در یک دامنه هدف ثابت عملکرد مناسبی دارند ممکن است هنگام مواجهه طولانی با توزیع‌های متغیر ناپایدار شوند. آن‌ها دو مشکل اصلی را برجسته کردند: انباشت خطا ناشی از سیگنال‌های خودنظارتی نادرست و فراموشی فاجعه‌بار ناشی از فاصله‌گرفتن تدریجی مدل از دانش عمومی مبدأ [4]. برای کاهش خطا، CoTTA از پیش‌بینی‌های میانگین‌گیری‌شده و برای حفظ دانش مبدأ از بازگردانی تصادفی بخشی از پارامترها به مقادیر اولیه استفاده می‌کند.

پس از آن، پژوهش‌های متعدد نشان داده‌اند که شرایط واقعی حتی می‌توانند دشوارتر باشند. RoTTA سناریویی را مطالعه می‌کند که در آن داده‌های متوالی علاوه بر تغییر توزیع، از نظر زمانی نیز هم‌پسته‌اند و از حافظه و یک ساختار معلم - دانش آموز برای افزایش پایداری انطباق استفاده می‌کند [17]. SAR نیز نشان داده است که TTA می‌تواند در حضور ترکیبی از تغییرات توزیع، اندازه کوچک دسته و توزیع نامتوازن کلاس‌ها ناپایدار شود [18].

این یافته‌ها نشان می‌دهند که OTTA صرفاً مسئله «به‌روزرسانی مدل روی هر دسته جدید» نیست، بلکه مسئله اصلی کنترل یک فرآیند یادگیری بدون نظارت در طول زمان است که کوچک‌ترین خطای سیستماتیک می‌تواند با تکرار به افت شدید عملکرد منجر شود.

انباشت خطا در انطباق آنلاین

در TTA و به‌خصوص OTTA، برچسب واقعی نمونه‌های هدف در دسترس نیست. بنابراین الگوریتم برای ایجاد سیگنال آموزشی باید به اطلاعاتی مانند آن‌تروپی پیش‌بینی، شبه‌برچسب‌ها، سازگاری میان نماهای مختلف یک تصویر، مدل معلم، نمونه‌های ذخیره‌شده در حافظه یا ساختار بازنمایی ویژگی متکی باشد.

Commented [ak14]: بیشتر بخون راجبشون

یکی از پرکاربردترین روش‌ها، شبه‌برچسب‌گذاری است. در این رویکرد، پیش‌بینی خود مدل به‌عنوان برچسب موقت در نظر گرفته می‌شود و برای به‌روزرسانی پارامترها مورد استفاده قرار می‌گیرد. اگر پیش‌بینی اولیه صحیح باشد، این فرآیند می‌تواند موجب بهبود مدل شود؛ اما اگر مدل به دلیل شکاف دامنه پیش‌بینی نادرستی ایجاد کند، همان پیش‌بینی نادرست وارد فرآیند آموزش می‌شود.

این مسئله در محیط آنلاین می‌تواند یک چرخه بازخورد مثبت نامطلوب ایجاد کند. یک شبه‌برچسب نادرست سبب به‌روزرسانی اشتباه پارامترها می‌شود؛ این تغییر احتمال تولید شبه‌برچسب‌های اشتباه در نمونه‌های بعدی را افزایش می‌دهد؛ خطاهای جدید مجدداً برای آموزش استفاده می‌شوند و با ادامه این چرخه، مدل می‌تواند به تدریج از مسیر صحیح فاصله بگیرد. این پدیده با عنوان انباشت خطا شناخته می‌شود و CoTTA آن را یکی از مشکلات بنیادی محیط‌های غیرایستای TTA معرفی می‌کند [4].

اهمیت این مسئله در مطالعات بعدی نیز تأیید شده است. RDumb در یک ارزیابی بلندمدت نشان داد که بسیاری از روش‌های CTTA که در توالی‌های کوتاه نتایج مناسبی دارند، در بازه‌های طولانی ممکن است دچار فروپاشی عملکرد شوند؛ حتی یک راهبرد ساده بازنشانی دوره‌ای مدل در برخی ارزیابی‌ها می‌تواند با روش‌های پیچیده رقابت کند [19]. این نتیجه نشان می‌دهد که پایداری بلندمدت باید در کنار بهبود کوتاه‌مدت دقت به‌عنوان یکی از معیارهای اصلی طراحی OTTA در نظر گرفته شود.

فراموشی فاجعه‌بار و تعادل پایداری - انعطاف‌پذیری

چالش مهم دوم، فراموشی فاجعه‌بار است. در این حالت ممکن است مدل بتواند خود را با توزیع جدید سازگار کند، اما در جریان این سازگاری بخشی از دانشی را که در آموزش اولیه کسب کرده است از دست بدهد. اگر پارامترها تنها بر اساس چند دسته اخیر داده هدف به‌روزرسانی شوند، مدل می‌تواند بیش از حد به شرایط فعلی وابسته شود و بازنمایی‌های عمومی و مفیدی را که از مبدأ آموخته بود تخریب کند.

بنابراین در OTTA یک تضاد بنیادی میان دو نیاز وجود دارد. از یک سو مدل باید انعطاف‌پذیری کافی برای یادگیری سریع از داده‌های جدید داشته باشد و از سوی دیگر باید پایداری کافی برای حفظ دانش گذشته داشته باشد. تطبیق بیش از حد ضعیف موجب باقی ماندن شکاف دامنه می‌شود، در حالی که تطبیق بیش از حد تهاجمی می‌تواند به فراموشی یا حتی فروپاشی مدل منجر شود. EATA این مسئله را مستقیماً مورد توجه قرار داده است. این روش علاوه بر انتخاب نمونه‌های مناسب برای کاهش تعداد محاسبات پس‌انتشار، از یک تابع منظم‌سازی برای محدود کردن تغییر پارامترهای مهم مدل استفاده می‌کند و از این طریق تلاش می‌کند انطباق با داده‌های خارج از توزیع را بدون تخریب شدید عملکرد روی توزیع اصلی انجام دهد [7].

CoTTA نیز از بازگردانی تصادفی بخشی از پارامترها به وزن‌های مدل مبدأ استفاده می‌کند [4]. مجموعه این روش‌ها نشان می‌دهد که حفظ نوعی لنگر نسبت به دانش مبدأ، چه از طریق وزن‌ها، منظم‌سازی، معماری معلم - دانش‌آموز، حافظه یا ساختارهای دیگر، یکی از مؤلفه‌های مهم در طراحی الگوریتم‌های پایدار TTA است.

چالش‌های خاص انطباق در زمان آزمون برای تشخیص اشیا

بخش عمده‌ای از تحقیقات اولیه TTA و CTTA روی مسئله دسته‌بندی تصویر انجام شده است. انتقال مستقیم این روش‌ها به تشخیص اشیا ساده نیست؛ زیرا ساختار خروجی و تابع هدف در آشکارسازی به مراتب پیچیده‌تر است.

در دسته‌بندی تصویر، برای هر تصویر معمولاً یک توزیع احتمال روی کلاس‌ها تولید می‌شود. اما یک آشکارساز باید ابتدا چندین نمونه بالقوه را در تصویر پیدا کند، سپس برای هر نمونه کلاس تعیین کند و همزمان موقعیت آن را از طریق مختصات جعبه محدودکننده تخمین بزند. بنابراین سیگنال بدون نظارت در تشخیص اشیا باید دو جنبه معنایی و مکانی را به‌طور همزمان مدیریت کند.

شبه‌برچسب یک شیء معمولاً حداقل از یک برچسب کلاس، یک نمره اطمینان و مختصات جعبه محدودکننده تشکیل می‌شود. ممکن است مدل کلاس شیء را درست تشخیص دهد ولی جعبه آن را اشتباه تخمین بزند، یا برعکس، محل شیء را درست بیابد ولی آن را به کلاس اشتباه تخصیص دهد. علاوه بر این، جعبه نادرست باعث می‌شود ویژگی‌های مربوط به پس‌زمینه یا بخش نامرتب از تصویر وارد فرآیند آموزش شوند.

Ruan و Tang در پژوهش «Fully Test-time Adaptation for Object Detection» نشان داده‌اند که یکی از مشکلات اساسی خودآموزی در این شرایط، غیرقابل اعتماد بودن شبه‌برچسب‌ها تحت تغییر دامنه است و اتکا به نمره اطمینان طبقه‌بندی به‌تنهایی برای تعیین کیفیت یک شبه‌جعبه کافی نیست. آن‌ها به همین دلیل معیارهای مبتنی بر IoU را برای پالایش شبه‌برچسب‌ها وارد فرآیند انطباق کردند [5].

از سوی دیگر، معماری معلم-دانش‌آموز که در UDA تشخیص اشیا بسیار موفق بوده است، در شرایط test-time می‌تواند هزینه بالایی ایجاد کند؛ زیرا تولید چند نمای تقویت‌شده، چندین عبور رو به جلو و پس‌انتشار و نگهداری دو نسخه از مدل، سرعت پردازش را کاهش می‌دهد. Yoo و همکاران در CVPR ۲۰۲۴ به‌صراحت اشاره می‌کنند که بسیاری از روش‌های TTA از دسته‌بندی تصویر به تشخیص اشیا قابل انتقال مستقیم نیستند و به همین دلیل مسئله را در قالب سه سؤال «چه بخشی از آشکارساز به‌روزرسانی شود؟»، «چگونه به‌روزرسانی شود؟» و «چه زمانی به‌روزرسانی انجام گیرد؟» صورت‌بندی کردند [8].

در روش آن‌ها، به جای تغییر همه پارامترهای آشکارساز، ماژول‌های سبک‌وزن تطبیقی به مدل افزوده می‌شوند و مدل تنها در شرایطی که نیاز به انطباق وجود دارد به‌روزرسانی می‌شود. این رویکرد نشان می‌دهد که برای OTTA در تشخیص اشیا، انتخاب محل و زمان به‌روزرسانی به اندازه انتخاب تابع زیان اهمیت دارد.

Commented [ak15]: منظورش احتمال شرطی روی کلاس‌ها هست

Commented [ak16]: Paper جالبی هه بخون حتما

Commented [ak17]: مهمه بخون راجیش

Commented [ak18]: بخون راج

Commented [ak19]: بخون راجبش

این مسیر در تحقیقات جدیدتر ادامه یافته است. Wang و همکاران در CVPR ۲۰۲۵ مسئله Continual Test-Time Adaptive Object Detection را مستقیماً به عنوان انطباق آنلاین یک آشکارساز از پیش آموزش دیده در محیط های دائماً متغیر تعریف کرده اند و نشان داده اند که هزینه محاسباتی یک مسئله مستقل و مهم در این حوزه است. روش آن ها با شناسایی و هرس کانال های حساس به دامنه تلاش می کند ضمن حفظ عملکرد انطباق، سربار محاسبات را کاهش دهد [9].

همچنین Li و همکاران در ICCV ۲۰۲۵، CTTA برای تشخیص اشیا را در محیط های پویا بررسی کرده اند و سه چالش را به طور مشخص مطرح می کنند: انطباق آنلاین با داده های بدون برچسب، ضرورت کارایی محاسباتی و جلوگیری از فراموشی فاجعه بار. آن ها به جای بهینه سازی تعداد زیادی پارامتر، از ساختارهای تطبیقی مبتنی بر LoRA و تولید پارامتر وابسته به محیط استفاده کرده اند [20].

بنابراین، روند ادبیات جدید نشان می دهد که مسئله از «آیا می توان مدل را در زمان آزمون تطبیق داد؟» به سمت پرسش دقیق تری حرکت کرده است: چگونه می توان یک آشکارساز را در جریان داده واقعی، با حداقل نظارت، حداقل تخریب دانش گذشته و حداقل هزینه محاسباتی، به طور مستمر سازگار نگه داشت؟

کارایی محاسباتی به عنوان بخشی از مسئله

در کاربرد آنلاین، افزایش دقت تنها معیار موفقیت نیست. اگر یک روش انطباق برای هر فریم نیازمند چندین مرحله پس انتشار یا اجرای چند نسخه از شبکه باشد، ممکن است حتی در صورت افزایش mAP نیز برای سامانه بلادرنگ مناسب نباشد. این مسئله در تشخیص اشیا جدی تر است؛ زیرا خود اجرای یک آشکارساز نسبت به یک دسته بند تصویر هزینه محاسباتی بیشتری دارد. به همین دلیل در ارزیابی روش های OTTA علاوه بر معیارهای دقت باید معیارهایی مانند زمان انطباق، سرعت پردازش، حافظه مصرفی، تعداد پارامترهای قابل آموزش و حجم محاسبات نیز در نظر گرفته شوند. مقاله مروری جدید OTTA نیز بر ارزیابی همزمان اثربخشی و کارایی با معیارهایی مانند GFLOPs، زمان واقعی اجرا و حافظه GPU تأکید می کند [16]. این موضوع در جدیدترین تحقیقات CTTA نیز همچنان از محورهای اصلی است. برای نمونه، پژوهش های سال های ۲۰۲۵ و ۲۰۲۶ همچنان تعادل میان کارایی و قدرت تعمیم را به عنوان یکی از مسائل حل نشده CTTA مطرح می کنند.

صورت بندی جایگاه پژوهش حاضر

بر اساس مطالب فوق، می توان سناریوی پژوهش حاضر را به صورت زیر در نظر گرفت. یک مدل تشخیص اشیا ابتدا در یک دامنه مبدأ آموزش داده می شود که می تواند بخش عمده یا تمام داده های آن مصنوعی باشد. پس از اتمام آموزش، داده های مبدأ دیگر در اختیار فرآیند انطباق قرار ندارند. مدل در محیط واقعی مستقر می شود و با جریانی از تصاویر بدون برچسب مواجه است که توزیع آن ها می تواند با دامنه مبدأ متفاوت باشد و علاوه بر آن، در طول زمان نیز تغییر کند.

در هر لحظه t ، تنها نمونه یا دسته کوچک جاری B_t و وضعیت فعلی مدل در اختیار الگوریتم قرار دارد. مدل باید پیش بینی تشخیص اشیا را تولید کند و در صورت نیاز با استفاده از اطلاعات بدون برچسب همین جریان خود را به روزرسانی نماید. وضعیت حاصل از انطباق می تواند برای پردازش دسته های بعدی مورد استفاده قرار گیرد؛ بنابراین خطا یا دانش آموخته شده در مراحل گذشته مستقیماً بر رفتار آینده مدل اثر می گذارد.

در چنین تنظیمی، چهار مسئله به یکدیگر وابسته اند. نخست، مدل باید از داده های بدون برچسب هدف سیگنال نظارتی قابل اعتماد استخراج کند و در تشخیص اشیا، اعتبار هر دو جزء طبقه بندی و مکانیابی را در نظر بگیرد. دوم، باید مانع از آن شود که شبه برچسب های نادرست در طول جریان داده به انباشت خطا منجر شوند. سوم، باید تعادلی میان یادگیری شرایط جدید و حفظ دانش عمومی مدل ایجاد شود تا فراموشی فاجعه بار کنترل گردد. چهارم، کل این فرآیند باید با محدودیت های زمانی و محاسباتی یک سامانه آنلاین سازگار باشد.

از این منظر، هدف پژوهش حاضر صرفاً ارائه یک روش جدید برای SFDA یا انطباق یک آشکارساز با یک مجموعه هدف ثابت نیست؛ بلکه تمرکز آن بر توسعه و بهبود انطباق آنلاین در زمان آزمون برای تشخیص اشیا در محیط های دارای تغییر توزیع متوالی است. SFDA در این چارچوب پیش شرط عملی مسئله را مشخص می کند، یعنی «عدم دسترسی به داده های مبدأ». TTA مشخص می کند که انطباق در مرحله استقرار انجام می شود؛ OTTA محدودیت جریان داده و یکبار مشاهده شدن دسته ها را

اضافه می‌کند؛ و CTTA شرایط دشوارتر و واقع‌گرایانه‌تری را در نظر می‌گیرد که در آن خود توزیع هدف نیز در طول زمان تغییر می‌کند. نکته مهم این است که OTTA و CTTA را یکی در نظر نگیریم. OTTA مفهوم گسترده‌تر انطباق آنلاین است؛ CTTA یک تنظیم دشوارتر است که در آن تغییر توزیع ادامه‌دار است، مرز دامنه‌ها ممکن است مشخص نباشد و وضعیت مدل نیز در طول زمان حفظ می‌شود.

در نهایت، سناریوی انتقال از داده مصنوعی به داده واقعی بستر مناسبی برای مطالعه این مسئله فراهم می‌کند؛ زیرا از یک سو استفاده از داده‌های مصنوعی می‌تواند هزینه تولید مجموعه آموزشی را به‌طور قابل توجهی کاهش دهد و از سوی دیگر، شکاف طبیعی میان شبیه‌سازی و واقعیت، مدل را در زمان استقرار با تغییر توزیع واقعی مواجه می‌کند. هدف نهایی آن است که آشکارساز از پیش آموزش‌دیده بتواند بدون دسترسی به داده‌های اصلی مبدأ و بدون دریافت برچسب از محیط هدف، ضمن پردازش آنلاین داده‌های ورودی، خود را با تغییرات دامنه سازگار سازد و همزمان دقت طبقه‌بندی و مکانیابی، پایداری بلندمدت، حفظ دانش پیشین و کارایی محاسباتی را در سطح قابل قبول حفظ نماید.

3-3 - ضرورت انجام تحقیق :

پیشرفت مدل‌های یادگیری عمیق موجب شده است سامانه‌های بینایی ماشین و به‌ویژه مدل‌های تشخیص اشیا در شرایط آزمایشگاهی به عملکرد بالایی دست یابند؛ با این حال، استقرار این مدل‌ها در محیط‌های واقعی همچنان با مسئله مهم تغییر توزیع داده مواجه است. مدلی که روی یک توزیع مشخص آموزش دیده است، ممکن است در اثر تغییر شرایط تصویربرداری، روشنایی، آب‌وهوا، نوع حسگر، محیط جغرافیایی، پس‌زمینه یا سایر عوامل عملیاتی با داده‌هایی مواجه شود که با توزیع آموزش متفاوت و در نتیجه عملکرد آن کاهش یابد. از آنجا که امکان پیش‌بینی و بازنمایی تمام شرایطی که یک سامانه پس از استقرار با آن‌ها روبه‌رو خواهد شد وجود ندارد، صرف افزایش تنوع مجموعه داده آموزشی نمی‌تواند به‌تنهایی مسئله تعمیم در محیط‌های پویا را به‌طور کامل حل کند. از این‌رو، توانایی سازگارشده مدل پس از استقرار و در مواجهه با داده‌های واقعی، به یکی از مسائل مهم در توسعه سامانه‌های قابل اعتماد بینایی ماشین تبدیل شده است [16].

این ضرورت در سناریوهایی که مدل با استفاده از داده‌های مصنوعی آموزش داده می‌شود اهمیت بیشتری پیدا می‌کند. استفاده از شبیه‌سازها می‌تواند هزینه جمع‌آوری و برچسب‌گذاری داده را کاهش داده و امکان تولید حجم زیادی از نمونه‌های برچسب‌دار را فراهم کند؛ اما تفاوت میان فرآیند تولید تصاویر مصنوعی و شرایط تصویربرداری واقعی سبب ایجاد شکاف «مصنوعی به واقعی» می‌شود. از این‌رو، هرچند داده‌های مصنوعی از نظر هزینه و مقیاس‌پذیری مزیت قابل توجهی دارند، استفاده عملی از مدل‌های آموزش‌دیده روی این داده‌ها مستلزم وجود سازوکاری است که بتواند مدل را پس از استقرار با توزیع واقعی داده تطبیق دهد. این مسئله در پژوهش حاضر اهمیت ویژه‌ای دارد؛ زیرا یکی از سناریوهای اصلی مورد بررسی، انتقال مدل تشخیص اشیا از داده‌های آموزشی مصنوعی به داده‌های واقعی است.

روش‌های کلاسیک انطباق دامنه تا حدی امکان کاهش این شکاف را فراهم کرده‌اند؛ با این حال، بخش قابل توجهی از آن‌ها فرض می‌کنند که دامنه هدف پیش از استقرار مشخص است و فرآیند انطباق می‌تواند به‌صورت آفلاین انجام شود. حتی در تنظیم انطباق دامنه بدون منبع نیز معمولاً یک مجموعه هدف مشخص در اختیار مدل قرار می‌گیرد تا پیش از استفاده نهایی روی آن تطبیق انجام شود. این فرض با شرایط بسیاری از سامانه‌های واقعی سازگار نیست؛ زیرا مدل پس از استقرار ممکن است به‌طور مداوم وارد محیط‌هایی شود که در زمان آموزش ناشناخته بوده‌اند. پژوهش VS و همکاران در حوزه تشخیص اشیا نیز به‌صراحت نشان می‌دهد که انطباق آفلاین با یک دامنه هدف ثابت برای سامانه‌ای که هنگام استقرار با تغییرات جدید و متوالی دامنه روبه‌رو می‌شود، کافی نیست و انطباق آنلاین برای چنین شرایطی ضرورت دارد [10].

به همین دلیل، انطباق در زمان آزمون و به‌طور خاص انطباق آنلاین در زمان آزمون اهمیت پیدا می‌کند. در OTTA، مدل باید هنگام دریافت داده‌های بدون برچسب و همزمان با انجام استنتاج، خود را با توزیع جاری سازگار کند. برخلاف تنظیمات آفلاین، امکان چندین بار مشاهده کل مجموعه هدف یا انجام چندین دوره آموزش روی آن وجود ندارد و داده‌ها غالباً به‌صورت دسته‌های کوچک و متوالی وارد سامانه می‌شوند. مرور جامع Wang و همکاران نشان می‌دهد که این ویژگی بلادرنگ OTTA آن را برای محیط‌های واقعی مناسب می‌کند، اما در عین حال محدودیت‌های مهمی مانند وابستگی برخی روش‌ها به اندازه دسته، ناپایداری

Commented [ak20]: UDA به داده مبدأ نیاز دارد ← در

استقرار نمی‌خواهیم یا نمی‌توانیم داده مبدأ را داشته باشیم ←

SFDA این محدودیت را حذف می‌کند ← اما SFDA آفلاین هنوز

فرض می‌کند داده هدف را از قبل داریم ← در دنیای واقعی

چنین نیست ← پس TTA و در داده جریان ← OTTA و در

تغییرات مداوم CTTA.

تمرکز پژوهش بر انطباق آنلاین در زمان آزمون برای تشخیص اشیا است، با تأکید ویژه بر سناریوی انطباق پیوسته تحت تغییرات غیرایستای توزیع هدف.

بهینه‌سازی و هزینه محاسباتی را به همراه دارد. این مطالعه همچنین نشان می‌دهد که عملکرد تعدادی از روش‌های موجود با کوچک‌شدن اندازه دسته کاهش می‌یابد؛ در حالی که در بسیاری از سامانه‌های واقعی ممکن است مدل مجبور باشد هر نمونه یا تعداد بسیار محدودی از نمونه‌ها را در هر لحظه پردازش کند [16].

ضرورت پژوهش حاضر زمانی بیشتر آشکار می‌شود که محیط هدف نیز ثابت نباشد. در کاربردهایی نظیر خودروهای خودران، ربات‌های متحرک و سامانه‌های نظارت تصویری، مدل ممکن است به‌صورت متوالی با شرایط متفاوتی مانند روشنایی روز و شب، باران، مه، تغییر دوربین، تغییر محیط جغرافیایی یا سایر اغتشاش‌های تصویری روبه‌رو شود. در این وضعیت، مدل نه‌تنها باید شکاف میان دامنه مبدأ و هدف را کاهش دهد، بلکه باید تغییر خود توزیع هدف را نیز در طول زمان دنبال کند. چنین مسئله‌ای در قالب انطباق پیوسته در زمان آزمون یا CoTTA مطالعه می‌شود. CoTTA نشان داده است که روش‌های متکی بر خودآموزی یا کمینه‌سازی آنتروپی در محیط‌های غیرایستا ممکن است به دلیل کاهش کیفیت شبیه‌برچسب‌ها به انباشت خطا و در ادامه به فراموشی فاجعه‌بار منجر شوند [4].

انباشت خطا یکی از مهم‌ترین دلایل ضرورت توسعه روش‌های جدید در این حوزه است. در زمان آزمون، برچسب صحیح داده‌های ورودی در اختیار مدل قرار ندارد و در بسیاری از روش‌ها، خود پیش‌بینی مدل یا نسخه‌ای پالایش‌شده از آن به‌عنوان سیگنال نظارتی مورد استفاده قرار می‌گیرد. در چنین شرایطی، اگر مدل به علت شکاف دامنه در مراحل اولیه پیش‌بینی نادرستی انجام دهد، استفاده مجدد از همان پیش‌بینی برای به‌روزرسانی پارامترها می‌تواند احتمال خطا در نمونه‌های بعدی را افزایش دهد. در یک سامانه آنلاین، این فرآیند ممکن است بارها تکرار شود و خطاهای کوچک اولیه به انحراف تدریجی مدل تبدیل شوند. پژوهش‌های جدید نیز همچنان این حلقه بازخورد خودارجاع را یکی از مسائل اصلی CTTA می‌دانند. برای نمونه، Chen و همکاران در ۲۰۲۶CVPR تصریح می‌کنند که اتکا به خودنظارتی می‌تواند خطاهای اولیه را تقویت کرده و به «رانس مدل» منجر شود [21].

در کنار انباشت خطا، فراموشی فاجعه‌بار نیز یک مانع بنیادی است. مدلی که به‌طور مداوم تنها بر اساس داده‌های جدید به‌روزرسانی می‌شود ممکن است به تدریج بازنمایی‌ها و دانشی را که در مرحله آموزش مبدأ کسب کرده است از دست بدهد. بنابراین، روش انطباق باید میان دو ویژگی متعارض تعادل ایجاد کند: از یک سو، انعطاف‌پذیری کافی برای یادگیری سریع تغییرات جدید و از سوی دیگر، پایداری کافی برای جلوگیری از تخریب دانش پیشین. CoTTA برای مقابله با این مسئله بخشی از پارامترهای مدل را به وزن‌های مبدأ بازمی‌گرداند [4] و EATA نیز با حفظ پارامترهای مهم مدل تلاش می‌کند فراموشی ناشی از انطباق را کاهش دهد [7]. این موضوع در پژوهش ما نیز به‌عنوان یکی از چالش‌های اصلی OTTA در نظر گرفته شده است. پژوهش EATA علاوه بر

مسئله فراموشی، هزینه انجام پس‌انتشار برای هر نمونه آزمون را نیز یکی از محدودیت‌های روش‌های TTA معرفی می‌کند. این چالش‌ها در وظیفه تشخیص اشیا نسبت به بسیاری از مطالعات اولیه TTA که بر دسته‌بندی تصویر متمرکز بوده‌اند، پیچیده‌تر هستند. در دسته‌بندی تصویر، خروجی اصلی مدل یک برچسب برای کل تصویر است؛ اما در تشخیص اشیا، مدل باید همزمان کلاس اشیا و موقعیت آن‌ها را از طریق جعبه‌های محدودکننده تعیین کند. بنابراین یک شبیه‌برچسب می‌تواند از نظر طبقه‌بندی صحیح اما از نظر مکانیابی نادرست باشد، یا بالعکس. Ruan و Tang در پژوهش خود درباره Fully Test-Time Adaptation for Object Detection نشان داده‌اند که نمره اطمینان طبقه‌بندی به‌تنهایی معیار کافی برای سنجش کیفیت شبیه‌برچسب‌های تشخیص اشیا نیست و عدم اطمینان ناشی از شکاف دامنه می‌تواند فرآیند خودآموزی را مختل کند [5].

اهمیت همزمان طبقه‌بندی و مکانیابی حتی در پژوهش‌های جدید سال ۲۰۲۶ نیز همچنان مورد تأکید است. Qin و همکاران در ۲۰۲۶CVPR بیان می‌کنند که بسیاری از روش‌های Test-Time Adaptive Object Detection عمدتاً بر بهبود اطمینان طبقه‌بندی تمرکز داشته‌اند و افت دقت جعبه‌های محدودکننده را کمتر مورد توجه قرار داده‌اند؛ در حالی که برای یک آشکارساز، هر دو مؤلفه طبقه‌بندی و مکانیابی باید تحت تغییر دامنه پایدار باقی بمانند [22]. این موضوع نشان می‌دهد که انطباق در زمان آزمون برای تشخیص اشیا هنوز دارای چالش‌های خاصی است که نمی‌توان آن‌ها را صرفاً با انتقال مستقیم روش‌های دسته‌بندی برطرف کرد.

از سوی دیگر، بسیاری از روش‌های TTA اولیه روی وظیفه دسته‌بندی و با به‌روزرسانی لایه‌های نرمال‌سازی یا سر طبقه‌بندی توسعه یافته‌اند و انتقال مستقیم آن‌ها به آشکارسازهای پیچیده همواره امکان‌پذیر نیست. Yoo و همکاران در ۲۰۲۴CVPR

Commented [ak21]
Efficient Test-Time Model Adaptation without Forgetting
مقاله خوبیه بخونش

Commented [ak22]
ViTPrompt: Training-Free Prompt Refinement with Visual Tokens for Open-Vocabulary Detection

Commented [ak23]: چک کن حتما چی کار می کنه:
What How and When Should Object Detectors Update in Continually Changing Test Domains?

محدودیت را به طور مستقیم مطرح کرده و مسئله انطباق پیوسته آشکارساز اشیاء را بر اساس سه پرسش «چه بخشی از مدل به روزرسانی شود؟»، «به چه روش به روزرسانی شود؟» و «در چه زمانی به روزرسانی انجام گیرد؟» صورت بندی کرده اند [8]. نتایج آن ها نشان می دهد که طراحی مازول های سبک و انتخاب زمان مناسب انطباق می تواند در کنار افزایش دقت، سرعت پردازش را نیز حفظ کند. همین موضوع نشان می دهد که در تشخیص اشیاء، نحوه کنترل فرآیند به روزرسانی بخشی از خود مسئله پژوهشی است و نه صرفاً یک جزئیات اجرایی.

کارایی محاسباتی نیز یکی دیگر از دلایل اصلی ضرورت انجام این پژوهش است. هدف یک روش آنلاین صرفاً افزایش دقت نیست؛ زیرا اگر فرآیند انطباق موجب افزایش شدید زمان پردازش، مصرف حافظه یا تعداد عملیات پس انتشار شود، استفاده از آن در یک سامانه واقعی و به ویژه در کاربردهای دارای محدودیت زمانی یا سخت افزاری امکان پذیر نخواهد بود. مرور OTTA در IJCV به همین دلیل علاوه بر دقت، معیارهایی نظیر GFLOPs، زمان واقعی اجرا و مصرف حافظه GPU را برای ارزیابی روش های انطباق آنلاین وارد مقایسه کرده است [16].

اهمیت این مسئله برای تشخیص اشیاء در سال های اخیر به طور مستقیم مورد توجه قرار گرفته است. Wang و همکاران در CVPR ۲۰۲۵ بیان می کنند که بسیاری از روش های CTTA برای تشخیص اشیاء عمدتاً بر اثربخشی انطباق تمرکز کرده اند و کارایی محاسباتی را کمتر مورد توجه قرار داده اند؛ در حالی که این ویژگی برای استقرار در سامانه های دارای منابع محدود ضروری است [9]. روش آن ها با تمرکز بر کانال های حساس به دامنه توانسته است سربار محاسباتی را نسبت به روش مرجع کاهش دهد، اما مطرح شدن چنین مسئله ای در یک پژوهش مستقل نشان می دهد که تعادل میان کیفیت انطباق و هزینه محاسباتی همچنان یک مسئله باز در CTTA و ODTA است.

این مسئله حتی در پژوهش های سال ۲۰۲۶ نیز حل شده تلقی نمی شود. Lai و همکاران در CVPR ۲۰۲۶، مسئله CTTA را صراحتاً دارای یک تعارض میان کارایی و تعمیم پذیری معرفی می کنند؛ به این معنا که به روزرسانی تعداد بیشتری از پارامترها می تواند توان انطباق را افزایش دهد، اما در مقابل هزینه استنتاج آنلاین را بالا می برد [23]. از این رو، یافتن زیرمجموعه یا سازوکاری کم هزینه برای انطباق مؤثر، همچنان یکی از محورهای فعال پژوهش در این حوزه است.

Commented [ak24]: The Golden Subspace: Where Efficiency Meets Generalization in Continual Test-Time Adaptation

علاوه بر آن، پژوهش های جدید نشان می دهند که مسئله فقط «قدرت از مدل به روزرسانی شود» نیست، بلکه نوع سیگنال مورد استفاده برای انطباق نیز اهمیت بنیادی دارد. Chen و همکاران در CVPR ۲۰۲۶ نشان داده اند که چرخه های خودنظارتی می توانند خطاهای اولیه را در طول انطباق پیوسته تقویت کنند [21]؛ همچنین Que و همکاران در مسئله Test-Time Prompt Tuning برای تشخیص اشیاء نشان داده اند که کمینه سازی آنتروپی در شرایط تغییر دامنه می تواند پیش بینی های اشتباه را با اطمینان بالاتر تثبیت کرده و به مشکل کالیبراسیون منجر شود [24]. اگرچه چارچوب آن ها بر آشکارسازهای مبتنی بر مدل های بینایی-زبان متمرکز است، نتیجه اصلی آن ها اهمیت طراحی سیگنال انطباق قابل اعتماد در تشخیص اشیاء را تقویت می کند.

Commented [ak25]: InsCal: Calibrated Multi-Source Fully Test-Time Prompt Tuning for Object Detection

همچنین، پژوهش Li و همکاران در ICCV ۲۰۲۵ سه مسئله را برای CTTA در تشخیص اشیاء به صورت مستقیم برجسته می کند: انطباق آنلاین با داده های بدون برچسب، نیاز به کارایی محاسباتی بالا و حفظ عملکرد مدل در مواجهه با تغییرات متوالی محیط [20]. این پژوهش نشان می دهد که حتی به روزرسانی تعداد محدودی از پارامترها بر اساس تعداد کمی تصویر آزمون ممکن است بازنمایی بخش های دیگر شبکه را تحت تأثیر قرار داده و باعث افت عملکرد شود؛ از این رو، هنوز در مورد بهترین سازوکار برای تغییر مدل در زمان آزمون اتفاق نظر مشخصی وجود ندارد.

از منظر کاربردی نیز انجام این پژوهش اهمیت دارد. سامانه های تشخیص اشیاء در حوزه هایی مانند رانندگی خودران، کنترل ترافیک، رباتیک متحرک و نظارت تصویری با داده های جریانی و شرایط محیطی متغیر سروکار دارند. در چنین کاربردهایی، نمی توان برای هر تغییر آب و هوا، هر دوربین جدید یا هر محیط جغرافیایی، یک مجموعه داده برچسب دار جدید تهیه و مدل را از ابتدا آموزش داد. همچنین، در بسیاری از موارد داده های مبدأ در محل استقرار مدل در دسترس نیستند و امکان ذخیره سازی یا انتقال آن ها وجود ندارد. بنابراین، یک روش انطباق آنلاین که تنها با استفاده از مدل از پیش آموزش دیده و جریان داده های بدون برچسب بتواند خود را با محیط جدید سازگار کند، می تواند فاصله میان عملکرد آزمایشگاهی و استقرار واقعی مدل های تشخیص اشیاء را کاهش دهد.

بر این اساس، ضرورت پژوهش حاضر از اجتماع چند مسئله حل نشده ناشی می‌شود: تغییر مستمر توزیع داده پس از استقرار، عدم دسترسی به برچسب‌های دامنه هدف و داده‌های مبدأ، غیرقابل اعتماد بودن سیگنال‌های خودنظارتی و شبه‌برچسب‌ها، خطر انباشت خطا در طول زمان، فراموشی فاجعه‌بار دانش مبدأ، پیچیدگی همزمان طبقه‌بندی و مکانیابی در تشخیص اشیا و ضرورت محدود نگه‌داشتن هزینه محاسباتی انطباق. ادبیات جدید سال‌های ۲۰۲۴ تا ۲۰۲۶ نشان می‌دهد که هر یک از این موارد همچنان محور پژوهش‌های فعال TTA و CTA است و راه‌حل واحدی که بتواند همه این نیازها را به‌طور همزمان برآورده کند وجود ندارد. در نتیجه، انجام پژوهشی با تمرکز بر بهبود روش‌های انطباق آنلاین در زمان آزمون برای تشخیص اشیا ضروری است تا مدلی که در ابتدا روی دامنه مبدأ و به‌ویژه داده‌های مصنوعی آموزش دیده است بتواند هنگام استقرار، بدون دسترسی به داده‌های آموزشی مبدأ و بدون دریافت برچسب از دامنه هدف، با جریان‌های متغیر داده تطبیق پیدا کند. چنین روشی باید علاوه بر افزایش دقت تشخیص در دامنه‌های جدید، کیفیت سیگنال انطباق را کنترل کند، از تشدید خطاهای متوالی جلوگیری نماید، دانش مفید مدل مبدأ را حفظ کند و هزینه محاسباتی آن به اندازه‌ای باشد که امکان استفاده در محیط‌های عملیاتی و آنلاین را فراهم سازد. از این منظر، مسئله پژوهش حاضر نه صرفاً بهبود یک معیار دقت در یک مجموعه داده ثابت، بلکه حرکت به سمت آشکارسازهایی پایدار، سازگار، کم‌هزینه و قابل استفاده در محیط‌های واقعی و پویا است.

3-4 - سابقه تحقیقات و مطالعات انجام گرفته :

با توجه به اهمیت مسئله تغییر توزیع داده و کاهش عملکرد مدل‌های یادگیری عمیق در شرایط خارج از توزیع آموزش، طی سال‌های اخیر مطالعات گسترده‌ای در زمینه سازگارسازی مدل‌ها با دامنه‌های جدید انجام شده است. مسیر توسعه این تحقیقات را می‌توان از روش‌های کلاسیک انطباق دامنه آغاز کرد و سپس با ظهور محدودیت‌های عملی، به سمت روش‌های بدون منبع، انطباق در زمان آزمون و در نهایت انطباق آنلاین و پیوسته در زمان آزمون دنبال کرد. در ادامه، مهم‌ترین مطالعات انجام‌شده در این مسیر و ارتباط آن‌ها با مسئله پژوهش حاضر بررسی می‌شوند.

مطالعات اولیه در انطباق دامنه و کاهش شکاف توزیع

یکی از نخستین رویکردها برای مقابله با افت عملکرد مدل‌ها در دامنه‌های جدید، استفاده از روش‌های انطباق دامنه بوده است. ایده اصلی این روش‌ها کاهش اختلاف میان توزیع داده‌های دامنه مبدأ و هدف است تا مدلی که روی داده‌های مبدأ آموزش دیده، بتواند در دامنه هدف نیز عملکرد مناسبی داشته باشد.

در بسیاری از روش‌های اولیه، فرض می‌شد که داده‌های مبدأ دارای برچسب و داده‌های هدف بدون برچسب در دسترس هستند. این تنظیم که با عنوان تطبیق دامنه بدون نظارت شناخته می‌شود، تلاش می‌کند با استفاده از داده‌های بدون برچسب دامنه هدف، بازنمایی‌های استخراج‌شده توسط مدل را میان دو دامنه هم‌راستا کند.

یکی از مسیرهای مهم در UDA، استفاده از روش‌های مبتنی بر هم‌ترازی ویژگی‌ها بود. در این روش‌ها تلاش می‌شود فاصله آماری میان ویژگی‌های استخراج‌شده از دو دامنه کاهش یابد. روش‌هایی مانند Deep Domain Confusion و Maximum Mean Discrepancy نشان دادند که می‌توان با نزدیک کردن توزیع ویژگی‌های دو دامنه، قابلیت تعمیم مدل را افزایش داد [25].

با گسترش استفاده از شبکه‌های عمیق در وظایف بینایی ماشین، روش‌های مبتنی بر یادگیری تخصصی نیز مورد توجه قرار گرفتند. در این روش‌ها، یک شبکه استخراج‌کننده ویژگی تلاش می‌کند ویژگی‌هایی تولید کند که یک شبکه تشخیص دامنه نتواند تفاوت میان داده‌های مبدأ و هدف را تشخیص دهد. Ganin و همکاران با معرفی Domain-Adversarial Neural Network (DANN) نشان دادند که می‌توان با استفاده از آموزش تخصصی، ویژگی‌هایی مستقل‌تر از دامنه ایجاد کرد [26]. اگرچه این روش‌ها توانستند شکاف دامنه را در بسیاری از مسائل کاهش دهند، اما یک محدودیت بنیادی داشتند: نیاز به دسترسی همزمان به داده‌های مبدأ و هدف در زمان انطباق. این محدودیت در کاربردهای واقعی، به‌خصوص در شرایطی که داده‌های مبدأ حجیم، محرمانه یا غیرقابل انتقال هستند، استفاده از این روش‌ها را دشوار می‌کند.

مطالعات انجام شده در انطباق دامنه برای تشخیص اشیا

⁶ Unsupervised Domain Adaptation (UDA)

در مقایسه با دسته‌بندی تصویر، مسئله انطباق دامنه در تشخیص اشیا پیچیدگی بیشتری دارد؛ زیرا مدل علاوه بر تعیین کلاس، باید موقعیت مکانی اشیا را نیز پیش‌بینی کند. بنابراین تغییر دامنه می‌تواند هم ویژگی‌های معنایی و هم ویژگی‌های مکانی اشیا را تحت تأثیر قرار دهد.

Chen و همکاران در پژوهش *Domain Adaptive Faster R-CNN for Object Detection in the Wild* یکی از مطالعات بنیادی در این زمینه را ارائه کردند. آن‌ها نشان دادند که تغییر دامنه در تشخیص اشیا می‌تواند هم در سطح تصویر و هم در سطح نمونه شیء رخ دهد و به همین دلیل، انطباق باید هر دو سطح را در نظر بگیرد. روش ارائه‌شده با استفاده از شبکه‌های انطباق دامنه در سطح تصویر و نمونه تلاش کرد ویژگی‌های استخراج‌شده توسط آشکارساز *Faster R-CNN* را میان دو دامنه هم‌تراز کند [11].

پس از آن، روش‌های مبتنی بر مدل معلم - دانش‌آموز و شبه‌برچسب‌گذاری به یکی از مسیرهای اصلی انطباق تشخیص اشیا تبدیل شدند. Deng و همکاران در روش *Unbiased Mean Teacher for Cross-Domain Object Detection* نشان دادند که استفاده از یک مدل معلم پایدار برای تولید شبه‌برچسب‌های باکیفیت‌تر می‌تواند فرآیند انتقال دانش به مدل دانش‌آموز را بهبود دهد. این روش با کاهش سوگیری ناشی از نمونه‌های با اطمینان پایین، عملکرد تشخیص اشیا را در دامنه هدف افزایش داد [12]. روش *Contrastive Mean Teacher* نیز با اضافه کردن یادگیری کنتراستی تلاش کرد فاصله میان نمونه‌های مشابه در دو دامنه را کاهش داده و بازنمایی‌های مقاوم‌تری ایجاد کند [6].

با وجود موفقیت این روش‌ها، آن‌ها همچنان به داده‌های مبدأ در مرحله آموزش یا انطباق وابسته هستند. بنابراین، در شرایطی که داده‌های مبدأ پس از آموزش مدل در دسترس نباشند، نیاز به روش‌های جدیدتر احساس شد.

مطالعات انجام شده در Source-Free Domain Adaptation

برای رفع محدودیت وابستگی به داده‌های مبدأ، مفهوم *Source-Free Domain Adaptation (SFDA)* مطرح شد. در این تنظیم، تنها مدل آموزش‌دیده روی دامنه مبدأ و داده‌های بدون برچسب دامنه هدف در دسترس هستند و داده‌های اصلی مبدأ در فرآیند انطباق استفاده نمی‌شوند.

Liang و همکاران با معرفی روش *Source Hypothesis Transfer (SHOT)* از نخستین مطالعات مهم در این زمینه بودند. آن‌ها نشان دادند که می‌توان بدون دسترسی به داده‌های مبدأ و تنها با استفاده از مدل آموزش‌دیده، بازنمایی‌های استخراج‌شده را برای دامنه هدف تطبیق داد. ایده اصلی این روش، جداسازی بخش استخراج ویژگی و طبقه‌بندی و سپس تطبیق ویژگی‌ها با استفاده از داده‌های هدف بدون برچسب بود [13].

پس از SHOT، مطالعات متعددی در حوزه SFDA انجام شد که هدف آن‌ها بهبود کیفیت انطباق بدون استفاده از داده‌های مبدأ بود. روش‌هایی مانند *NRC*، *AdaContrast* و دیگر روش‌های مبتنی بر خوشه‌بندی، یادگیری کنتراستی و خودآموزی نشان دادند که می‌توان با استفاده از ساختار داخلی داده‌های هدف، مدل را به سمت توزیع جدید هدایت کرد.

با این حال، بسیاری از روش‌های SFDA همچنان یک فرض مهم دارند: مجموعه‌ای از داده‌های هدف باید پیش از استفاده نهایی مدل در اختیار الگوریتم قرار گیرد تا فرآیند انطباق به‌صورت آفلاین انجام شود. این موضوع باعث شد که توجه پژوهشگران به سمت شرایطی جلب شود که داده‌های هدف به‌صورت تدریجی و همزمان با استفاده از مدل وارد سیستم می‌شوند.

مطالعات اولیه در Test-Time Adaptation

با هدف کاهش وابستگی مدل به شرایط ثابت آموزش، مفهوم *Test-Time Adaptation (TTA)* مطرح شد. در این چارچوب، مدل پس از آموزش اولیه، هنگام مرحله آزمون و با استفاده از داده‌های بدون برچسب ورودی، خود را با شرایط جدید سازگار می‌کند.

یکی از مطالعات تأثیرگذار در این حوزه، روش *Tent: Fully Test-Time Adaptation by Entropy Minimization* توسط Wang و همکاران است. این روش نشان داد که می‌توان تنها با کمینه‌سازی آنروپی خروجی مدل روی داده‌های آزمون و

به‌روزرسانی پارامترهای affine لایه‌های Batch Normalization، بدون استفاده از داده‌های مبدأ، مدل را با توزیع جدید تطبیق داد [3].

اگرچه TENT نشان داد که انطباق در زمان آزمون امکان‌پذیر است، اما محدودیت‌هایی نیز داشت. این روش عمدتاً روی دسته‌بندی تصویر آزمایش شد و فرض می‌کرد که تغییرات دامنه نسبتاً پایدار هستند. همچنین، استفاده از تنها نمونه‌های جاری و نبود سازوکارهای حفظ دانش گذشته می‌توانست در شرایط طولانی‌مدت موجب ناپایداری شود. در ادامه، روش‌هایی مانند EATA تلاش کردند این مشکلات را کاهش دهند. Niu و همکاران با معرفی EATA نشان دادند که همه نمونه‌های آزمون برای انطباق مفید نیستند و انتخاب نمونه‌های مناسب می‌تواند علاوه بر کاهش هزینه محاسباتی، از تغییرات مخرب مدل جلوگیری کند. همچنین، استفاده از منظم‌سازی برای حفظ پارامترهای مهم مدل، مسئله فراموشی را کاهش داد [7].

مطالعات انجام شده در Online Test-Time Adaptation و Continual Test-Time Adaptation

با افزایش توجه به کاربردهای واقعی، مشخص شد که بسیاری از روش‌های TTA هنوز برای شرایط عملیاتی واقعی کافی نیستند؛ زیرا در محیط واقعی، داده‌ها معمولاً به‌صورت یک جریان پیوسته وارد سیستم می‌شوند و امکان مشاهده دوباره کامل داده‌های آزمون وجود ندارد.

در این شرایط، مفهوم Online Test-Time Adaptation (OTTA) مطرح شد. برخلاف تنظیمات آفلاین، در OTTA مدل باید هنگام دریافت داده‌های جدید، همزمان با انجام پیش‌بینی، خود را نیز به‌روزرسانی کند. Wang و همکاران در روش Continual Test-Time Domain Adaptation (CoTTA) یکی از نخستین مطالعات مهم در این حوزه را ارائه کردند. آن‌ها نشان دادند که روش‌های معمول TTA در مواجهه با تغییرات پیوسته دامنه دچار دو مشکل اصلی می‌شوند: انباشت خطا و فراموشی فاجعه‌بار. برای مقابله با این مشکلات، CoTTA از ترکیب مدل معلم میانگین‌گیری‌شده، افزایش داده و بازگردانی تصادفی بخشی از پارامترها استفاده کرد [4].

پس از CoTTA، روش‌های متعددی برای بهبود پایداری CTTA ارائه شدند. RoTTA با تمرکز بر داده‌های وابسته به زمان و توزیع‌های پویا، استفاده از حافظه و نمونه‌برداری متوازن را برای حفظ تنوع داده پیشنهاد کرد [27]. همچنین، روش SAR تلاش کرد با اصلاح فرآیند بهینه‌سازی و جلوگیری از انطباق بیش از حد، پایداری مدل را در شرایط دشوار افزایش دهد [18].

Commented [ak26] "RoTTA: Robust Test-Time Adaptation in Dynamic Scenarios
بخون پیپر اش رو

با این حال، مطالعات بعدی نشان دادند که حتی روش‌های پیشرفته CTTA نیز در بازه‌های طولانی ممکن است دچار افت عملکرد شوند. پژوهش RDumb با بررسی بلندمدت روش‌های CTTA نشان داد که بسیاری از الگوریتم‌ها در مواجهه با توالی‌های طولانی داده، به دلیل انباشت خطا و رانش مدل، عملکرد خود را از دست می‌دهند [19].

مطالعات جدید در Online Test-Time Adaptation برای تشخیص اشیا

اگرچه بخش زیادی از مطالعات اولیه TTA روی دسته‌بندی تصویر انجام شده‌اند، انتقال این ایده‌ها به تشخیص اشیا همچنان یک مسئله باز است. دلیل اصلی این موضوع، پیچیدگی ساختار خروجی آشکارسازها و نیاز همزمان به حفظ دقت طبقه‌بندی و مکانیابی است.

VS و همکاران در پژوهش Towards Online Domain Adaptive Object Detection یکی از مطالعات اولیه در زمینه انطباق آنلاین آشکارسازها را ارائه کردند. آن‌ها نشان دادند که روش‌های آفلاین انطباق دامنه برای شرایطی که داده‌ها به‌صورت جریان وارد می‌شوند مناسب نیستند و آشکارساز باید بتواند هنگام استقرار خود را با تغییرات محیطی سازگار کند [10]. Ruan و Tang در پژوهش Fully Test-Time Adaptation for Object Detection مسئله استفاده از TTA در تشخیص اشیا را بررسی کردند. آن‌ها نشان دادند که استفاده مستقیم از معیارهای رایج مانند اطمینان طبقه‌بندی برای انتخاب شبهه‌برچسب‌ها کافی نیست، زیرا کیفیت مکانیابی جعبه‌های محدودکننده نیز باید در فرآیند انطباق در نظر گرفته شود.

Yoo و همکاران در پژوهش *What, How, and When Should Object Detectors Update in Continually Changing Environments* مسئله CTTA برای آشکارسازهای اشیا را از منظر سه سؤال اساسی بررسی کردند: چه بخشی از مدل باید به‌روزرسانی شود، چگونه باید به‌روزرسانی انجام شود و چه زمانی مدل باید تغییر کند. این پژوهش نشان داد که طراحی فرآیند انطباق برای آشکارسازها تنها به انتخاب تابع زیان محدود نیست، بلکه کنترل محل و زمان به‌روزرسانی نیز اهمیت بنیادی دارد [8].

در ادامه، Wang و همکاران در CVPR 2025 مسئله *Efficient Test-Time Adaptive Object Detection via Sensitivity-Guided Pruning* را مطرح کردند. آن‌ها نشان دادند که علاوه بر افزایش دقت انطباق، کاهش هزینه محاسباتی یکی از چالش‌های اصلی استقرار CTTA در تشخیص اشیا است و پیشنهاد کردند تنها بخش‌های حساس به تغییر دامنه به‌روزرسانی شوند [9].

همچنین Li و همکاران در ICCV 2025 مسئله *Continual Adaptation for Object Detection in Dynamic Scenarios* را بررسی کردند و با استفاده از تولید پارامترهای وابسته به محیط تلاش کردند میان سازگاری با شرایط جدید و حفظ دانش قبلی تعادل ایجاد کنند [20].

3-5 - فرضیه‌های تحقیق (سوالات تحقیق) :

3-6 - نتایج مورد انتظار پس از انجام تحقیق :

3-7 - در صورت کاربردی بودن تحقیق، چه سازمان‌هایی می‌توانند از نتایج بدست آمده استفاده کنند .

ردیف	نام سازمان	نوع استفاده
1	شرکت‌های خودروسازی و توسعه‌دهندگان فناوری رانندگی خودران ایران خودرو و سایپا و شرکت‌های دانش‌بنیان فعال در این حوزه	تطبیق و بومی‌سازی سیستم‌های ادراک (Perception Systems) که این شرکت‌ها مدل‌های تشخیص اشیا خود را بر روی حجم عظیمی از داده‌های شبیه‌سازی شده و داده‌های جمع‌آوری شده در یک منطقه خاص آموزش می‌دهند. با استفاده از نتایج این تحقیق، آن‌ها می‌توانند مدل پایه خود را به مشتریان یا ناوگان‌های فعال در مناطق جغرافیایی با شرایط آب و هوایی جدید تطبیق دهند، بدون آنکه نیاز به اشتراک‌گذاری داده‌های محرمانه و گران‌قیمت اولیه خود داشته باشند.
2	مراکز مدیریت و کنترل ترافیک هوشمند (Smart City & Traffic Management)	افزایش کارایی سیستم‌های نظارت ترافیکی: این سازمان‌ها از دوربین‌های هوشمند برای تحلیل ترافیک، شناسایی تخلفات و مدیریت تقاطع‌ها استفاده می‌کنند. یک مدل تشخیص خودروی مرکزی می‌تواند توسعه داده شود و سپس در صدها یا هزاران دوربین مختلف در سطح یک شهر یا کشور نصب گردد. روش SFDA به هر دوربین اجازه می‌دهد تا مدل را با شرایط نوری، زاویه دید و

الگوهای ترافیکی خاص خود تطبیق دهد و دقت سیستم نظارتی را به طور قابل توجهی افزایش دهد.		
به روزرسانی خودکار نقشه‌های با دقت بالا (HD Maps): این شرکت‌ها از خودروهای مجهز به دوربین برای اسکن مداوم جاده‌ها و به روزرسانی نقشه‌های سه‌بعدی مورد نیاز خودروهای خودران استفاده می‌کنند. مدل‌های تشخیص اشیاء آن‌ها باید بتوانند علائم راهنمایی، خط‌کشی‌ها و وضعیت جاده را در کشورهای مختلف با استانداردها و شرایط متفاوت، به دقت تشخیص دهند. نتایج این تحقیق به آن‌ها کمک می‌کند تا مدل‌های خود را به سرعت برای مناطق جدید تطبیق داده و فرایند به روزرسانی نقشه را تسریع بخشند.	شرکت‌های فعال در حوزه نقشه‌برداری HD و نگهداری زیرساخت‌های جاده‌ای	3
بهبود تشخیص ماشین‌ها و خودروها با کاربرد های مختلف نظامی	شرکت‌های فعال در صنعت نظامی	4

4- روش انجام تحقیق :

4-1 - روش گردآوری اطلاعات :

روش گردآوری اطلاعات در این پژوهش، با توجه به ماهیت آن که بر توسعه و ارزیابی یک الگوریتم جدید متمرکز است، به دو بخش اصلی تقسیم می‌شود: گردآوری اطلاعات نظری و گردآوری داده‌های عملی.

۱. گردآوری اطلاعات نظری و مبانی تحقیق (مطالعات کتابخانه‌ای)

این بخش از طریق مطالعات کتابخانه‌ای و بررسی اسنادی (Document-based Research) انجام خواهد شد. هدف، کسب دانش عمیق و به روز در مورد مبانی نظری و کارهای پیشین مرتبط با موضوع تحقیق است. منابع اصلی برای این منظور عبارتند از:

- پایگاه‌های علمی و دیجیتال:
 - IEEE Xplore
 - ACM Digital Library
 - SpringerLink
 - ScienceDirect
- موتورهای جستجوی آکادمیک:
 - Google Scholar
 - Semantic Scholar
 - arXiv.org برای دسترسی به جدیدترین مقالات پیش از انتشار رسمی
- مجموعه مقالات کنفرانس‌های برتر:
 - کنفرانس‌های اصلی بینایی ماشین (CVPR, ICCV, ECCV)
 - کنفرانس‌های اصلی یادگیری ماشین (NeurIPS, ICML, ICLR)

کلیدواژه‌های اصلی برای جستجو:

"Domain Adaptation", "Unsupervised Domain Adaptation (UDA)", "Source-Free Domain Adaptation (SFDA)", "Object Detection", "Prototype-based Learning", "Adversarial Learning", "Catastrophic Forgetting", "Synth-to-Real".

علاوه بر این، مخازن کد متن-باز (Open-Source Repositories) مانند GitHub برای مطالعه و تحلیل پیاده‌سازی‌های عملی روش‌های پیشرفته مورد بررسی قرار خواهند گرفت تا درک عمیق‌تری از جزئیات فنی آن‌ها حاصل شود.

۲. گردآوری داده‌های عملی برای آزمایش‌ها (استفاده از مجموعه داده‌های عمومی)

داده‌های مورد نیاز برای آموزش، اعتبارسنجی و آزمون روش پیشنهادی، از طریق مجموعه داده‌های عمومی و استاندارد (Public Datasets) که به صورت گسترده در تحقیقات مشابه استفاده می‌شوند، گردآوری خواهند شد. این رویکرد، قابلیت مقایسه مستقیم نتایج این تحقیق با کارهای پیشین را تضمین می‌کند.

مجموعه داده‌های اصلی مورد استفاده عبارتند از:

- Cityscapes: مجموعه داده‌ای بزرگ و متنوع از تصاویر خیابان‌های شهری با برچسب‌های دقیق.
- Foggy Cityscapes: نسخه‌ای از مجموعه داده Cityscapes که به صورت مصنوعی شرایط مه‌آلود را شبیه‌سازی می‌کند و برای ارزیابی مقاومت مدل در برابر تغییرات آب و هوایی ایده‌آل است.
- Sim10k: مجموعه‌ای از داده‌های مصنوعی (رندر شده از یک بازی کامپیوتری) که برای سناریوی کلیدی انتقال از داده مصنوعی به واقعی (Synth-to-Real) استفاده می‌شود.
- مجموعه داده کاربردی تشخیص خودرو: یک مجموعه داده استاندارد دیگر در این حوزه مانند KITTI یا BDD100K برای ارزیابی عملکرد در یک سناریوی واقعی تر انتخاب خواهد شد.

این مجموعه داده‌ها از وبسایت‌های رسمی آن‌ها دانلود شده و طبق دستورالعمل‌های ارائه شده برای استفاده آکادمیک، مورد بهره‌برداری قرار خواهند گرفت. لازم به ذکر است که این تحقیق شامل مرحله میدانی و جمع‌آوری داده اولیه (Primary Data Collection) نخواهد بود و تمامی آزمایش‌ها بر روی داده‌های از پیش موجود انجام می‌شود.

- داده‌های جمع‌آوری شده در آزمایشگاه که دیتاست‌های مربوط به تانک و خودروهای نظامی را با استفاده از نرم‌هایی مانند CVAT و image label برچسب گذاری شده است تا برای کاربردهایی مانند تشخیص و تمایز ماشین‌ها با کاربرد های نظامی متفاوت و غیر نظامی مورد استفاده قرار گیرد.

4-2 - روش و مراحل تحقیق :

4-3 - قلمرو تحقیق :

4-4 - روشهای مورد نظر برای تجزیه و تحلیل اطلاعات و آزمون فرضیه‌ها :

5- نیازهای تحقیق :

5-1 - هزینه انجام تحقیق :

توضیحات	برآورد هزینه (ریال)	شرح هزینه
وابسته به استفاده از منابع دانشگاهی یا سرویس‌های ابری	۵۰۰-۰ میلیون	سخت‌افزار و توان پردازشی
تمامی منابع مورد نیاز رایگان هستند.	۰	نرم‌افزار و داده
تنها در صورت ارسال و پذیرش مقاله اعمال می‌شود.	۱۰۰ میلیون	انتشار نتایج
بسته به شرایط و انتخاب‌های موجود	۶۰۰-۰ میلیون	مجموع برآورد هزینه

5-2 - امکانات لازم (سخت‌افزاری - نرم‌افزاری و منابع و ...):

- پردازنده گرافیکی (GPU): دسترسی به یک یا چند پردازنده گرافیکی قدرتمند، مهم‌ترین نیاز سخت‌افزاری این تحقیق است. به دلیل پیچیدگی مدل‌های تشخیص اشیاء و نیاز به اجرای آزمایش‌های متعدد، استفاده از کارت‌های گرافیکی مدرن با حافظه VRAM بالا (ترجیحاً ۲۴ گیگابایت یا بیشتر) ضروری است. مدل‌های پیشنهادی شامل سری NVIDIA RTX مانند RTX 4090/5090 یا کارت‌های محاسباتی ویژه سرور مانند A100 می‌باشند.

- پردازنده مرکزی (CPU) و حافظه اصلی (RAM): یک پردازنده مرکزی چند-هسته‌ای مدرن و حافظه اصلی کافی (حداقل ۳۲ گیگابایت) برای پیش‌پردازش داده‌ها، مدیریت فرآیندهای آموزش و اجرای روان سیستم‌عامل ضروری است.
- حافظه ذخیره‌سازی: به دلیل حجم بالای مجموعه داده‌های تصویری، دسترسی به حافظه ذخیره‌سازی پرسرعت SSD ترجیحاً از نوع NVMe با ظرفیت کافی (حداقل ۱ ترابایت) برای تسریع فرآیند بارگذاری داده‌ها و کاهش زمان انتظار در طول آموزش مدل، الزامی است.

۲. امکانات نرم‌افزاری (Software)

- سیستم‌عامل: سیستم‌عامل لینوکس ترجیحاً توزیع Ubuntu به دلیل پشتیبانی گسترده و پایداری بالا در اکوسیستم یادگیری عمیق.
- زبان برنامه‌نویسی پایتون (Python) نسخه ۳.۸ یا بالاتر.
- چارچوب‌های یادگیری عمیق:
 - PyTorch: به عنوان چارچوب اصلی برای پیاده‌سازی، آموزش و ارزیابی مدل‌های تشخیص اشیاء.
- کتابخانه‌های کمکی: کتابخانه‌های استاندارد علم داده و بینایی ماشین مانند NumPy, OpenCV, Matplotlib و Scikit-learn برای پردازش تصویر، تحلیل نتایج و مصورسازی.
- محیط توسعه و مدیریت بسته‌ها: استفاده از Conda برای مدیریت محیط‌های مجازی و وابستگی‌های نرم‌افزاری پروژه.

۳. منابع داده و علمی (Data and Scientific Resources)

- مجموعه داده‌های استاندارد: دسترسی به مجموعه داده‌های عمومی و شناخته‌شده در حوزه تطبیق دامنه برای تشخیص اشیاء به منظور ارزیابی و مقایسه با سایر روش‌ها. این مجموعه داده‌ها عبارتند از:
 - Cityscapes: تصاویر واقعی از محیط‌های شهری.
 - Foggy Cityscapes: نسخه مه‌آلود از مجموعه داده Cityscapes برای شبیه‌سازی شرایط آب و هوایی نامساعد.
 - Sim10k: مجموعه داده مصنوعی شامل تصاویر از بازی کامپیوتری (Grand Theft Auto V (GTAV))
- مجموعه داده کاربردی: دسترسی به مجموعه داده تشخیص ماشین (شامل داده‌های شبیه‌سازی شده و واقعی) که به عنوان یکی از اهداف اصلی تحقیق، برای اعتبارسنجی عملی روش پیشنهادی استفاده خواهد شد. این داده باید توسط آزمایشگاه جمع‌آوری شده باشد و یا باید جمع‌آوری شود.
- منابع علمی: دسترسی به پایگاه‌های داده مقالات علمی مانند IEEE Xplore, ACM Digital Library, SpringerLink و وبسایت arXiv برای مطالعه مستمر آخرین دستاوردهای پژوهشی در این حوزه. این موارد می‌توانند از طریق gigaLib و iranpaper قابل تأمین هستند.

۶- حداکثر زمان مورد نیاز برای انجام تحقیق:

ردیف	فاز تحقیق	شرح فعالیت‌ها	حداکثر زمان تخصیص یافته (ماه)
۱	فاز اول: مطالعه و تعمیق در مسئله	مرور جامع و عمیق ادبیات موضوع، مطالعه مقالات کلیدی در حوزه‌های DA, UDA, SFDA، دسته‌بندی و تحلیل دقیق روش‌های موجود. نهایی‌سازی ایده نوآورانه و صورت‌بندی دقیق مسئله تحقیق.	۳ ماه

۲ ماه	-آماده‌سازی محیط برنامه‌نویسی و نصب کتابخانه‌های مورد نیاز مانند PyTorch CUDA, ... و جمع آوری، پیش‌پردازش و آماده‌سازی مجموعه داده‌های استاندارد و کاربردی. پیاده‌سازی و اجرای یک یا چند مدل پایه (Baseline) برای اطمینان از صحت خط لوله (Pipeline) و کسب نتایج اولیه.	۲ فاز دوم: آماده‌سازی و پیاده‌سازی پایه
۶ ماه	پیاده‌سازی کامل چارچوب اصلی مانند معماری و توسعه و پیاده‌سازی ماژول‌های نوآورانه مانند پالایش شبه-برچسب با CLIP و مکانیزم جلوگیری از فراموشی. ادغام، تست و رفع خطای (Debug) کامل کدهای نوشته شده.	۳ فاز سوم: طراحی و پیاده‌سازی روش پیشنهادی
۴ ماه	اجرای سناریوهای اصلی آزمایش بر روی تمام مجموعه داده‌ها. اجرای آزمایش‌های مربوط به مطالعه مؤلفه‌ها (Ablation Study) برای سنجش تأثیر هر بخش از نوآوری. مقایسه نتایج به دست آمده با روش‌های پیشرفته (State-of-the-art). تحلیل دقیق نتایج، استخراج جداول، نمودارها و نتیجه‌گیری‌های علمی.	۴ فاز چهارم: اجرای آزمایش‌ها و تحلیل نتایج
۳ ماه	نگارش فصول مختلف پایان‌نامه/مقاله (مقدمه، کارهای پیشین، روش پیشنهادی، آزمایش‌ها، نتیجه‌گیری). آماده‌سازی اسلایدهای ارائه برای دفاع. بازبینی و اصلاح نهایی متن بر اساس بازخورد اساتید راهنما.	۵ فاز پنجم: نگارش و تدوین نهایی
۱۸ ماه	مجموع زمان	

۷ - زمان‌بندی تحقیق (نمودار گانت):

زمان مورد نیاز	ماه اول	ماه دوم	ماه سوم	ماه چهارم	ماه پنجم	ماه ششم	ماه هفتم	ماه هشتم	ماه نهم	ماه دهم	ماه یازدهم	ماه دوازدهم
فاز اول	■	■	■									
فاز دوم				■	■							
فاز سوم					■	■	■	■	■	■		
فاز چهارم									■	■	■	■
فاز پنجم											■	■

۸ - فهرست منابع و مأخذ:

H. Tang and K. Jia, "A New Benchmark: On the Utility of Synthetic Data With [1] Blender for Bare Supervised Learning and Downstream Domain Adaptation," presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2023, pp. 15954–15964. Accessed: Sep. 11, 2026. [Online]. Available:

- https://openaccess.thecvf.com/content/CVPR2023/html/Tang_A_New_Benchmark_On_the_Utility_of_Synthetic_Data_With_CVPR_2023_paper.html
- J. Nath Kundu, N. Venkat, M. V. Rahul, and R. Venkatesh Babu, “Universal Source-Free Domain Adaptation,” in *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2020, pp. 4543–4552. doi: 10.1109/CVPR42600.2020.00460. [2]
- D. Wang, E. Shelhamer, S. Liu, B. Olshausen, and T. Darrell, “Tent: Fully Test-time Adaptation by Entropy Minimization,” Mar. 18, 2021, *arXiv*: arXiv:2006.10726. doi: 10.48550/arXiv.2006.10726. [3]
- Q. Wang, O. Fink, L. Van Gool, and D. Dai, “Continual Test-Time Domain Adaptation,” presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2022, pp. 7201–7211. Accessed: Sep. 13, 2026. [4]
- [Online]. Available: https://openaccess.thecvf.com/content/CVPR2022/html/Wang_Continual_Test-Time_Domain_Adaptation_CVPR_2022_paper.html?utm_source=chatgpt.com
- X. Ruan and W. Tang, “Fully Test-time Adaptation for Object Detection,” in *2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, Jun. 2024, pp. 1038–1047. doi: 10.1109/CVPRW63382.2024.00110. [5]
- S. Cao, D. Joshi, L.-Y. Gui, and Y.-X. Wang, “Contrastive Mean Teacher for Domain Adaptive Object Detectors,” in *2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2023, pp. 23839–23848. doi: 10.1109/CVPR52729.2023.02283. [6]
- S. Niu *et al.*, “Efficient Test-Time Model Adaptation without Forgetting,” in *Proceedings of the 39th International Conference on Machine Learning*, PMLR, Jun. 2022, pp. 16888–16905. Accessed: Sep. 13, 2026. [Online]. Available: <https://proceedings.mlr.press/v162/niu22a.html>
- “What, How, and When Should Object Detectors Update in Continually Changing Test Domains?” Accessed: Sep. 13, 2026. [Online]. Available: <https://www.computer.org/csdl/proceedings-article/cvpr/2024/530000x354/20hMpwgeig8> [8]
- K. Wang *et al.*, “Efficient Test-Time Adaptive Object Detection via Sensitivity-Guided Pruning,” in *2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2025, pp. 10577–10586. doi: 10.1109/CVPR52734.2025.00989. [9]
- V. Vs, P. Oza, and V. M. Patel, “Towards Online Domain Adaptive Object Detection,” *arXiv.org*. Accessed: Sep. 13, 2026. [Online]. Available: <https://arxiv.org/abs/2204.05289v2> [10]
- Y. Chen, W. Li, C. Sakaridis, D. Dai, and L. Van Gool, “Domain Adaptive Faster R-CNN for Object Detection in the Wild,” in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, Jun. 2018, pp. 3339–3348. doi: 10.1109/CVPR.2018.00352. [11]
- J. Deng, W. Li, Y. Chen, and L. Duan, “Unbiased Mean Teacher for Cross-domain Object Detection,” in *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Jun. 2021, pp. 4089–4099. doi: 10.1109/CVPR46437.2021.00408. [12]

- “Do We Really Need to Access the Source Data? Source Hypothesis Transfer for Unsupervised Domain Adaptation.” Accessed: Sep. 14, 2026. [Online]. Available: <https://proceedings.mlr.press/v119/liang20a.html> [13]
- “Source-free unsupervised domain adaptation: A survey - ScienceDirect.” Accessed: Sep. 14, 2026. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S0893608024001540> [14]
- “A Comprehensive Survey on Test-Time Adaptation Under Distribution Shifts | International Journal of Computer Vision.” Accessed: Sep. 14, 2026. [Online]. Available: <https://dl.acm.org/doi/10.1007/s11263-024-02181-w> [15]
- “In Search of Lost Online Test-Time Adaptation: A Survey | International Journal of Computer Vision | Springer Nature Link.” Accessed: Sep. 14, 2026. [Online]. Available: <https://link.springer.com/article/10.1007/s11263-024-02213-5> [16]
- L. Yuan, B. Xie, and S. Li, “Robust Test-Time Adaptation in Dynamic Scenarios,” arXiv.org. Accessed: Sep. 14, 2026. [Online]. Available: <https://arxiv.org/abs/2303.13899v1> [17]
- S. Niu *et al.*, “Towards Stable Test-Time Adaptation in Dynamic Wild World,” arXiv.org. Accessed: Sep. 14, 2026. [Online]. Available: <https://arxiv.org/abs/2302.12400v1> [18]
- O. Press, S. Schneider, M. Kümmerer, and M. Bethge, “RDumb: A simple approach that questions our progress in continual test-time adaptation,” arXiv.org. Accessed: Sep. 14, 2026. [Online]. Available: <https://arxiv.org/abs/2306.05401v3> [19]
- D. Li, A. Wu, Y. Li, Y. Wang, and Y. Han, “Continual Adaptation: Environment-Conditional Parameter Generation for Object Detection in Dynamic Scenarios,” presented at the Proceedings of the IEEE/CVF International Conference on Computer Vision, 2025, pp. 4434–4443. Accessed: Sep. 15, 2026. [Online]. Available: https://openaccess.thecvf.com/content/ICCV2025/html/Li_Continual_Adaptation_Environment-Conditional_Parameter_Generation_for_Object_Detection_in_Dynamic_ICCV_2025_paper.html?utm_source=chatgpt.com [20]
- X. Chen *et al.*, “Test-Time Distillation for Continual Model Adaptation,” presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2026, pp. 7593–7604. Accessed: Sep. 17, 2026. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2026F/html/Chen_Test-Time_Distillation_for_Continual_Model_Adaptation_CVPRF_2026_paper.html?utm_source=chatgpt.com [21]
- Y. Qin *et al.*, “ViTPrompt: Training-Free Prompt Refinement with Visual Tokens for Open-Vocabulary Detection,” presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2026, pp. 3111–3121. Accessed: Sep. 17, 2026. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2026/html/Qin_ViTPrompt_Training-Free_Prompt_Refinement_with_Visual_Tokens_for_Open-Vocabulary_Detection_CVPR_2026_paper.html?utm_source=chatgpt.com [22]
- G. Lai, D.-W. Zhou, Z. Li, and H.-J. Ye, “The Golden Subspace: Where Efficiency Meets Generalization in Continual Test-Time Adaptation,” presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2026, pp. 3866–3875. Accessed: Sep. 17, 2026. [Online]. Available: [23]

- https://openaccess.thecvf.com/content/CVPR2026/html/Lai_The_Golden_Subspace_Where_Efficiency_Meets_Generalization_in_Continual_Test-Time_CVPR_2026_paper.html?utm_source=chatgpt.com
- X. Que, D. Wang, X. Liu, and Q. Yu, "InsCal: Calibrated Multi-Source Fully Test-Time Prompt Tuning for Object Detection," presented at the Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2026, pp. 36936–36946. Accessed: Sep. 17, 2026. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2026/html/Que_InsCal_Calibrated_Multi-Source_Fully_Test-Time_Prompt_Tuning_for_Object_Detection_CVPR_2026_paper.html?utm_source=chatgpt.com
- E. Tzeng, J. Hoffman, N. Zhang, K. Saenko, and T. Darrell, "Deep Domain Confusion: Maximizing for Domain Invariance," Dec. 10, 2014, *arXiv*: arXiv:1412.3474. doi: 10.48550/arXiv.1412.3474. [25]
- Y. Ganin *et al.*, "Domain-Adversarial Training of Neural Networks," May 26, 2016, *arXiv*: arXiv:1505.07818. doi: 10.48550/arXiv.1505.07818. [26]
- L. Yuan, B. Xie, and S. Li, "Robust Test-Time Adaptation in Dynamic Scenarios," Mar. 24, 2023, *arXiv*: arXiv:2303.13899. doi: 10.48550/arXiv.2303.13899. [27]

* کلیه صفحات به صورت تایپ شده تحویل شوند.

9- نظریه شورای تحصیلات تکمیلی مجتمع دانشگاهی برق و کامپیوتر
(دقت شود که این صفحه به طور مجزا تهیه و تکمیل شود)

پایان نامه دانشجو خانم / آقای

با موضوع پایان نامه..... به

راهنمایی آقای دکتر و استاد مشاور آقای دکتر در

شورای گروه علمی..... مورخ

مورد بررسی قرار و به تصویب رسید.

ردیف	نام و نام خانوادگی اعضای گروه علمی	محل امضاء
1		
2		

