

پیشنهاد پایان نامه مقطع کارشناسی ارشد

کمیته محترم تحصیلات تکمیلی مجتمع دانشگاهی برق و کامپیوتر

احتراماً، اینجانب امیررضا کاظم لو به شماره دانشجویی ۴۰۳۱۴۱۹۰۱۳ دانشجوی کارشناسی ارشد رشته مهندسی کامپیوتر گرایش هوش مصنوعی و رباتیک شاغل در - که تحصیلات خود را در رشته فوق از نیمسال اول سال تحصیلی ۱۴۰۳ شروع نمودم و تاکنون تعداد ۲۶ واحد از دروس اصلی و اختصاصی را با موفقیت و با معدل کل ۱۹.۴۶ گذرانده‌ام در مرحله شروع پایان نامه خود هستم.

پس از انجام مشاوره‌های لازم و با عنایت به زمینه علمی موردنیاز، آقای دکتر محمدعلی کیوان راد را بعنوان استاد راهنمای پایان نامه انتخاب کردم و با استفاده از نظرات و راهنماییهای ایشان پس از بررسی و مطالعه دقیق موضوع تحقیق، موضوع پایان نامه خود را کتباً و در قالب فرم پیوست تقدیم می‌نمایم. بدیهی است پذیرش قطعی موضوع پایان نامه منوط بر تصویب آن در کمیته می‌باشد.

ضمناً با پیشنهاد استاد راهنمای پایان نامه آقای - را نیز بعنوان استاد مشاور انتخاب نموده‌ام.

تاریخ: ۱۴۰۵/۰۶/۲۰



امضاء دانشجو

عنوان کامل پایان نامه :

نوع پروژه:

بدون طبقه‌بندی	محرمانه	خیلی محرمانه	سری	بکلی سری
----------------	---------	--------------	-----	----------

مراتب فوق مورد تأیید است:

- | | |
|---|---------------|
| 1 - نام و نام خانوادگی استاد راهنما | تاریخ و امضاء |
| دکتر محمد علی کیوان راد | |
| 2 - نام و نام خانوادگی استاد مشاور | تاریخ و امضاء |
| 3 - نام و نام خانوادگی کارشناس آموزش و تحصیلات تکمیلی مجتمع | تاریخ و امضاء |
| 4 - نام و نام خانوادگی مدیریت آموزش و تحصیلات تکمیلی مجتمع | تاریخ و امضاء |

پرسشنامه تهیه پیشنهاد اولیه (پروپوزال) جهت پایان نامه کارشناسی ارشد

نام و نام خانوادگی دانشجو : امیررضا کاظم لو

شماره دانشجویی : ۴۰۳۱۴۱۹۰۱۳

رشته و گرایش تحصیلی : مهندسی کامپیوتر - گرایش هوش مصنوعی و رباتیک

عنوان پایان نامه :

به فارسی : تطبیق دامنه برای تشخیص اشیاء در زمان آزمایش

به لاتین: Test time Domain Adaptation for Object Detection

نوع تحقیق :

☐ کاربردی

☐ توسعه‌ای

☒ بنیادی

1 - اطلاعات مربوط به دانشجو :

1-1- تعداد واحدهای گذرانده : ۲۶ تعداد واحدهای باقیمانده : ۶ معدل (تاکنون) : ۱۹.۴۶

1-2- آدرس : تهران، شهرک ولی عصر خیابان آقابابایان، کوچه گلنار، پلاک ۲۳، طبقه اول

1-2-1- شماره تلفن ثابت : ۰۲۱۶۶۱۳۳۵۷۱ 1-2-2- شماره تلفن همراه: ۰۹۱۰۱۷۲۷۲۳۴

1-3 - در صورت بورسیه بودن، نام سازمان بورسیه دهنده :

2 - اطلاعات مربوط به اساتید راهنما و مشاور :

سمت	نام و نام خانوادگی	تخصص یا رشته	رتبه علمی	تعداد پایان نامه‌های راهنمایی شده		تعداد پایان نامه‌های تحت راهنمایی	
				ارشد	دکتری	ارشد	دکتری
استاد راهنمای اول	محمد علی کیوان راد	مهندسی کامپیوتر - هوش مصنوعی	استادیار				
استاد راهنمای دوم							
استاد مشاور							

* تذکر : در صورتی که اساتید فوق عضو هیأت علمی دانشگاه صنعتی مالک اشتر نمی‌باشند؛ آدرس و شماره تلفن آن‌ها ذیلاً قید شود.

آدرس استاد (اساتید) راهنما :

شماره تلفن استاد (اساتید) راهنما :

آدرس استاد مشاور :

شماره تلفن استاد مشاور :

3 - اطلاعات مربوط به پایان نامه :

3-1 - مسئله و اهداف اصلی تحقیق :

مسئله تحقیق

تشخیص اشیاء (Object Detection) یکی از وظایف بنیادین در حوزه بینایی ماشین است که کاربردهای حیاتی در زمینه‌هایی مانند خودروهای خودران، نظارت تصویری، رباتیک و تصویربرداری پزشکی دارد. مدل‌های یادگیری عمیق، به ویژه شبکه‌های عصبی کانولوشنی (CNNs)، به موفقیت‌های چشمگیری در این زمینه دست یافته‌اند. با این حال، عملکرد این مدل‌ها به شدت به یک فرض کلیدی وابسته است: داده‌های آموزش و آزمون باید از توزیع یکسانی پیروی کنند.

در دنیای واقعی، این فرض تقریباً هرگز برقرار نیست. یک مدل تشخیص اشیاء که بر روی داده‌های یک دامنه (مانند تصاویر شبیه‌سازی شده یا تصاویر گرفته شده در روز) آموزش دیده است، هنگام مواجهه با داده‌های یک دامنه دیگر (مانند تصاویر واقعی یا تصاویر گرفته شده در شب) با افت عملکرد شدید مواجه می‌شود. این پدیده که به «شکاف دامنه» (Domain Shift) معروف است، مانع اصلی بر سر راه استقرار قابل اعتماد این سیستم‌ها در محیط‌های پویا و کنترل نشده است.

برای غلبه بر این چالش، تطبیق دامنه (Domain Adaptation - DA) به عنوان یک راه‌حل کلیدی مطرح شده است. هدف DA، انتقال دانش از یک دامنه منبع (Source Domain) غنی از داده‌های برچسب‌دار به یک دامنه هدف (Target Domain) است که در آن برچسبی وجود ندارد (Unsupervised Domain Adaptation - UDA). در سال‌های اخیر، تمرکز اصلی بر روی سناریوی انتقال از داده‌های مصنوعی به واقعی (Synth-to-Real) بوده است، زیرا تولید داده‌های مصنوعی برچسب‌دار ارزان و مقیاس‌پذیر است، اما این داده‌ها شکاف بصری قابل توجهی با دنیای واقعی دارند. با این حال، اکثر روش‌های تطبیق دامنه کلاسیک با یک محدودیت عملی بزرگ روبرو هستند: آن‌ها نیازمند دسترسی همزمان به داده‌های هر دو دامنه منبع و هدف در طول فرآیند آموزش هستند. این امر در بسیاری از کاربردهای واقعی به دلایل زیر غیرممکن یا نامطلوب است:

1. حریم خصوصی و امنیت داده: شرکت‌ها و مؤسسات ممکن است به دلیل محرمانگی یا مالکیت معنوی، تمایلی به اشتراک‌گذاری مجموعه داده‌های منبع (مثلاً داده‌های شبیه‌ساز اختصاصی خود) نداشته باشند.
2. حجم عظیم داده: مجموعه داده‌های منبع می‌توانند بسیار حجیم (در حد ترابایت) باشند و انتقال و ذخیره‌سازی آن‌ها برای هر فرآیند تطبیق، غیرعملی است.

این محدودیت‌ها، یک سناریوی جدید، چالش‌برانگیز و بسیار واقع‌گرایانه را به نام تطبیق دامنه بدون منبع (Source-Free Domain Adaptation - SFDA) به وجود آورده است. در SFDA، ما تنها به یک مدل از پیش آموزش‌دیده بر روی دامنه منبع و داده‌های بدون برچسب دامنه هدف دسترسی داریم. مسئله اصلی در اینجا این است: چگونه می‌توان دانش مدل را به دامنه هدف جدید تطبیق داد، بدون آنکه به داده‌های اصلی منبع دسترسی داشته باشیم و همزمان از فراموشی فاجعه‌بار (Catastrophic Forgetting) دانش اولیه جلوگیری کنیم؟ این پژوهش قصد دارد تا با تمرکز بر این مسئله خفیه، به طراحی و ارزیابی روش‌های نوآورانه در چارچوب SFDA برای وظیفه تشخیص اشیاء بپردازد.

اهداف اصلی تحقیق

در راستای حل مسئله فوق، اهداف اصلی و گام‌های اجرایی این پژوهش به شرح زیر تعریف می‌گردد:

1. طراحی و پیاده‌سازی یک چارچوب نوآورانه برای تطبیق دامنه بدون منبع (SFDA) در وظیفه تشخیص اشیاء.
 - این هدف اصلی تحقیق است که بر روی توسعه یک الگوریتم جدید با تمرکز بر یادگیری خود-محور (Self-Driven Learning) و معماری Teacher-Student متمرکز خواهد بود.
2. بهبود کیفیت و کاهش نویز در فرآیند خود-آموزی (Self-Training).
 - ارائه یک مکانیزم هوشمند برای پالایش شبه-برچسب‌ها (Pseudo-Labels) با استفاده از دانش معنایی استخراج‌شده از مدل‌های پایه بزرگ مانند CLIP به منظور جلوگیری از انباشت خطا در طی فرآیند تطبیق.
3. جلوگیری از فراموشی فاجعه‌بار (Catastrophic Forgetting) در غیاب داده‌های منبع.
 - توسعه یک روش کارآمد برای بازسازی یا تولید ویژگی‌های آماری دامنه منبع به منظور حفظ دانش اولیه مدل در حین سازگاری با دامنه هدف.
4. ارزیابی جامع و مقایسه عملکرد روش پیشنهادی.

- سنجش دقت و کارایی روش طراحی شده بر روی مجموعه داده‌های استاندارد و بنچمارک‌های شناخته‌شده در حوزه تطبیق دامنه مانند Cityscapes و Foggy Cityscapes
- اعتبارسنجی عملی روش بر روی یک مجموعه داده کاربردی و جدید در حوزه تشخیص کشتی به منظور نمایش قابلیت‌های آن در یک سناریوی واقعی.

5. تحلیل و بررسی میزان تأثیرگذاری مؤلفه‌های پیشنهادی.

- انجام یک مطالعه جامع (Ablation Study) برای ارزیابی نقش و اهمیت هر یک از نوآوری‌های پیشنهادی (مانند ماژول پالایش شبه-برچسب و مکانیزم جلوگیری از فراموشی) در عملکرد نهایی مدل.

2-3 - تشریح و بیان موضوع :

اهمیت و چالش تشخیص اشیاء در دنیای واقعی

تشخیص اشیاء (Object Detection) به عنوان یکی از وظایف بنیادین و محوری در حوزه بینایی ماشین، به دنبال شناسایی و مکان‌یابی اشیاء مختلف در تصاویر و ویدئوها است. این فناوری، ستون فقرات بسیاری از کاربردهای حیاتی و مدرن، از جمله سیستم‌های ناوبری خودروهای خودران، رباتیک هوشمند، نظارت تصویری پیشرفته، تحلیل تصاویر پزشکی و مدیریت ترافیک دریایی را تشکیل می‌دهد. در سال‌های اخیر، مدل‌های یادگیری عمیق، به ویژه شبکه‌های عصبی کانولوشنی (CNNs)، با دستیابی به دقت‌های بی‌سابقه، این حوزه را متحول کرده‌اند.

با این حال، موفقیت چشمگیر این مدل‌ها به یک پیش‌فرض اساسی و در عین حال شکننده وابسته است: داده‌های مورد استفاده در مرحله آموزش و مرحله آزمون باید از یک توزیع آماری یکسان پیروی کنند. این فرض در محیط‌های کنترل‌شده آزمایشگاهی برقرار است، اما در دنیای واقعی به ندرت صدق می‌کند. یک مدل که با دقت بالا بر روی داده‌های یک دامنه (Domain) خاص (مانند تصاویر شبیه‌سازی شده کامپیوتری یا تصاویر ثبت‌شده در شرایط آب و هوایی آفتابی) آموزش دیده است، هنگام مواجهه با یک دامنه جدید (مانند تصاویر واقعی یا تصاویر ثبت‌شده در مه یا شب) با افت عملکرد شدید و غیرمنتظره‌ای روبرو می‌شود. این پدیده که به شکاف دامنه (Domain Shift) یا عدم تطابق دامنه (Domain Mismatch) معروف است، بزرگترین مانع بر سر راه استقرار امن و قابل اعتماد سیستم‌های تشخیص اشیاء در کاربردهای دنیای واقعی محسوب می‌شود.

تطبیق دامنه (Domain Adaptation) به عنوان راه‌حل

برای غلبه بر چالش شکاف دامنه، حوزه تحقیقاتی «تطبیق دامنه (Domain Adaptation - DA)» ظهور کرده است. هدف اصلی DA، انتقال دانش آموخته‌شده از یک دامنه منبع (Source Domain) که در آن داده‌های برچسب‌دار فراوانی وجود دارد، به یک دامنه هدف (Target Domain) است که در آن داده‌ها فاقد برچسب هستند (سناریوی تطبیق دامنه بدون نظارت یا UDA در سال‌های اخیر، سناریوی انتقال از داده‌های مصنوعی به واقعی (Synth-to-Real) به دلیل سهولت و هزینه پایین تولید داده‌های مصنوعی برچسب‌دار، توجه ویژه‌ای را به خود جلب کرده است).

روش‌های تطبیق دامنه برای تشخیص اشیاء در طول زمان تکامل یافته‌اند و می‌توان آن‌ها را به چند دسته اصلی تقسیم کرد:

1. روش‌های مبتنی بر اختلاف (Discrepancy-Based): این روش‌های پیشگام با استفاده از معیارهای آماری مانند [1] MMD، تلاش می‌کنند تا توزیع کلی ویژگی‌ها را در دو دامنه به یکدیگر نزدیک کنند [2].
2. روش‌های مبتنی بر یادگیری تخاصمی (Adversarial-Based): این رویکرد که با الهام از شبکه‌های مولد تخاصمی (GANs) [3] و مقاله [4] DANN شکل گرفت، از یک تفکیک‌کننده دامنه برای آموزش استخراج‌کننده ویژگی به منظور تولید ویژگی‌های نامتمایز از دامنه استفاده می‌کند. این ایده در مقالات متعددی مانند Domain Adaptive Faster R-CNN برای هم‌ترازی ویژگی‌ها در سطوح مختلف (تصویر و نمونه) به کار گرفته شد.
3. روش‌های مبتنی بر خود-آموزی (Self-Training): این پارادایم مدرن، به جای هم‌ترازی صریح توزیع‌ها، بر تولید شبه-برچسب (Pseudo-Labels) برای داده‌های هدف و آموزش مدل به صورت خود-نظارت شده متمرکز است.

معماری Teacher-Student [6], [5] که در آن یک مدل «معلم» پایدار، مدل «دانش‌آموز» را هدایت می‌کند، سنگ بنای این رویکرد است و در روش‌های پیشرفته‌ای مانند MIC [7] به کار رفته است.

ظهور یک چالش جدید و واقع‌گرایانه تطبیق دامنه بدون منبع (SFDA):

با وجود تمام پیشرفت‌ها، تقریباً تمام روش‌های ذکر شده بر یک پیش‌فرض کلیدی استوارند: نیاز به دسترسی همزمان به داده‌های هر دو دامنه منبع و هدف در طول فرآیند آموزش. این پیش‌فرض در بسیاری از سناریوهای عملی، یک محدودیت جدی و گاهی غیرقابل عبور است:

- حریم خصوصی و مالکیت داده: شرکت‌ها و مؤسسات به دلایل امنیتی و رقابتی، حاضر به اشتراک‌گذاری داده‌های منبع خود (مانند شبیه‌سازهای اختصاصی یا داده‌های بالینی) نیستند.
 - هزینه و حجم داده: مجموعه داده‌های منبع مدرن می‌توانند چندین ترابایت حجم داشته باشند. انتقال، ذخیره‌سازی و پردازش این حجم از داده برای هر کاربر نهایی که قصد تطبیق مدل را دارد، غیرعملی است.
- این موانع عملی، منجر به تعریف یک مسئله جدید، پیچیده‌تر و بسیار کاربردی‌تر به نام تطبیق دامنه بدون منبع (Source-Free) (SFDA - Domain Adaptation) شده است. در این سناریو، تنها دارایی‌های ما عبارتند از:
1. یک مدل از پیش آموزش‌دیده بر روی دامنه منبع.
 2. داده‌های بدون برچسب از دامنه هدف.

مسئله اصلی تحقیق در اینجا شکل می‌گیرد: چگونه می‌توان دانش نهفته در مدل از پیش آموزش‌دیده را به دامنه هدف جدید منتقل کرد، بدون آنکه به داده‌های اصلی منبع دسترسی داشته باشیم؟ این فرآیند باید به گونه‌ای هوشمندانه انجام شود که نه تنها مدل با دامنه جدید سازگار شود، بلکه از فراموشی فاجعه‌بار (Catastrophic Forgetting) دانش ارزشمندی که در مرحله اولیه آموخته است نیز جلوگیری به عمل آید. این پژوهش قصد دارد تا با تمرکز بر این چالش کلیدی، روش‌هایی نوآورانه برای وظیفه تشخیص اشیاء در چارچوب SFDA ارائه دهد.

3-3 - ضرورت انجام تحقیق:

انجام این پژوهش با توجه به شکاف‌های موجود میان دستاوردهای آکادمیک و نیازهای عملی در دنیای واقعی، از ضرورت بالایی برخوردار است. این ضرورت را می‌توان در سه جنبه اصلی تشریح کرد:

1. ضرورت عملی و صنعتی: عبور از محدودیت‌های استقرار مدل‌های هوشمند
- اگرچه مدل‌های تشخیص اشیاء به دقت‌های بالایی در محیط‌های آزمایشگاهی دست یافته‌اند، استقرار موفق آن‌ها در دنیای واقعی با یک مانع بزرگ روبرو است: شکنندگی در برابر تغییر دامنه. یک سیستم نظارتی که در یک شهر آموزش دیده، ممکن است در شهر دیگر به دلیل تفاوت در معماری یا شرایط نوری، عملکرد ضعیفی داشته باشد. راه‌حل‌های تطبیق دامنه کلاسیک، با پیش‌فرض دسترسی کامل به داده‌های منبع، این مشکل را در تئوری حل می‌کنند، اما در عمل با موانع جدی مواجه هستند:
- حریم خصوصی و مالکیت معنوی: شرکت‌ها و سازمان‌ها به هیچ وجه حاضر به اشتراک‌گذاری داده‌های اختصاصی و ارزشمند خود (مانند داده‌های شبیه‌سازهای پیشرفته یا داده‌های بالینی) نیستند.
 - هزینه و مقیاس‌پذیری: انتقال و پردازش حجم عظیم داده‌های منبع برای هر کاربر نهایی که نیاز به تطبیق مدل دارد، از نظر اقتصادی و فنی غیرعملی است.
- بنابراین، ضرورت حرکت به سمت پارادایم تطبیق دامنه بدون منبع (SFDA) یک انتخاب نیست، بلکه یک الزام برای ساخت سیستم‌های هوشمند، مقیاس‌پذیر، امن و قابل اعتماد در دنیای واقعی است. این تحقیق به طور مستقیم به این نیاز صنعتی پاسخ می‌دهد و راه را برای توسعه محصولات هموار می‌کند که می‌توانند به راحتی توسط کاربران نهایی برای محیط‌های جدید، بدون نیاز به دسترسی به داده‌های محرمانه اولیه، سفارشی‌سازی شوند.

۲. ضرورت علمی: حرکت به سمت مرزهای جدید دانش در یادگیری ماشین

حوزه SFDA در تقاطع چندین شاخه کلیدی و پیشرفته یادگیری ماشین قرار دارد، از جمله:

- یادگیری انتقالی (Transfer Learning): چگونه می‌توان دانش را به صورت مؤثر منتقل کرد، زمانی که دسترسی به منبع اصلی دانش قطع شده است؟
 - یادگیری مستمر (Continual Learning): چگونه می‌توان دانش جدید را آموخت بدون آنکه دانش قبلی فراموش شود (جلوگیری از فراموشی فاجعه‌بار)؟
 - یادگیری خود-نظارت شده (Self-Supervised Learning): چگونه می‌توان از ساختار خود داده‌های هدف برای هدایت فرآیند یادگیری استفاده کرد؟
- پژوهش در زمینه SFDA برای وظیفه پیچیده‌ای مانند تشخیص اشیاء، به ناچار منجر به نوآوری در این حوزه‌های بنیادین می‌شود. طراحی الگوریتم‌هایی که بتوانند دانش را از یک مدل «جعبه سیاه» استخراج کنند، آن را در برابر فراموشی مقاوم سازند و به صورت هوشمندانه با داده‌های جدید تطبیق دهند، به پیشبرد مرزهای دانش در هوش مصنوعی کمک شایانی می‌کند.

۳. ضرورت کاربردی: افزایش ایمنی و قابلیت اطمینان در حوزه‌های حساس (مانند رانندگی خودران)

این تحقیق با تمرکز بر روی یک مجموعه داده کاربردی مانند تشخیص خودرو، اهمیت عملی خود را دوچندان می‌کند. سیستم‌های رانندگی خودران (Autonomous Driving) و دستیارهای پیشرفته راننده (ADAS) برای درک محیط اطراف، جلوگیری از تصادفات و اتخاذ تصمیمات ایمن، به شدت به تشخیص دقیق و قابل اعتماد سایر وسایل نقلیه، عابران پیاده و موانع در شرایط مختلف آب و هوایی (آفتابی، بارانی، مه‌آلود، برفی)، نوری (روز و شب) و جغرافیایی (شهرهای مختلف با معماری و علائم متفاوت) وابسته هستند.

مدلی که تنها در شرایط ایده‌آل یا در یک منطقه جغرافیایی خاص آموزش دیده باشد، در یک محیط واقعی و پویا کارایی خود را به سرعت از دست می‌دهد و می‌تواند منجر به تصمیمات فاجعه‌بار و به خطر افتادن جان انسان‌ها شود. انجام این تحقیق و ارائه یک روش تطبیق دامنه قوی و بدون نیاز به منبع، گامی مستقیم و ضروری در جهت افزایش ایمنی، قابلیت اطمینان و تسریع در توسعه خودروهای خودران، یعنی یکی از تحول‌آفرین‌ترین صنایع جهان، خواهد بود. بنابراین، این پژوهش نه تنها به یک چالش علمی مهم پاسخ می‌دهد، بلکه یک راه‌حل عملی برای یکی از بزرگترین موانع موجود بر سر راه استفاده گسترده و قابل اعتماد از هوش مصنوعی در دنیای واقعی ارائه می‌کند.

3-4 - سابقه تحقیقات و مطالعات انجام گرفته :

حوزه تطبیق دامنه (Domain Adaptation) در سال‌های اخیر، به ویژه برای وظایف پیچیده بینایی ماشین مانند تشخیص اشیاء، شاهد رشد و تکامل چشمگیری بوده است. سیر تکاملی این پژوهش‌ها را می‌توان به عنوان حرکتی از راهکارهای کلی و سراسری به سمت روش‌های دقیق، ساختاریافته و در نهایت، خود-محور و مستقل از منبع، خلاصه کرد. در ادامه، این سیر تکاملی در چند دسته اصلی مورد بررسی قرار می‌گیرد.

1. روش‌های مبتنی بر اختلاف (Discrepancy-Based Methods)

این دسته از روش‌ها، به عنوان اولین تلاش‌ها برای مقابله با شکاف دامنه، بر این اصل استوار بودند که با کمینه کردن یک معیار فاصله آماری بین توزیع ویژگی‌های استخراج‌شده از دامنه‌های منبع و هدف، می‌توان دانش را منتقل کرد. معروف‌ترین معیار مورد استفاده در این روش‌ها، Maximum Mean Discrepancy (MMD) است که در فضاهای کرنل با ابعاد بالا، فاصله بین دو توزیع را اندازه‌گیری می‌کند. مقالات پیشگامی مانند (DDC) [2] با افزودن یک لایه تطبیق MMD به انتهای شبکه‌های عصبی عمیق، این ایده را پیاده‌سازی کردند.

- نقاط قوت: سادگی مفهومی و پیاده‌سازی آسان.

- نقد و محدودیت: این روش‌ها یک هم‌ترازی کلی (Global Alignment) را انجام می‌دهند و فرض می‌کنند که توزیع داده‌ها تک-حالت (unimodal) است. این فرض برای وظیفه پیچیده‌ای مانند تشخیص اشیاء که توزیع ویژگی‌ها به شدت چند-حالت (multi-modal) و وابسته به کلاس‌های مختلف است، صحیح نبوده و منجر به هم‌ترازی ناقص و عملکرد ضعیف می‌شود.

۲. روش‌های مبتنی بر یادگیری تخاصمی (Adversarial-Based Methods)

با الهام از موفقیت چشمگیر شبکه‌های مولد تخاصمی [3] (GANs)، این پارادایم به سرعت به رویکرد غالب در تطبیق دامنه تبدیل شد. ایده اصلی در مقاله Domain-Adversarial Neural Networks (DANN) [8] معرفی شد که در آن، یک تفکیک‌کننده دامنه (Domain Discriminator) به شبکه اضافه می‌شود. این تفکیک‌کننده تلاش می‌کند تا تشخیص دهد که یک ویژگی ورودی متعلق به دامنه منبع است یا هدف. همزمان، شبکه استخراج‌کننده ویژگی در یک بازی مینی‌مکس، تلاش می‌کند تا ویژگی‌هایی تولید کند که تفکیک‌کننده را "فریب" داده و قادر به تشخیص دامنه آن‌ها نباشد. این فرآیند، شبکه را به سمت یادگیری ویژگی‌های نامتغیر از دامنه (domain-invariant) سوق می‌دهد. برای وظیفه تشخیص اشیاء، مقاله Domain Adaptive Faster R-CNN [9] این ایده را با معرفی یک مکانیزم هم‌ترازی چندسطحی (در سطح تصویر و در سطح نمونه یا instance) به کار برد و به نتایج قابل توجهی دست یافت.

- نقاط قوت: توانایی یادگیری هم‌ترازی‌های پیچیده و غیرخطی.
- نقد و محدودیت: فرآیند آموزش تخاصمی می‌تواند ناپایدار باشد و به تنظیم دقیق هایپرپارامترها نیاز دارد. همچنین، در صورت عدم تعادل کلاس‌ها یا تفاوت زیاد بین دامنه‌ها، ممکن است منجر به هم‌ترازی منفی (negative transfer) شود.

۳. روش‌های مبتنی بر بازسازی و ترجمه تصویر (Reconstruction-Based Methods)

این دسته از روش‌ها به جای هم‌تراز کردن ویژگی‌ها در یک فضای نهان، به دنبال کاهش شکاف دامنه در سطح پیکسل هستند. با استفاده از مدل‌های ترجمه تصویر-به-تصویر مانند CycleGAN [10]، این روش‌ها تلاش می‌کنند تا تصاویر دامنه منبع را به سبک بصری دامنه هدف ترجمه کنند. سپس، مدل تشخیص اشیاء بر روی این داده‌های منبع "سبک‌دهی" شده آموزش می‌بیند. مقاله CyCADA [11] یک نمونه برجسته از این رویکرد است که سازگاری را هم در سطح پیکسل و هم در سطح ویژگی اعمال می‌کند.

- نقاط قوت: به صورت شهودی جذاب هستند و به طور مستقیم با تفاوت‌های ظاهری دامنه‌ها مقابله می‌کنند.
- نقد و محدودیت: این روش‌ها از نظر محاسباتی بسیار پرهزینه هستند. فرآیند ترجمه تصویر ممکن است مصنوعات (artifacts) ناخواسته ایجاد کند یا محتوای معنایی مهم تصویر را تغییر دهد که به عملکرد مدل نهایی آسیب می‌زند.

۴. روش‌های مبتنی بر خود-آموزی (Self-Training Methods)

این پارادایم مدرن که در سال‌های اخیر به نتایج پیشرفته‌ای (State-of-the-Art) دست یافته است، رویکردی متفاوت را در پیش می‌گیرد. به جای هم‌ترازی صریح توزیع‌ها، این روش‌ها بر تولید شبه-برچسب (Pseudo-Labels) برای داده‌های بدون برچسب دامنه هدف و استفاده از آن‌ها برای آموزش مدل تمرکز دارند. سنگ بنای این رویکرد، معماری Teacher-Student [6] است. در این چارچوب، یک مدل «معلم» که نسخه‌ای پایدار و میانگین‌گیری شده (EMA) از مدل «دانش‌آموز» است، وظیفه تولید شبه-برچسب‌های باکیفیت و پایدار را بر عهده دارد و مدل دانش‌آموز از این برچسب‌ها برای یادگیری و تطبیق خود استفاده می‌کند. روش‌های نوآورانه‌ای مانند MIC [7] با استفاده از منظم‌سازی سازگاری بر روی تصاویر ماسک‌زده و ConfMix [12] با ترکیب نواحی با اطمینان بالا، به طور مؤثری با مشکل نویز در شبه-برچسب‌ها مقابله کرده و عملکرد را به طور چشمگیری بهبود بخشیده‌اند.

- نقاط قوت: کارایی بسیار بالا، عدم نیاز به هم‌ترازی صریح و قابلیت انطباق با سناریوهای پیچیده.
- نقد و محدودیت: موفقیت این روش‌ها به شدت به کیفیت شبه-برچسب‌های تولیدی وابسته است و در صورت وجود نویز زیاد، ممکن است مدل دچار انباشت خطا (error accumulation) شود.

شکاف تحقیقاتی و حرکت به سمت تطبیق دامنه بدون منبع (SFDA)

با وجود تمام پیشرفت‌های ذکر شده، یک فرض مشترک و محدودکننده در تمامی این روش‌ها وجود دارد: نیاز به دسترسی همزمان به داده‌های دامنه منبع و هدف. همانطور که در بخش بیان مسئله تشریح شد، این فرض در بسیاری از کاربردهای واقعی برقرار نیست. این محدودیت، منجر به شکل‌گیری حوزه تحقیقاتی نوپا، چالش‌برانگیز و بسیار مهم SFDA شده است. در این سناریو، هدف، تطبیق یک مدل از پیش آموزش‌دیده تنها با استفاده از داده‌های هدف است. کارهای اولیه در این حوزه عمدتاً بر روی روش‌هایی مانند تولید داده مجازی (Data Generation) از طریق یک شبکه مولد یا حفظ دانش منبع از طریق تکنیک‌های تقطیر دانش (Knowledge Distillation) تمرکز کرده‌اند. با این حال، این حوزه همچنان در ابتدای راه خود قرار دارد و جای خالی برای پژوهش در زمینه‌های زیر به شدت احساس می‌شود:

- طراحی روش‌های ترکیبی (Hybrid) که به طور همزمان از خود-آموزی، تولید داده و مکانیزم‌های جلوگیری از فراموشی بهره ببرند.
 - استفاده از دانش غنی موجود در مدل‌های پایه بزرگ (Foundation Models) مانند CLIP برای هدایت فرآیند تطبیق و بهبود کیفیت شبه-برچسب‌ها.
 - توسعه روش‌هایی برای افزایش قابلیت اطمینان (Reliability) و تفسیرپذیری (Interpretability) مدل تطبیق‌یافته در سناریوی SFDA.
- این پژوهش قصد دارد با تمرکز دقیق بر این شکاف‌های تحقیقاتی، یک راه حل نوآورانه و کارآمد برای مسئله SFDA در تشخیص اشیاء ارائه دهد.

3-5 - فرضیه‌های تحقیق (سؤالات تحقیق):

این پژوهش در تلاش است تا به یک سؤال محوری و چندین سؤال فرعی در حوزه تطبیق دامنه بدون منبع پاسخ دهد. برای هر سؤال، یک فرضیه متناظر تعریف شده است که در طی فرآیند تحقیق، صحت آن مورد آزمون قرار خواهد گرفت.

سؤال اصلی تحقیق:

آیا می‌توان با استفاده از یک چارچوب مبتنی بر یادگیری پروتوتایپ و خوشه‌بندی تخصصی، یک مدل تشخیص اشیاء را به صورت کارآمد و بدون دسترسی به داده‌های منبع، به یک دامنه هدف جدید تطبیق داد و به دقتی رقابتی یا برتر از روش‌های پیشرفته موجود دست یافت؟

فرضیه اصلی تحقیق (H1):

می‌توان یک چارچوب نوآورانه مبتنی بر یادگیری پروتوتایپ و ساختارسازی تخصصی فضای ویژگی طراحی کرد که به طور معناداری عملکرد یک مدل تشخیص اشیاء را در دامنه هدف (بدون دسترسی به داده‌های منبع) بهبود می‌بخشد. این بهبود عملکرد، مدل را قادر می‌سازد تا به دقتی (mAP) قابل مقایسه یا برتر از روش‌های پیشرفته (State-of-the-art) در حوزه SFDA دست یابد.

سؤالات و فرضیه‌های فرعی:

برای پاسخ به سؤال اصلی و آزمودن فرضیه اصلی، سؤالات و فرضیه‌های جزئی‌تر زیر مطرح می‌شوند:

چالش فراموشی دانش:

- سؤال: در غیاب داده‌های منبع، چگونه می‌توان از پدیده فراموشی فاجعه‌بار (Catastrophic Forgetting) دانش اولیه مدل در حین تطبیق با دامنه هدف جلوگیری کرد؟
- فرضیه (H2): استفاده از یک مازول بازسازی ویژگی (Feature Reconstruction) که با بهره‌گیری از آمارهای لایه‌های کلیدی مدل اولیه، ویژگی‌های مجازی دامنه منبع را تولید می‌کند، یک مکانیزم مؤثر برای حفظ دانش اولیه و جلوگیری از افت عملکرد ناشی از فراموشی فاجعه‌بار است.

۲. ساختار فضای ویژگی:

- سؤال: چگونه می‌توان مدل را وادار کرد تا برای داده‌های بدون برچسب دامنه هدف، یک فضای ویژگی (Feature Space) منسجم، با خوشه‌های کلاسی فشرده و با جدایی‌پذیری بالا ایجاد کند؟

- فرضیه (H3): به کارگیری یک مکانیزم خوشه‌بندی تخصصی (Adversarial Clustering)، که در آن مدل برای فریب دادن یک تفکیک‌کننده آموزش می‌بیند، به طور مؤثری ساختار فضای ویژگی را بهبود می‌بخشد و نسبت به روش‌های ساده‌تر تولید شبه برچسب، منجر به جداسازی بهتر کلاس‌ها و در نتیجه، دقت بالاتر می‌شود.

۳. نقش پروتوتایپ‌ها:

- سؤال: آیا می‌توان از پروتوتایپ‌های کلاسی به عنوان یک نقطه اتکای قابل اعتماد برای هدایت فرآیند یادگیری و تولید شبه برچسب‌های باکیفیت در دامنه هدف استفاده کرد؟
- فرضیه (H4): یادگیری مبتنی بر پروتوتایپ (Prototype-based Learning)، که در آن شبه برچسب‌ها بر اساس نزدیکی به مراکز کلاس (پروتوتایپ‌ها) تعیین می‌شوند، یک رویکرد کارآمد برای کاهش نویز در فرآیند خود-آموزی است و منجر به همگرایی پایدارتر و نتایج دقیق‌تر در مقایسه با اتکای صرف به خروجی لایه طبقه‌بندی‌کننده می‌شود.
- آزمایش‌های طراحی‌شده در این پژوهش، به ویژه مطالعه مؤلفه‌ها (Ablation Study)، به طور مستقیم به آزمون صحت این فرضیه‌های فرعی و در نهایت، پاسخ به سؤال اصلی تحقیق خواهند پرداخت.

3-6 - نتایج مورد انتظار پس از انجام تحقیق:

با توجه به اهداف و فرضیه‌های مطرح‌شده، انتظار می‌رود که در پایان این تحقیق به مجموعه‌ای از نتایج کمی، کیفی و مفهومی دست یابیم که نه تنها به حل مسئله اصلی کمک می‌کنند، بلکه به پیشبرد دانش در این حوزه نیز منجر خواهند شد. این نتایج به شرح زیر پیش‌بینی می‌شوند:

۱. دستیابی به یک الگوریتم نوآورانه و کارآمد برای تطبیق دامنه بدون منبع (SFDA):

- نتیجه اصلی و ملموس این تحقیق، ارائه یک چارچوب کامل و پیاده‌سازی شده برای تطبیق دامنه مدل‌های تشخیص اشیاء، بدون نیاز به دسترسی به داده‌های منبع خواهد بود. این الگوریتم که بر پایه یادگیری مبتنی بر پروتوتایپ و خوشه‌بندی تخصصی استوار است، به عنوان یک راه‌حل عملی برای یکی از مهم‌ترین چالش‌های استقرار سیستم‌های هوشمند ارائه خواهد شد.

۲. بهبود معنادار عملکرد تشخیص اشیاء در دامنه هدف:

- انتظار می‌رود روش پیشنهادی، افزایش قابل توجهی در معیار دقت متوسط (mAP) بر روی مجموعه داده‌های هدف مانند Foggy Cityscapes و مجموعه داده کاربردی خودرو در مقایسه با مدل پایه (Source-Only) ایجاد کند. این نتیجه به معنای پر کردن بخش بزرگی از شکاف دامنه (Domain Gap) خواهد بود.
- پیش‌بینی می‌شود که عملکرد روش پیشنهادی، رقابتی یا برتر از روش‌های پیشرفته (State-of-the-art) موجود در حوزه SFDA برای تشخیص اشیاء باشد که این امر، نوآوری و کارایی الگوریتم را به اثبات خواهد رساند.

۳. ارائه تحلیل عمیق از مکانیزم‌های داخلی روش:

- از طریق مطالعه مؤلفه‌ها (Ablation Study)، به طور مستند نشان داده خواهد شد که هر یک از اجزای نوآورانه تحقیق، نقش کلیدی در بهبود عملکرد دارند:
 - اثبات خواهد شد که ماژول بازسازی ویژگی برای جلوگیری از فراموشی فاجعه‌بار ضروری است.
 - نشان داده خواهد شد که خوشه‌بندی تخصصی به طور مؤثری به ساختارسازی بهینه فضای ویژگی و جداسازی بهتر کلاس‌ها کمک می‌کند.

- تحلیل‌های کیفی، مانند مصورسازی فضای ویژگی با t-SNE، به صورت بصری نشان خواهند داد که چگونه روش پیشنهادی، خوشه‌های کلاسی فشرده و متمایزی را در دامنه هدف ایجاد می‌کند.

۴. افزایش قابلیت اطمینان سیستم‌های کاربردی:

- در نهایت، مهم‌ترین نتیجه کاربردی این تحقیق، ارائه راهکاری است که به ساخت سیستم‌های تشخیص اشیاء قوی‌تر، انعطاف‌پذیرتر و قابل اعتمادتر برای کاربردهای حساس مانند رانندگی خودران کمک می‌کند. این امر، گامی در جهت کاهش موانع عملی برای استقرار گسترده و ایمن هوش مصنوعی در دنیای واقعی خواهد بود.

3-7 - در صورت کاربردی بودن تحقیق، چه سازمانهایی می‌توانند از نتایج بدست آمده استفاده کنند .

ردیف	نام سازمان	نوع استفاده
1	شرکت‌های خودروسازی و توسعه‌دهندگان فناوری رانندگی خودران ایران خودرو و سایپا و شرکت‌های دانش‌بنیان فعال در این حوزه	تطبیق و بومی‌سازی سیستم‌های ادراک (Perception Systems) که این شرکت‌ها مدل‌های تشخیص اشیاء خود را بر روی حجم عظیمی از داده‌های شبیه‌سازی شده و داده‌های جمع‌آوری شده در یک منطقه خاص آموزش می‌دهند. با استفاده از نتایج این تحقیق، آن‌ها می‌توانند مدل پایه خود را به مشتریان یا ناوگان‌های فعال در مناطق جغرافیایی یا شرایط آب و هوایی جدید تطبیق دهند، بدون آنکه نیاز به اشتراک‌گذاری داده‌های محرمانه و گران‌قیمت اولیه خود داشته باشند.
2	مراکز مدیریت و کنترل ترافیک هوشمند (Smart City & Traffic Management)	افزایش کارایی سیستم‌های نظارت ترافیکی: این سازمان‌ها از دوربین‌های هوشمند برای تحلیل ترافیک، شناسایی تخلفات و مدیریت تقاطع‌ها استفاده می‌کنند. یک مدل تشخیص خودروی مرکزی می‌تواند توسعه داده شود و سپس در صدها یا هزاران دوربین مختلف در سطح یک شهر یا کشور نصب گردد. روش SFDA به هر دوربین اجازه می‌دهد تا مدل را با شرایط نوری، زاویه دید و الگوهای ترافیکی خاص خود تطبیق دهد و دقت سیستم نظارتی را به طور قابل توجهی افزایش دهد.
3	شرکت‌های فعال در حوزه نقشه‌برداری HD و نگهداری زیرساخت‌های جاده‌ای	به‌روزرسانی خودکار نقشه‌های با دقت بالا (HD Maps): این شرکت‌ها از خودروهای مجهز به دوربین برای اسکن مداوم جاده‌ها و به‌روزرسانی نقشه‌های سه‌بعدی مورد نیاز خودروهای خودران استفاده می‌کنند. مدل‌های تشخیص اشیاء آن‌ها باید بتوانند علائم راهنمایی، خط‌کشی‌ها و وضعیت جاده را در کشورهای مختلف با استانداردها و شرایط متفاوت، به دقت تشخیص دهند. نتایج این تحقیق به آن‌ها کمک می‌کند تا مدل‌های خود را به سرعت برای مناطق جدید تطبیق داده و فرآیند به‌روزرسانی نقشه را تسریع بخشند.

۴	شرکت های فعال در صنعت نظامی	بهبود تشخیص ماشین ها و خودرو ها با کاربرد های مختلف نظامی
---	-----------------------------	---

4- روش انجام تحقیق :

4-1- روش گردآوری اطلاعات :

روش گردآوری اطلاعات در این پژوهش، با توجه به ماهیت آن که بر توسعه و ارزیابی یک الگوریتم جدید متمرکز است، به دو بخش اصلی تقسیم می شود: گردآوری اطلاعات نظری و گردآوری داده های عملی.

۱. گردآوری اطلاعات نظری و مبانی تحقیق (مطالعات کتابخانه ای)

این بخش از طریق مطالعات کتابخانه ای و بررسی اسنادی (Document-based Research) انجام خواهد شد. هدف، کسب دانش عمیق و به روز در مورد مبانی نظری و کارهای پیشین مرتبط با موضوع تحقیق است. منابع اصلی برای این منظور عبارتند از:

• پایگاه های علمی و دیجیتال:

- IEEE Xplore
- ACM Digital Library
- SpringerLink
- ScienceDirect

• موتورهای جستجوی آکادمیک:

- Google Scholar
- Semantic Scholar
- arXiv.org برای دسترسی به جدیدترین مقالات پیش از انتشار رسمی

• مجموعه مقالات کنفرانس های برتر:

- کنفرانس های اصلی بینایی ماشین (CVPR, ICCV, ECCV)
- کنفرانس های اصلی یادگیری ماشین (NeurIPS, ICML, ICLR)

کلیدواژه های اصلی برای جستجو:

"Domain Adaptation", "Unsupervised Domain Adaptation (UDA)", "Source-Free Domain Adaptation (SFDA)", "Object Detection", "Prototype-based Learning", "Adversarial Learning", "Catastrophic Forgetting", "Synth-to-Real".

علاوه بر این، مخازن کد متن-باز (Open-Source Repositories) مانند GitHub برای مطالعه و تحلیل پیاده سازی های عملی روش های پیشرفته مورد بررسی قرار خواهند گرفت تا درک عمیق تری از جزئیات فنی آنها حاصل شود.

۲. گردآوری داده های عملی برای آزمایش ها (استفاده از مجموعه داده های عمومی)

داده های مورد نیاز برای آموزش، اعتبارسنجی و آزمون روش پیشنهادی، از طریق مجموعه داده های عمومی و استاندارد (Public Datasets) که به صورت گسترده در تحقیقات مشابه استفاده می شوند، گردآوری خواهند شد. این رویکرد، قابلیت مقایسه مستقیم نتایج این تحقیق با کارهای پیشین را تضمین می کند.

مجموعه داده های اصلی مورد استفاده عبارتند از:

- Cityscapes: مجموعه داده ای بزرگ و متنوع از تصاویر خیابان های شهری با برچسب های دقیق.
- Foggy Cityscapes: نسخه ای از مجموعه داده Cityscapes که به صورت مصنوعی شرایط مه آلود را شبیه سازی می کند و برای ارزیابی مقاومت مدل در برابر تغییرات آب و هوایی ایده آل است.
- Sim10k: مجموعه ای از داده های مصنوعی (رندر شده از یک بازی کامپیوتری) که برای سناریوی کلیدی انتقال از داده مصنوعی به واقعی (Synth-to-Real) استفاده می شود.
- مجموعه داده کاربردی تشخیص خودرو: یک مجموعه داده استاندارد دیگر در این حوزه مانند KITTI یا BDD100K برای ارزیابی عملکرد در یک سناریوی واقعی تر انتخاب خواهد شد.

این مجموعه داده ها از وبسایت های رسمی آنها دانلود شده و طبق دستورالعمل های ارائه شده برای استفاده آکادمیک، مورد بهره برداری قرار خواهند گرفت. لازم به ذکر است که این تحقیق شامل مرحله میدانی و جمع آوری داده اولیه (Primary Data Collection) نخواهد بود و تمامی آزمایش ها بر روی داده های از پیش موجود انجام می شود.

- داده های جمع آوری شده در آزمایشگاه که دیتاست های مربوط به تانک و خودرو های نظامی را با استفاده از نرم هایی مانند CVAT و image label برچسب گذاری شده است تا برای کاربرد هایی مانند تشخیص و تمایز ماشین ها با کاربرد های نظامی متفاوت و غیر نظامی مورد استفاده قرار گیرد.

2-4 - روش و مراحل تحقیق :

این پژوهش یک تحقیق توسعه ای-کاربردی (Developmental-Applied Research) است که بر طراحی، پیاده سازی و ارزیابی یک الگوریتم جدید در حوزه یادگیری ماشین متمرکز است. فرآیند اجرای تحقیق در پنج مرحله اصلی و به صورت متوالی و تکرارشونده (Iterative) به شرح زیر انجام خواهد شد:

مرحله اول: مطالعه عمیق و آماده سازی زیرساخت (ماه ۱ تا ۳)

این مرحله به بنیان گذاری نظری و عملی تحقیق اختصاص دارد.

1. مرور جامع و نظام مند ادبیات: مطالعه عمیق مقالات کلیدی در حوزه های زیر:

- تطبیق دامنه بدون نظارت (UDA) و بدون منبع (SFDA) برای تشخیص اشیاء.
- یادگیری مبتنی بر پروتوتایپ و یادگیری متریک. (Metric Learning)
- کاربردهای یادگیری تخصصی برای ساختار سازی فضای ویژگی.
- روش های جلوگیری از فراموشی فاجعه بار در یادگیری انتقالی.

2. صورت بندی نهایی مسئله: بر اساس مطالعات انجام شده، جزئیات دقیق معماری و توابع زیان روش پیشنهادی نهایی خواهد شد.

3. آماده سازی محیط تحقیق:

- راه اندازی محیط توسعه بر روی سیستم عامل لینوکس ترجیحاً Ubuntu.
- نصب و پیکربندی ابزارهای مورد نیاز شامل Python، CUDA، cuDNN و چارچوب یادگیری عمیق PyTorch.

○ دانلود، استخراج و پیش پردازش مجموعه داده های مورد نظر Cityscapes, Foggy Cityscapes, Sim10k و مجموعه داده کاربردی خودرو.

مرحله دوم: پیاده سازی و ارزیابی مدل های پایه (ماه ۴ تا ۵)

در این مرحله، یک خط لوله (Pipeline) استاندارد برای اجرای آزمایش ها پیاده سازی و نتایج مبنا استخراج می شود.

1. پیاده سازی مدل تشخیص اشیاء پایه: یک معماری استاندارد مانند Faster R-CNN با بک بون ResNet-101

پیاده سازی و بر روی دامنه منبع مثلاً Cityscapes آموزش داده می شود تا مدل از پیش آموزش دیده اولیه به دست آید.

2. استخراج نتایج مبنا (Baselines):

○ Source-Only: اجرای مدل آموزش دیده در مرحله قبل، بدون هیچ گونه تطبیق، بر روی داده های دامنه هدف برای اندازه گیری شکاف دامنه اولیه.

○ Oracle: آموزش همان مدل بر روی داده های برچسب دار دامنه هدف برای تعیین حد بالای عملکرد. این نتایج به عنوان معیاری برای سنجش میزان پیشرفت روش پیشنهادی در مراحل بعد به کار می روند.

مرحله سوم: پیاده سازی و توسعه روش پیشنهادی (ماه ۶ تا ۱۰)

این مرحله، بخش مرکزی و فنی تحقیق است که شامل پیاده سازی الگوریتم نوآورانه پیشنهادی می باشد.

1. پیاده سازی ماژول بازسازی ویژگی: پیاده سازی یک شبکه مولد کوچک که با استفاده از آمارهای لایه های Batch

Normalization مدل منبع، ویژگی های مجازی برای جلوگیری از فراموشی تولید می کند.

2. پیاده سازی چارچوب یادگیری مبتنی بر پروتوتایپ:

- استخراج پروتوتایپ های اولیه از وزن های لایه طبقه بندی کننده مدل منبع.
- پیاده سازی مکانیزم تولید شبه-برچسب بر اساس نزدیکی به پروتوتایپ ها.

3. پیاده‌سازی ماژول خوشه‌بندی تخصصی:

- طراحی و پیاده‌سازی شبکه تفکیک‌کننده برای تمایز بین نمونه‌های با اطمینان بالا و پایین.
- پیاده‌سازی تابع زیان تخصصی برای آموزش شبکه استخراج‌کننده ویژگی.

4. ادغام و آموزش End-to-End: ترکیب تمام ماژول‌ها و توابع زیان (شامل زیان تشخیص اشیاء بر روی شبه-برچسب‌ها، زیان تخصصی و زیان بازسازی ویژگی) در یک فرآیند آموزشی واحد.

5. رفع خطا و تنظیمات اولیه: اجرای کد بر روی بخش کوچکی از داده‌ها برای اطمینان از صحت عملکرد و یافتن محدوده مناسب برای هایپرپارامترهای کلیدی (مانند نرخ یادگیری و وزن توابع زیان).

مرحله چهارم: اجرای آزمایش‌ها و تجزیه و تحلیل نتایج (ماه ۱۰ تا ۱۲)

این مرحله به اجرای گسترده آزمایش‌ها و استخراج نتایج نهایی اختصاص دارد.

1. اجرای آزمایش‌های اصلی: اجرای کامل روش پیشنهادی بر روی تمام سناریوهای تطبیق دامنه تعریف شده و محاسبه معیار mAP.

2. اجرای مطالعه مؤلفه‌ها (Ablation Study): اجرای مجدد آزمایش‌ها با حذف هر یک از اجزای نوآورانه (مانند حذف بخش تخصصی یا حذف ماژول بازسازی ویژگی) برای ارزیابی تأثیر آن‌ها بر نتیجه نهایی.

3. مقایسه با روش‌های پیشرفته: مقایسه نتایج به دست آمده با نتایج منتشر شده از روش‌های State-of-the-art در حوزه SFDA.

4. تحلیل کیفی نتایج:

- مصورسازی فضای ویژگی با استفاده از t-SNE برای نمایش بهبود ساختار خوشه‌ها.

- ارائه نمونه‌های بصری از خروجی مدل (تصاویر با جعبه‌های مرزی پیش‌بینی‌شده) برای نمایش بهبود کیفی تشخیص اشیاء.

مرحله پنجم: تدوین و نگارش مستندات (ماه ۱۲ تا ۱۴)

در فاز نهایی، تمامی یافته‌ها و دستاوردهای تحقیق به صورت مستندات علمی استاندارد تدوین خواهد شد.

1. نگارش فصول پایان‌نامه: نگارش کامل و دقیق تمامی بخش‌های پایان‌نامه، شامل مقدمه، مرور ادبیات، روش تحقیق، یافته‌ها و آزمایش‌ها، و نتیجه‌گیری.

2. آماده‌سازی مقاله: در صورت کسب نتایج مطلوب، تدوین یک مقاله علمی بر اساس یافته‌های تحقیق برای ارسال به یک کنفرانس یا مجله معتبر.

3. آماده‌سازی ارائه دفاع: تهیه اسلایدهای استاندارد و تمرین برای ارائه شفاهی نتایج در جلسه دفاع.

4. بازبینی و اصلاح نهایی: اعمال اصلاحات نهایی بر اساس بازخورد اساتید راهنما و داوران.

3-4 - قلمرو تحقیق:

این پژوهش با هدف ارائه یک راه‌حل نوآورانه در یک حوزه مشخص و پیشرفته از یادگیری ماشین انجام می‌شود. برای شفاف‌سازی و تعیین دقیق مرزهای تحقیق، قلمرو آن در سه حوزه موضوعی، روش‌شناسی و کاربردی به شرح زیر تعریف می‌گردد:

1. قلمرو موضوعی و مفهومی (Thematic and Conceptual Scope)

این تحقیق در حوزه کلی هوش مصنوعی و زیرشاخه‌های یادگیری ماشین و بینایی ماشین قرار می‌گیرد.

حوزه تخصصی: تمرکز اصلی پژوهش بر روی مبحث یادگیری انتقالی (Transfer Learning) و به طور خاص، تطبیق دامنه (Domain Adaptation) است.

مسئله کانونی: این تحقیق به طور مشخص به سناریوی پیشرفته و واقع‌گرایانه تطبیق دامنه بدون منبع (Source-Free)

(Domain Adaptation - SFDA) می‌پردازد. این به آن معناست که فرض می‌شود در مرحله تطبیق، هیچ‌گونه دسترسی به

داده‌های دامنه منبع وجود ندارد و تنها دارایی ما، یک مدل از پیش آموزش‌دیده و داده‌های بدون برچسب دامنه هدف است. وظیفه

مورد بررسی در این پژوهش، تشخیص اشیاء (Object Detection) است که یک وظیفه پیچیده و ساختاریافته در بینایی ماشین محسوب می‌شود.

مفاهیم مرتبط: این تحقیق برای حل مسئله اصلی، مجموعه‌ای از مفاهیم پیشرفته را به کار می‌گیرد و در تقاطع آن‌ها قرار دارد:

- یادگیری مبتنی بر پروتوتایپ (Prototype-based Learning): به جای تکیه بر یک مدل معلم، تمرکز بر روی یادگیری و به‌روزرسانی نماینده‌های کلاسی (Class Prototypes) در فضای ویژگی خواهد بود. این پروتوتایپ‌ها به عنوان مراکز خوشه‌های هر کلاس عمل کرده و فرآیند تخصیص شبه-برچسب را هدایت می‌کنند.
- یادگیری تخصصی برای ساختارسازی فضای ویژگی (Adversarial Learning for Feature Space Structuring): برخلاف کاربرد کلاسیک یادگیری تخصصی برای هم‌ترازی بین دامنه‌ها، در این پژوهش از آن برای ساختارسازی درون دامنه هدف استفاده خواهد شد. یک مکانیزم تخصصی طراحی می‌شود تا مدل را مجبور به تولید ویژگی‌های منسجم و قابل تفکیک برای نمونه‌های با اطمینان بالا و پایین کند و در نتیجه، فشردگی خوشه‌ها را افزایش دهد.
- یادگیری خود-محور (Self-Driven Learning): کل فرآیند تطبیق به صورت خودکار و تنها با استفاده از اطلاعات استخراج شده از خود داده‌های هدف (مانند نزدیکی به پروتوتایپ‌ها) هدایت می‌شود.
- جلوگیری از فراموشی فاجعه‌بار (Catastrophic Forgetting): این مفهوم همچنان یک چالش کلیدی است و برای مقابله با آن، از تکنیک‌های بازسازی ویژگی (Feature Reconstruction) به منظور حفظ دانش اولیه مدل استفاده خواهد شد.

2. قلمرو روش‌شناسی (Methodological Scope)

چارچوب اصلی روش‌شناسی بر اساس پارادایم یادگیری مبتنی بر پروتوتایپ و خوشه‌بندی تخصصی (Prototype-based Learning and Adversarial Clustering) بنا خواهد شد. در این رویکرد، به جای تکیه بر پایداری یک مدل معلم، تمرکز بر روی ساختار ذاتی فضای ویژگی (Feature Space) در دامنه هدف خواهد بود. هدف، ایجاد خوشه‌های (Clusters) فشرده و با جدایی‌پذیری بالا برای هر کلاس، بدون دسترسی به برچسب‌های واقعی است. نوآوری اصلی تحقیق در ادغام تکنیک‌های زیر با چارچوب اصلی خواهد بود:

- مقابله با فراموشی دانش از طریق بازسازی ویژگی: با استفاده از آمار لایه‌های کلیدی مدل از پیش آموزش دیده (مانند Batch Normalization)، یک شبکه مولد (Generator) آموزش داده می‌شود تا ویژگی‌هایی را تولید کند که توزیع دامنه منبع را تقلید می‌کنند. این ویژگی‌های مجازی برای حفظ دانش اولیه مدل در طی فرآیند تطبیق به کار گرفته می‌شوند.
- شروع فرآیند با پروتوتایپ‌های منبع: وزن‌های لایه طبقه‌بندی‌کننده (Classifier Head) مدل اولیه به عنوان نماینده یا پروتوتایپ اولیه برای هر کلاس در نظر گرفته می‌شوند.
- یادگیری تخصصی مبتنی بر خوشه‌بندی: یک تفکیک‌کننده (Discriminator) طراحی می‌شود که تلاش می‌کند تا ویژگی‌های نمونه‌های «نزدیک به پروتوتایپ» (نمونه‌های با اطمینان بالا) را از ویژگی‌های نمونه‌های «دور از پروتوتایپ» (نمونه‌های با عدم قطعیت بالا) تشخیص دهد. شبکه استخراج‌کننده ویژگی (Feature Extractor) به صورت تخصصی آموزش می‌بیند تا ویژگی‌هایی تولید کند که این تفکیک‌کننده را فریب دهند. این فرآیند، مدل را مجبور می‌کند تا برای تمام نمونه‌های هدف، ویژگی‌هایی منسجم و نزدیک به مراکز کلاس تولید کند و در نتیجه، ساختار فضای ویژگی را بهینه می‌سازد.

- تولید شبه برچسب مبتنی بر نزدیکی به پروتوتایپ: شبه-برچسبها برای داده‌های هدف، بر اساس میزان نزدیکی ویژگی‌های آن‌ها به پروتوتایپ‌های به‌روز شده هر کلاس، تعیین می‌شوند. این رویکرد، برخلاف تکیه صرف بر خروجی Softmax، از ساختار هندسی فضای ویژگی برای تصمیم‌گیری بهره می‌برد.

3. قلمرو کاربردی و داده‌ای (Application and Data Scope)

تمرکز اصلی بر روی سناریوی کاربردی و چالش‌برانگیز انتقال از داده‌های مصنوعی به واقعی (Synth-to-Real) خواهد بود. مجموعه داده‌های استاندارد: برای مقایسه با سایر روش‌های پیشرفته، از مجموعه داده‌های بنچمارک و شناخته‌شده در این حوزه مانند Cityscapes, Foggy Cityscapes و Sim10k استفاده خواهد شد. مجموعه داده کاربردی: به منظور نمایش کارایی عملی روش پیشنهادی، عملکرد آن بر روی یک مجموعه داده خاص در حوزه تشخیص خودرو ارزیابی خواهد شد تا قابلیت اطمینان آن در یک سناریوی حیاتی سنجیده شود.

4-4 - روشهای مورد نظر برای تجزیه و تحلیل اطلاعات و آزمون فرضیه‌ها :

1. چارچوب ارزیابی (Evaluation Framework)

- برای اطمینان از یک تحلیل دقیق و قابل مقایسه، ابتدا چارچوب ارزیابی به شرح زیر تعریف می‌شود: مجموعه داده‌ها: از بنچمارک‌های استاندارد در حوزه تطبیق دامنه برای تشخیص اشیاء استفاده خواهد شد، از جمله:
 - Cityscapes → Foggy Cityscapes: برای ارزیابی مقاومت مدل در برابر تغییرات آب و هوایی.
 - Sim10k → Cityscapes: برای ارزیابی عملکرد در سناریوی کلیدی انتقال از داده مصنوعی به واقعی.
 - مجموعه داده کاربردی تشخیص خودرو: بررسی بر روی مجموعه داده جمع‌آوری شده و برچسب زده شده در آزمایشگاه برای سنجش کارایی روش در یک سناریوی عملی و حیاتی. در این دیتاست ایی از مجموعه تانک ها و خودرو های عادی شبیه سازی شده در بازی های کامپیوتری را به عنوان source در نظر گرفته می شود و دیتاستی شامل تصاویر خودرو های نظامی و خودرو های عادی را به عنوان target استفاده می شود.
- معیار ارزیابی اصلی: معیار اصلی برای سنجش عملکرد کمی، میانگین دقت متوسط (mean Average Precision - mAP) با آستانه تلاقی بر اتحاد (IoU) استاندارد (معمولاً 0.5) خواهد بود. این معیار به صورت جامع، هم دقت طبقه‌بندی و هم دقت مکان‌یابی اشیاء را ارزیابی می‌کند.
- روش‌های مبنا (Baselines): برای تحلیل معنادار نتایج، عملکرد روش پیشنهادی با سه گروه اصلی مقایسه خواهد شد:
 - مدل فقط-منبع (Source-Only): عملکرد مدل از پیش آموزش‌دیده، بدون هیچ‌گونه تطبیق، بر روی دامنه هدف. این معیار، میزان اولیه «شکاف دامنه» را مشخص می‌کند.
 - مدل اوراکل (Oracle): عملکرد همان معماری پایه، اما آموزش‌دیده بر روی داده‌های برچسب‌دار دامنه هدف. این معیار، حد بالای تئوریک عملکرد را نشان می‌دهد.
 - روش‌های پیشرفته (State-of-the-Art): مقایسه با نتایج منتشر شده از جدیدترین و مرتبط‌ترین روش‌های SFDA برای تشخیص اشیاء (مانند SHOT, DIPE و غیره).

2. آزمون فرضیه اصلی تحقیق

فرضیه اصلی (H1): روش پیشنهادی مبتنی بر یادگیری پروتوتایپ و خوشه‌بندی تخصصی، قادر است به طور معناداری عملکرد یک مدل تشخیص اشیاء را در دامنه هدف (بدون دسترسی به داده‌های منبع) بهبود بخشد و به دقتی رقابتی یا برتر از روش‌های پیشرفته موجود در حوزه SFDA دست یابد.

روش آزمون: این فرضیه از طریق مقایسه مستقیم و کمی نتایج mAP روش پیشنهادی با mAP روش‌های مبنا (به ویژه Source-Only و روش‌های SOTA) بر روی مجموعه داده‌های آزمون، مورد سنجش قرار خواهد گرفت. ارائه نتایج در قالب جداول مقایسه‌ای، شاهدهی بر تأیید یا رد این فرضیه خواهد بود.

3. تحلیل تفصیلی و آزمون فرضیه‌های ثانویه (Ablation Study)

برای درک عمیق‌تر مکانیزم‌های داخلی روش پیشنهادی، یک مطالعه جامع بر روی مؤلفه‌ها (Ablation Study) انجام خواهد شد تا فرضیه‌های ثانویه زیر مورد آزمون قرار گیرند:

- فرضیه ثانویه (H2): استفاده از مکانیزم بازسازی ویژگی (Feature Reconstruction) برای مقابله با فراموشی فاجعه‌بار، نقش کلیدی در حفظ دانش اولیه مدل و بهبود عملکرد نهایی دارد.
روش آزمون: روش پیشنهادی یک بار به صورت کامل و یک بار با حذف ماژول بازسازی ویژگی اجرا می‌شود. مقایسه نتایج mAP این دو حالت، میزان اهمیت این مؤلفه را نشان خواهد داد.
- فرضیه ثانویه (H3): به‌کارگیری یادگیری تخصصی برای ساختارسازی فضای ویژگی (Adversarial Clustering)، نسبت به روش‌های ساده‌تر تولید شبه-برچسب، منجر به ایجاد خوشه‌های کلاسی فشرده‌تر و در نتیجه، عملکرد بهتر مدل می‌شود.
روش آزمون: روش پیشنهادی با یک نسخه ساده‌تر از خودش مقایسه می‌شود که در آن، بخش تخصصی حذف شده و شبه-برچسب‌ها تنها بر اساس نزدیک‌ترین پروتوتایپ (Nearest Prototype) تعیین می‌شوند. تفاوت در عملکرد، مؤید تأثیر مثبت بخش تخصصی خواهد بود.
- فرضیه ثانویه (H4): میزان فشردگی و جدایی‌پذیری خوشه‌های کلاسی در فضای ویژگی، همبستگی مستقیمی با دقت نهایی مدل دارد.
روش آزمون: این فرضیه به صورت کیفی و کمی تحلیل می‌شود:
تحلیل کیفی: با استفاده از تکنیک‌های کاهش ابعاد مانند t-SNE یا UMAP، فضای ویژگی نمونه‌های دامنه هدف در مراحل مختلف تطبیق (ابتدا، اواسط و انتها) به تصویر کشیده خواهد شد. انتظار می‌رود با پیشرفت آموزش، خوشه‌های مربوط به هر کلاس به صورت بصری فشرده‌تر و از یکدیگر متمایزتر شوند.
تحلیل کمی: از معیارهای سنجش کیفیت خوشه‌بندی مانند Silhouette Score برای ارزیابی کمی میزان فشردگی و جدایی‌پذیری خوشه‌ها استفاده خواهد شد و ارتباط آن با منحنی یادگیری mAP بررسی می‌گردد.
این رویکرد تحلیلی جامع، نه تنها به اثبات کارایی روش پیشنهادی کمک می‌کند، بلکه درک عمیقی از دلایل موفقیت آن و نقش هر یک از اجزای نوآورانه در دستیابی به نتیجه نهایی فراهم می‌آورد.

5- نیازهای تحقیق :

5-1 - هزینه انجام تحقیق :

توضیحات	برآورد هزینه (ریال)	شرح هزینه
وابسته به استفاده از منابع دانشگاهی یا سرویس‌های ابری	۵۰۰-۰ میلیون	سخت‌افزار و توان پردازشی
تمامی منابع مورد نیاز رایگان هستند.	۰	نرم‌افزار و داده
تنها در صورت ارسال و پذیرش مقاله اعمال می‌شود.	۱۰۰ میلیون	انتشار نتایج
بسته به شرایط و انتخاب‌های موجود	۶۰۰-۰ میلیون	مجموع برآورد هزینه

5-2 - امکانات لازم (سخت‌افزاری - نرم‌افزاری و منابع و ...):

- پردازنده گرافیکی (GPU): دسترسی به یک یا چند پردازنده گرافیکی قدرتمند، مهم‌ترین نیاز سخت‌افزاری این تحقیق است. به دلیل پیچیدگی مدل‌های تشخیص اشیاء و نیاز به اجرای آزمایش‌های متعدد، استفاده از کارت‌های گرافیکی مدرن با حافظه VRAM بالا (ترجیحاً ۲۴ گیگابایت یا بیشتر) ضروری است. مدل‌های پیشنهادی شامل سری NVIDIA RTX مانند RTX 4090/5090 یا کارت‌های محاسباتی ویژه سرور مانند A100 می‌باشند.
- پردازنده مرکزی (CPU) و حافظه اصلی (RAM): یک پردازنده مرکزی چند-هسته‌ای مدرن و حافظه اصلی کافی (حداقل ۳۲ گیگابایت) برای پیش‌پردازش داده‌ها، مدیریت فرآیندهای آموزش و اجرای روان سیستم‌عامل ضروری است.
- حافظه ذخیره‌سازی: به دلیل حجم بالای مجموعه داده‌های تصویری، دسترسی به حافظه ذخیره‌سازی پرسرعت SSD ترجیحاً از نوع NVMe با ظرفیت کافی (حداقل ۱ ترابایت) برای تسریع فرآیند بارگذاری داده‌ها و کاهش زمان انتظار در طول آموزش مدل، الزامی است.

۲. امکانات نرم‌افزاری (Software)

- سیستم‌عامل: سیستم‌عامل لینوکس ترجیحاً توزیع Ubuntu به دلیل پشتیبانی گسترده و پایداری بالا در اکوسیستم یادگیری عمیق.
- زبان برنامه‌نویسی پایتون (Python) نسخه ۳.۸ یا بالاتر.
- چارچوب‌های یادگیری عمیق:
 - PyTorch: به عنوان چارچوب اصلی برای پیاده‌سازی، آموزش و ارزیابی مدل‌های تشخیص اشیاء.
- کتابخانه‌های کمکی: کتابخانه‌های استاندارد علم داده و بینایی ماشین مانند NumPy, OpenCV, Matplotlib و Scikit-learn برای پردازش تصویر، تحلیل نتایج و مصورسازی.
- محیط توسعه و مدیریت بسته‌ها: استفاده از Conda برای مدیریت محیط‌های مجازی و وابستگی‌های نرم‌افزاری پروژه.

۳. منابع داده و علمی (Data and Scientific Resources)

- مجموعه داده‌های استاندارد: دسترسی به مجموعه داده‌های عمومی و شناخته‌شده در حوزه تطبیق دامنه برای تشخیص اشیاء به منظور ارزیابی و مقایسه با سایر روش‌ها. این مجموعه داده‌ها عبارتند از:
 - Cityscapes: تصاویر واقعی از محیط‌های شهری.
 - Foggy Cityscapes: نسخه مه‌آلود از مجموعه داده Cityscapes برای شبیه‌سازی شرایط آب و هوایی نامساعد.
 - Sim10k: مجموعه داده مصنوعی شامل تصاویر از بازی کامپیوتری Grand Theft Auto V (GTAV)
- مجموعه داده کاربردی: دسترسی به مجموعه داده تشخیص ماشین (شامل داده‌های شبیه‌سازی شده و واقعی) که به عنوان یکی از اهداف اصلی تحقیق، برای اعتبارسنجی عملی روش پیشنهادی استفاده خواهد شد. این داده باید توسط آزمایشگاه جمع‌آوری شده باشد و یا باید جمع‌آوری شود.
- منابع علمی: دسترسی به پایگاه‌های داده مقالات علمی مانند IEEE Xplore, ACM Digital Library, SpringerLink و وبسایت arXiv برای مطالعه مستمر آخرین دستاوردهای پژوهشی در این حوزه. این موارد می‌توانند از طریق gigaLib و iranpaper قابل تأمین هستند.

6 - حداکثر زمان موردنیاز برای انجام تحقیق:

ردیف	فاز تحقیق	شرح فعالیت‌ها	حداکثر زمان تخصیص یافته (ماه)
۱	فاز اول: مطالعه و تعمیق در مسئله	مرور جامع و عمیق ادبیات موضوع، مطالعه مقالات کلیدی در حوزه‌های DA, UDA, SFDA دسته‌بندی و تحلیل دقیق روش‌های موجود. نهایی‌سازی ایده نوآورانه و صورت‌بندی دقیق مسئله تحقیق.	۳ ماه
۲	فاز دوم: آماده‌سازی و پیاده‌سازی پایه	-آماده‌سازی محیط برنامه‌نویسی و نصب کتابخانه‌های مورد نیاز مانند PyTorch CUDA, ... و جمع‌آوری، پیش‌پردازش و آماده‌سازی مجموعه داده‌های استاندارد و کاربردی. پیاده‌سازی و اجرای یک یا چند مدل پایه (Baseline) برای اطمینان از صحت خط لوله (Pipeline) و کسب نتایج اولیه.	۲ ماه
۳	فاز سوم: طراحی و پیاده‌سازی روش پیشنهادی	پیاده‌سازی کامل چارچوب اصلی مانند معماری و توسعه و پیاده‌سازی ماژول‌های نوآورانه مانند پالایش شبه-برچسب با CLIP و مکانیزم جلوگیری از فراموشی. ادغام، تست و رفع خطای (Debug) کامل کدهای نوشته شده.	۶ ماه
۴	فاز چهارم: اجرای آزمایش‌ها و تحلیل نتایج	اجرای سناریوهای اصلی آزمایش بر روی تمام مجموعه داده‌ها، اجرای آزمایش‌های مربوط به مطالعه مؤلفه‌ها (Ablation Study) برای سنجش تأثیر هر بخش از نوآوری. مقایسه نتایج به دست آمده با روش‌های پیشرفته (State-of-the-art). تحلیل دقیق نتایج، استخراج جداول، نمودارها و نتیجه‌گیری‌های علمی.	۴ ماه
۵	فاز پنجم: نگارش و تدوین نهایی	نگارش فصول مختلف پایان‌نامه/مقاله (مقدمه، کارهای پیشین، روش پیشنهادی، آزمایش‌ها، نتیجه‌گیری). آماده‌سازی اسلایدهای ارائه برای دفاع. بازبینی و اصلاح نهایی متن بر اساس بازخورد اساتید راهنما.	۳ ماه
		مجموع زمان	۱۸ ماه

۷- زمان‌بندی تحقیق (نمودار گانت):

زمان مورد نیاز مراحل تحقیق	ماه اول	ماه دوم	ماه سوم	ماه چهارم	ماه پنجم	ماه ششم	ماه هفتم	ماه هشتم	ماه نهم	ماه دهم	ماه یازدهم	ماه دوازدهم
فاز اول	■	■	■									
فاز دوم				■	■							
فاز سوم					■	■	■	■	■	■	■	
فاز چهارم									■	■	■	■
فاز پنجم											■	■

۸- فهرست منابع و مأخذ:

- [1] K. M. Borgwardt, A. Gretton, M. J. Rasch, H.-P. Kriegel, B. Schölkopf, and A. J. Smola, "Integrating structured biological data by Kernel Maximum Mean Discrepancy," *Bioinformatics*, vol. 22, no. 14, pp. e49–e57, July 2006, doi: 10.1093/bioinformatics/btl242.
- [2] E. Tzeng, J. Hoffman, N. Zhang, K. Saenko, and T. Darrell, "Deep Domain Confusion: Maximizing for Domain Invariance," Dec. 10, 2014, *arXiv*: arXiv:1412.3474. doi: 10.48550/arXiv.1412.3474.
- [3] I. J. Goodfellow *et al.*, "Generative Adversarial Networks," June 10, 2014, *arXiv*: arXiv:1406.2661. doi: 10.48550/arXiv.1406.2661.
- [4] E. Tzeng, J. Hoffman, K. Saenko, and T. Darrell, "Adversarial Discriminative Domain Adaptation," Feb. 17, 2017, *arXiv*: arXiv:1702.05464. doi: 10.48550/arXiv.1702.05464.
- [5] G. French, M. Mackiewicz, and M. Fisher, "Self-ensembling for visual domain adaptation," Sept. 23, 2018, *arXiv*: arXiv:1706.05208. doi: 10.48550/arXiv.1706.05208.
- [6] A. Tarvainen and H. Valpola, "Mean teachers are better role models: Weight-averaged consistency targets improve semi-supervised deep learning results," Apr. 16, 2018, *arXiv*: arXiv:1703.01780. doi: 10.48550/arXiv.1703.01780.
- [7] L. Hoyer, D. Dai, H. Wang, and L. V. Gool, "MIC: Masked Image Consistency for Context-Enhanced Domain Adaptation," Mar. 24, 2023, *arXiv*: arXiv:2212.01322. doi: 10.48550/arXiv.2212.01322.
- [8] Y. Ganin *et al.*, "Domain-Adversarial Training of Neural Networks," May 26, 2016, *arXiv*: arXiv:1505.07818. doi: 10.48550/arXiv.1505.07818.
- [9] Y. Chen, W. Li, C. Sakaridis, D. Dai, and L. V. Gool, "Domain Adaptive Faster R-CNN for Object Detection in the Wild," Mar. 08, 2018, *arXiv*: arXiv:1803.03243. doi: 10.48550/arXiv.1803.03243.
- [10] H. Huang, Q. Huang, and P. Krahenbuhl, "Domain transfer through deep activation matching," presented at the Proceedings of the European Conference on Computer Vision (ECCV), 2018, pp. 590–605. Accessed: Oct. 13, 2025. [Online]. Available: https://openaccess.thecvf.com/content_ECCV_2018/html/Haoshuo_Huang_Domain_transfer_through_ECCV_2018_paper.html
- [11] J. Hoffman *et al.*, "CyCADA: Cycle-Consistent Adversarial Domain Adaptation," Dec. 29, 2017, *arXiv*: arXiv:1711.03213. doi: 10.48550/arXiv.1711.03213.
- [12] G. Mattolin, L. Zanella, E. Ricci, and Y. Wang, "ConfMix: Unsupervised Domain Adaptation for Object Detection via Confidence-based Mixing," in *2023 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, Jan. 2023, pp. 423–433. doi: 10.1109/WACV56688.2023.00050.

مقالات مروری (Survey Papers)

Unsupervised Domain Adaptation of Object Detectors: A Survey 1

Authors: Poojan Oza. ○

Journal/Year: IEEE Transactions on Circuits and Systems for Video Technology, 2021. ○

○ چرا مهم است :این یک مقاله مروری بسیار جامع و جدید است که به طور خاص بر روی وظیفه تشخیص اشیاء تمرکز دارد. این مقاله یک دسته‌بندی عالی از روش‌ها، مجموعه داده‌ها و چالش‌های موجود ارائه می‌دهد و برای فصل مرور ادبیات شما یک منبع فوق‌العاده است.

A Survey on Deep Domain Adaptation 2

Authors: Zhaoxin Li ○

Journal/Year: Neurocomputing, 2024. ○

○ چرا مهم است :این مقاله یک دید بسیار گسترده و به‌روز از کل حوزه تطبیق دامنه عمیق (نه فقط برای تشخیص اشیاء) ارائه می‌دهد و به شما کمک می‌کند تا کار خود را در یک چشم‌انداز وسیع‌تر قرار دهید.

Source-free unsupervised domain adaptation : A survey 3

Authors: Yuqi Fang. ○

Journal/Year: ACM Computing Surveys, 2024. ○

چرا مهم است: این مقاله به طور خاص بر روی مسئله SFDA تمرکز دارد که دقیقاً هسته اصلی تحقیق شماست. مطالعه این مقاله برای درک کامل چالش‌ها و رویکردهای موجود در این سناریوی خاص، ضروری است.

4. A Comprehensive Survey on Source-free Domain Adaptation

Authors: Zhiqi Yu ○

IEEE Transactions on Pattern Analysis and Machine Intelligence ○

چرا مهم است: این مقاله به طور خاص بر روی مسئله SFDA تمرکز دارد که دقیقاً هسته اصلی تحقیق شماست. مطالعه این مقاله برای درک کامل چالش‌ها و رویکردهای موجود در این سناریوی خاص، ضروری است.

این مقاله به‌طور ویژه بر مسئله‌ی SFDA متمرکز است، که مستقیماً با محور اصلی پژوهش شما ارتباط دارد. بررسی این مقاله برای درک عمیق‌تر چالش‌ها و روش‌های مطرح‌شده در این حوزه‌ی خاص، کاملاً ضروری است.

مقالات پژوهشی جدید و تأثیرگذار (Recent High-Impact Papers)

4. PUnDA: Probabilistic Unsupervised Domain Adaptation for Knowledge Transfer Across Visual Categories

Authors: Behnam Gholami ○

Conference/Year: IEEE International Conference on Computer Vision 2024. ○

چرا مهم است: یک مقاله بسیار جدید از یکی از برترین کنفرانس‌ها که از رویکردی مبتنی بر احتمالات و پروتوتایپ برای UDA استفاده می‌کند. مطالعه این مقاله می‌تواند ایده‌های نوآورانه‌ای برای بخش یادگیری مبتنی بر پروتوتایپ به شما بدهد.

5. Source-Free Object Detection by Learning To Overlook Domain Style

Authors: S. Kundu et al. ○

Conference/Year: CVPR 2023. ○

چرا مهم است: این مقاله به طور مستقیم به مسئله SFDA برای تشخیص اشیاء می‌پردازد و یک روش جالب برای نادیده گرفتن "سبک" دامنه ارائه می‌دهد. این یک رقیب مستقیم و یک نقطه مرجع عالی برای روش پیشنهادی شماست.

6. Revisiting Domain-Adaptive 3D Object Detection by Reliable, Diverse and Class-balanced Pseudo-Labeling

Authors: Zhuoxiao Chen ○

Conference/Year: CVPR 2024. ○

چرا مهم است: اگرچه این مقاله بر روی تشخیص اشیاء سه‌بعدی تمرکز دارد، اما تکنیک‌های پیشرفته آن برای تولید شبه-برچسب (Pseudo-Labeling) مبتنی بر IoU در سناریوی SFDA، می‌تواند بسیار الهام‌بخش باشد و نشان‌دهنده آخرین روندهای این حوزه است.

* کلیه صفحات به صورت تایپ شده تحویل شوند.

9- نظریه شورای تحصیلات تکمیلی مجتمع دانشگاهی برق و کامپیوتر
(دقت شود که این صفحه به طور مجزا تهیه و تکمیل شود)

پایان نامه دانشجو خانم/ آقای

با موضوع پایان نامه به

راهنمایی آقای دکتر و استاد مشاور آقای دکتر..... در

شورای گروه علمی..... مورخ

مورد بررسی قرار و به تصویب رسید.

ردیف	نام و نام خانوادگی اعضای گروه علمی	محل امضاء
1		
2		
3		
4		
5		
6		
7		
8		
9		

